

UNIVERSIDADE FEDERAL DO PARANÁ

NATIELE CAUMO MEZACASA

INVESTIGAÇÃO DO POTENCIAL DE APLICAÇÃO DE SENSORES LIDAR E
ESPECTRAIS PARA AVALIAÇÃO AUTOMATIZADA DE EXPERIMENTOS DE
MELHORAMENTO GENÉTICO DE *Eucalyptus* spp.

CURITIBA

2025

NATIELE CAUMO MEZACASA

INVESTIGAÇÃO DO POTENCIAL DE APLICAÇÃO DE SENSORES LIDAR E
ESPECTRAIS PARA AVALIAÇÃO AUTOMATIZADA DE EXPERIMENTOS DE
MELHORAMENTO GENÉTICO DE *Eucalyptus* spp.

Trabalho de Conclusão de Curso apresentado ao
curso de Graduação em Engenharia Florestal, Setor
de Ciências Agrárias, Universidade Federal do
Paraná, como requisito parcial à obtenção do título
de Bacharel em Engenharia Florestal.

Orientadora: Prof.^a Dr.^a Ana Paula Dalla Corte

Coorientadores: Dr.^a Adriane Avelhaneda Mallmann
Dr. Aurélio Mendes Aguiar
Dr. Ricardo Cavalheiro

CURITIBA

2025



MINISTÉRIO DA EDUCAÇÃO
UNIVERSIDADE FEDERAL DO PARANÁ
SETOR DE CIÊNCIAS AGRÁRIAS
CURSO DE ENGENHARIA FLORESTAL

PARECER

Defesa nº 402

A Banca Examinadora, instituída pelo Colegiado do Curso de Engenharia Florestal do Setor de Ciências Agrárias, da Universidade Federal do Paraná, após arguir a **ACADÊMICA NATIELE CAUMO MEZACASA** em relação ao seu Trabalho de Conclusão de Curso intitulado “**INVESTIGAÇÃO DO POTENCIAL DE APLICAÇÃO DE SENsoRES LIDAR E ESPECTRAIS PARA AVALIAÇÃO AUTOMATIZADA DE EXPERIMENTOS DE MELHORAMENTO GENÉTICO DE *Eucalyptus spp.***”, é de parecer favorável à **APROVAÇÃO** na disciplina ENGF010 - Trabalho de Conclusão de Curso em Engenharia Florestal, condicionada a entrega da versão final corrigida.

TUPINAMBA SIMOES
FREDERICO - Y8251065J

Digitally signed by TUPINAMBA
SIMOES FREDERICO - Y8251065J
Date: 2025.07.04 15:27:40 +02'00'

M. Sc. Frederico Tupinambá Simões
1. Avaliador

Prof. Dr. Alexandre Behling
2. Avaliador

Documento assinado digitalmente
gov.br ANA PAULA DALLA CORTE
Data: 04/07/2025 10:39:22-0300
Verifique em <https://validar.itd.gov.br>

Prof.^a Dr.^a Ana Paula Dalla Corte
Orientadora - Presidente da Banca

Curitiba, 04 de julho de 2025.

Prof.^a Dr.^a Lucieli Rossi
Vice-Coordenadora do curso de Engenharia Florestal

Ao meu primeiro orientador “Zé” (*in memoriam*),
que despertou em mim a paixão pelo conhecimento,
Dedico.

AGRADECIMENTOS

A quem me salvou, meu companheiro, camarada e parceiro de vida, Djoni, que me acompanhou e apoiou durante toda essa trajetória, meus mais sinceros agradecimentos. Não sei se teria chegado tão longe sem teu constante suporte, carinho e amor. Obrigada por nunca desistir de mim, mesmo nos dias em que eu mesma quase desisti. Compartilhar a vida contigo é um presente diário.

Aos meus camaradinhas, Chumi, Nema e Numi, que me adotaram e se tornaram parte essencial do meu cotidiano. Com seu jeito único e imprevisível, foram fontes de afeto, conforto e leveza. Foram meu suporte emocional constante e, com certeza, deram os melhores conselhos.

À minha mãe, Marta, amiga, parceira de vida e maior exemplo de força, que sempre me incentivou a voar mais alto, mesmo quando o céu parecia distante. Comemorou comigo cada pequena vitória e esteve ao meu lado em cada tropeço. Juntas, superamos muitos desafios e, apesar (ou por causa) das dificuldades, consegui chegar até aqui. Sei que grande parte da minha resiliência e determinação nasceu do que enfrentamos juntas.

Ao meu padrinho Geraldo, por sua sabedoria e simplicidade que tanto acolhe, os “bom dia” que trocamos, mesmo em meio ao cansaço, foram pequenas luzes em dias escuros. À minha tia Adelaide, minha prima Mili e meu primo Ger, que, com suas histórias e jeitos de ser, me inspiraram a levar a graduação com mais leveza. Com vocês aprendi o valor de estar disponível, de ajudar sem hesitar e de não ter medo de pedir ajuda quando necessário.

Às minhas sobrinhas, Lari e Stella, que amo com uma intensidade difícil de colocar em palavras. Que eu possa ser para vocês um bom exemplo, um porto seguro, e o mesmo tipo de apoio que sempre me fez falta. E aos meus demais familiares, que foram minhas primeiras referências e fontes de inspiração.

Ao meu orientador e amigo, Mestre Décio, que me acolheu e fez da universidade minha segunda casa – com destaque para o cafezinho (top 1 de Curitiba) e para as conversas que tornaram o ambiente acadêmico mais leve e acolhedor.

À minha orientadora, prof Ana Paula, cuja didática e paixão pela inovação me fascinaram desde nosso primeiro contato. Sua orientação foi essencial para que eu pudesse estudar esse tema que me cativou. Te admiro muito e sou imensamente grata pelas oportunidades que me proporcionou.

Aos meus coorientadores, Ricardo (Camcore) e Aurélio (Suzano), por me apresentarem esse desafio que foi o que me motivou a aprender a programar. Obrigada também pela confiança, incentivo e por viabilizarem este trabalho.

À minha coorientadora e querida amiga, Adri, que sempre esteve disponível, me ouviu, apoiou e incentivou nos momentos mais difíceis. Sua escuta e acolhimento foram fundamentais.

Aos meus estimados amigos Lara e Lucas, ter conhecido vocês foi uma das maiores alegrias dessa graduação. Obrigada por me acolherem com todas as minhas esquisitices e por embarcarem comigo nas ideias mais absurdas. Vocês tornaram essa jornada mais divertida, suportável e, acima de tudo, mais significativa.

Aos meus queridos amigos e camaradas do BIOFIX – Carla, Iaci, Maria Emilia, Rebecca, José Augusto, Thais, Fabiano, Lina, Kauana, Jordan, Darcy, André, Mirella, Letícia... – por terem feito do laboratório minha terceira casa. Entre processamentos, análises, cafezinhos, fofocas, risadas e desabafos, formamos uma rede de apoio que me sustentou em muitos momentos. Sou muito grata pela parceria e amizade de cada um.

Às amizades espontâneas, Aline, Cris e Thainá: o laço com vocês se formou com uma naturalidade e intensidade raras. Tenho certeza de que poderíamos passar décadas sem contato e, ainda assim, ao nos reencontrarmos, a intimidade e o carinho estariam intactos, como se o tempo nunca tivesse passado.

Às minhas primeiras amizades na graduação – Giovana, Fer, Fabi, Luana, Kemy, Luane, Débora e Kamilla – vocês marcaram o início dessa jornada e sempre terão um lugar especial em meu coração.

Às amizades antigas que resistiram ao tempo e à distância, Jana e Necá, minha gratidão por permanecerem presentes mesmo quando a vida nos levou por caminhos diferentes. O vínculo que construímos segue firme, como se nunca houvesse hiatos.

À Lenhadores, que foi como uma família para mim e a primeira instituição acadêmica da qual fiz parte. Vivemos momentos de fraternidade que sempre levarei comigo.

Aos colegas que compartilharam esse percurso, cada conversa e cada troca deixaram marcas no meu processo de formação e, mais importante, na pessoa que me tornei.

A todos os docentes do curso, que despertaram em mim um amor cada vez maior pela Engenharia Florestal - em especial profs Alexandre, Christopher, Márcio, Renato Robert, Romano e Rozimeiry. Aos técnicos, servidores e trabalhadores terceirizados, que silenciosamente sustentam a universidade.

Ao CNPq, pelo apoio à iniciação científica, que enriqueceu minha formação acadêmica. Ao Instituto Água e Terra, onde tive meu primeiro contato com a prática profissional. À Sociedade de Investigações Florestais, pelo apoio e pelo papel essencial na ponte com a Camcore e a Suzano. À equipe da Vankka (Clarissa, Panasolo, Rubens e demais colegas) por acreditarem em mim e me proporcionarem experiências profissionais desafiadoras e enriquecedoras.

Aos programas de acesso e suporte estudantil, e à Universidade Federal do Paraná, que me possibilitaram o acesso a um ensino superior público e de qualidade.

Esses foram, sem dúvida, os melhores anos da minha vida. Agradeço, de coração, a todos que, de alguma forma, fizeram parte dessa trajetória.

Os homens fazem sua própria história; contudo não a fazem de livre e espontânea vontade, pois não são eles quem escolhem as circunstâncias sobre as quais ela é feita, mas estas lhes foram transmitidas assim como se encontram.

(Karl Marx)

RESUMO

A mensuração florestal tradicional, embora fundamental para programas de melhoramento genético, enfrenta limitações como baixa eficiência, custos elevados e escopo restrito de variáveis mensuráveis. Este estudo investigou o potencial de aplicação de sensores LiDAR (Light Detection and Ranging) (Unmanned Aerial Vehicle Laser Scanner - UAV-LiDAR e Mobile Laser Scanner - MLS) e espectrais (pancromáticos e multiespectrais) para a avaliação automatizada de dois experimentos de melhoramento de *Eucalyptus spp.*, visando superar essas limitações. Foram avaliados dois experimentos, um em Caçapava-SP com 500 árvores e 25 clones e outro em Itapeva-SP com 660 árvores e 28 clones. Foi realizado um inventário à 100% em ambas as áreas com mensuração de diâmetro à altura do peito (dap) e altura total (ht) e estimativa de volume total (vt). Os dados UAV-LS foram coletados com DJI Matrice 300 RTK + Livox AVIA e MLS com LiBackpack DG50 + VLP-16, já os pancromáticos com DJI Mavic 3 Enterprise e os multiespectrais com eBee X + Parrot Sequoia. Desenvolveu-se uma metodologia automatizada para extrair mais de 300 métricas individuais no total, incluindo atributos dendrométricos, estruturais e fisiológicos. Os resultados mostraram concordância moderada-alta para dap (Caçapava: $r=0,72$; $A=0,86$; $rRMSE=11,97\%$ e Itapeva: $r=0,81$; $A=0,9$; $rRMSE=14,69\%$) e ht (Caçapava: $r=0,6$; $A=0,74$; $rRMSE=10,82\%$ e Itapeva: $r=0,68$; $A=0,69$; $rRMSE=14,99\%$), já para vt houve erros superiores (Caçapava: $r=0,63$; $A=0,72$; $rRMSE=32,89\%$ e Itapeva: $r=0,66$; $A=0,35$; $rRMSE=87,22\%$). O F1-Score de detecção de árvores foi de 0,98 em Caçapava e 0,91 em Itapeva. A segmentação semântica, com a remoção de galhos inferiores, melhorou significativamente a precisão das métricas. Além disso, foram constatadas correlações promissoras entre os dados de inventário e as métricas LiDAR e índices de vegetação extraídos dos dados espectrais. As métricas obtidas permitiram a discriminação de clones com 87,3% de acurácia na classificação, com a combinação MLS+UAV-LiDAR tendo proporcionado as principais métricas discriminatórias. Os resultados evidenciam o potencial dos sensores LiDAR e espectrais para ampliar a escala, eficiência e escopo da fenotipagem florestal, oferecendo suporte promissor para programas modernos de melhoramento genético.

Palavras-chave: MLS; UAV-LiDAR; multiespectral; melhoramento florestal; pipeline

ABSTRACT

Traditional forest measurement, although fundamental for genetic improvement programs, faces limitations such as low efficiency, high costs and restricted scope of measurable variables. This study investigated the potential application of LiDAR (Light Detection and Ranging) (Unmanned Aerial Vehicle Laser Scanner - UAV-LiDAR and Mobile Laser Scanner - MLS) and spectral (panchromatic and multispectral) sensors for the automated evaluation of two *Eucalyptus* spp. breeding experiments, with a view to overcoming these limitations. Two experiments were evaluated, one in Caçapava-SP with 500 trees and 25 clones and the other in Itapeva-SP with 660 trees and 28 clones. A 100% inventory was carried out in both areas, measuring diameter at breast height (dap) and total height (ht) and estimating total volume (vt). UAV-LS data was collected with DJI Matrice 300 RTK + Livox AVIA and MLS with LiBackpack DG50 + VLP-16, while panchromatic data was collected with DJI Mavic 3 Entreprise and multispectral data with eBee X + Parrot Sequoia. An automated methodology was developed to extract more than 300 individual metrics in total, including dendrometric, structural and physiological attributes. The results showed moderate-high agreement for dap (Caçapava: $r=0.72$; $A=0.86$; $rRMSE=11.97\%$ and Itapeva: $r=0.81$; $A=0.9$; $rRMSE=14.69\%$) and ht (Caçapava: $r=0.6$; $A=0.74$; $rRMSE=10.82\%$ and Itapeva: $r=0.68$; $A=0.69$; $rRMSE=14.99\%$), while for vt there were higher errors (Caçapava: $r=0.63$; $A=0.72$; $rRMSE=32.89\%$ and Itapeva: $r=0.66$; $A=0.35$; $rRMSE=87.22\%$). The F1-Score for tree detection was 0.98 in Caçapava and 0.91 in Itapeva. Semantic segmentation, with the removal of lower branches, significantly improved the accuracy of the metrics. In addition, promising correlations were found between the inventory data and the LiDAR metrics and vegetation indices extracted from the spectral data. The metrics obtained allowed clones to be discriminated with 87.3% classification accuracy, with the MLS+UAV-LiDAR combination providing the main discriminatory metrics. The results highlight the potential of LiDAR and spectral sensors to expand the scale, efficiency and scope of forest phenotyping, offering promising support for modern genetic improvement programs.

Keywords: MLS; UAV-LiDAR; multispectral; forest tree breeding; pipeline

LISTA DE FIGURAS

FIGURA 1 - TIPOS, ABRANGÊNCIA, ESCALA E ACURÁCIA DA TECNOLOGIA LIDAR EM DIFERENTES PLATAFORMAS APLICADAS AO SETOR FLORESTAL	34
FIGURA 2 - MAPA DE LOCALIZAÇÃO DO EXPERIMENTO EM CAÇAPAVA, SÃO PAULO.....	42
FIGURA 3 - LOCALIZAÇÃO DO EXPERIMENTO EM ITAPEVA, SÃO PAULO	43
FIGURA 4 - DRONE DJI MAVIC 3 ENTREPRISE	45
FIGURA 5 - DRONE DE ASA FIXA EBEE X.....	45
FIGURA 6 - DRONE DJI MATRICE 300 RTK	46
FIGURA 7 - SLAM LIBACKPACK DG50 + VLP-16 (X2).....	46
FIGURA 8 - CROQUI DO CAMINHAMENTO MLS	47
FIGURA 9 - PARCELAS CIRCULARES DE 10 M DE RAIO GERADAS A PARTIR DAS NUVENS DE PONTOS DOS SISTEMAS MLS E UAV-LIDAR NOS DOIS LOCAIS DE ESTUDO	51
FIGURA 10 - FLUXO DE PROCESSAMENTO PARA NORMALIZAÇÃO DAS NUVENS E GERAÇÃO DOS PRODUTOS CARTOGRÁFICOS MDS, MDT E CHM.....	52
FIGURA 11 - PROCESSO DE EXTRAÇÃO DE MÉTRICAS INDIVIDUAIS DE DADOS UAV-LIDAR	54
FIGURA 12 - ESQUEMA DA ABORDAGEM VIA PACOTES lidR + TreeLS	55
FIGURA 13 - ABORDAGEM VIA FSCT+FILTROS/3DFIN+FILTROS	57
FIGURA 14 - ESQUEMA DA SEGMENTAÇÃO SEMÂNTICA DAS ÁRVORES	58
FIGURA 15 - EXEMPLO DO EFEITO DA RAMIFICAÇÃO BASAL SOBRE A MODELAGEM QSM.....	59
FIGURA 16 - FLUXO DO PROCESSO DE EXTRAÇÃO DE MÉTRICAS INDIVIDUAIS DOS DADOS MLS E MLS+UAV-LIDAR, MOSTRANDO A INTEGRAÇÃO ENTRE OS DIFERENTES ALGORITMOS UTILIZADOS.....	60
FIGURA 17 - ÁRVORE INDIVIDUAL FILTRADA MODELADA EM QSM VIA AdTree	60
FIGURA 18 - ILUSTRAÇÃO DA EXTRAÇÃO DOS ÂNGULOS E DO POTENCIAL DE CLASSIFICAÇÃO ATRAVÉS DE ESTATÍSTICAS DERIVADAS.	61

FIGURA 19 - ILUSTRAÇÃO ESQUEMÁTICA DA CLASSIFICAÇÃO DE VP, VN, FP E FN E DAS MÉTRICAS DE PRECISÃO E RECALL.....	63
FIGURA 20 - GRÁFICOS VIOLINO DAS VARIÁVEIS QUANTITATIVAS DOS INVENTÁRIOS FLORESTAIS DE CAÇAPAVA (A) E ITAPEVA (B)..	67
FIGURA 21 - MÉDIAS DE DIÂMETRO E ALTURA TOTAL POR CLONE NOS EXPERIMENTOS DE CAÇAPAVA (ACIMA) E ITAPEVA (ABAIXO). AS LINHAS PONTILHADAS REPRESENTAM AS MÉDIAS GERAIS DE CADA VARIÁVEL.....	68
FIGURA 22 - CONDIÇÃO GERAL DOS CLONES DOS EXPERIMENTOS EM CAÇAPAVA (ESQUERDA) E ITAPEVA (DIRETA).....	69
FIGURA 23 - CONDIÇÕES DOS CLONES DOS EXPERIMENTOS EM CAÇAPAVA (ESQUERDA) E ITAPEVA (DIRETA)	69
FIGURA 24 - GRÁFICOS VIOLINO DAS VARIÁVEIS QUANTITATIVAS DOS INVENTÁRIOS FLORESTAIS DE CAÇAPAVA (A) E ITAPEVA (B) ..	70
FIGURA 25 - MÉDIAS DE DIÂMETRO E ALTURA TOTAL POR CLONE NOS EXPERIMENTOS DE CAÇAPAVA (ACIMA) E ITAPEVA (ABAIXO). AS LINHAS PONTILHADAS REPRESENTAM AS MÉDIAS GERAIS DE CADA VARIÁVEL.....	71
FIGURA 26 - CONDIÇÃO GERAL DOS CLONES DOS EXPERIMENTOS EM CAÇAPAVA (ESQUERDA) E ITAPEVA (DIRETA).....	72
FIGURA 27 - CONDIÇÕES DOS CLONES DOS EXPERIMENTOS EM CAÇAPAVA (ESQUERDA) E ITAPEVA (DIRETA)	72
FIGURA 28 - DTM, DSM E CHM GERADOS PARA OS DADOS MLS, UAV-LIDAR E COMBINADOS (MLS+UAV-LIDAR) PARA O EXPERIMENTO DE CAÇAPAVA	73
FIGURA 29 - DTM, DSM E CHM GERADOS PARA OS DADOS MLS, UAV-LIDAR E COMBINADOS (MLS+UAV-LIDAR) PARA O EXPERIMENTO DE ITAPEVA.....	74
FIGURA 30 - NUvens DE PONTOS NORMALIZADAS PARA OS DIFERENTES CONJUNTOS DE DADOS - EXPERIMENTO DE ITAPEVA.....	75
FIGURA 31 - PERFIS VERTICAIS DE DENSIDADE DE PONTOS DOS DADOS UAV-LIDAR, MLS E COMBINADOS (MLS+UAV-LIDAR).....	76
FIGURA 32 - VISUALIZAÇÃO DA COMBINAÇÃO DOS DADOS UAV-LIDAR + MLS. REPRESENTAÇÃO A PARTIR DE PLOTS DE 10 M DE RAIO	76

FIGURA 33 - RESULTADOS OBTIDOS COM A APLICAÇÃO DO MODELO FASTSAM-S.....	77
FIGURA 34 - RESULTADOS DA DELIMITAÇÃO DE COPAS PELA ABORDAGEM SEMI-AUTOMATIZADA EM CAÇAPAVA (ESQUERDA) E ITAPEVA (DIREITA)	78
FIGURA 35 - RESULTADO DA DETECÇÃO DE ÁRVORES NO EXPERIMENTO DE CAÇAPAVA	79
FIGURA 36 - RESULTADO DA DETECÇÃO DE ÁRVORES NO EXPERIMENTO DE ITAPEVA.....	79
FIGURA 37 - EXEMPLOS DO RESULTADO QUALITATIVO DA SEGMENTAÇÃO SEMÂNTICA DE CADA ABORDAGEM	81
FIGURA 38 - EXEMPLARES DE ÁRVORES DOMINADAS SEGMENTADAS PELAS ABORDAGENS FSCT + FILTROS E 3DFIN + FILTROS	81
FIGURA 39 - DESEMPENHO GERAL DA SEGMENTAÇÃO SEMANTICA	82
FIGURA 40 - EXEMPLOS DAS PRINCIPAIS FALHAS NA SEGMENTAÇÃO SEMÂNTICA.....	83
FIGURA 41 - PERDA DE REPETIÇÕES DECORRENTE DO PROCESSAMENTO DOS DADOS LIDAR, DESCONSIDERADAS FALHAS DE PLANTIO E ÁRVORES MORTAS. EXPERIMENTO DE CAÇAPAVA.....	84
FIGURA 42 - PERDA DE REPETIÇÕES DECORRENTE DO PROCESSAMENTO DOS DADOS LIDAR, DESCONSIDERADAS FALHAS DE PLANTIO E ÁRVORES MORTAS. EXPERIMENTO DE ITAPEVA.....	84
FIGURA 43 - GRÁFICOS DE COMPARAÇÃO ENTRE OS DAP OBTIDO DOS DADOS LIDAR E DE INVENTÁRIO CONVENCIONAL - EXPERIMENTO DE CAÇAPAVA.....	86
FIGURA 44 - GRÁFICOS DE COMPARAÇÃO ENTRE OS DAP OBTIDO DOS DADOS LIDAR E DE INVENTÁRIO CONVENCIONAL - EXPERIMENTO DE ITAPEVA	86
FIGURA 45 - GRÁFICOS DE COMPARAÇÃO ENTRE AS ALTURAS OBTIDAS DOS DADOS LIDAR E DE INVENTÁRIO CONVENCIONAL - EXPERIMENTO DE CAÇAPAVA.....	86
FIGURA 46 - GRÁFICOS DE COMPARAÇÃO ENTRE AS ALTURAS OBTIDAS DOS DADOS LIDAR E DE INVENTÁRIO CONVENCIONAL - EXPERIMENTO DE ITAPEVA	87

FIGURA 47 - GRÁFICOS DE COMPARAÇÃO ENTRE OS VT OBTIDOS DOS DADOS LIDAR E DE INVENTÁRIO CONVENCIONAL - EXPERIMENTO DE CAÇAPAVA.....	87
FIGURA 48 - GRÁFICOS DE COMPARAÇÃO ENTRE OS VT OBTIDOS DOS DADOS LIDAR E DE INVENTÁRIO CONVENCIONAL - EXPERIMENTO DE ITAPEVA	87
FIGURA 49 - GRÁFICO VIOLINO DAS ALTURAS OBTIDAS POR INVENTÁRIO E EXTRAÍDAS DOS DADOS COMBINADOS (MLS + UAV-LIDAR), MLS, E UAV-LIDAR, RESPECTIVAMENTE. EXPERIMENTO DE CAÇAPAVA (A) E ITAPEVA (B).....	88
FIGURA 50 - GRÁFICO VIOLINO DOS DAP (ESQUERDA) E VT (DIREITA) OBTIDOS POR INVENTÁRIO E EXTRAÍDOS DOS DADOS COMBINADOS (MLS + UAV-LIDAR) E MLS, RESPECTIVAMENTE. EXPERIMENTO DE CAÇAPAVA.....	88
FIGURA 51 - GRÁFICO VIOLINO DOS DAP (ESQUERDA) E VT (DIREITA) OBTIDOS POR INVENTÁRIO E EXTRAÍDOS DOS DADOS COMBINADOS (MLS + UAV-LIDAR) E MLS, RESPECTIVAMENTE. EXPERIMENTO DE ITAPEVA	89
FIGURA 52 - MATRIZ DE CORRELAÇÕES PARCIAL ENTRE MÉTRICAS NÃO PAREADAS EXTRAÍDAS DOS DADOS LIDAR E ESPECTRAIS E DADOS DE INVENTÁRIO.....	92
FIGURA 53 - MATRIZ DE CONFUSÃO DA CLASSIFICAÇÃO DOS CLONES REALIZADA ATRAVÉS DE ANÁLISE DISCRIMINANTE	97
FIGURA 54 - RESULTADOS DAS FUNÇÕES DISCRIMINANTES 1 E 2, PARA O AGRUPAMENTO DOS CLONES, COM OS RESPECTIVOS GRUPOS CENTROIDES, PARA O CONJUNTO DE TODAS AS VARIÁVEIS AVALIADAS	98
FIGURA 55 - GRÁFICOS VIOLINO, PARA CADA GRUPO, DAS MÉTRICAS DO INVENTÁRIO DAP, HT E VT E DAS MÉTRICAS LIDAR ÂNGULO MÉDIO DO FUSTE E DESVIO PADRÃO (SD) DOS ÂNGULOS DO FUSTE + GRÁFICO DE BARRAS DA PROPORÇÃO DE ÁRVORES COM MÁ CONFORMAÇÃO.....	99
FIGURA 56 - GRÁFICOS VIOLINO DAS MÉTRICAS DAS MÉTRICAS DE ALTURA LIDAR NOS PERCENTIS 45,40 E 35 PARA CADA GRUPO	100

LISTA DE QUADROS

QUADRO 1 - ÍNDICES DE VEGETAÇÃO PASSÍVEIS DE SEREM CALCULADOS COM DADOS DE SENSORES PANCRÔMÁTICOS	28
QUADRO 2 - ÍNDICES DE VEGETAÇÃO PASSÍVEIS DE SEREM CALCULADOS COM DADOS DE SENSORES MULTIESPECTRAIS	29
QUADRO 3 - FILTROS PARA REFINAMENTO DA SEGMENTAÇÃO DE ÁRVORES INDIVIDUAIS	56
QUADRO 4 - FILTROS APLICADOS PARA REFINAMENTO DA SEGMENTAÇÃO SEMÂNTICA	58
QUADRO 5 - CRITÉRIOS UTILIZADOS PARA CLASSIFICAR AS ÁRVORES DETECTADAS NOS DADOS LIDAR	63

LISTA DE TABELAS

TABELA 1 - RESUMO DO INVENTÁRIO TRADICIONAL.....	48
TABELA 2 - RESUMO DAS COLETAS DE DADOS LIDAR E ESPECTRAIS.	48
TABELA 3 - CARACTERÍSTICAS DOS DADOS LIDAR COLETADOS EM CAÇAPAVA ¹ E ITAPEVA ²	51
TABELA 4 - ESTATÍSTICAS DESCRIPTIVAS DAS VARIÁVEIS QUANTITATIVAS DOS DADOS DE INVENTÁRIO PARA CAÇAPAVA E ITAPEVA.....	68
TABELA 5 - ESTATÍSTICAS DESCRIPTIVAS DAS VARIÁVEIS QUANTITATIVAS DOS DADOS DE INVENTÁRIO PARA CAÇAPAVA E ITAPEVA.....	71
TABELA 6 - ESTATÍSTICAS DA DETECÇÃO DE ÁRVORES DOS DADOS LIDAR NOS EXPERIMENTOS DE ITAPEVA E CAÇAPAVA.....	79
TABELA 7 - PROPORÇÃO DE ERRO PARA A DETECÇÃO DE ÁRVORES EM CADA CLASSE DE QUALIDADE DO FUSTE	80
TABELA 8 - ESTATÍSTICAS DA DETECÇÃO DE ÁRVORES DAS DIFERENTES ABORDAGENS APLICADAS AOS DADOS LIDAR MLS E MLS+UAV- LIDAR	80
TABELA 9 - RESULTADOS DA AVALIAÇÃO DAS MÉTRICAS PAREADAS (INVENTÁRIO X LIDAR) - EXPERIMENTO DE CAÇAPAVA	85
TABELA 10 - RESULTADOS DA AVALIAÇÃO DAS MÉTRICAS PAREADAS (INVENTÁRIO X LIDAR) - EXPERIMENTO DE ITAPEVA	85
TABELA 11 - COMPARAÇÃO DOS RESULTADOS OBTIDOS COM OS APRESENTADOS POR LIANG ET AL. (2018), MONTOYA ET AL. (2021), KRISANSKI ET AL. (2021) E LAINO ET AL. (2024)	90
TABELA 12 - RESULTADO DA AVALIAÇÃO DAS MÉTRICAS PAREADAS (INVENTÁRIO X LIDAR) SEM A REALIZAÇÃO DA SEGMENTAÇÃO SEMÂNTICA E FILTRAGEM DE GALHOS INFERIORES	91
TABELA 13 - DURAÇÃO (EM HORAS:MINUTOS) DAS ETAPAS DO PROCESSAMENTO DOS DADOS LIDAR.....	93
TABELA 14 - RESULTADOS DA ANÁLISE DE VARIÂNCIA MULTIVARIADA PARA O CONJUNTO COMPOSTO POR TODAS AS VARIÁVEIS AVALIADAS	95

TABELA 15 - PORCENTAGEM DA VARIÂNCIA EXPLICADA, AUTOVALORES (>1) E COEFICIENTES DE CORRELAÇÃO CANÔNICA DAS FUNÇÕES DISCRIMINANTES	96
TABELA 16 - RESULTADO PARCIAL DAS CORRELAÇÕES CANÔNICAS ENTRE AS VARIÁVEIS ORIGINAIS AVALIADAS E AS FUNÇÕES DISCRIMINANTES OBTIDAS	96

LISTA DE ABREVIATURAS OU SIGLAS

ALS	- <i>Aerial Laser Scanning</i>
CAP	- Circunferência à altura do peito
CBD	- <i>Canopy Bulk Density</i>
CFL	- <i>Canopy Fuel Load</i>
CHM	- <i>Canopy Height Model</i>
CIVE	- <i>Color Index of Vegetation Extraction</i>
dap	- Diâmetro à altura do peito
DGCNN	- <i>Deep Graph Convolutional Neural Network</i>
DTM	- <i>Digital Terrain Model</i>
DSM	- <i>Digital Surface Model</i>
DVI	- <i>Difference Vegetation Index</i>
ExG	- <i>Excess Green Index</i>
ExGR	- <i>Excess Green minus Excess Red</i>
ExR	- <i>Excess Red Index</i>
FA	- Modelos fatoriais analíticos
GEDI	- <i>Global Ecosystem Dynamics Investigation</i>
GEE	- Google Earth Engine
GNDVI	- <i>Green NDVI</i>
GNSS	- <i>Global Navigation Satellite System</i>
GxE	- Genótipo x Ambiente
HTP	- <i>High-Throughput Phenotyping</i>
ht	- Altura total
IAF	- Índice de Área Foliar
IMU	- <i>Inertial Measurement Unit</i>
IV	- Índices de Vegetação
LAI	- <i>Leaf Area Index</i>
LiDAR	- <i>Light Detection and Ranging</i>
MLS	- <i>Mobile Laser Scanning</i>
NDRE	- <i>Normalized Difference Red Edge</i>
NDVI	- <i>Normalized Difference Vegetation Index</i>
NGBDI	- <i>Normalized Green-Blue Difference Index</i>
NIR	- <i>Near Infrared Reflectance</i>

PCA	- <i>Principal Component Analysis</i>
QSM	- <i>Quantitative Structure Model</i>
RGB	- <i>Red-Green-Blue</i>
RGBVI	- <i>Red-Green-Blue Vegetation Index</i>
RMSE	- <i>Root Mean Squared Error</i>
RTK	- <i>Real-Time Kinematic</i>
SAM	- <i>Segment Anything Model</i>
SAVI	- <i>Soil Adjusted Vegetation Index</i>
SR	- <i>Simple Ratio</i>
ssGBLUP	- <i>Single-Step Genomic Best Linear Unbiased Prediction</i>
SWIR	- <i>Short Wave Infrared</i>
TLS	- <i>Terrestrial Laser Scanning</i>
TVI	- <i>Triangular Vegetation Index</i>
UAV	- <i>Unmanned Aerial Vehicle</i>
UAV-LiDAR	- <i>Unmanned Aerial Vehicle-Laser Scanning</i>
VARI	- <i>Visible Atmospherically Resistant Index</i>
VANT	- Veículo Aéreo Não Tripulado
vt	- Volume total

SUMÁRIO

1 INTRODUÇÃO.....	22
1.1 OBJETIVOS.....	25
1.1.1 Objetivo geral	25
1.1.2 Objetivos específicos	25
2 REVISÃO DE LITERATURA	26
2.1 AVALIAÇÃO DE EXPERIMENTOS DE MELHORAMENTO FLORESTAL	26
2.2 SENsoRES ESPECTRAIS.....	27
2.3 LiDAR	33
2.3.1 UAV-LiDAR	34
2.3.2 MLS	36
2.3.3 Combinação de dados LiDAR	37
2.4 SEGMENTAÇÃO EM INSTÂNCIA.....	38
2.5 SEGMENTAÇÃO SEMÂNTICA.....	40
3 MATERIAL E MÉTODOS	42
3.1 CARACTERIZAÇÃO DAS ÁREAS DE ESTUDO	42
3.1.1 Caçapava.....	42
3.1.2 Itapeva	43
3.2 COLETA DE DADOS	44
3.2.1 Inventário à 100% (censo florestal)	44
3.2.2 Dados espectrais	44
3.2.3 Dados LiDAR	45
3.2.4 Georreferenciamento	47
3.2.5 Resumo.....	47
3.3 HARDWARE DE PROCESSAMENTO.....	49
3.4 TEMPO DE PROCESSAMENTO.....	49
3.5 PRÉ-PROCESSAMENTO.....	49
3.5.1 Dados de inventário	50
3.5.2 Dados espectrais	50
3.5.3 Dados LiDAR	50
3.5.3.1 Georreferenciamento e limpeza.....	50
3.5.3.2 Normalização	52
3.5.3.3 MLS + UAV-LIDAR.....	52

3.6 PROCESSAMENTO	53
3.6.1 Dados espectrais	53
3.6.1.1 Segmentação de copas	53
3.6.1.2 Índices de vegetação.....	53
3.6.2 Dados UAV-LIDAR.....	54
3.6.2.1 Segmentação em Instância	54
3.6.2.2 Extração das métricas individuais.....	54
3.6.3 Dados MLS e MLS+UAV-LIDAR	55
3.6.3.1 Segmentação em Instância	55
3.6.3.2 Segmentação Semântica.....	57
3.6.3.3 Extração das métricas em nível de árvore individual	59
3.7 AVALIAÇÃO.....	62
3.7.1 Compilação e pareamento de dados	62
3.7.2 Detecção de árvores	62
3.7.3 Qualidade da segmentação em instância e semântica.....	64
3.7.4 Métricas extraídas	64
3.7.4.1 Métricas pareadas (inventário x SR).....	64
3.7.4.2 Métricas não pareadas	65
3.8 AGRUPAMENTO DE CLONES.....	66
3.8.1 Pré-processamento	66
3.8.2 MANOVA e Análise discriminante	66
4 RESULTADOS	67
4.1 PRÉ-PROCESSAMENTO	67
4.1.1 Dados de inventário	67
4.1.1.1 Análise exploratória	67
4.1.1.2 Dados de inventário utilizados	70
4.1.2 Dados LiDAR	73
4.2 DETECÇÃO E SEGMENTAÇÃO DE ÁRVORES INDIVIDUAIS	77
4.2.1 Dados espectrais	77
4.2.2 Dados LiDAR	78
4.3 SEGMENTAÇÃO SEMÂNTICA.....	82
4.4 PERDA DE REPETIÇÕES NO PROCESSAMENTO	83
4.5 MÉTRICAS PAREADAS (INVENTÁRIO X LIDAR).....	85
4.5.1 Resultados sem aplicação de segmentação semântica	91

4.6 MÉTRICAS NÃO PAREADAS.....	92
4.7 TEMPO DE PROCESSAMENTO E HARDWARE	93
4.8 AGRUPAMENTO DE CLONES.....	95
4.9 DISCUSSÃO: PARA ALÉM DAS MÉTRICAS	100
5 CONSIDERAÇÕES FINAIS.....	102
5.1 RECOMENDAÇÕES PARA TRABALHOS FUTUROS.....	103
REFERÊNCIAS	105
APÊNDICE 1 - DESCRIÇÃO DOS PROGRAMAS, PACOTES, FERRAMENTAS, ALGORITMOS E FUNÇÕES APLICADOS.	
APÊNDICE 2 - DESCRIÇÃO DAS MÉTRICAS EXTRAÍDAS DOS DADOS UAV- LIDAR	
APÊNDICE 3 - DESCRIÇÃO DAS MÉTRICAS EXTRAÍDAS DOS DADOS LIDAR MLS E COMBINAÇÃO	
APÊNDICE 4 - LINK E QR CODE PARA REPOSITÓRIO GITHUB CONTENDO OS CÓDIGOS DESENVOLVIDOS	
APÊNDICE 5 - MATRIZ DE CORRELAÇÃO COMPLETA - MÉTRICAS NÃO PAREADAS COM $R > 0,4$	
APÊNDICE 6 - PLOT DOS IV CALCULADOS - EXPERIMENTO DE CAÇAPAVA	
APÊNDICE 7 - PLOT DOS IV CALCULADOS - EXPERIMENTO DE ITAPEVA	
APÊNDICE 8 - EXEMPLO DE APLICAÇÃO DE DADOS MLS+UAV-LIDAR PARA AVALIAÇÃO VISUAL DE CLONES	

1 INTRODUÇÃO

A mensuração florestal, ciência dedicada à medição e quantificação dos recursos florestais, constitui a base do manejo e pesquisa florestal fundamentados em evidências (Campos & Leite, 2017). No contexto dos programas de melhoramento genético de árvores, técnicas precisas e eficientes de mensuração são essenciais para avaliar ganhos genéticos, analisar a adaptação e orientar decisões de seleção (White et al., 2016). À medida que a demanda global por produtos florestais aumenta, a disponibilidade de terras diminui e os efeitos das mudanças climáticas se intensificam, a importância de programas de melhoramento que maximizem a produtividade e a resiliência nunca foi tão grande (White et al., 2016; Duncanson et al., 2019). No entanto, a eficácia desses programas depende fundamentalmente da capacidade de medir e avaliar com precisão o desempenho das árvores em ambientes diversos e ao longo do tempo.

Os métodos tradicionais de mensuração florestal têm sido a base de dados para pesquisas em melhoramento genético. Essas abordagens convencionais, baseadas principalmente em medições de campo como diâmetro, altura e outros atributos físicos, permitiram avanços significativos na genética florestal e no melhoramento de espécies (Næsset, 2014). No entanto, esses métodos enfrentam limitações que restringem sua eficácia nos programas modernos de melhoramento.

As exigências de tempo das medições manuais limitam a frequência e a abrangência da coleta de dados, criando gargalos nos fluxos de trabalho das pesquisas (Howie et al., 2024). Restrições financeiras associadas a campanhas de campo intensivas em mão de obra frequentemente forçam compromissos no desenho experimental ou na intensidade da amostragem (Butler et al., 2021). Desafios operacionais, incluindo dificuldades de acesso, dependência de condições climáticas e inconsistências nas medições, dificultam ainda mais os esforços de coleta de dados em ensaios de melhoramento (Ferrer Velasco et al., 2022).

Ademais, os métodos tradicionais de mensuração geralmente capturam apenas um conjunto limitado de variáveis, concentrando-se principalmente no diâmetro e na altura das árvores, deixando de lado traços estruturais e fisiológicos mais complexos que podem ser essenciais para uma avaliação genética abrangente (Ewald et al., 2018). Essa limitação na coleta de dados restringe a profundidade das análises possíveis em pesquisas de melhoramento, podendo deixar de considerar

características ou interações importantes que influenciam as decisões de seleção. À medida que os programas de melhoramento passam a visar, cada vez mais, a adaptação às mudanças climáticas, resistência a pragas e atributos de qualidade da madeira, além do crescimento, torna-se evidente a necessidade de abordagens de medição mais abrangentes.

Avanços recentes em sensoriamento remoto (SR), especialmente com o uso de sistemas *Light Detection and Ranging* (LiDAR) e sensores espectrais, oferecem soluções promissoras para essas limitações, ao mesmo tempo em que expandem o leque de atributos florestais mensuráveis (Coops et al., 2021). A tecnologia LiDAR transformou a capacidade de mensuração florestal ao possibilitar a geração de representações tridimensionais precisas da estrutura das florestas (Coops et al., 2021).

Essa tecnologia permite medições precisas de variáveis tradicionais como altura e diâmetro, ao mesmo tempo em que capta atributos estruturais complexos como dimensão da copa, padrões de ramificação e estratificação do dossel, os quais são difíceis ou impossíveis de quantificar com métodos convencionais (Mäyrä et al., 2021). A capacidade do LiDAR de avaliar rapidamente grandes áreas com alta precisão o torna particularmente valioso para experimentos de melhoramento que envolvem numerosas entradas genéticas em múltiplos locais (Du Toit et al., 2022).

Complementando as medições estruturais do LiDAR, os sensores espectrais fornecem informações sobre propriedades bioquímicas e fisiológicas da vegetação florestal. Sensores do espectro visível (*Red-Green-Blue*, RGB), apesar de sua simplicidade relativa, demonstraram utilidade considerável para a classificação de espécies arbóreas, monitoramento fenológico e delimitação de copas (Grybas & Congalton, 2021).

Sensores multiespectrais permitem o mapeamento de nutrientes foliares, estado hídrico e outros traços fisiológicos relevantes para o desempenho e adaptação das árvores (Ewald et al., 2018). Quando integradas aos dados do LiDAR, essas medições espectrais criam sinergias poderosas para uma avaliação florestal abrangente, permitindo a análise simultânea do desenvolvimento estrutural e da condição fisiológica.

A integração dessas tecnologias avançadas de sensoriamento remoto em programas de melhoramento oferece diversas vantagens. Primeiro, permitem coletas de dados mais frequentes e extensas sem aumentos proporcionais de custo ou mão

de obra (Tatsumi et al., 2023; Foster et al., 2024). Segundo, expandem o conjunto de características mensuráveis para além dos métricos tradicionais de crescimento, incluindo atributos estruturais, bioquímicos e fisiológicos que podem ser critérios importantes de seleção (Morsdorf et al., 2009; Ewald et al., 2018). Terceiro, fornecem dados espacialmente explícitos que ajudam a considerar a heterogeneidade ambiental dentro dos sítios experimentais, potencialmente melhorando a precisão das avaliações genéticas (Atkins et al., 2023; Kamoske et al., 2022). E criam oportunidades para a avaliação não destrutiva de características que anteriormente exigiam amostragem destrutiva, como volume e biomassa, por exemplo (Calders et al., 2020; Liang et al., 2016).

Dessa forma, considerando o elevado potencial, ainda pouco explorado, da aplicação de sensores LiDAR e espectrais em experimentos de melhoramento florestal, este estudo investigou a viabilidade dessas tecnologias para a avaliação de dois experimentos de melhoramento florestal de *Eucalyptus* spp., por meio da extração automatizada de mais de 300 métricas, a nível de árvore individual, derivadas dos dados LiDAR e espectrais. Espera-se que esta pesquisa não apenas promova avanços metodológicos na quantificação não destrutiva e eficiente de atributos dendrométricos, fisiológicos e estruturais, mas também amplie as perspectivas para o melhoramento genético de espécies florestais.

1.1 OBJETIVOS

1.1.1 Objetivo geral

Investigar o potencial de aplicação de sensores LiDAR (UAV-LiDAR e MLS) e espectrais (pancromático e multiespectral) para a avaliação automatizada de dois experimentos de melhoramento genético florestal de *Eucalyptus* spp.

1.1.2 Objetivos específicos

O presente estudo tem como objetivos específicos:

- 1) Desenvolver um fluxo metodológico automatizado para a extração, a nível de árvore individual, de métricas dendrométricas, fisiológicas e estruturais derivadas de dados LiDAR e espectrais;
- 2) Avaliar diferentes abordagens metodológicas para a extração das métricas a partir dos dados coletados;
- 3) Comparar a acurácia e a eficiência das métricas pareadas extraídas dos dados LiDAR (UAV-LiDAR, MLS e a combinação MLS+UAV-LiDAR), com as obtidas por inventário tradicional;
- 4) Analisar correlações entre métricas não pareadas derivadas dos dados LiDAR e espectrais e as obtidas por inventário tradicional; e
- 5) Investigar a aplicabilidade das métricas extraídas de dados LiDAR e espectrais para discriminação e agrupamento de clones.

2 REVISÃO DE LITERATURA

2.1 AVALIAÇÃO DE EXPERIMENTOS DE MELHORAMENTO FLORESTAL

A mensuração florestal desempenha um papel central na avaliação de experimentos de melhoramento genético, fornecendo os dados fenotípicos que fundamentam a estimativa de parâmetros genéticos, a predição de valores genéticos e a definição de estratégias de seleção. Em espécies de relevância econômica, como *Eucalyptus* spp., a quantificação precisa de características dendrométricas, como diâmetro à altura do peito (dap), altura total (ht), volume total (vt), forma do fuste e densidade da madeira, permite identificar genótipos com maior potencial produtivo e adaptabilidade (Næsset, 2014).

Da mesma forma, atributos da copa, como área foliar, índice de competição e estrutura tridimensional, constituem indicadores relevantes de eficiência fotossintética e de resposta a diferentes condições edafoclimáticas (Oliveira et al., 2025; Cortés et al., 2020; Sano et al., 2024), além de contribuírem para a avaliação da estabilidade do desempenho genético em ambientes diversos (Li et al., 2017).

Apesar de sua importância, os métodos tradicionais de inventário florestal apresentam limitações consideráveis em termos de escalabilidade, eficiência e abrangência fenotípica. A coleta manual de dados com fita métrica, hipsômetro e relascópio é morosa, onerosa e suscetível a erros operacionais, como imprecisão de leitura ou variação na posição de medição do dap (Dalla Corte et al. 2022; Dassot et al., 2012).

Tais limitações são agravadas em ensaios genéticos de grande escala, que envolvem centenas de genótipos avaliados em múltiplas repetições e ambientes. Além disso, esses métodos geralmente não capturam informações estruturais quantitativas mais complexas, como medidas de tortuosidade do fuste ou assimetria da copa, que são potencialmente relevantes para a qualidade da madeira e a resiliência mecânica da árvore (Ahlinder et al., 2024; Liziniewicz et al., 2025; Torres-Sánchez et al., 2024).

Diante desses desafios, novas tecnologias têm sido progressivamente integradas à avaliação fenotípica em programas de melhoramento florestal. A fenotipagem de alta produtividade (*High-Throughput Phenotyping* - HTP), baseada em sensores acoplados a veículos aéreos não tripulados (VANT) ou sistemas terrestres,

como LiDAR, possibilita a aquisição automatizada e em larga escala de atributos dendrométricos com elevada acurácia (Pugh et al., 2025; Sano et al., 2024).

A integração de dados de sensoriamento remoto com abordagens genéticas e genômicas tem ampliado a capacidade de caracterização de genótipos em experimentos florestais. Métricas extraídas de nuvens de pontos tridimensionais por meio de algoritmos de visão computacional e Aprendizado de Máquina (*Machine Learning*) têm sido empregadas para estimar variáveis fenotípicas complexas, reduzindo a necessidade de medições manuais (Cortés et al., 2020; Sano et al., 2024).

A incorporação dessas métricas em modelos de predição genética, especialmente quando combinadas com informações genômicas por meio de abordagens como o BLUP genômico de passo único (ssGBLUP), tem permitido ganhos expressivos na acurácia da seleção e na redução do intervalo entre gerações (Simiqueli et al., 2024; Duarte et al., 2024).

Além disso, a aplicação de modelos estatísticos avançados, como os modelos fatoriais analíticos (FA) e a análise por componentes principais (PCA), tem contribuído para a interpretação mais robusta das interações genótipo x ambiente (GxE) e para a realização de análises multivariadas eficientes, mesmo diante de grandes volumes de dados (Li et al., 2017; Ahlinder et al., 2024).

2.2 SENORES ESPECTRAIS

Avanços recentes em tecnologias de sensoriamento remoto ampliaram significativamente a precisão e a aplicabilidade dos dados espectrais em aplicações florestais, proporcionando novas possibilidades de monitoramento e análise dos ecossistemas em múltiplas escalas espectrais, espaciais e temporais. Tais sensores permitem não apenas a avaliação de variáveis estruturais, mas também a análise de características bioquímicas e fisiológicas da vegetação (Yan et al., 2025). Os sensores espectrais podem ser classificados em quatro categorias principais conforme sua resolução espectral:

- a) Sensores Pancromáticos ou RGB: capturam luz visível (400 nm - 700 nm) e são econômicos, com processamento simples. A resolução espacial pode ser subdecimétricas, especialmente com drones (Xia et al., 2021). São uma solução econômica para o cálculo de uma série de

índices de vegetação (IV) (Quadro 1), identificação de árvores, estimativas de copa e falhas no povoamento (Pádua, et al., 2022).

- b) Sensores Multiespectrais: operam em bandas específicas (ex.: RED, *Near Infrared Reflectance* - NIR, *Short Wave Infrared* - SWIR) entre 400 nm - 1000 nm, permitindo o cálculo de índices de vegetação mais aplicados, eficazes para monitorar vigor, clorofila e teor hídrico (Quadro 2).
- c) Sensores Hiperespectrais: capturam centenas de bandas estreitas e contínuas, permitindo análises espectrais e bioquímicas detalhadas (Adão et al., 2017). São ideais para identificar espécies, fases fenológicas e características fisiológicas (Zarco-Tejada et al., 2019).
- d) Sensores Térmicos: detectam radiação emitida na faixa de 7.500 nm - 13.500 nm e convertem os dados em temperatura. São úteis para avaliar estresse hídrico e processos térmicos na vegetação (Manfreda et al., 2018).

QUADRO 1 - ÍNDICES DE VEGETAÇÃO PASSÍVEIS DE SEREM CALCULADOS COM DADOS DE SENSORES PANCRÔMÁTICOS

Índice	Fórmula	Aplicações	Referência
CIVE (<i>Color Index of Vegetation Extraction</i>)	$18,78745 + 0,44.R - 0,88.G + 0,385.B$	Segmentação de vegetação	Yang et al. (2005)
ExG (<i>Excess Green Index</i>)	$2.G - R - B$	Segmentação de vegetação	Yang et al. (2015)
ExGR (<i>Excess Green minus Excess Red</i>)	$ExG - (1,4.R - G)$	Segmentação de vegetação	Gitelson et al. (2002)
ExR (<i>Excess Red Index</i>)	$1,4.R - G$	Detecção de estresse hídrico e senescência	Bendig et al. (2015)
GLI (<i>Green Leaf Index</i>)	$\frac{2.G - R - B}{2.G + R + B}$	Avaliação de saúde foliar	Louhaichi et al. (2001)
MGRVI (<i>Modified Green Red Vegetation Index</i>)	$\frac{G^2 - R^2}{G^2 + R^2}$	Segmentação de vegetação	Bendig et al. (2015)
NDI (<i>Normalized Difference Index</i>)	$128 \cdot \left(\frac{G - R}{G + R} + 1 \right)$	Classificação de vegetação	Meyer & Camargo Neto (2008)

Índice	Fórmula	Aplicações	Referência
NGBDI (<i>Normalized Green-Blue Difference Index</i>)	$\frac{G - B}{G + B}$	Segmentação de vegetação em estágios iniciais	Bendig et al. (2015)
RGBVI (<i>Red-Green-Blue Vegetation Index</i>)	$\frac{G^2 - R \cdot B}{G^2 + R \cdot B}$	Avaliação da clorofila em estágios iniciais de crescimento	Bendig et al. (2015)
RGI (<i>Red Green Index</i>)	$\frac{R}{G}$	Identificação de estresse vegetal e senescência	Bendig et al. (2015)
TGI (<i>Triangular Greenness Index</i>)	$G - 0,39 \cdot R - 0,61 \cdot B$	Estimativa do conteúdo de clorofila	Hunt et al. (2011)
VARI (<i>Visible Atmospherically Resistant Index</i>)	$\frac{G - R}{G + R - B}$	Análise de área e densidade foliar	Gitelson et al. (2002)
VIgreen (<i>Vegetation Index Green</i>)	$\frac{G - R}{G + R}$	Análise de cobertura e detecção de mudanças fenológicas	Gitelson et al. (2002)

Em que: R é vermelho (*Red*); G é verde (*Green*); B é azul (*Blue*).

FONTE: Adaptado de Andrade Junior et al. (2021)

QUADRO 2 - ÍNDICES DE VEGETAÇÃO PASSÍVEIS DE SEREM CALCULADOS COM DADOS DE SENSORES MULTIESPECTRAIS

Índice	Fórmula	Aplicações	Referência
CVI (<i>Chlorophyll vegetation Index</i>)	$NIR * \frac{R}{G^2}$	Estimativa do desenvolvimento da folhagem em dosséis	Vincini et al. (2007)
DVI (<i>Difference Vegetation Index</i>)	$NIR - R$	Detecção de biomassa vegetal e resposta espectral da vegetação	Jordan (1969)
GCI (<i>Green Chlorophyll Index</i>)	$\frac{NIR}{G} - 1$	Avaliação do estado fisiológico da planta e estimativa do teor de clorofila	Gitelson et al. (2003)

Índice	Fórmula	Aplicações	Referência
GNDVI (<i>Green NDVI</i>)	$\frac{NIR - G}{NIR + G}$	Avaliação das variações de biomassa verde na escala do dossel	Gitelson, Kaufman & Merzlyak (1997)
MSAVI (<i>Modified SAVI</i>)	$\frac{1}{2} \cdot (2 \cdot NIR + 1 - \sqrt{(2 \cdot NIR + 1)^2 - 8 \cdot (NIR - R)})$	Avaliar a saúde da vegetação em estágios iniciais	Qi et al (1994)
MSR (<i>Modified SR</i>)	$\frac{\frac{NIR}{R} - 1}{\sqrt{1 + \frac{NIR}{R}}}$	Relação melhorada para estimar IAF	Chen (1996)
MCARI1 (<i>First Modified Chlorophyll Absorption Ratio Index</i>)	$\frac{1}{2} \cdot \left[2,5 \cdot (NIR - G) - 1,3 \cdot (R - G) \right]$	Estimativa do teor de clorofila	Haboudane et al. (2004)
MCARI2 (<i>Second Modified Chlorophyll Absorption Ratio Index</i>)	$\frac{\frac{1}{2} \cdot \left[2,5 \cdot (NIR - G) - 1,3 \cdot (R - G) \right]}{\sqrt{2 \cdot (NIR + 1)^2 - 0,5 - 6 \cdot (NIR - 5 \cdot \sqrt{R})}}$	Estimativa do teor de clorofila	Haboudane et al. (2004)
NDRE (<i>Normalized Difference Red Edge</i>)	$\frac{NIR - RE}{NIR + RE}$	Monitoramento de saúde vegetal e atividade fotossintética	Barnes et al. (2000)
NDVI (<i>Normalized Difference Vegetation Index</i>)	$\frac{NIR - R}{NIR + R}$	Análise de vigor vegetativo, cobertura e estresse hídrico	Rouse, et al. (1973)
OSAVI (<i>Optimized SAVI</i>)	$\frac{NIR - R}{NIR + R + 0,16}$	Avaliar a saúde da vegetação em áreas com vegetação esparsa	Rondeaux, Steven & Baret (1996)
RDVI (<i>Renormalized Difference Vegetation Index</i>)	$\sqrt{NDVI \cdot DVI}$	Aperfeiçoamento do NDVI (minimiza efeitos do solo e da posição do sol)	Roujean & Breon (1995)

Índice	Fórmula	Aplicações	Referência
SAVI (Soil Adjusted Vegetation Index)	$(1 + L) \cdot \frac{NIR - R}{NIR + R + L}$	Calcular o Índice de Área Foliar (IAF): $\frac{IAF}{\ln(0,69 - SAVI)} = \frac{0,59}{0,91}$	Huete (1998)
SIFI (Structural Inensitive Pigment Index)	$\frac{NIR - B}{NIR + R}$	Monitorar a saúde das plantas, stress fisiológico e estimar a produtividade	Peñuelas et al. (1995)
SR (Simple Ratio)	$\frac{NIR}{R}$	Relação simples para estimar biomassa e vigor vegetativo	Birth e McVey (1968)
TVI (Triangular Vegetation Index)	$\frac{1}{2} \cdot [120 \cdot (NIR - G) - 200 \cdot (R - G)]$	Estimar o IAF	Broge & Leblanc (2001)

Em que: R é vermelho (Red); G é verde (Green); B é azul (Blue); NIR é infravermelho próximo (Near Infrared Reflectance); RE é borda do vermelho (Red Edge); L é fator de correção (L igual a 0,25 indica vegetação densa; 0,5 é indicativo de vegetação com densidade intermediária; quando L é igual a 1, a vegetação é rala ou com baixa densidade).

FONTE: Adaptado de Bernardi et al. (2014) e D'Oliveira et. al (2023).

Os IV tornaram-se ferramentas importantes no monitoramento florestal, em razão de sua simplicidade, robustez e capacidade de captar atributos relevantes da vegetação. Desde 1986, os IV vêm sendo amplamente desenvolvidos, com uma aceleração acentuada a partir de 2012, impulsionada pelo aumento na disponibilidade de dados de satélites de observação terrestre e pela criação de novos índices (Yan et al., 2025).

A sensibilidade dos VI a variáveis vegetais varia conforme o índice: o OSAVI é mais sensível ao índice de área foliar (*Leaf Area Index - LAI*), enquanto o S2REP destaca-se para clorofila. A escolha adequada de VI deve considerar o objetivo do estudo, as variáveis avaliadas e as condições locais (Yan et al., 2025). Ademais, criação de índices espectrais especializados representa um avanço importante na avaliação florestal. Amiri et al. (2025) desenvolveram o “needleleaf index”, destinado à identificação de florestas coníferas na América do Norte, superando a limitação de assinaturas espectrais semelhantes entre diferentes tipos de vegetação.

A integração de diferentes sensores tem proporcionado avanços substanciais na estimativa de variáveis estruturais e funcionais das florestas. Aragoneses et al. (2025) combinaram dados LiDAR orbitais (*Global Ecosystem Dynamics Investigation* - GEDI), imagens multiespectrais (Landsat 8), radar (PALSAR) e variáveis biofísicas para gerar, com elevada acurácia, os primeiros mapas continentais da carga de combustível de dossel (CFL; $r = 0,85$) e da densidade volumétrica de dossel (CBD; $r = 0,75$) na Europa.

De forma similar, Yadav et al. (2025) integraram imagens Landsat-8 e *WorldView-3* com atributos topográficos derivados de LiDAR para prever a densidade dos estratos vegetais em florestas de eucalipto na Tasmânia, com melhor desempenho no estrato superior ($R^2 = 0,65$), evidenciando a eficácia da abordagem multissensorial na caracterização vertical da vegetação.

Paralelamente à evolução dos sensores, avanços computacionais têm ampliado a capacidade analítica dessas tecnologias. O uso de plataformas como o *Google Earth Engine* (GEE) viabiliza a análise geoespacial em larga escala, por meio de processamento paralelo (Amiri et al., 2025). Além disso, algoritmos de Aprendizado de Máquina vêm sendo amplamente utilizados na extração de variáveis estruturais em áreas não amostradas (Aragoneses et al., 2025), e a inteligência artificial tem permitido o mapeamento preciso da vegetação em escalas regionais e globais (Yan et al., 2025).

Apesar dos avanços, a aplicação operacional de sensores espectrais ainda enfrenta limitações relevantes. Um dos principais desafios é a relação inversa entre resolução espectral e espacial. Essa restrição, entretanto, vem sendo atenuada por meio de técnicas de *pansharpening*, que consistem na fusão de imagens multiespectrais ou hiperespectrais com imagens pancromáticas de maior resolução espacial, preservando a integridade espectral e aprimorando os detalhes geométricos (Aiazzi; Baronti; Selva, 2007; Laetitia Loncan et al., 2015).

Outro desafio recorrente refere-se à obstrução por cobertura de nuvens, que compromete a aquisição de dados ópticos em determinadas regiões e épocas do ano, exigindo o uso de estratégias eficazes de mascaramento e a integração com sensores ativos, como Radar e LiDAR, menos suscetíveis a interferências atmosféricas (Amiri et al., 2025).

Adicionalmente, a validação dos parâmetros obtidos por sensoriamento remoto requer medições de campo extensivas, frequentemente onerosas e

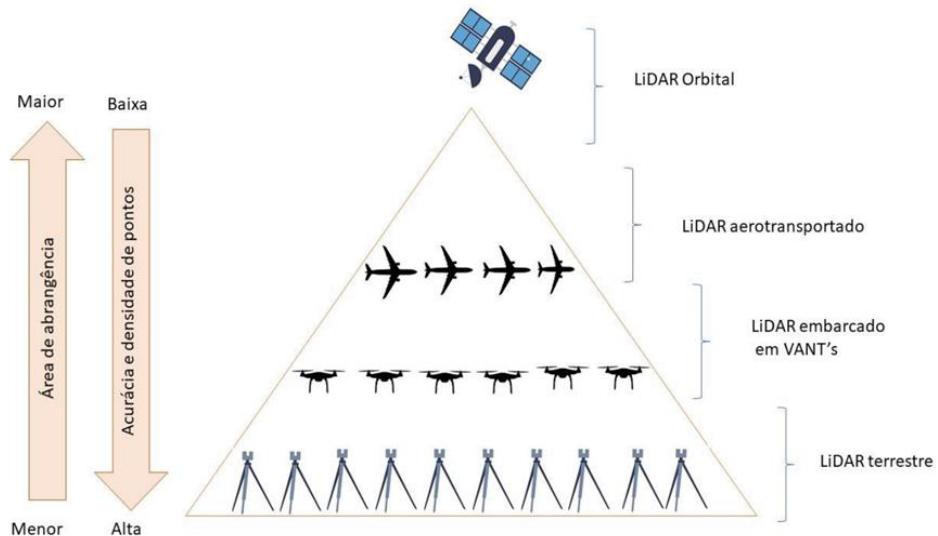
logisticamente complexas, especialmente em áreas de difícil acesso (Aragoneses et al., 2025). Em regiões montanhosas, os desafios são amplificados devido às distorções topográficas, à variabilidade na iluminação e à elevada heterogeneidade estrutural e composicional da vegetação, fatores que comprometem a acurácia e a consistência das estimativas espectrais (Besic et al., 2025).

2.3 LIDAR

O LiDAR representa uma tecnologia revolucionária para a avaliação florestal, possibilitando a caracterização tridimensional da estrutura vegetal (Barros et al., 2023). Esta tecnologia baseia-se na emissão de pulsos laser e na medição precisa do tempo de retorno destes pulsos após interação com diferentes componentes da vegetação e do terreno (Debnath et al, 2023). A partir destes dados, são geradas nuvens de pontos tridimensionais que permitem quantificar com precisão variáveis estruturais em diferentes escalas, desde árvores individuais até paisagens florestais completas (Fassnacht et al., 2023).

Nas últimas décadas, as aplicações do LiDAR na mensuração florestal expandiram-se de forma significativa, impulsionadas pelo desenvolvimento de distintas plataformas de aquisição, que incluem sistemas orbitais, aéreos e terrestres (Figura 1). No contexto aéreo, destacam-se o *Aerial Laser Scanning* (ALS) e os sistemas embarcados em veículos aéreos não tripulados (*Unmanned Aerial Vehicles* - UAV). No domínio terrestre, o LiDAR pode ser classificado em *Terrestrial Laser Scanning* (TLS), de posição fixa, e *Mobile Laser Scanning* (MLS), de posição móvel (Holopainen et al., 2011; Vasconcellos, 2020; Yan et al., 2019).

FIGURA 1 - TIPOS, ABRANGÊNCIA, ESCALA E ACURÁCIA DA TECNOLOGIA LIDAR EM DIFERENTES PLATAFORMAS APLICADAS AO SETOR FLORESTAL



FONTE: Vasconcellos (2020).

2.3.1 UAV-LiDAR

O LiDAR acoplado a veículos aéreos não tripulados (*Unmanned Aerial Vehicle-Laser Scanning - UAV-LIDAR*) representa um avanço na mensuração florestal de precisão, combinando a flexibilidade operacional dos drones com a capacidade de aquisição tridimensional do sensoriamento a laser (Barros et al., 2023). Este sistema opera por meio da emissão de pulsos laser comumente na faixa espectral do infravermelho próximo, que são refletidos pelos diversos componentes da vegetação e pelo terreno, gerando nuvens de pontos tridimensionais com densidades que podem chegar a mais de 1.400 pontos/m², dependendo da altitude de voo e das características do sensor (Dalla Corte et al., 2020).

A precisão do sistema é garantida pela integração de tecnologias complementares: sistemas de navegação por satélite (*Global Navigation Satellite Systems - GNSS*) com correção diferencial (DGPS/RTK) e unidades de medição inercial (IMU), que em conjunto proporcionam alta acurácia posicional vertical e horizontal (M. Pilarska et al., 2016).

A adoção do UAV-LIDAR na mensuração florestal oferece vantagens distintas em relação aos métodos tradicionais e a outras plataformas de aquisição LiDAR. Sob a perspectiva operacional, destaca-se a capacidade de aquisição de dados em

intervalos temporais reduzidos (semanais ou mensais), permitindo o monitoramento fenológico detalhado e a avaliação de respostas das árvores a variações ambientais (Atkins et al., 2020). Do ponto de vista econômico, estudos comparativos indicam que, para grandes áreas, os custos associados ao uso de UAV-LIDAR são comparáveis aos do LiDAR aerotransportado convencional. No entanto, o UAV-LIDAR oferece vantagens adicionais, como maior densidade de pontos e menor custo operacional para áreas de menor extensão (McClelland et al., 2018).

As aplicações práticas do UAV-LIDAR na mensuração florestal abrangem desde inventários tradicionais até análises avançadas de estrutura de copas:

- a) Inventário de precisão: estudos recentes reportam erros médios relativos (RMSE%) de 11% - 27% na estimativa de dap e 2% - 8% na altura das árvores quando utilizados algoritmos de segmentação individual adequados (Panagiotidis et al., 2022, Dalla Corte et al., 2020, Chen et al., 2022; Hyppä et al., 2020).
- b) Modelagem volumétrica: a abordagem baseada em nuvem de pontos UAV-LIDAR permite estimativas de volume com erros entre 9% - 18% (Yoshii et al., 2022, Liao et al., 2022).
- c) Análise de copas: métricas tridimensionais como volume de copa, projeção de área foliar e assimetria de copa têm se mostrado valiosas para avaliar competição intraespecífica e eficiência fotossintética (Puletti et al., 2024).

Apesar do evidente potencial, a aplicação de sistemas UAV-LIDAR enfrenta desafios técnicos relevantes que devem ser cuidadosamente considerados durante o planejamento de levantamentos florestais. A penetração dos pulsos *laser* no dossel varia substancialmente em função da densidade foliar, o que pode afetar a acurácia na detecção de estruturas abaixo da copa (Hu et al., 2021). Além disso, condições meteorológicas adversas, especialmente ventos superiores a 8 m/s e a ocorrência de precipitação, podem comprometer significativamente a qualidade dos dados devido ao movimento excessivo das copas e à absorção atmosférica dos pulsos *laser*.

O processamento dos dados obtidos demanda abordagens computacionais avançadas, capazes de realizar a separação precisa entre pontos correspondentes à vegetação, ao solo e a ruídos, além de identificar e delimitar com acurácia árvores individuais, particularmente em povoamentos densos, etapa essencial para estimativas em nível de árvore (Buck et al., 2014).

2.3.2 MLS

O LiDAR Móvel Terrestre (*Mobile Laser Scanning - MLS*) tem emergido como uma tecnologia transformadora para a aquisição de dados dendrométricos, superando muitas limitações dos métodos tradicionais de inventário florestal (Dassot et al., 2012; Dalla Corte et al. 2022). Diferente dos sistemas estáticos terrestres (TLS), os sistemas MLS são instalados em plataformas móveis como veículos, mochilas ou dispositivos portáteis, permitindo a cobertura eficiente de grandes áreas florestais (Dalla Corte et al., 2022). Estes sistemas têm capacidade de varredura que atingem até 2 milhões de pontos/s, gerando nuvens de pontos tridimensionais com densidades superiores a 120.000 pontos/m², com precisão de até 1 cm (Hyppä et al., 2020).

As principais vantagens do MLS na mensuração florestal incluem sua capacidade de capturar detalhes estruturais abaixo do dossel, inclinação do fuste e arquitetura de galhos - características tradicionalmente difíceis de quantificar com outros métodos (Terryn et al., 2020; Bastien Vandendaele et al., 2022). Um estudo recente conduzido por Fangming et al. (2024) demonstrou que o escaneamento por MLS foi aproximadamente 20 vezes mais rápido do que as medições de campo tradicionais, apresentando erros inferiores a 4% na estimativa do dap. Além disso, a integração desses sistemas com sensores complementares, como câmeras RGB, amplia seu potencial analítico, ao permitir a obtenção simultânea de informações espectrais e estruturais, o que favorece análises mais abrangentes da vegetação (Wang et al., 2020).

Na prática, os sistemas MLS têm demonstrado bom desempenho na aquisição de métricas dendrométricas tradicionais. Pesquisas reportam erros (RMSE%) de 4% - 6 % na estimativa de dap e 2,5% - 9 % na determinação de altura comercial quando utilizados algoritmos de processamento adequados (Zeybek & Vatandaşlar, 2021; Fangming et al., 2024; Hyppä et al., 2020). Para mensurações volumétricas, os erros se mantêm na faixa de 9% - 14 % (Hyppä et al., 2020; Bastien Vandendaele et al., 2022). Além das métricas tradicionais, o MLS permite a quantificação de variáveis estruturais avançadas como *taper* do fuste, simetria de copa e características de inserção de galhos (Bastien Vandendaele et al., 2022; Terryn et al., 2020).

As principais limitações do MLS em aplicações florestais envolvem fatores técnicos, operacionais e ambientais. A oclusão da vegetação dificulta a captação

completa das estruturas, impactando a detecção de árvores (Mak et al., 2025; Balestra et al., 2024), enquanto a estimativa de altura apresenta erros superiores a 12% em florestas maduras (Lee; Lee, 2025). Restrições operacionais incluem mobilidade limitada em terrenos accidentados, dependência de sinais GNSS (Pires et al., 2024; Di Stefano et al., 2021), e a necessidade de processamento intensivo de nuvens de pontos densas (Liang et al., 2018; Calders et al., 2020). Além disso, custos iniciais ainda elevados e falta de padronização para integração multi-sensor limitam a adoção e a acurácia em diferentes contextos florestais (Zeybek; Vatandaşlar, 2021; Stovall et al., 2018).

Apesar desses desafios, avanços tecnológicos vêm superando muitas dessas barreiras. A miniaturização dos equipamentos tem ampliado a aplicabilidade do MLS em ambientes desafiadores (Fangming et al., 2024), enquanto algoritmos baseados em inteligência artificial têm melhorado a segmentação e extração de variáveis estruturais em florestas densas (Dalla Corte et al., 2022).

A integração com sensores multiespectrais e térmicos tem ampliado as análises ecológicas (Lin et al., 2023), e o surgimento de sistemas de baixo custo tem democratizado o acesso à tecnologia. Métodos inovadores, como uso de voxels e modelagem direta da estrutura 3D, vêm reduzindo a dependência de equações tradicionais, melhorando a estimativa de volume e biomassa (Gollob et al., 2021; Balestra et al., 2024), consolidando o MLS como uma ferramenta promissora para inventários florestais precisos e não destrutivos.

2.3.3 Combinação de dados LiDAR

Segundo Balestra et al., (2024) o termo 'combinação de dados', quando aplicado a dados LiDAR, pode ser usado para indicar todo o processo que inclui a fusão de dados começando na etapa de pré-processamento até a integração de dados na etapa de tomada de decisão. Essa abordagem permite aproveitar as vantagens complementares de diferentes sistemas, como a cobertura abrangente do LiDAR aerotransportado e a alta resolução estrutural do LiDAR terrestre (Shenkin et al., 2019).

Na prática florestal, esta abordagem tem demonstrado aplicações relevantes em três domínios principais. Para inventários de precisão, a combinação de métricas globais (derivadas de UAV-LIDAR/ALS) com detalhes estruturais locais (obtidos por

MLS/TLS) permite erros reduzidos nas mensurações e maior taxa de detecção (Panagiotidis et al., 2022). Na modelagem 3D completa, a fusão viabiliza a reconstrução precisa desde raízes expostas até ápices foliares, superando limitações de oclusão características dos sistemas isolados (Shenkin et al., 2019; Raúl et al., 2024). Ademais, a fusão com dados multiespectrais e hiperespectrais tem ampliado o escopo das aplicações. Matasci et al. (2018), por exemplo, combinaram dados LiDAR aerotransportados com imagens compostas do Landsat para gerar mapas detalhados e espacialmente extensos da estrutura florestal.

Contudo, o registro preciso entre diferentes conjuntos de dados constitui um desafio técnico considerável. Este alinhamento pode ser realizado com base em pontos de controle no solo (*Ground Control Points - GCP*) ou por meio da identificação de feições comuns entre os conjuntos de dados, como árvores dominantes, copas amplas ou localizações específicas de indivíduos arbóreos (Panagiotidis et al., 2022). Em alguns casos, o co-registro é realizado manualmente, utilizando essas feições como guias de alinhamento.

Além das dificuldades relacionadas ao registro de dados, há barreiras computacionais relevantes, como o processamento de nuvens que atingem tamanhos de arquivo substanciais, exigindo equipamentos com alta capacidade de memória RAM (Thompson et al., 2023). Nesse sentido, têm sido desenvolvidas soluções de processamento em nuvem e computação distribuída. Ademais, a padronização de protocolos de aquisição e processamento de dados também emerge como uma necessidade crítica, com o objetivo de viabilizar a interoperabilidade entre diferentes plataformas e aumentar a comparabilidade entre estudos (Balestra et al., 2024).

2.4 SEGMENTAÇÃO EM INSTÂNCIA

A segmentação em instância de nuvens de pontos LiDAR permite identificar e delimitar árvores individualmente dentro de uma mesma classe, sendo essencial para estimativas precisas de biomassa, monitoramento do crescimento e saúde das árvores, além de apoiar inventários florestais detalhados (Henrich et al., 2024). Essa abordagem tem ganhado destaque com a transição de práticas florestais baseadas em talhões para o nível de árvore individual no manejo de precisão (Wielgosz et al., 2024).

Estudos demonstram a utilidade dessa segmentação em diversos contextos. Zhang et al. (2015) aplicaram-na com sucesso a inventários urbanos, enquanto Ayrey et al. (2017) e Malladi et al. (2024) destacaram seu papel em pesquisas ecológicas e automação de análises florestais. Ferraz et al. (2012) demonstraram sua eficácia em florestas mediterrâneas multicamadas para gestão de biodiversidade e prevenção de incêndios. Estimativas de altura e estrutura das árvores a nível individual obtidas por segmentação por instância são interessantes para aplicações como modelagem de crescimento, avaliação de habitats e melhoramento florestal (Wang et al., 2019).

Diversos algoritmos vêm sendo propostos. O *TreeLearn*, por exemplo, é baseado em Aprendizado Profundo (*Deep Learning*) e pode ser treinado com dados gerados automaticamente e refinado com anotações manuais (Henrich et al., 2024). O *SegmentAnyTree* mostrou maior transferibilidade entre sensores LiDAR de diferentes plataformas e melhor detecção de árvores do sub-bosque (Wielgosz et al., 2024). Outras abordagens incluem o algoritmo *Layer Stacking* (Ayrey et al., 2017), segmentações baseadas em RANSAC (Tittmann et al., 2011) e métodos tradicionais otimizados para ambientes urbanos e florestas densas (Li et al., 2012; Zhang et al., 2015).

As abordagens são geralmente classificadas em três categorias: métodos tradicionais, baseados em Aprendizado Profundo e híbridos. Enquanto os primeiros dependem de regras pré-definidas e se limitam em ambientes com copas sobrepostas, os métodos de Aprendizado Profundo extraem características diretamente dos dados, com modelos como *PointGroup* mostrando bons resultados (Henrich et al., 2024). Abordagens híbridas combinam a robustez de algoritmos clássicos com a flexibilidade do Aprendizado Profundo, sendo úteis especialmente em florestas complexas.

A qualidade da segmentação por instância em nuvens de pontos LiDAR é influenciada por fatores como densidade da nuvem, estrutura do sub-bosque, composição das espécies e padrões de plantio. Densidades mais altas geralmente melhoram a segmentação, mas exigem mais recursos computacionais. A subamostragem aleatória pode aumentar a robustez do modelo (Wielgosz et al., 2024). Florestas densas ou com copas sobrepostas e espécies com morfologias variadas representam desafios adicionais.

As principais limitações apontadas são: (i) dificuldade em separar árvores em florestas densas, onde copas de árvores se sobrepõem significativamente, levando a

erros de subsegmentação, onde múltiplas árvores são identificadas como uma única instância; (ii) supersegmentação em copas com formatos irregulares ou lacunas na nuvem de pontos, onde uma única árvore é dividida em múltiplas instâncias; (iii) baixa detecção de árvores do sub-bosque e (iv) baixa generalização ou exigência de ajuste extensivo de hiperparâmetros.

2.5 SEGMENTAÇÃO SEMÂNTICA

A segmentação semântica de nuvens de pontos LiDAR em nível de árvore é uma ferramenta fundamental para a gestão florestal e monitoramento ecológico, permitindo classificar pontos em categorias como tronco, galhos, folhagem e solo, o que possibilita a criação de mapas detalhados e análises estruturais precisas dos ecossistemas (Wołk e Tatara, 2024).

Estudos demonstram ganhos significativos no uso da segmentação semântica para estimativas florestais. Por exemplo, Yang et al. (2024) mostraram reduções significativas no erro quadrático médio relativo (RMSE) para dap, de 29,30% para 8,59%, e altura de árvores, de 7,33% para 3,65%. Kim et al. (2023) evidenciaram que a técnica permite estimativas não destrutivas de biomassa acima do solo, reduzindo riscos e custos operacionais. Além disso, Chen et al. (2021) destacam sua importância para inventários florestais, avaliações de carbono e monitoramento da biodiversidade.

As abordagens para segmentação semântica de nuvens de pontos LiDAR podem ser categorizadas em três grupos principais: métodos tradicionais de Aprendizado de Máquina, Aprendizado Profundo e métodos híbridos. Técnicas tradicionais baseiam-se em características manuais extraídas das nuvens de pontos, como geometria, intensidade e contexto, usadas para treinar classificadores como Florestas Aleatórias e Máquinas de Vetores de Suporte (*Support Vectors Machine - SVM*).

Já os métodos baseados em Aprendizado Profundo aprendem automaticamente representações hierárquicas a partir dos dados brutos, utilizando arquiteturas como *PointNet++*, *3D-UNet* e redes convolucionais gráficas (Wielgosz et al., 2024). Abordagens híbridas combinam a extração automática com algoritmos tradicionais de pós-processamento, otimizando tanto a precisão quanto a eficiência computacional.

Avanços recentes em algoritmos têm melhorado significativamente a precisão e eficiência da segmentação semântica em nível de árvore, destacando-se métodos como o *GrowSP-ForMS*, que utiliza aprendizado profundo não supervisionado para separar componentes foliares e lenhosos em dados LiDAR multiespectrais sem necessidade de rotulagem (Xiang et al., 2025), e o *Forest-PointNet*, que integra informações espaciais e espectrais para segmentar estruturas verticais complexas com alta acurácia (Li et al., 2024).

O *PointNet++*, com pré-processamento adaptado, otimizou a segmentação de troncos, copas e galhos utilizando reamostragem de pontos representativos (Kim et al., 2023), enquanto a Rede Neural Convolucional Gráfica Dinâmica (*Deep Graph Convolutional Neural Network - DGCNN*) alcançou 91,2% de acurácia na separação de componentes fotossintéticos e não fotossintéticos, superando métodos tradicionais (Wang et al., 2020). Além disso, técnicas como o filtro baseado em simulação de tecido para separar solo e vegetação (Zhang et al., 2016) e redes convolucionais multiescala com 93,7% de acurácia para classificar folhas e madeira (Zhao et al., 2021) evidenciam o progresso robusto e a aplicabilidade desses algoritmos em diversas condições florestais.

A qualidade da segmentação depende da densidade da nuvem de pontos, do pré-processamento, da complexidade florestal, das condições ambientais e das características do sensor (Yang et al., 2024). Florestas densas e heterogêneas apresentam desafios adicionais, como oclusões causadas por galhos e sub-bosque, enquanto condições adversas e limitações do sensor afetam a integridade dos dados. A robustez dos algoritmos está associada à adaptação a esses fatores.

Apesar dos avanços, desafios permanecem, a generalização entre diferentes tipos de floresta e plataformas sensoriais ainda é limitada, exigindo reconfiguração ou re-treinamento dos modelos (Kim et al., 2023). O processamento de inventários em larga escala continua sendo computacionalmente exigente. Além disso, a escassez de dados rotulados limita o desenvolvimento de abordagens supervisionadas, embora métodos não supervisionados e auto-supervisionados apresentem potencial promissor para superar essa limitação (Xiang et al., 2025).

3 MATERIAL E MÉTODOS

3.1 CARACTERIZAÇÃO DAS ÁREAS DE ESTUDO

O estudo foi conduzido em dois experimentos de melhoramento genético de *Eucalyptus* spp., localizados em propriedades da Suzano S/A, no estado de São Paulo, Brasil.

3.1.1 Caçapava

O experimento SP22MG50014 está localizado na Fazenda Nossa Senhora d'Ajuda ($23^{\circ}07'40"S$ $45^{\circ}37'33"W$, altitude 629 m), município de Caçapava, São Paulo (Figura 2). Implantado em dezembro de 2022, o ensaio experimental compreende 500 parcelas de uma árvore (25 clones \times 20 repetições), em espaçamento 2 m \times 3 m.

FIGURA 2 - MAPA DE LOCALIZAÇÃO DO EXPERIMENTO EM CAÇAPAVA, SÃO PAULO



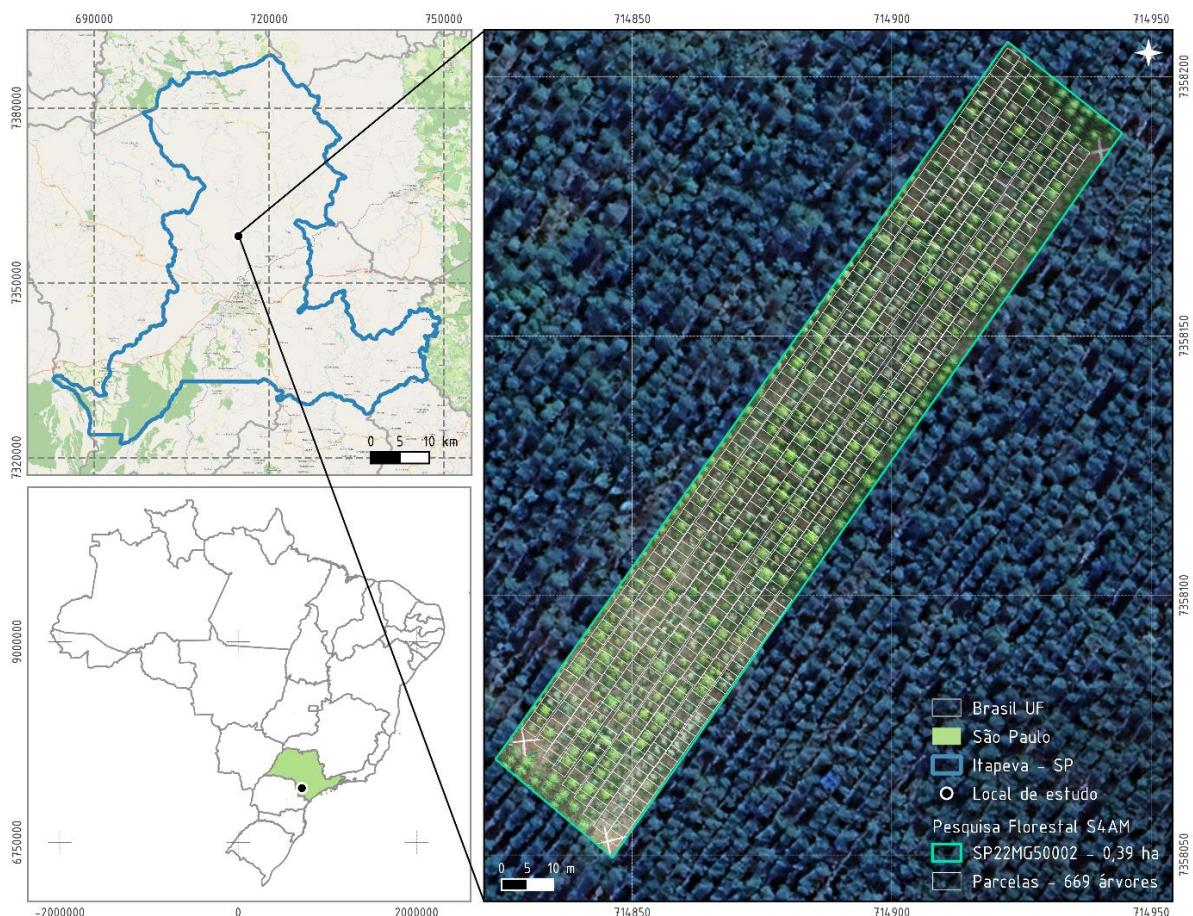
FONTE: A autora (2025).

A região apresenta clima Cfa segundo a classificação de Köppen-Geiger, caracterizado como subtropical úmido (Alvares et al., 2013), com temperatura média anual de aproximadamente 20 °C. As temperaturas médias mensais variam de mínimas em torno de 5 °C no inverno a máximas médias de até 33 °C no verão. A precipitação média anual é de 1.530 mm (Agritempo, 2025; INMET, 2025). O solo da área é classificado como Latossolo Amarelo Distrófico, com textura argilosa (BDIA, 2023).

3.1.2 Itapeva

O experimento SP22MG50014 está localizado na Fazenda Karamacy ($23^{\circ}52'26"S$ $48^{\circ}53'22"W$, altitude 696 m), município de Itapeva, São Paulo (Figura 3). Implantado em maio de 2022, o ensaio experimental compreende 669 parcelas de uma árvore (49 clones), em espaçamento $2\text{ m} \times 3\text{ m}$.

FIGURA 3 - LOCALIZAÇÃO DO EXPERIMENTO EM ITAPEVA, SÃO PAULO



FONTE: A autora (2025).

A área de estudo apresenta clima do tipo Cfa, segundo a classificação de Köppen-Geiger, caracterizado como subtropical úmido (Alvares et al., 2013), com temperatura média anual de 21 °C, médias mínimas de 4 °C e máximas de 35 °C. A precipitação média anual é de aproximadamente 1.230 mm (Agritempo, 2025). O solo da área é classificado como Latossolo Vermelho Distrófico, com textura argilosa (BDIA, 2023).

3.2 COLETA DE DADOS

3.2.1 Inventário à 100% (censo florestal)

Os dados de inventário florestal censitário foram fornecidos pela Suzano S/A. As medições em Caçapava ocorreram em 26/08/2024, enquanto em Itapeva foram realizadas em 12/07/2024. Foram coletados dados de circunferência à altura do peito (CAP), alturas totais (ht) e condição da árvore (normal, falha, dominada, bifurcada, torta, quebrada, tombada, ponta seca ou morta). A equipe de campo utilizou fita métrica para medição do CAP e hipsômetro para ht de 500 árvores no experimento Caçapava e 669 árvores no experimento Itapeva.

3.2.2 Dados espectrais

A coleta de dados espectrais ocorreu em novembro de 2025, com voos realizados em condições de céu claro (nebulosidade < 15%) entre 10h e 14h para minimizar variações na iluminação solar. Em Caçapava, os voos aconteceram em 14/11/2024, enquanto em Itapeva foram realizados em 17/12/2024. Para a aquisição de imagens pancromáticas, utilizou-se o drone DJI Mavic 3 Enterprise equipado com câmera 4/3" CMOS de 20 MP (Figura 4), operando a 120 m de altitude com velocidade de 9 m/s e sobreposição de 70% x 80%, garantindo resolução espacial de 11 cm/pixel.

Os dados multiespectrais foram coletados com o drone de asa fixa eBee X (Figura 5), equipado com sensor *Parrot Sequoia* cobrindo cinco bandas espectrais (*Blue, Green, Red, Red Edge* e *NIR*). Este sistema operou a 120 m de altura com velocidade de 12 m/s e sobreposição de 70% x 80%, produzindo imagens com resolução de 27 cm/pixel. A calibração radiométrica foi realizada antes e após cada

voo utilizando painel de reflectância MicaSense, garantindo a qualidade dos dados espectrais adquiridos.

FIGURA 4 - DRONE DJI MAVIC 3 ENTREPRISE



FONTE: A autora (2024) (esquerda); WDDrones (2025) (direita).

FIGURA 5 - DRONE DE ASA FIXA EBEE X



FONTE: Santiago & Cintra (2025).

3.2.3 Dados LiDAR

O levantamento LiDAR com sistema UAV-LIDAR ocorreu em 14/11/2024 em Caçapava e em 17/12/2024 em Itapeva, utilizando a plataforma DJI Matrice 300 RTK equipada com sensor Livox AVIA (Figura 6). O sistema foi configurado para operar entre 70 e 80 m de altura com velocidade de 5 m/s, atingindo uma densidade de pontos de cerca de 780 pts/m². Os voos tiveram duração média de 10 minutos por hectare.

Para o MLS, empregou-se o sistema LiBackpack DG50 com dois sensores Velodyne VLP-16 operando simultaneamente (Figura 7), totalizando capacidade de aquisição de 600.000 pontos por segundo. O caminhamento foi realizado conforme o croqui ilustrado na Figura 8, visando minimizar possíveis oclusões, com duração

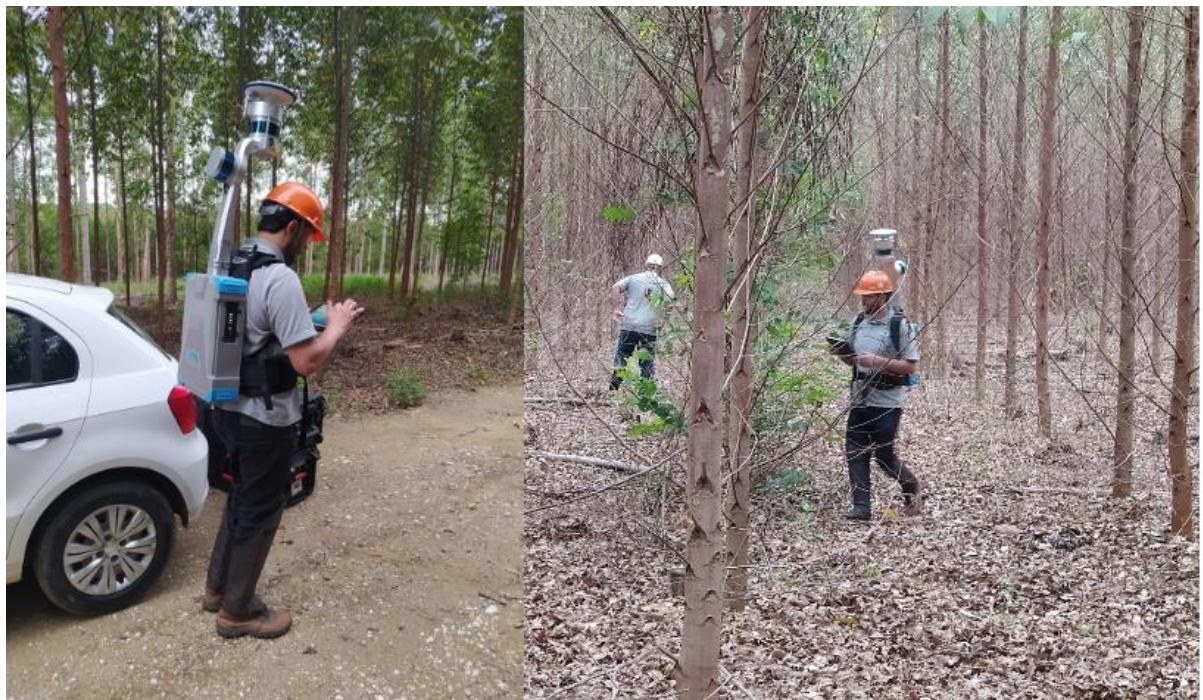
média de 50 minutos por hectare para o caminhamento + 15 minutos para a calibração inicial.

FIGURA 6 - DRONE DJI MATRICE 300 RTK



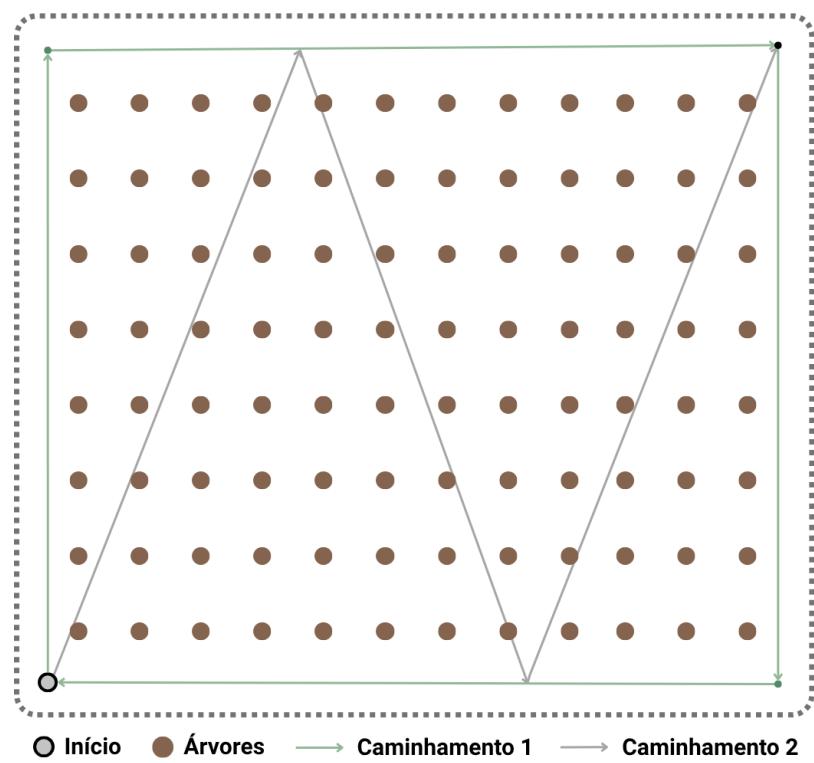
FONTE: A autora (2024) (esquerda); Tecno Drones (2025) (direita).

FIGURA 7 - SLAM LIBACKPACK DG50 + VLP-16 (X2)



FONTE: A autora (2024).

FIGURA 8 - CROQUI DO CAMINHAMENTO MLS



FONTE: A autora (2025).

3.2.4 Georreferenciamento

O georreferenciamento de todos os dados coletados foi realizado com estação GNSS *GreenValley International* equipada com chip Novatel OEM7500. A correção diferencial foi realizada via rede GNSS ativa do IBGE (IBGE-PPP), alcançando precisão pós-processada ≤ 5 cm. Todos os dados foram referenciados ao sistema SIRGAS2000, fuso 23S para Caçapava e 22S para Itapeva.

3.2.5 Resumo

As Tabelas 1 e 2 apresentam, respectivamente, um resumo das coletas de dados realizadas por meio de inventário censitário tradicional e por sensoriamento remoto nos experimentos conduzidos em Caçapava e Itapeva.

TABELA 1 - RESUMO DO INVENTÁRIO TRADICIONAL

Dados	Caçapava	Itapeva
Data inventário	26/08/2024	12/07/2024
Área (ha)	0,45	0,39
Espaçamento	2 m x 3 m	
*Idade (anos)	1,7	2,2
Clones	25	49
Árvores	500	669
Variáveis	CAP, ht e condição da árvore	

*Relativa à data do inventário.

TABELA 2 - RESUMO DAS COLETAS DE DADOS LIDAR E ESPECTRAIS.

Dados	Pancromático	Multiespectral	UAV-LiDAR	MLS	Georef.
¹ Data	14/11/24	14/11/24	14/11/24	14/11/24	14/11/24
² Data	17/12/24	17/12/24	17/12/24	17/12/24	17/12/2024
Suporte	DJI Mavic 3 Enterprise	eBee X	DJI Matrice 300 RTK	LiBackpack DG50	GNSS GreenValley International
Sensor		Parrot Sequoia	Livox AVIA	Velodyne VLP-16	Novatel OEM7500
Formato raw*	.jpg	RAW 10-bit TIFF	.vpts	.pcap	-
Software*	Emlid	Emotion	Ligeoreference		-
Altura voo	120	120	70-80	-	-
Velocidade	9	12	5	-	-
Sobreposição	70x80	70x80	50	-	-
Tamanho pixel	11 cm/px	27 cm/px	-	-	-
Densidade pt/s	-	-	240.000	600.000	-
nº voos	1	1	1	-	-
Duração total	15 min	15 min	25 min	45 min	-
¹ Área (ha)	4,14	4,14	4,14	1,3	-
² Área (ha)	3,2	3,2	3,2	0,9	-
Custo total	R\$ 3.000,00	R\$ 4.000,00	R\$ 12.000,00	R\$ 21.000,00	-

¹Caçapava; ²Itapeva.

3.3 HARDWARE DE PROCESSAMENTO

O processamento dos dados foi conduzido paralelamente em dois equipamentos com configurações distintas. O primeiro consistiu em um notebook Dell G3, equipado com processador Intel Core i7 de 9^a geração, 16 GB de memória RAM, unidade de armazenamento SSD de 500 GB, HD adicional de 1 TB e placa gráfica dedicada NVIDIA GeForce GTX 1660 Ti com 6 GB de VRAM.

O segundo equipamento utilizado foi um notebook Avell A75 RTX MUV com processador Inter Core i7 de 9^a geração, 64 GB de memória RAM, unidade de armazenamento SSD de 500 GB, HD adicional de 2 TB e placa gráfica dedicada NVIDIA GeForce RTX 2070. Todas as etapas do fluxo de processamento foram testadas em ambos os sistemas, visando avaliar se haveria limitações de desempenho.

3.4 TEMPO DE PROCESSAMENTO

Com o objetivo de analisar o tempo de execução das etapas de processamento dos dados LiDAR, este parâmetro foi mensurado considerando desde as fases iniciais, como a normalização e a geração de modelos digitais, até a obtenção dos resultados finais. Ressalta-se que foram contabilizados exclusivamente os tempos de execução dos algoritmos, desconsiderando-se períodos de latência relacionados à intervenção do usuário para o acionamento das rotinas, bem como o tempo necessário para a geração prévia dos arquivos no formato “.laz”. O tempo de processamento dos dados espectrais não foi monitorado, uma vez que sua execução ocorreu de forma praticamente instantânea.

3.5 PRÉ-PROCESSAMENTO

O pré-processamento constitui uma etapa fundamental para assegurar a qualidade, consistência e adequação dos dados às análises subsequentes. As etapas envolvidas nesta fase estão descritas nos subtópicos a seguir. Os algoritmos, softwares, bibliotecas e parâmetros específicos empregados em cada procedimento encontram-se detalhados no Apêndice 1.

3.5.1 Dados de inventário

Os dados brutos de inventário florestal foram submetidos a um processo de pré-processamento para garantir sua qualidade e compatibilidade com as análises subsequentes. Inicialmente, foi realizada uma análise exploratória detalhada, envolvendo o cálculo de estatísticas descritivas e a geração de gráficos do tipo violino, por meio dos ambientes *RStudio* e *Microsoft Excel*, com foco na identificação de valores discrepantes, dados ausentes e possíveis inconsistências nas medições.

O processo de tratamento dos dados incluiu: (1) padronização das unidades de medida; (2) filtragem de observações inválidas; (3) filtragem de clones com baixo número de repetições ($<=20$) (4) reestruturação da base e (5) harmonização dos formatos de identificadores únicos. Posteriormente, os dados foram organizados em um geodataset no formato “.gpkg” por meio de um grid espacial (metodologia detalhada na Seção 3.6.2.2), visando facilitar as integrações com demais dados e análise posteriores.

3.5.2 Dados espectrais

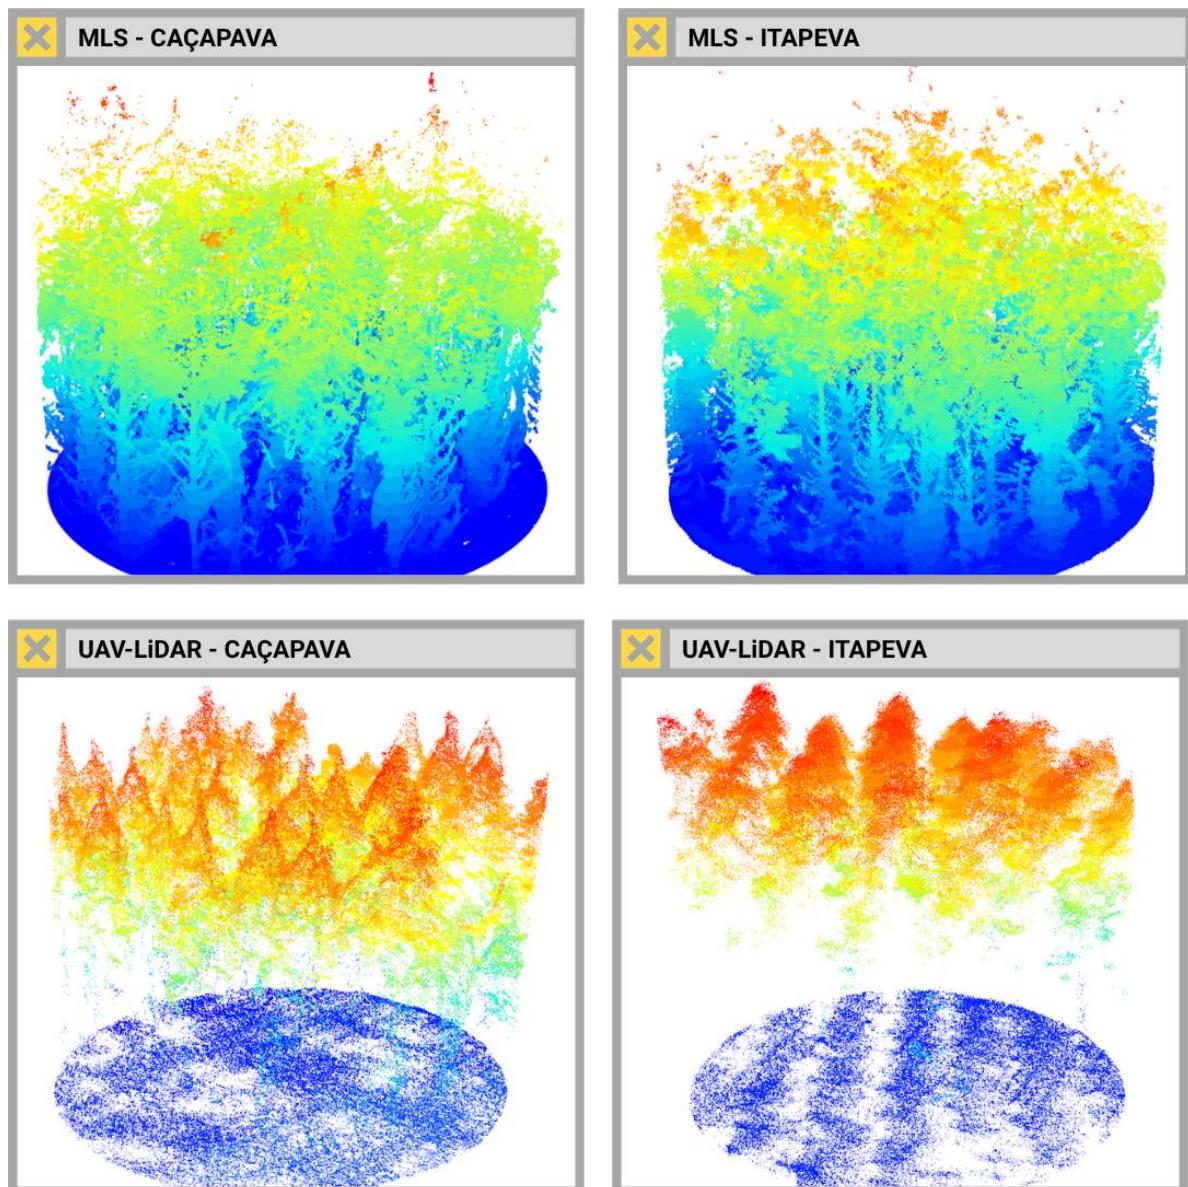
O processamento inicial dos dados espectrais incluiu etapas de georreferenciamento e correções radiométricas. O pré-processamento e o georreferenciamento das imagens pancromáticas foram realizados no software *Emlid Studio*, enquanto os dados multiespectrais foram processados no software *eMotion*, com aplicação de correção de reflectância baseada nos dados do painel de calibração.

3.5.3 Dados LiDAR

3.5.3.1 Georreferenciamento e limpeza

Os dados brutos LiDAR foram processados utilizando o software *Ligeoreference*, que permitiu o georreferenciamento e registro preciso baseado nos dados GNSS/IMU e a eliminação de ruídos. O processo resultou em nuvens de pontos georreferenciadas no sistema SIRGAS2000, armazenadas no formato “.laz” para preservação de metadados e eficiência no armazenamento. Um overview dos dados pode ser visualizado na Figura 9 e Tabela 3.

FIGURA 9 - PARCELAS CIRCULARES DE 10 M DE RAIO GERADAS A PARTIR DAS NUVENS DE PONTOS DOS SISTEMAS MLS E UAV-LIDAR NOS DOIS LOCAIS DE ESTUDO



FONTE: A autora (2025).

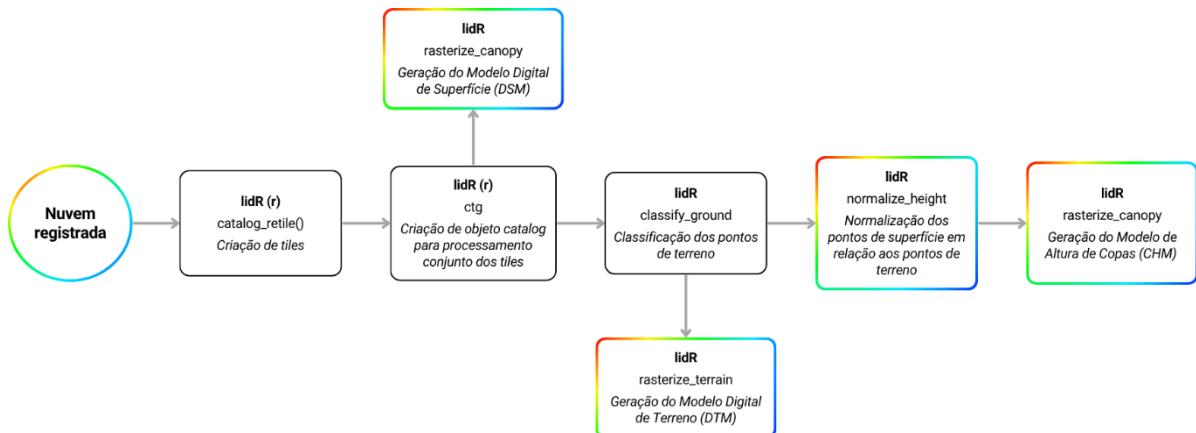
TABELA 3 - CARACTERÍSTICAS DOS DADOS LIDAR COLETADOS EM CAÇAPAVA¹ E ITAPEVA²

Dados	Nº de pontos	Área (m ²)	Densidade de pontos (pts/m ²)	Tamanho arquivo .laz
MLS ¹	157.690.000	12.881,30	12.241,82	1,4 GB
UAV-LiDAR ¹	6.440.000	8.184,00	786,90	58,4 MB
MLS ²	105.350.000	9.069,80	11.615,52	1 GB
UAV-LiDAR ²	8.460.000	9.828,00	860,81	77 MB

3.5.3.2 Normalização

A normalização das nuvens de pontos e geração dos produtos cartográficos Modelo Digital de Superfície (*Digital Surface Model - DSM/MDS*), Modelo Digital de Terreno (*Digital Terrain Model – DTM/MDT*) e Modelo de Altura De Copas (*Canopy Height Model, CHM*), foi realizada com o pacote “*lidR*”, no ambiente *RStudio*, seguindo o diagrama da Figura 10. As funções e parâmetros utilizados em cada etapa foram definidos a partir de uma análise detalhada em uma subárea de teste.

FIGURA 10 - FLUXO DE PROCESSAMENTO PARA NORMALIZAÇÃO DAS NUVENS E GERAÇÃO DOS PRODUTOS CARTOGRÁFICOS MDS, MDT E CHM



FONTE: A autora (2025).

3.5.3.3 MLS + UAV-LIDAR

A combinação das nuvens de pontos foi realizada por meio da função `ctg()` do pacote “*lidR*”, que permitiu a sobreposição precisa das nuvens graças ao bom georreferenciamento inicial. A combinação aproveitou as características complementares de cada plataforma: o UAV-LIDAR forneceu cobertura abrangente da estrutura superior das copas, enquanto o MLS capturou detalhes estruturais finos da porção inferior do dossel e fustes. A qualidade da combinação foi avaliada por meio da inspeção visual das nuvens, confirmando a sobreposição e continuidade estrutural entre os conjuntos de dados.

3.6 PROCESSAMENTO

O processamento dos dados se encontra detalhado nos tópicos a seguir. Os algoritmos, *softwares*, pacotes e parâmetros específicos utilizados em cada etapa estão detalhados no Apêndice 1 e no Apêndice 4.

3.6.1 Dados espectrais

3.6.1.1 Segmentação de copas

Foram testados diferentes algoritmos de Aprendizado Profundo para a segmentação de copas, utilizando modelos pré-treinados como “detectree2” (Ball et al., 2023), “FastSAM” (Zhao et al., 2023), “SAM” (Kirillov et al., 2023), “SAM2” (Ravi et al., 2024) e “YOLOv11” (Jocher, Qiu & Chaurasia, 2023). Contudo, a elevada homogeneidade estrutural do ambiente florestal impôs limitações à acurácia da segmentação automática, resultando em delineamentos inconsistentes das copas.

Diante dessa limitação, optou-se por uma abordagem semi-automatizada no *software QGIS*. Foi gerado um *grid* regular sobre as imagens, a partir do qual se extraíram os centróides das parcelas experimentais. Sobre cada ponto central foi aplicado um *buffer* circular de 1 metro de raio, respeitando o espaçamento experimental de 2 m × 3 m. Essa estratégia resultou em uma representação aproximada, porém funcional, das copas individuais, possibilitando a individualização dos dados espectrais por árvore.

3.6.1.2 Índices de vegetação

O processamento e cálculo dos índices de vegetação (IV) foram conduzidos integralmente no ambiente *RStudio*, por meio do pacote “terra” (Rspatial). Para os conjuntos de dados obtidos por sensores pancromáticos e multiespectrais, foram computados, no total, 29 IV (13 dos dados pancromáticos e 16 dos multiespectrais) amplamente documentados na literatura científica (Quadros 1 e 2, respectivamente), contemplando diferentes propriedades biofísicas da vegetação.

A individualização dos IV por árvore foi realizada com base nos polígonos de copa definidos na etapa anterior (Tópico 3.6.1.1). Os valores dos índices previamente

calculados foram extraídos para cada indivíduo arbóreo com o uso de operações zonais no pacote “terra”, considerando exclusivamente a área delimitada para cada copa. Essa abordagem permitiu associar os atributos espetrais às respectivas árvores no experimento.

3.6.2 Dados UAV-LIDAR

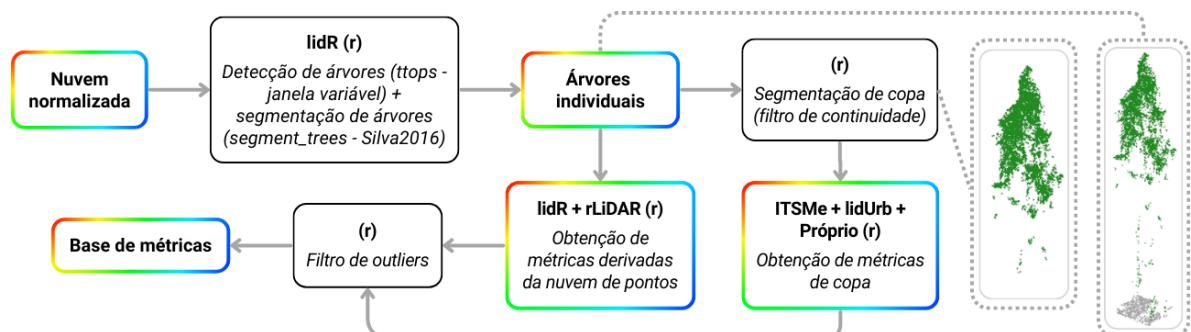
3.6.2.1 Segmentação em Instância

A segmentação em instância (segmentação de árvores individuais) nos dados UAV-LIDAR foi implementada por meio de uma abordagem em duas etapas. Primeiramente, identificaram-se os ápices das copas utilizando a função *treetops()* do pacote “lidR” (Roussel & Auty, 2023) com algoritmo de busca local de máximos (lmf) com janela variável (Apêndice 1). Em seguida, aplicou-se a função *segment_trees()* com o algoritmo “silva2016”, utilizando como sementes os ápices previamente detectados. Os parâmetros do algoritmo foram calibrados em uma subárea de teste (Apêndice 4).

3.6.2.2 Extração das métricas individuais

A extração de métricas individuais seguiu o fluxo de processamento detalhado na Figura 11. Inicialmente, as árvores segmentadas foram processadas, em ambiente *RStudio*, nos pacotes “lidR” e “rLiDAR” (Silva, 2019) para extração sistemática de métricas derivadas da nuvem de pontos. Este procedimento gerou um conjunto abrangente de variáveis, listadas e descritas no Apêndice 2.

FIGURA 11 - PROCESSO DE EXTRAÇÃO DE MÉTRICAS INDIVIDUAIS DE DADOS UAV-LIDAR



FONTE: A autora (2025).

Ainda no ambiente do *RStudio*, para a obtenção de características da copa, implementou-se um filtro de continuidade em Z, detalhado no Apêndice 4, seguido pela aplicação do algoritmo “ITSMe” (Louise, T., 2022) (*r*). Esta abordagem permitiu a quantificação de métricas como volume de copa, área projetada e outros apresentados no Apêndice 3.

3.6.3 Dados MLS e MLS+UAV-LIDAR

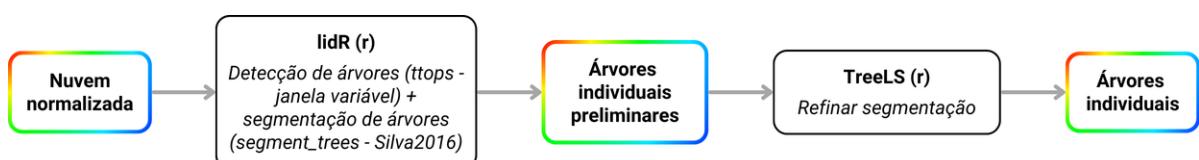
3.6.3.1 Segmentação em Instância

Foram testadas duas abordagens distintas para a segmentação em instância a partir das nuvens de pontos obtidas por MLS e três abordagens para os dados combinados (MLS + UAV-LIDAR).

Uma das abordagens, aplicada exclusivamente às nuvens combinadas, explorou a presença de picos de copa mais bem definidos, uma característica conferida pelos dados provenientes do UAV-LIDAR. Para sua implementação, foi realizada a integração dos pacotes “lidR” e “TreeLS” (Conto, 2020) no ambiente *RStudio* (Figura 12).

Inicialmente, utilizaram-se os topes de copa previamente identificados no processamento do UAV-LIDAR (Tópico 3.6.2.1), aplicando-se a função *segment_trees()* com o algoritmo *silva2016*, o que permitiu uma segmentação preliminar das árvores na nuvem combinada. Em seguida, a segmentação foi refinada por meio do pacote “TreeLS”, com o objetivo de corrigir casos de subsegmentação, nos quais múltiplas árvores foram erroneamente agrupadas como um único indivíduo.

FIGURA 12 - ESQUEMA DA ABORDAGEM VIA PACOTES lidR + TreeLS



FONTE: A autora (2025).

Nas abordagens aplicadas, tanto às nuvens MLS quanto às nuvens combinadas, a primeira etapa consistiu na segmentação das árvores em fileiras, utilizando como referência o CHM previamente gerado. A delimitação das fileiras foi

realizada manualmente no software QGIS (versão 3.34.6), com base na disposição espacial observada no CHM.

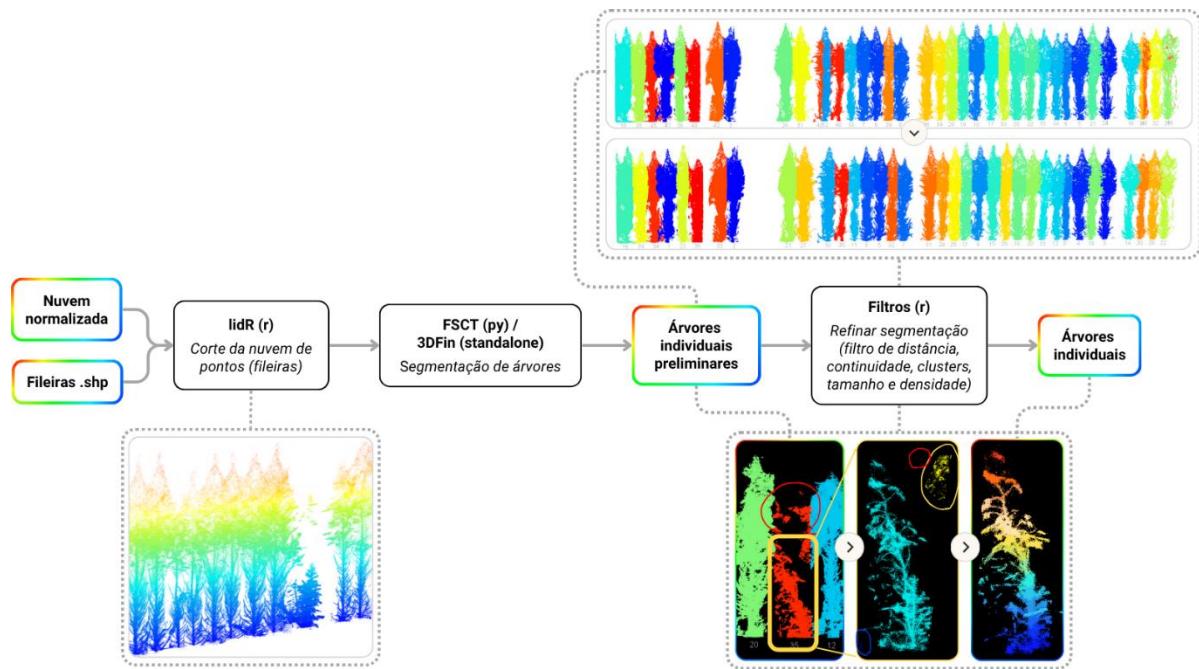
A primeira dessas abordagens empregou o pacote *python* “FSCT” (Krisanski et al., 2021), que implementa algoritmos baseados em Aprendizado de Máquina para o processamento de nuvens de pontos florestais. Após a segmentação inicial, uma série de filtros foram aplicados para correção de inconsistências, (Quadro 3 e Figura 13). Já a segunda abordagem utilizou o software *standalone 3DFin* (Laino et al., 2024), adotando a mesma sequência de filtros pós-segmentação para garantir comparabilidade entre os métodos.

QUADRO 3 - FILTROS PARA REFINAMENTO DA SEGMENTAÇÃO DE ÁRVORES INDIVIDUAIS

Filtro	Parâmetro	Objetivo	Impacto Esperado
Distância Euclidiana	Árvores < 1,15 m de distância	Fusão de múltiplas detecções da mesma árvore	Redução de falsos positivos por supersegmentação*
Continuidade Vertical	Segmentos descontínuos em Z	Remoção de segmentos de outras árvores	Isolamento preciso de árvores de menor porte
Clusters	Manter apenas o maior cluster por árvore	Exclusão de aglomerados de pontos isolados	Refinamento da segmentação
Tamanho relativo	Altura do segmento > 3,5	Descarte de segmentos pequenos	Remoção de detecções improváveis
Densidade relativa	Densidade da nuvem > 0,1% da densidade da fileira	Eliminar segmentos grandes, mas esparsos	Remoção de detecções improváveis

* casos em que uma única árvore foi segmentada como mais de um indivíduo.

FIGURA 13 - ABORDAGEM VIA FSCT+FILTROS/3DFIN+FILTROS



FONTE: A autora (2025).

3.6.3.2 Segmentação Semântica

A segmentação semântica das nuvens de pontos foi realizada utilizando uma abordagem híbrida que combinou a ferramenta “FSCT” com o pacote “TreeLS”. A ferramenta “FSCT”, originalmente desenvolvida em *Python*, foi parcialmente adaptada para o ambiente *RStudio* por meio do pacote “ForestClassR” (Bielak, 2025), permitindo a classificação inicial dos pontos nas categorias folha, madeira e outros.

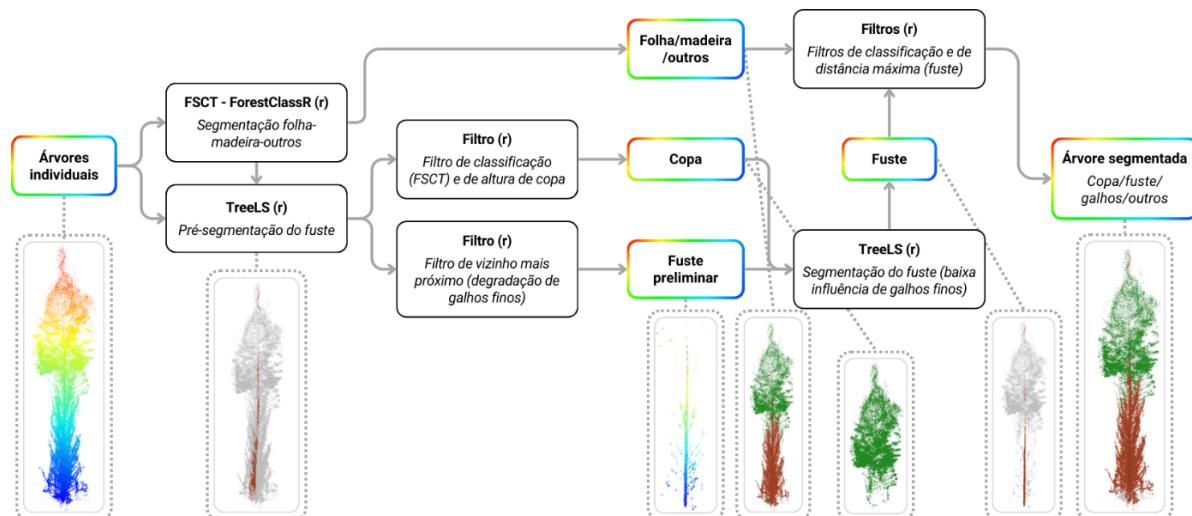
O pacote “TreeLS” foi então empregado para refinamento da classificação, com ênfase na identificação exata do fuste. Devido à alta densidade de galhos pequenos no fuste, foi necessário aplicar um filtro de vizinho mais próximo, com parâmetros elevados (Quadro 4) para degradar esses galhos.

Para evitar a perda dos pontos da copa, essa foi previamente filtrada para posterior combinação com os pontos filtrados do fuste (fuste preliminar). Posteriormente, um conjunto de filtros foi aplicado para refinamento da segmentação (Quadro 4). A aplicação desses filtros possibilitou a segmentação dos pontos em copa-fuste-galhos-outros, conforme esquematizado na Figura 14.

QUADRO 4 - FILTROS APLICADOS PARA REFINAMENTO DA SEGMENTAÇÃO SEMÂNTICA

Filtro	Parâmetro	Objetivo	Impacto Esperado
Vizinhos próximos	Distância (d)=0.05m, Número de vizinhos (n)=30	Degradar pontos de galhos	Melhoria na segmentação do fuste principal pelo algoritmo TreeLS
Altura relativa de copa	Filtrar pontos classificados como folhas (FSCT) e altura > 35% da altura da árvore	Filtrar/segmentar pontos de copa	Isolamento preciso dos pontos de copa
Classificação	Pontos classificados como madeira e não fuste são considerados galhos	Segmentar galhos	Separação precisa entre fuste e galhos para análises estruturais individuais
Distância euclidiana máxima	Pontos a > 0,5m do centro dos pontos de fuste são considerados galhos	Prevenção de supersegmentação do fuste principal devido a galhos	Melhorar robustez da segmentação do fuste principal

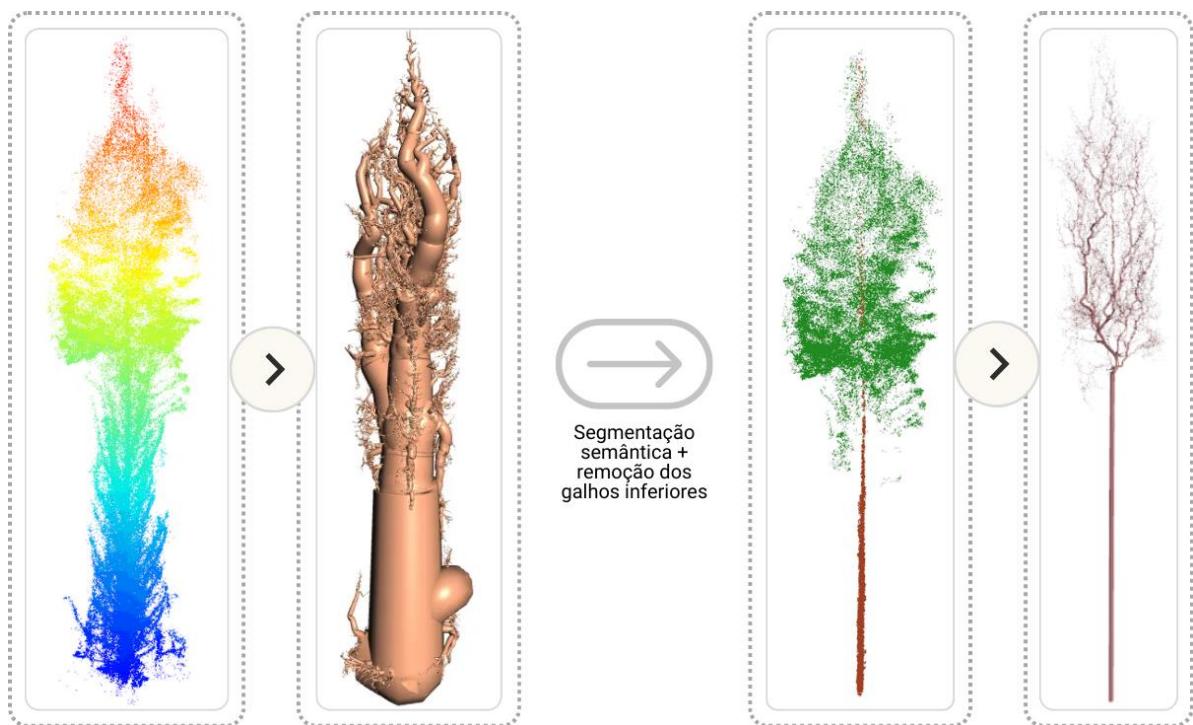
FIGURA 14 - ESQUEMA DA SEGMENTAÇÃO SEMÂNTICA DAS ÁRVORES



FONTE: A autora (2025).

A segmentação semântica foi uma etapa fundamental neste estudo, dadas as particularidades estruturais do povoamento. A alta densidade de galhos nas porções inferiores do fuste comprometeu a acurácia das métricas de diâmetro e volume obtidas em análises preliminares. Essa limitação é evidenciada na Figura 15, onde é apresentado um exemplo do efeito da ramificação basal sobre a modelagem QSM (Quantitative Structure Model) que será abordada na sequência.

FIGURA 15 - EXEMPLO DO EFEITO DA RAMIFICAÇÃO BASAL SOBRE A MODELAGEM QSM

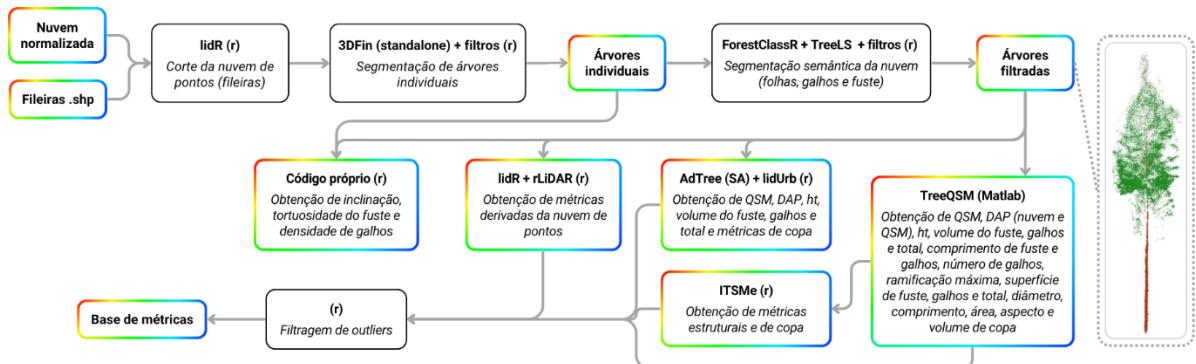


FONTE: A autora (2025).

3.6.3.3 Extração das métricas em nível de árvore individual

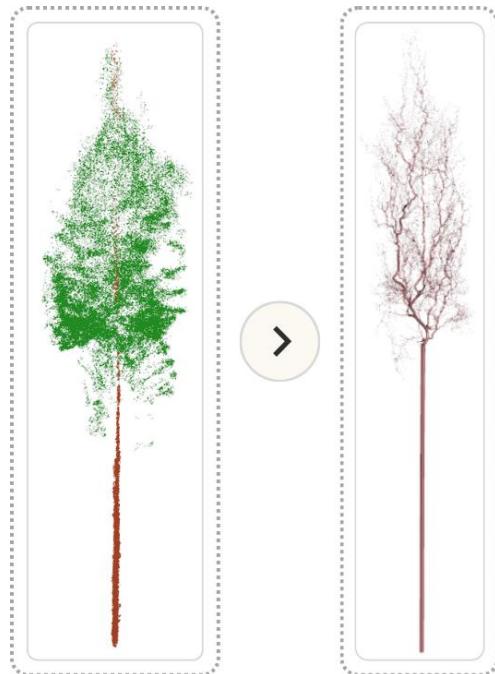
O processo de extração de métricas em nível de árvore individual seguiu um fluxo de trabalho integrado (Figura 16), combinando diferentes algoritmos e linguagens de programação para maximizar a exatidão e diversidade das métricas. Após as etapas de segmentação em instância e semântica, as árvores processadas, com remoção dos galhos inferiores, foram submetidas à modelagem QSM, ampliando substancialmente a gama de atributos estruturais deriváveis (Figura 17).

FIGURA 16 - FLUXO DO PROCESSO DE EXTRAÇÃO DE MÉTRICAS INDIVIDUAIS DOS DADOS MLS E MLS+UAV-LIDAR, MOSTRANDO A INTEGRAÇÃO ENTRE OS DIFERENTES ALGORITMOS UTILIZADOS



FONTE: A autora (2025).

FIGURA 17 - ÁRVORE INDIVIDUAL FILTRADA MODELADA EM QSM VIA AdTree



FONTE: A autora (2025).

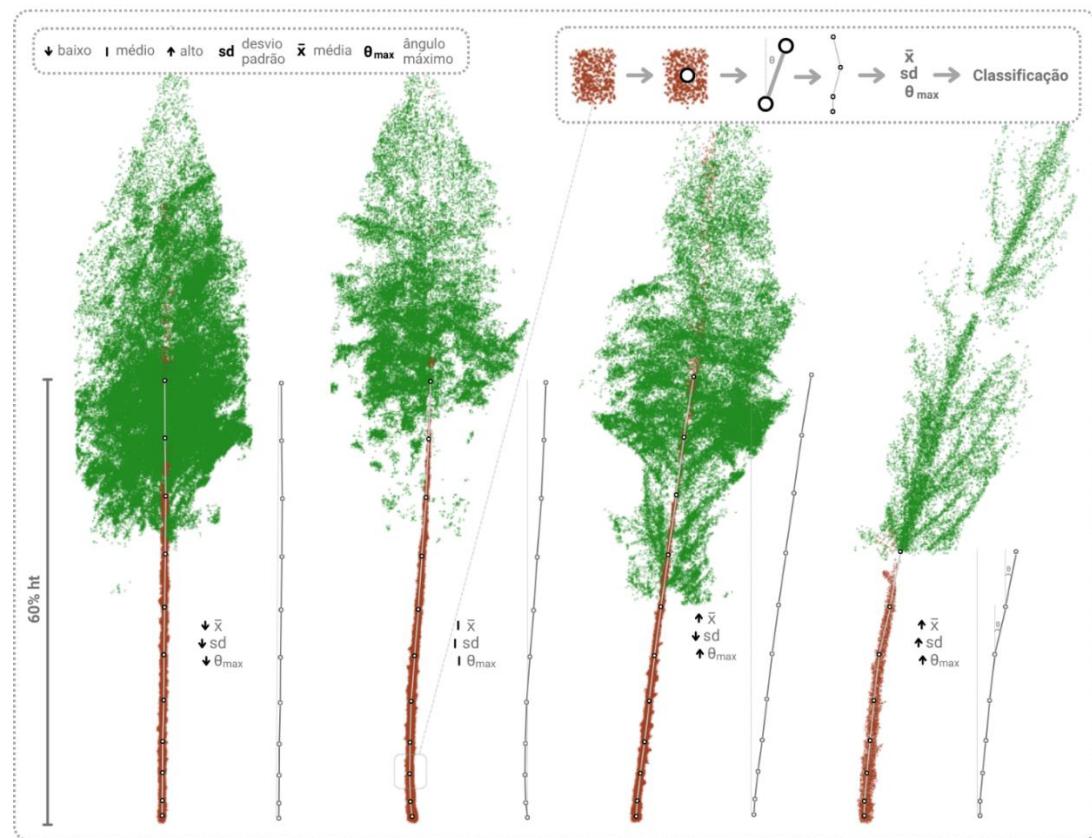
Dois algoritmos complementares foram utilizados para a reconstrução tridimensional das árvores: “TreeQSM” (Raumonen & Åkerblom, 2022), implementado em MATLAB, e *AdTree* (Du et al., 2019), uma ferramenta *standalone*. Os modelos QSM gerados pelo “TreeQSM” foram posteriormente processados com o pacote “ITSMe” no ambiente *RStudio*, resultando na extração de 17 métricas adicionais, totalizando 30 métricas estruturais (Apêndice 3), abrangendo variáveis relacionadas à

arquitetura da copa, morfologia dos galhos e distribuição volumétrica ao longo do fuste.

Simultaneamente, o modelo QSM do *AdTree* foi integrado ao pacote “lidUrb” (Lecigne, 2022), possibilitando a derivação de métricas como: dap, diâmetros relativos ao longo do fuste, altura total, volume total, volume por classes diamétricas e por ordens de ramificação. Adicionalmente, a nuvem de pontos filtrada foi processada novamente no ambiente de *RStudio*, utilizando os pacotes “lidR”, “rLiDAR” e “lidUrb”, resultando na extração de 68 métricas adicionais (Apêndice 3), diretamente derivadas da geometria da nuvem.

Como parte desse fluxo, foi desenvolvido um algoritmo personalizado (Apêndice 4) para o cálculo de cinco métricas estruturais complementares: (i) ângulos ao longo do fuste; (ii) média dos ângulos; (iii) desvio padrão dos ângulos; (iv) ângulo máximo; e (v) densidade de galhos. Ainda, a partir das métricas ii, iii e iv foi possível gerar uma classificação da qualidade do fuste (Figura 18).

FIGURA 18 - ILUSTRAÇÃO DA EXTRAÇÃO DOS ÂNGULOS E DO POTENCIAL DE CLASSIFICAÇÃO ATRAVÉS DE ESTATÍSTICAS DERIVADAS



FONTE: A autora (2025).

Foi realizada, ainda, uma etapa comparativa entre as nuvens de pontos filtradas e não filtradas de um dos experimentos, com vista a demonstrar estatisticamente a importância da aplicação da segmentação semântica, com remoção dos galhos inferiores. Para efeito de comparação, foram utilizadas as métricas pareadas com o inventário (dap, altura total -ht- e volume total -vt-).

3.7 AVALIAÇÃO

3.7.1 Compilação e pareamento de dados

A compilação das métricas derivadas dos dados de sensoriamento remoto, provenientes de diferentes ferramentas e algoritmos, e sua subsequente associação aos dados de inventário florestal foram realizadas com base em identificadores únicos por árvore e, através dos croquis dos experimentos disponibilizados pela empresa, por pareamento espacial. Esta abordagem dupla, espacial e por identificador único, permitiu validar a correspondência entre os conjuntos de dados e minimizar possíveis erros de pareamento.

3.7.2 Detecção de árvores

A avaliação da detecção de árvores foi realizada por meio do cálculo da Acurácia (1) e F1-Score (F1) (2) que combina precisão/exatidão (3) e recall/completude (4) em um único valor, proporcionando uma medida balanceada do desempenho do algoritmo. O F1-Score considera tanto os acertos (verdadeiros positivos - VP e verdadeiros negativos - VN) quanto os erros (falsos positivos - FP e falsos negativos - FN) do sistema de detecção. A Figura 19 ilustra esquematicamente esta relação entre as diferentes classificações.

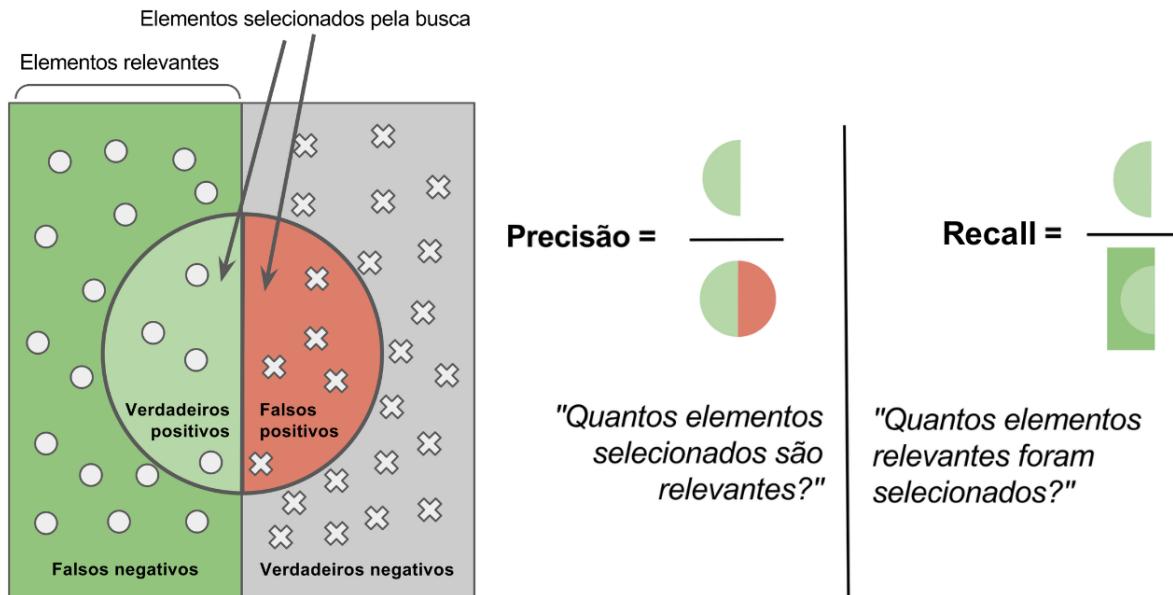
$$\text{Acurácia} = \frac{VP+VN}{VP+VN+FP+FN} \quad (1)$$

$$F1 = \frac{2.Precisão.Recall}{Precisão+Recall} \quad (2)$$

$$Precisão = \frac{VP}{VP+FP} \quad (3)$$

$$Recall = \frac{VP}{VP+FN} \quad (4)$$

FIGURA 19 - ILUSTRAÇÃO ESQUEMÁTICA DA CLASSIFICAÇÃO DE VP, VN, FP E FN E DAS MÉTRICAS DE PRECISÃO E RECALL



FONTE: Adaptado de Braga, 2017.

Para a quantificação dos VP, VN, FP e FN, foram estabelecidos critérios específicos baseados na comparação entre os dados do inventário florestal tradicional e as detecções realizadas na nuvem de pontos. O Quadro 5 detalha os critérios adotados para classificação dos resultados.

QUADRO 5 - CRITÉRIOS UTILIZADOS PARA CLASSIFICAR AS ÁRVORES DETECTADAS NOS DADOS LIDAR

Critério	Classificação
Árvore classificada como normal, torta, dominada etc. no inventário e detectada na nuvem de pontos	VP
Árvore classificada como normal no inventário e não detectada na nuvem de pontos	FN
Árvore classificada como bifurcada no inventário e detectada mais de uma vez na nuvem de pontos	VP
Árvore classificada como falha no inventário e não detectada na nuvem de pontos	VN
Árvore classificada como falha no inventário e detectada na nuvem de pontos	FP

Verdadeiros Positivos (VP); Verdadeiros Negativos (VN); Falsos Positivos (FP); e Falsos Negativos (FN).

Esta abordagem de classificação permite uma avaliação abrangente que considera não apenas a detecção correta de árvores, mas também casos como árvores bifurcadas e falhas no plantio. O critério para árvores bifurcadas, em particular, foi desenvolvido para lidar com situações onde uma única árvore pode ser

erroneamente segmentada em múltiplos indivíduos devido à sua arquitetura complexa.

3.7.3 Qualidade da segmentação em instância e semântica

Tanto a segmentação em instância (árvores individuais) quanto a segmentação semântica foram avaliadas por meio de inspeção visual sistemática das nuvens de pontos segmentadas. Essa análise visual possibilitou a identificação de padrões recorrentes de erro, como subsegmentação, quando duas ou mais árvores são erroneamente agrupadas como um único indivíduo, e supersegmentação, quando uma única árvore é dividida em múltiplos indivíduos. No caso da segmentação semântica, erros típicos incluíram atribuição incorreta de classes a galhos, tronco ou copa.

3.7.4 Métricas extraídas

A avaliação das métricas derivadas dos dados de sensoriamento remoto está descrita nos subtópicos a seguir. Para garantir a qualidade dos dados utilizados, as bases compiladas foram submetidas a um processo de limpeza minuciosa, que incluiu a exclusão de valores nulos e a filtragem sistemática de *outliers*. A detecção e remoção dos outliers foi conduzida por meio da função *rosnerTest()*, disponível no pacote “envstats” do R, aplicada iterativamente até que nenhum valor discrepante adicional fosse identificado.

3.7.4.1 Métricas pareadas (inventário x SR)

Para as métricas volume total (MLS e MLS+UAV-LIDAR), dap (MLS e MLS+UAV-LIDAR) e altura total (MLS, UAV-LIDAR e MLS+UAV-LIDAR), como há disponibilidade dos valores de inventário, foram calculados o Coeficiente de Correlação (*r*), Erro Quadrático Médio (*Root Mean Squared Error* - RMSE, 5), Erro Quadrático Médio Relativo (*Relative Root Mean Squared Error* - RMSE%, 6) e o Bias (Viés - 7).

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}} \quad (5)$$

$$RMSE\% = \frac{RMSE}{\bar{y}} \cdot 100 \quad (6)$$

$$Bias = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n} \quad (7)$$

Em que: y_i é o valor da variável de interesse obtida via inventário para a árvore i; \hat{y}_i é o valor da variável de interesse obtida pelo LiDAR para a árvore i; n é o número de observações; \bar{y} é a média da variável de interesse obtida no inventário florestal.

Além disso, foram aplicadas duas medidas de concordância: Coeficiente de Concordância (A, Robinson, 1957) e Coeficiente de Correlação de Concordância (CC1, Lin, 1989). O Coeficiente de Concordância (A) varia entre 0 (sem concordância) e 1 (concordância perfeita), dado por (8). Já o CC1 varia de 1 (concordância perfeita) a -1 (discordância perfeita), sendo 0 ausência de concordância, podendo ser expresso em duas formas equivalentes (11 e 12) (HUANG et al., 2019).

$$A = 1 - \frac{\sum(y_i - k_i)^2 + \sum(x_i - k_i)^2}{\sum(y_i - k)^2 + \sum(x_i - k)^2} \quad (8)$$

$$k_i = \frac{y_i + x_i}{2} \quad (9)$$

$$k = \frac{\sum y_i + \sum x_i}{2n} \quad (10)$$

Em que: A é o Coeficiente de Concordância; k_i é a média de y_i e x_i para a árvore i; y_i é o valor da variável de interesse obtida via inventário para a árvore i; x_i é o valor da variável de interesse obtida pelo LiDAR para a árvore i; n é o número de observações.

$$CC_1 = \frac{2S_{cov}}{S_y^2 + S_x^2 + (\bar{y} - \bar{x})^2} \quad (11)$$

$$CC_1 = \frac{2rS_yS_x}{S_y^2 + S_x^2 + (\bar{y} - \bar{x})^2} \quad (12)$$

$$r = \frac{\sum(y_i - \bar{y})(x_i - \bar{x})}{\sqrt{\sum(y_i - \bar{y})^2 \sum(x_i - \bar{x})^2}} \quad (13)$$

$$S_{cov} = \frac{1}{n} \sum (y_i - \bar{y})(x_i - \bar{x}) \quad (14)$$

Em que: CC_1 é o Coeficiente de Correlação de Concordância; r é o coeficiente de correlação; S_y^2 é a variância de y; S_x^2 é a variância de x; S_{cov} é a covariância; y_i é o valor da variável de interesse obtida via inventário para a árvore i; x_i é o valor da variável de interesse obtida pelo LiDAR para a árvore i; \bar{y} é a média de y; \bar{x} é a média de x; n é o número de observações.

3.7.4.2 Métricas não pareadas

A avaliação das métricas não pareadas obtidas por cada método foi realizada com base no coeficiente de correlação de Pearson (r), considerando exclusivamente as correlações entre as métricas não pareadas derivadas dos dados SR (LiDAR +

espectrais) e as do inventário (dap, ht e vt). Para fins de análise, foram selecionadas apenas as métricas que apresentaram coeficientes de correlação superiores a 0,4.

3.8 AGRUPAMENTO DE CLONES

3.8.1 Pré-processamento

O pré-processamento consistiu na consolidação de todas as métricas de ambos experimentos em um único conjunto de dados, seguido da remoção das variáveis com variância tendendo a zero, uma vez que essas apresentam baixa variabilidade e limitado poder explicativo. Em seguida, foram tratados os valores ausentes e os outliers, os quais foram substituídos pela média específica de cada clone, de modo a preservar a representatividade dos dados. Por fim, aplicou-se a padronização das variáveis para evitar o efeito das unidades de medidas nas análises subsequentes.

3.8.2 MANOVA e Análise discriminante

Com objetivo de testar a diferença entre os 53 clones, realizou-se uma análise multivariada de variância (MANOVA) que considerou todas as métricas obtidas a partir dos dados LiDAR e espectrais, sendo cada árvore tratada como uma repetição experimental. As estatísticas utilizadas para avaliar a significância das diferenças entre os clones foram Traço de Pillai, Lambda de Wilks, Traço de Hotelling e Maior raiz de Roy, as quais foram aplicadas após constatar aproximação de normalidade multivariada e matriz de variância-covariâncias homogêneas (Hair et al., 2005).

Uma vez que a MANOVA detectou diferença entre os clones, foi feita a análise discriminante para o conjunto de métricas, com o intuito de agrupar os clones e identificar as variáveis mais importantes na separação dos grupos formados. O número de funções discriminantes determinadas considerou um mínimo de 60% da variância total explicada. Essa proporção de variância foi definida considerando que o conjunto de dados é composto por 385 variáveis, assim, o objetivo foi selecionar o mínimo de variáveis discriminantes que explique a maior parte da variância original total. As variáveis mais importantes foram indicadas por meio da maior correlação canônica entre a variável original e a função discriminante (Hair et al., 2005).

4 RESULTADOS

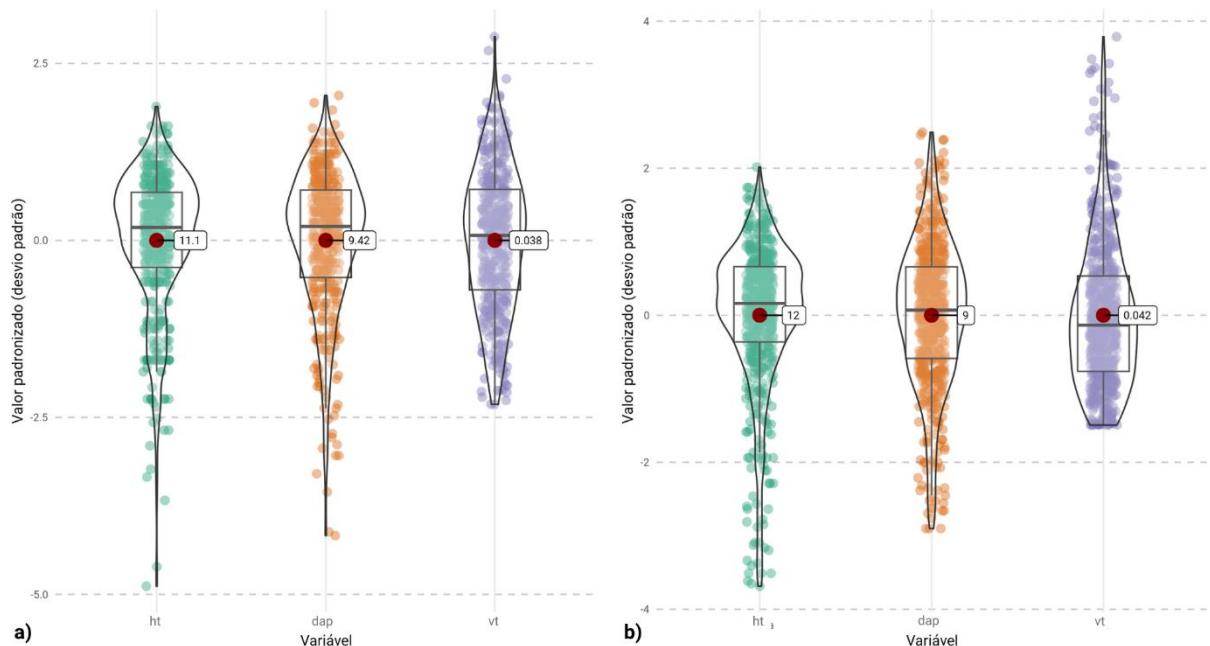
4.1 PRÉ-PROCESSAMENTO

4.1.1 Dados de inventário

4.1.1.1 Análise exploratória

A Figura 20 exibe os gráficos violino das variáveis quantitativas, enquanto a Tabela 4 e Figura 21 sintetizam as estatísticas descritivas correspondentes para os experimentos Caçapava e Itapeva. As Figuras 22 e 23 complementam a análise com a caracterização das variáveis qualitativas.

FIGURA 20 - GRÁFICOS VIOLETO DAS VARIÁVEIS QUANTITATIVAS DOS INVENTÁRIOS FLORESTAIS DE CAÇAPAVA (A) E ITAPEVA (B)

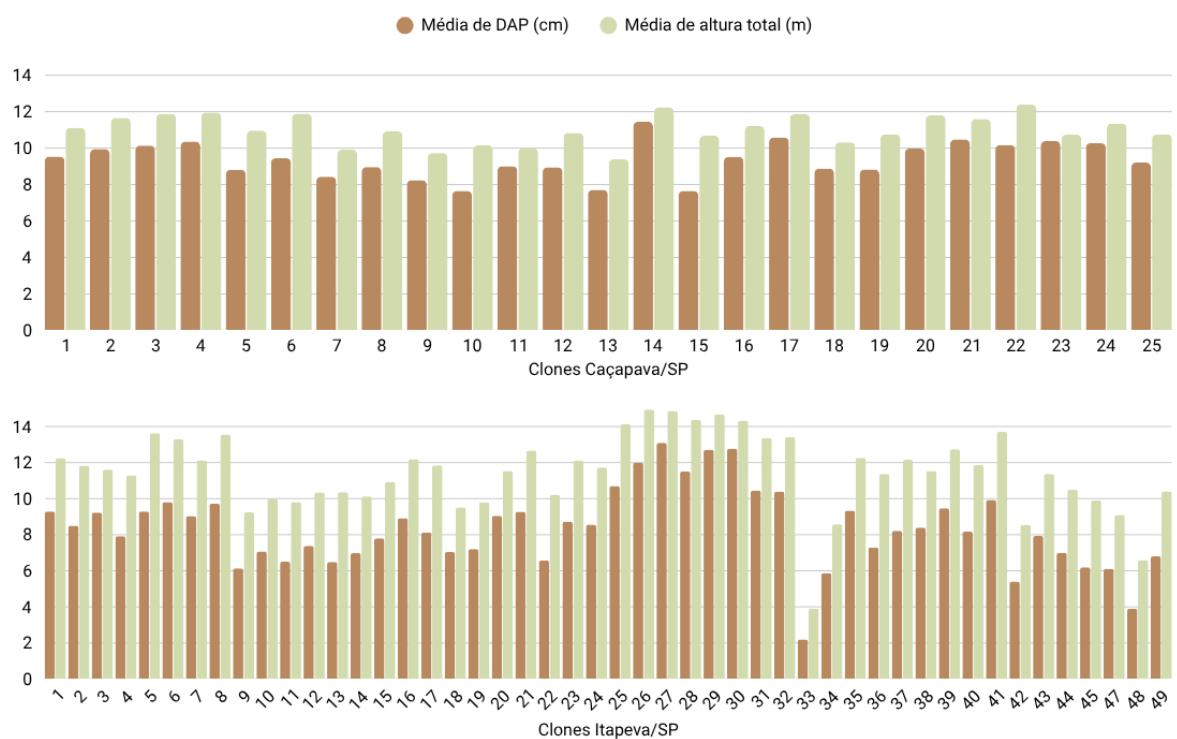


FONTE: A autora (2025).

TABELA 4 - ESTATÍSTICAS DESCRIPTIVAS DAS VARIÁVEIS QUANTITATIVAS DOS DADOS DE INVENTÁRIO PARA CAÇAPAVA E ITAPEVA

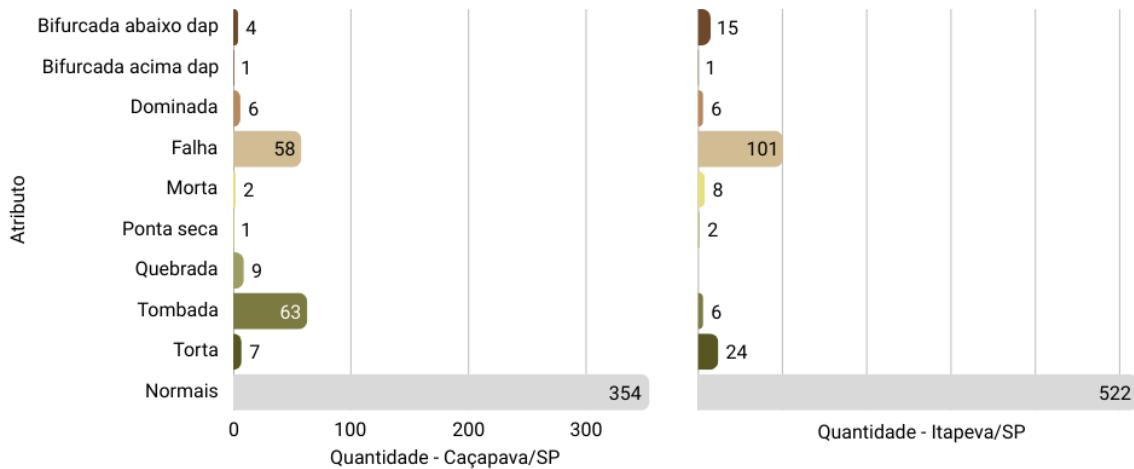
Estatística	Caçapava			Itapeva		
	dap (cm)	ht (m)	vt (m³)	dap (cm)	ht (m)	vt (m³)
Média	9,4	11,07	0,0383	9,0	12,04	0,0423
Erro padrão	0,1	0,09	0,0008	0,1	0,12	0,0012
Mediana	9,8	11,40	0,0395	9,2	12,50	0,0385
Moda	10,2	12,00	0,0447	10,2	14,00	0,0529
Desvio padrão	1,9	1,82	0,0165	2,9	2,86	0,0283
Variância da amostra	3,8	3,30	0,0003	8,4	8,17	0,0008
Coeficiente de variação %	20,7	16,4	43,0	32,2	23,7	66,9
Curtose	1,7	2,53	-0,4693	0,3	2,28	1,018
Assimetria	-1,1	-1,33	-0,1206	-0,4	-1,34	0,9217
Intervalo	12,1	12,30	0,0855	15,6	16,30	0,1496
Mínimo	1,3	2,20	0,0002	0,6	1,50	0,0000
Máximo	13,4	14,50	0,0857	16,2	17,80	0,1496

FIGURA 21 - MÉDIAS DE DIÂMETRO E ALTURA TOTAL POR CLONE NOS EXPERIMENTOS DE CAÇAPAVA (ACIMA) E ITAPEVA (ABAIXO). AS LINHAS PONTILHADAS REPRESENTAM AS MÉDIAS GERAIS DE CADA VARIÁVEL



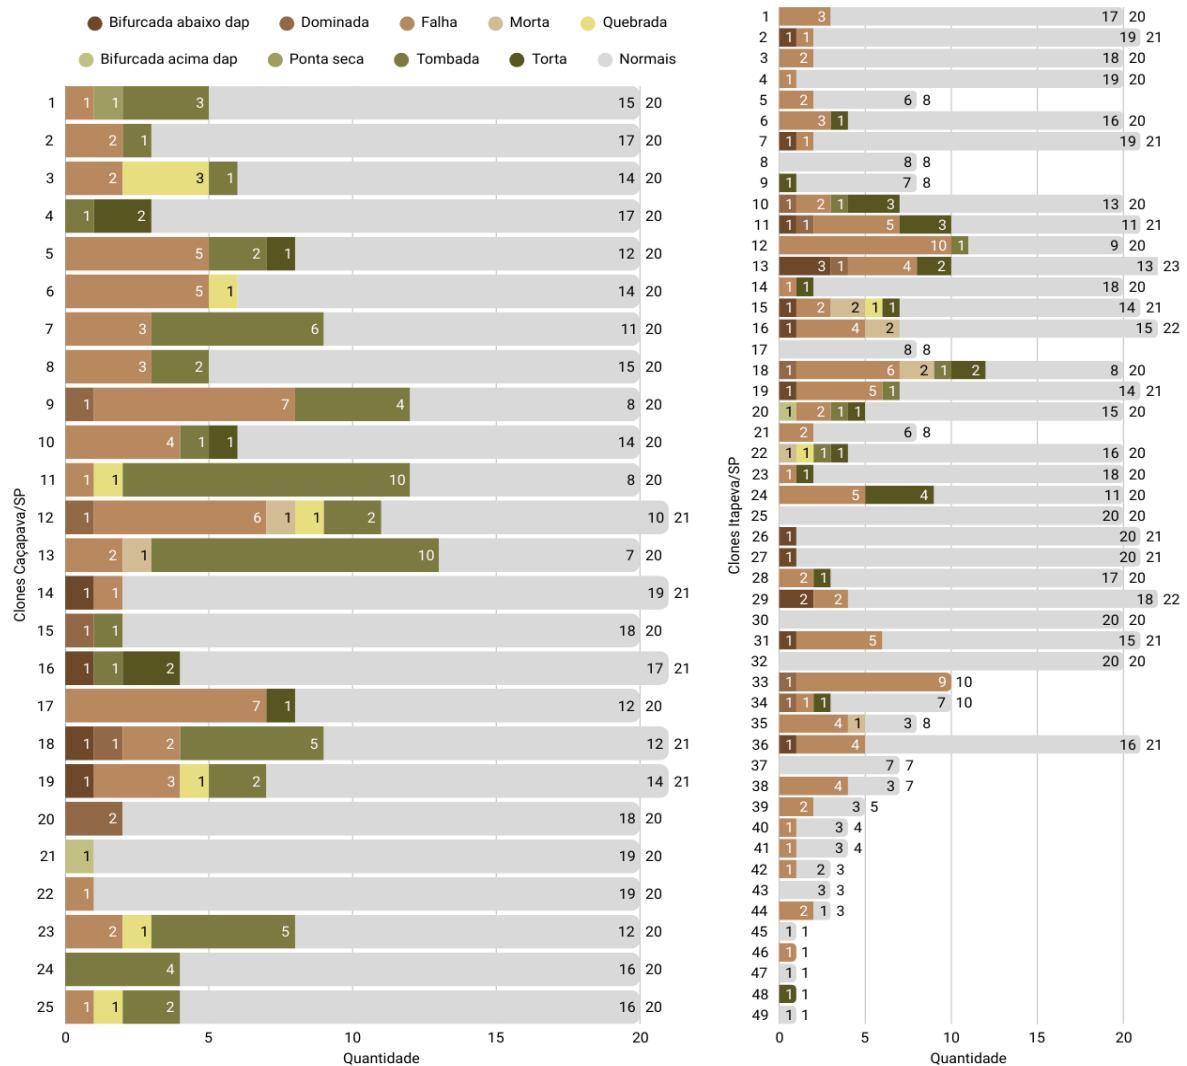
FONTE: A autora (2025).

FIGURA 22 - CONDIÇÃO GERAL DOS CLONES DOS EXPERIMENTOS EM CAÇAPAVA (ESQUERDA) E ITAPEVA (DIRETA)



FONTE: A autora (2025).

FIGURA 23 - CONDIÇÕES DOS CLONES DOS EXPERIMENTOS EM CAÇAPAVA (ESQUERDA) E ITAPEVA (DIRETA)



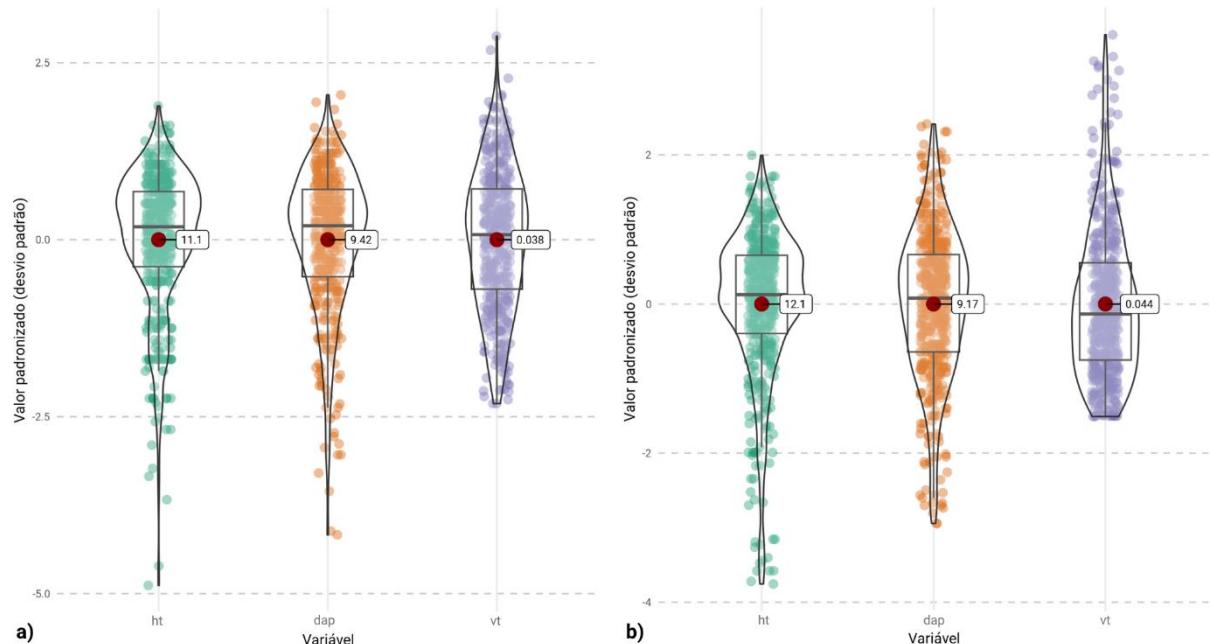
FONTE: A autora (2025).

4.1.1.2 Dados de inventário utilizados

Na etapa de análise exploratória dos dados de inventário, foi identificada a presença de clones com número reduzido de repetições no experimento de Itapeva. Para garantir a robustez das análises subsequentes, esses clones foram excluídos do conjunto de dados, mantendo-se apenas aqueles com mais de 20 repetições, total de 560 árvores e 28 clones. No experimento de Caçapava todos os 25 clones tiveram 20 ou mais repetições, sendo mantido o total de 500 árvores.

A Figura 24 apresenta os gráficos violino das variáveis quantitativas avaliadas, permitindo a visualização da distribuição e variabilidade dos dados filtrados no experimento Itapeva. A Tabela 5 e Figura 25 sintetizam as estatísticas descritivas correspondentes. As Figuras 26 e 27 complementam a caracterização com a análise das variáveis qualitativas.

FIGURA 24 - GRÁFICOS VIOLINO DAS VARIÁVEIS QUANTITATIVAS DOS INVENTÁRIOS FLORESTAIS DE CAÇAPAVA (A) E ITAPEVA (B)

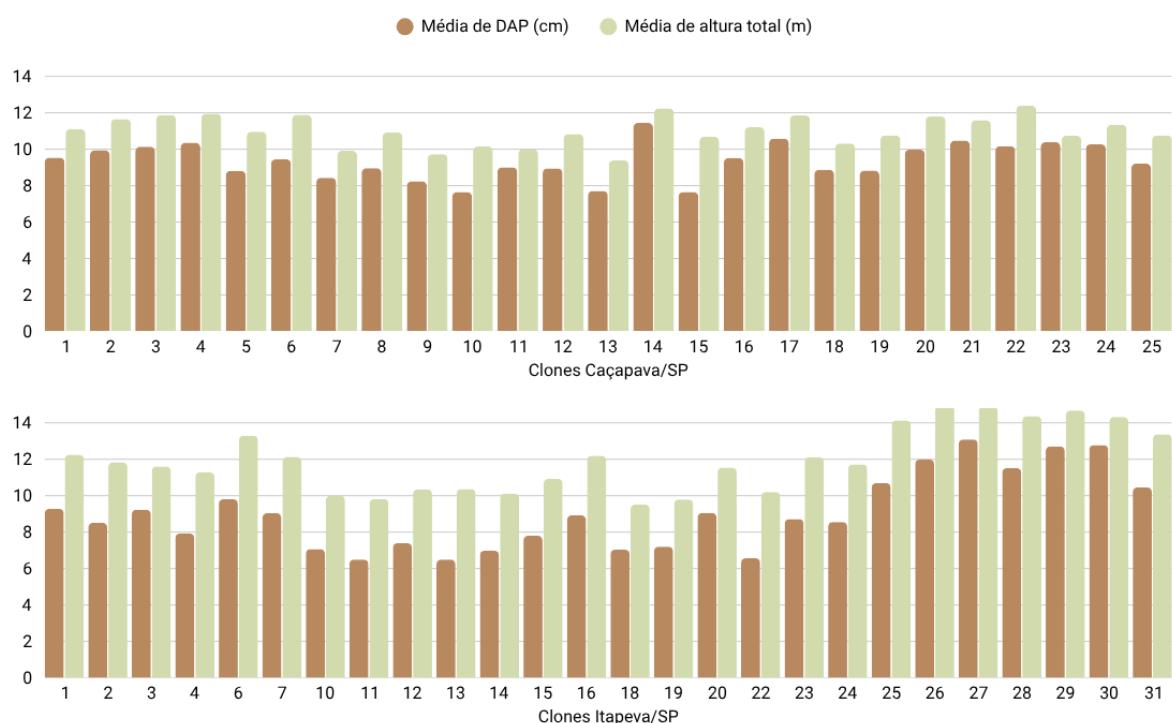


FONTE: A autora (2025).

TABELA 5 - ESTATÍSTICAS DESCRIPTIVAS DAS VARIÁVEIS QUANTITATIVAS DOS DADOS DE INVENTÁRIO PARA CAÇAPAVA E ITAPEVA.

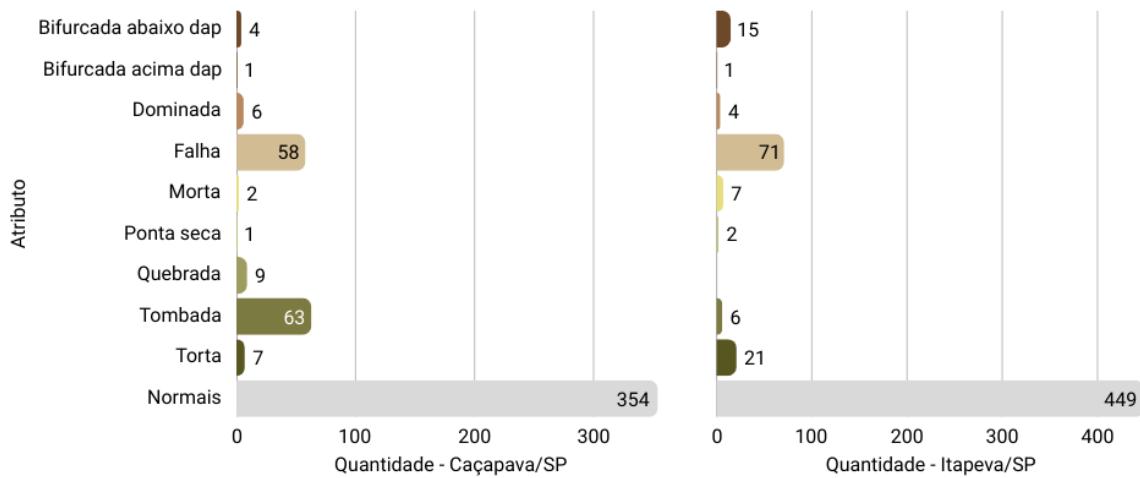
Estatística	Caçapava			Itapeva		
	dap (cm)	ht (m)	vt (m ³)	dap (cm)	ht (m)	vt (m ³)
Média	9,4	11,07	0,0383	9,2	12,15	0,0441
Erro padrão	0,1	0,09	0,0008	0,1	0,13	0,0013
Mediana	9,8	11,40	0,0395	9,4	12,50	0,0402
Moda	10,2	12,00	0,0447	10,2	12,40	0,0529
Desvio padrão	1,9	1,82	0,0165	2,9	2,83	0,0292
Variância da amostra	3,8	3,30	0,0003	8,5	8,03	0,0009
Coeficiente de variação %	20,7	16,4	43,0	31,8	23,3	66,3
Curtose	1,7	2,53	-0,4693	0,3	2,36	0,765
Assimetria	-1,1	-1,33	-0,1206	-0,4	-1,32	0,8644
Intervalo	12,1	12,30	0,0855	15,6	16,30	0,1496
Mínimo	1,3	2,20	0,0002	0,6	1,50	0,0000
Máximo	13,4	14,50	0,0857	16,2	17,80	0,1496

FIGURA 25 - MÉDIAS DE DIÂMETRO E ALTURA TOTAL POR CLONE NOS EXPERIMENTOS DE CAÇAPAVA (ACIMA) E ITAPEVA (ABAIXO). AS LINHAS PONTILHADAS REPRESENTAM AS MÉDIAS GERAIS DE CADA VARIÁVEL



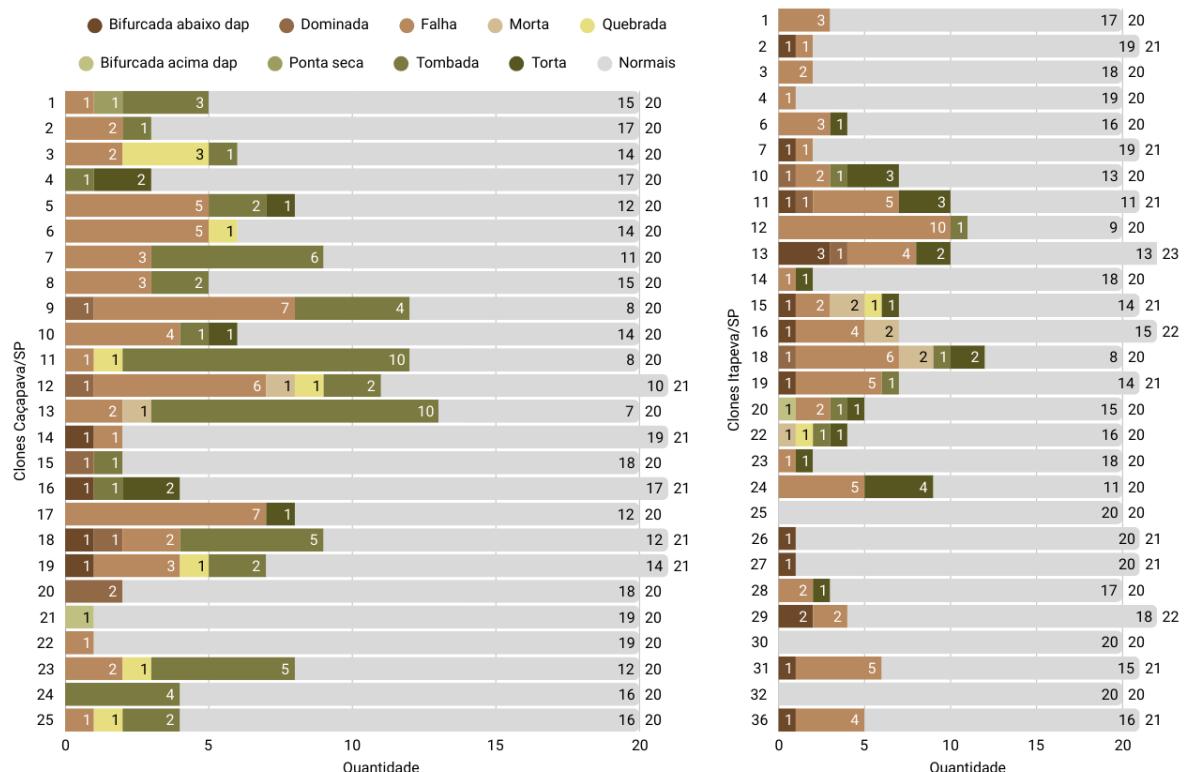
FONTE: A autora (2025).

FIGURA 26 - CONDIÇÃO GERAL DOS CLONES DOS EXPERIMENTOS EM CAÇAPAVA (ESQUERDA) E ITAPEVA (DIRETA)



FONTE: A autora (2025).

FIGURA 27 - CONDIÇÕES DOS CLONES DOS EXPERIMENTOS EM CAÇAPAVA (ESQUERDA) E ITAPEVA (DIREITA)

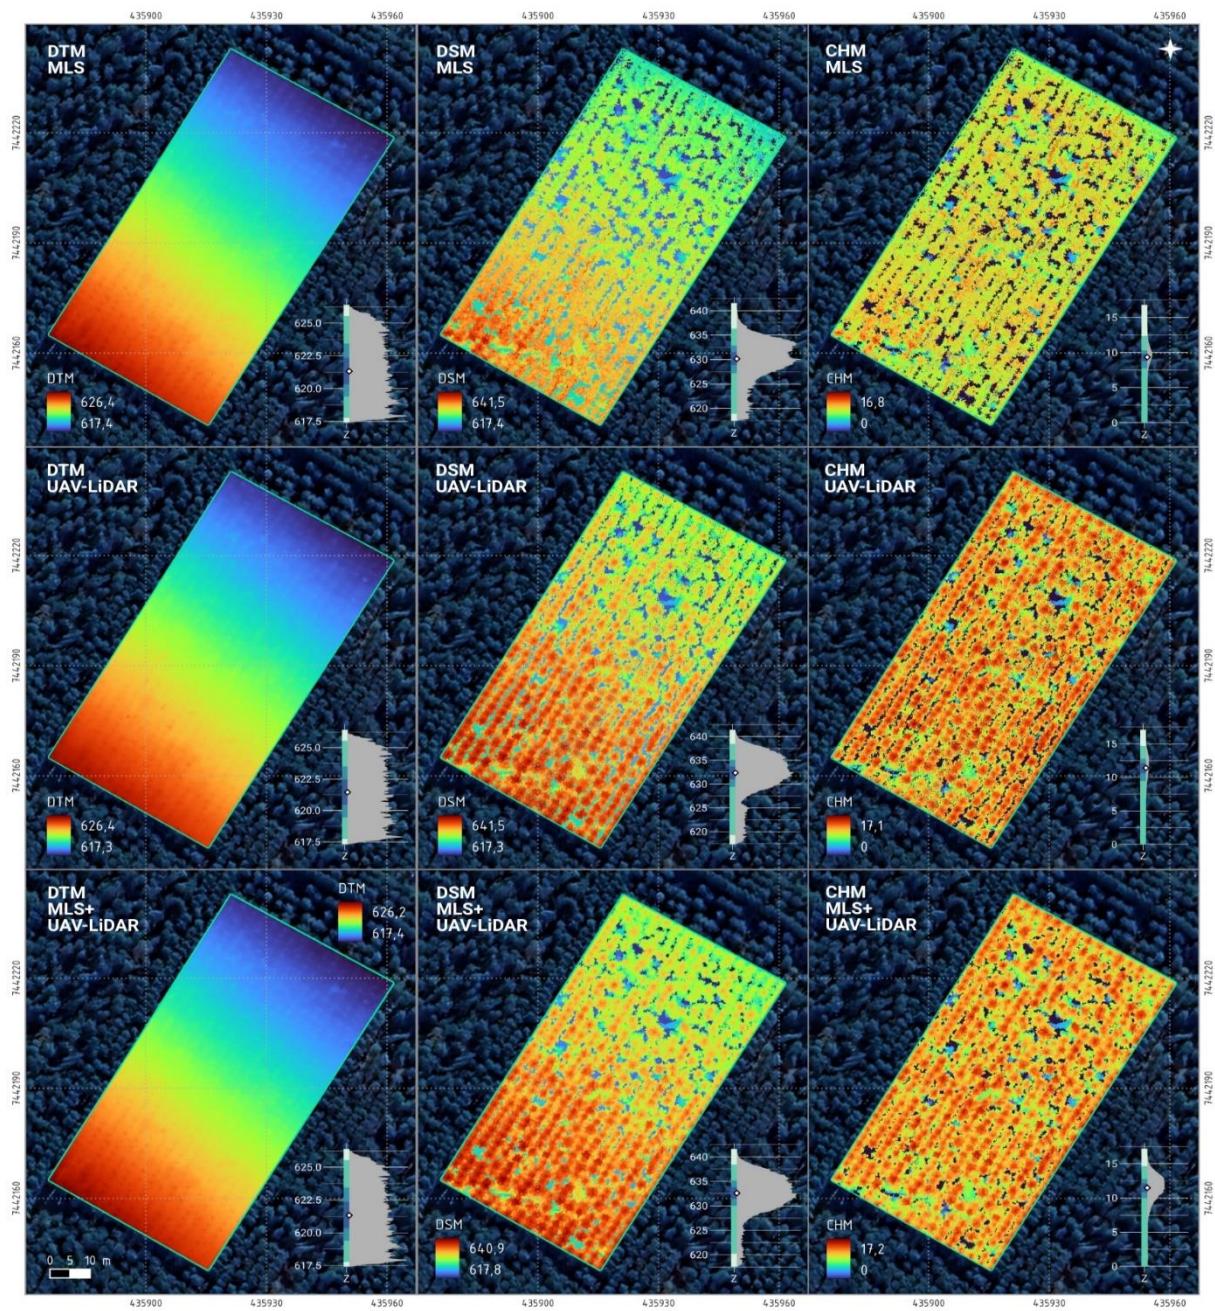


FONTE: A autora (2025).

4.1.2 Dados LiDAR

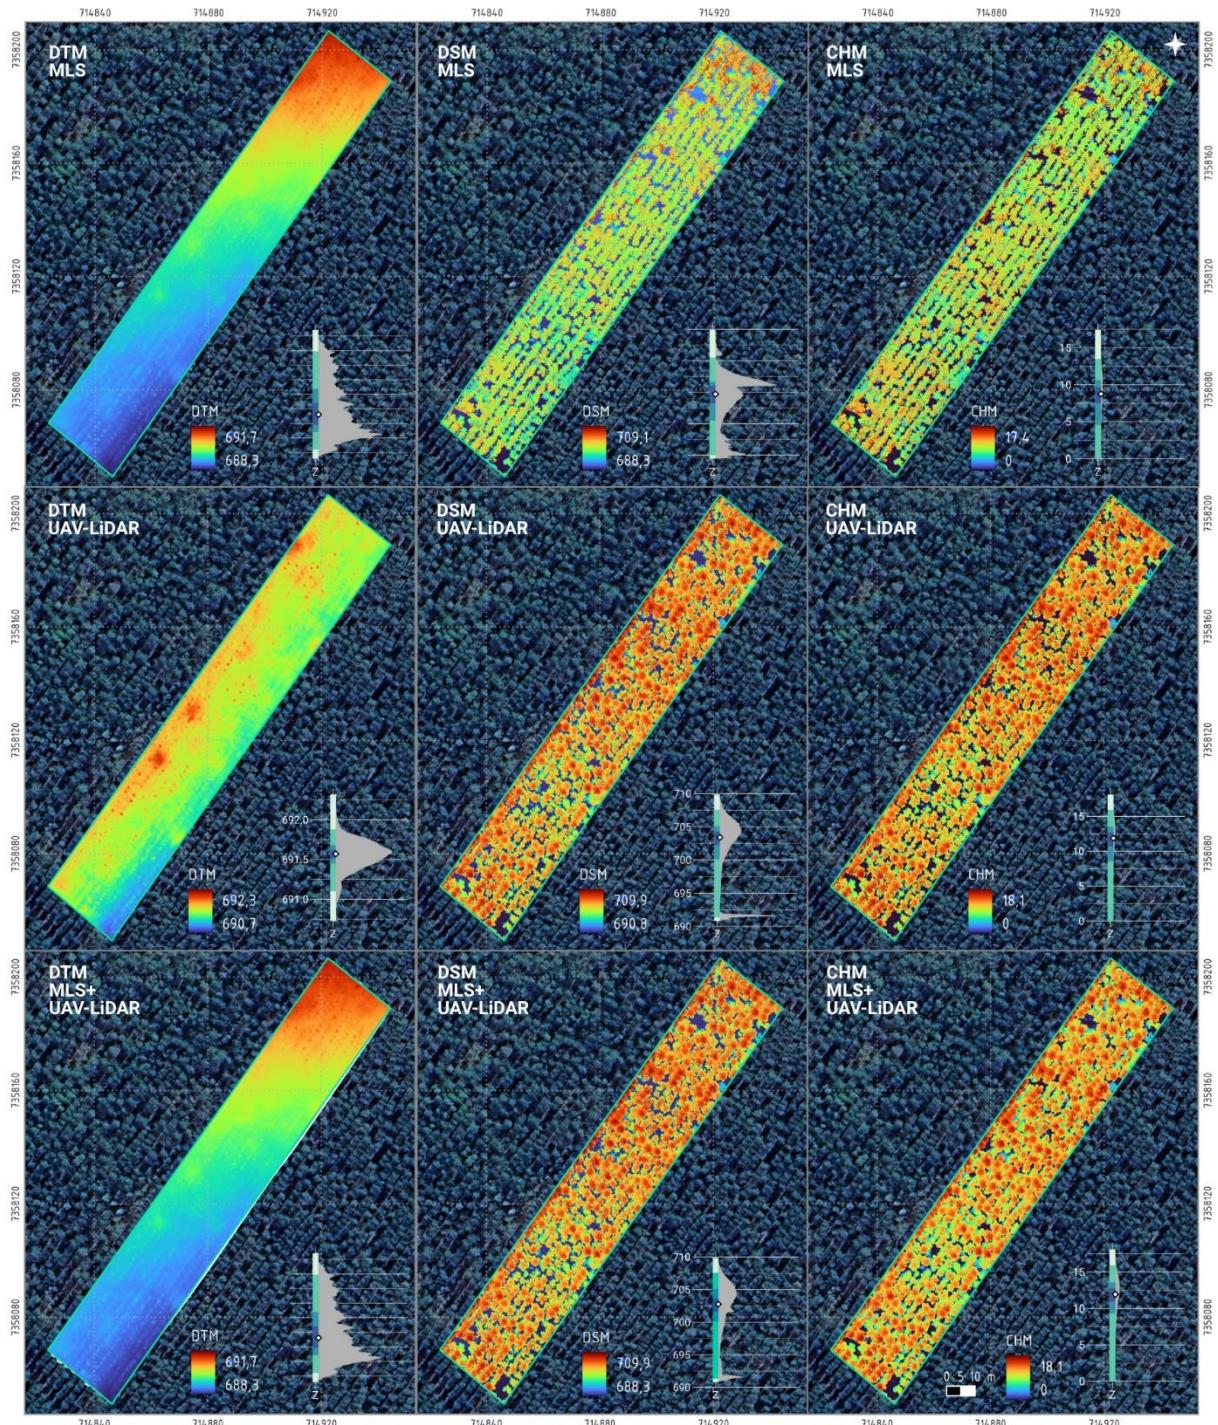
Para cada experimento foram gerados os produtos cartográficos DTM, DSM e CHM, acompanhados de seus respectivos histogramas de distribuição de alturas (Figura 28). Esses produtos permitem não apenas a visualização da estrutura horizontal da vegetação, mas também, no caso do DTM, uma avaliação da qualidade da classificação dos pontos de solo, fator determinante para uma boa normalização da nuvem de pontos.

FIGURA 28 - DTM, DSM E CHM GERADOS PARA OS DADOS MLS, UAV-LIDAR E COMBINADOS (MLS+UAV-LIDAR) PARA O EXPERIMENTO DE CAÇAPAVA



FONTE: A autora (2025).

FIGURA 29 - DTM, DSM E CHM GERADOS PARA OS DADOS MLS, UAV-LIDAR E COMBINADOS (MLS+UAV-LIDAR) PARA O EXPERIMENTO DE ITAPEVA

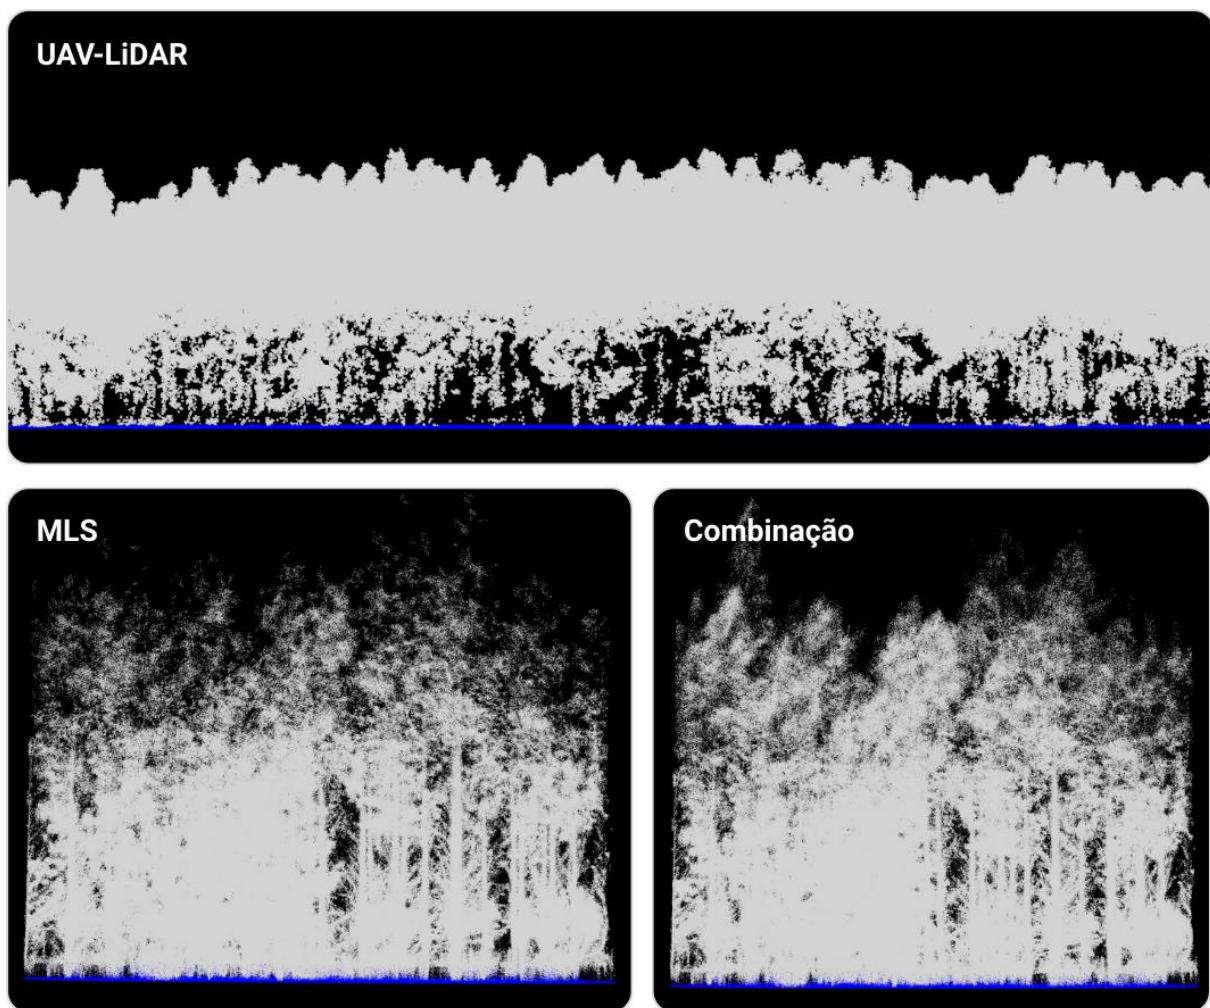


FONTE: A autora (2025).

Observa-se, em ambos os experimentos, a presença de ruídos sistemáticos nos DTM, os quais seguem o padrão do alinhamento das linhas de plantio (Figuras 28 e 29). Tais artefatos decorrem de classificações equivocadas, onde pontos pertencentes à base do tronco ou à ramificação basal foram rotulados como solo.

Contudo, esse efeito não comprometeu a normalização das nuvens, conforme demonstrado na Figura 30, que exemplifica a normalização para o experimento de Itapeva. No caso específico do DTM gerado a partir do UAV-LiDAR de Itapeva, foram identificadas perturbações mais pronunciadas. No entanto, inspeções subsequentes da nuvem de pontos normalizada não revelaram distorções evidentes, indicando que a etapa de normalização manteve sua consistência (Figura 30).

FIGURA 30 - NUVENS DE PONTOS NORMALIZADAS PARA OS DIFERENTES CONJUNTOS DE DADOS - EXPERIMENTO DE ITAPEVA

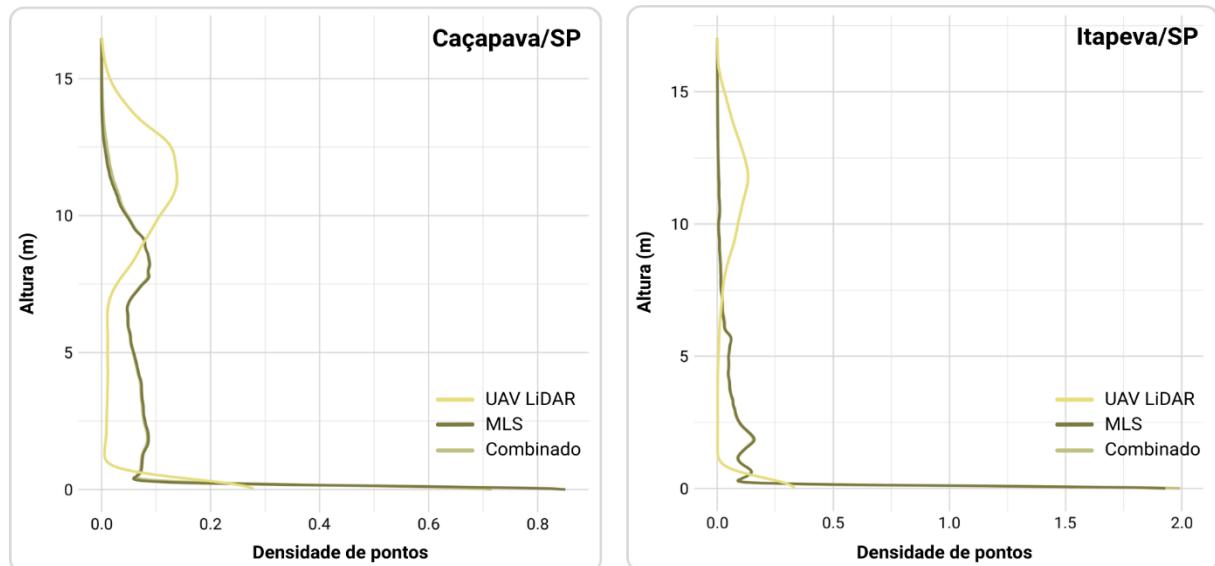


FONTE: A autora (2025).

A Figura 31 apresenta, de forma comparativa, os perfis de densidade de pontos ao longo da altura para os dados normalizados de um *plot* de 10 m de raio. Nota-se que o sensor UAV-LiDAR concentrou maior densidade de retornos no dossel, enquanto o MLS apresentou superioridade nas porções inferiores da vegetação. Os

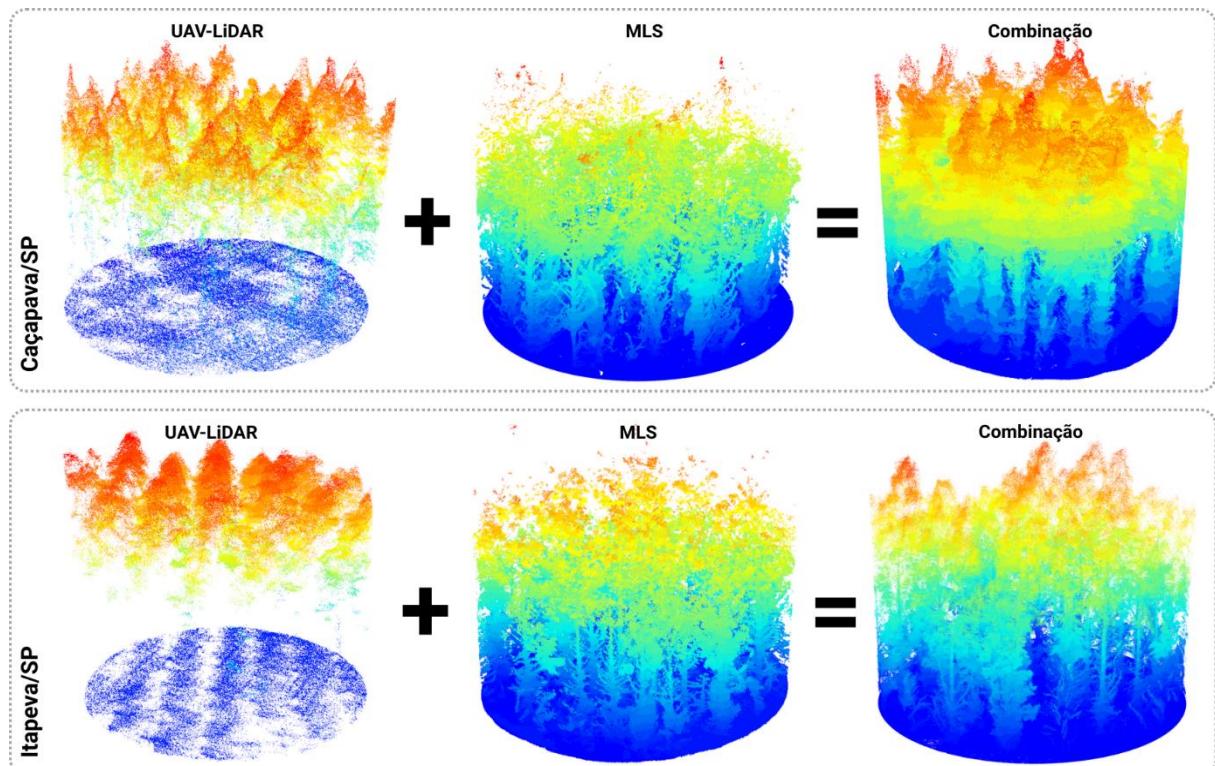
dados combinados (MLS + UAV-LiDAR) (Figura 32) seguiram quase que integralmente a curva do MLS, dada a maior densidade de pontos deste.

FIGURA 31 - PERFIS VERTICAIS DE DENSIDADE DE PONTOS DOS DADOS UAV-LIDAR, MLS E COMBINADOS (MLS+UAV-LIDAR)



FONTE: A autora (2025).

FIGURA 32 - VISUALIZAÇÃO DA COMBINAÇÃO DOS DADOS UAV-LIDAR + MLS.
REPRESENTAÇÃO A PARTIR DE PLOTS DE 10 M DE RAIO



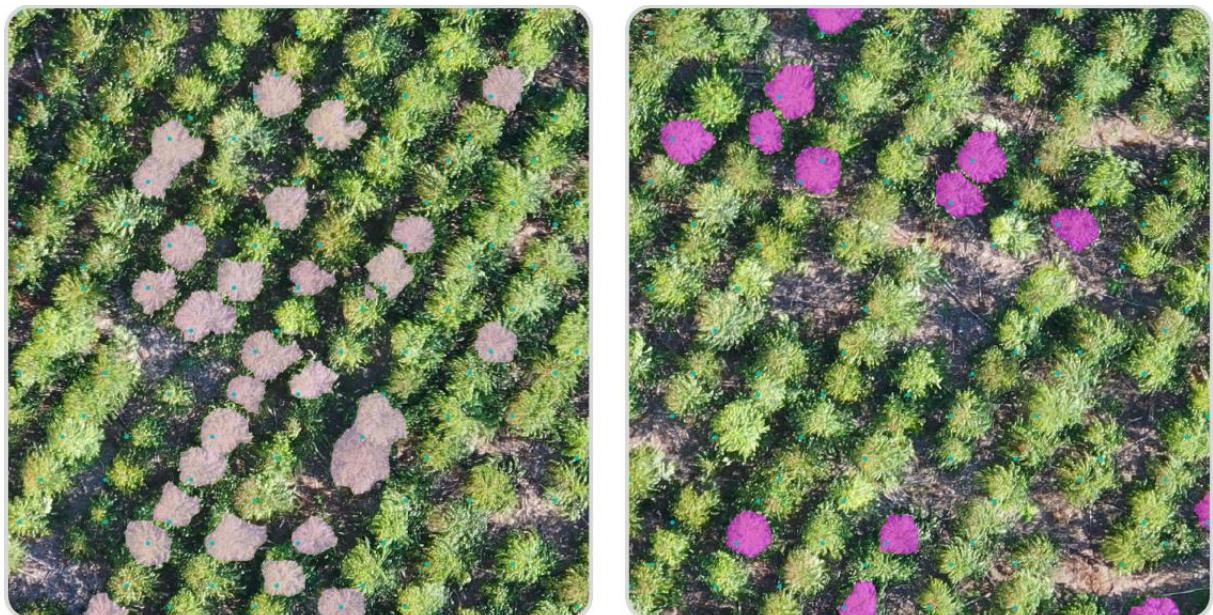
FONTE: A autora (2025).

4.2 DETECÇÃO E SEGMENTAÇÃO DE ÁRVORES INDIVIDUAIS

4.2.1 Dados espectrais

A Figura 33 apresenta os resultados obtidos com o modelo pré-treinado “FastSAM-s”, pertencente à arquitetura FastSAM, aplicado à segmentação de copas. Apesar das limitações impostas pela homogeneidade visual do dossel, o modelo foi capaz de segmentar aproximadamente 25% das copas, evidenciando potencial para ser aprimorado por meio de retreinamento supervisionado com dados rotulados. Já os demais algoritmos testados, Detectree2, SAM, SAM2 e YOLOv11, não foram capazes de segmentar nenhuma copa (zero detecções).

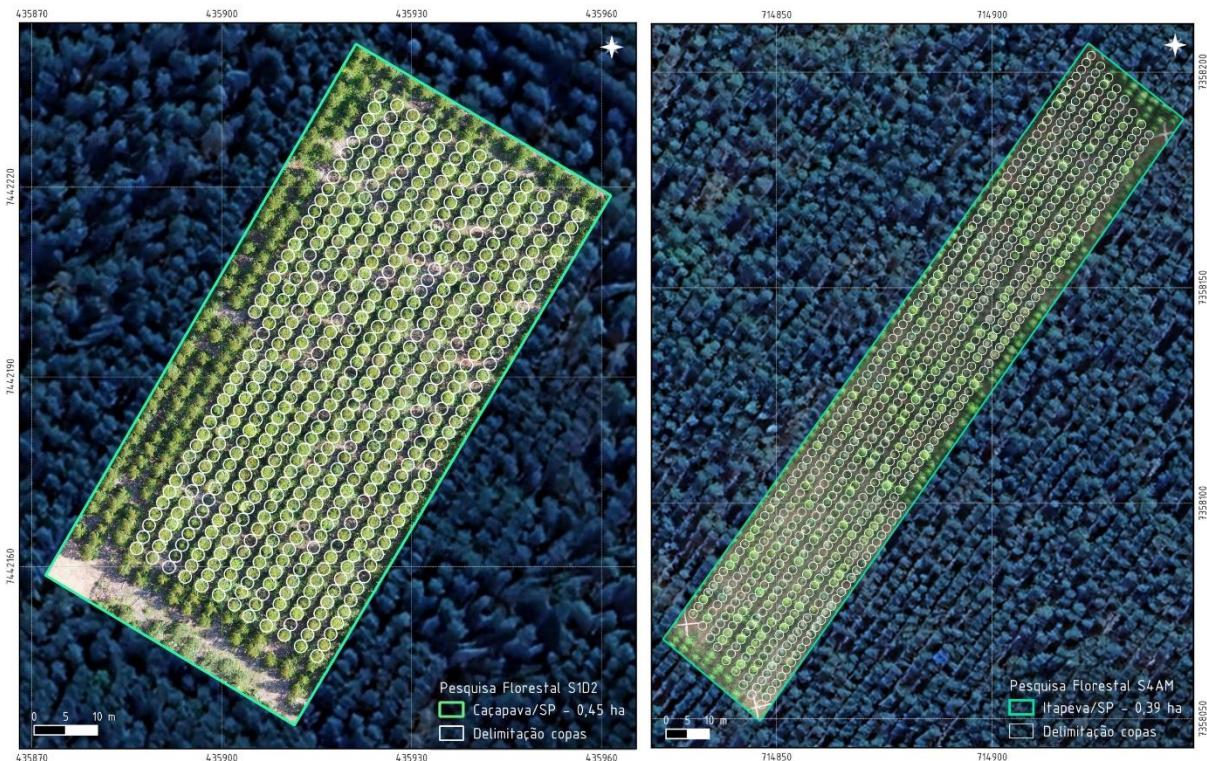
FIGURA 33 - RESULTADOS OBTIDOS COM A APLICAÇÃO DO MODELO FASTSAM-S.



FONTE: A autora (2025).

A Figura 34 apresenta o resultado da abordagem semi-automatizada, que foi adotada como alternativa para contornar as limitações observadas nos modelos automáticos.

FIGURA 34 - RESULTADOS DA DELIMITAÇÃO DE COPAS PELA ABORDAGEM SEMI-AUTOMATIZADA EM CAÇAPAVA (ESQUERDA) E ITAPEVA (DIREITA)



FONTE: A autora (2025).

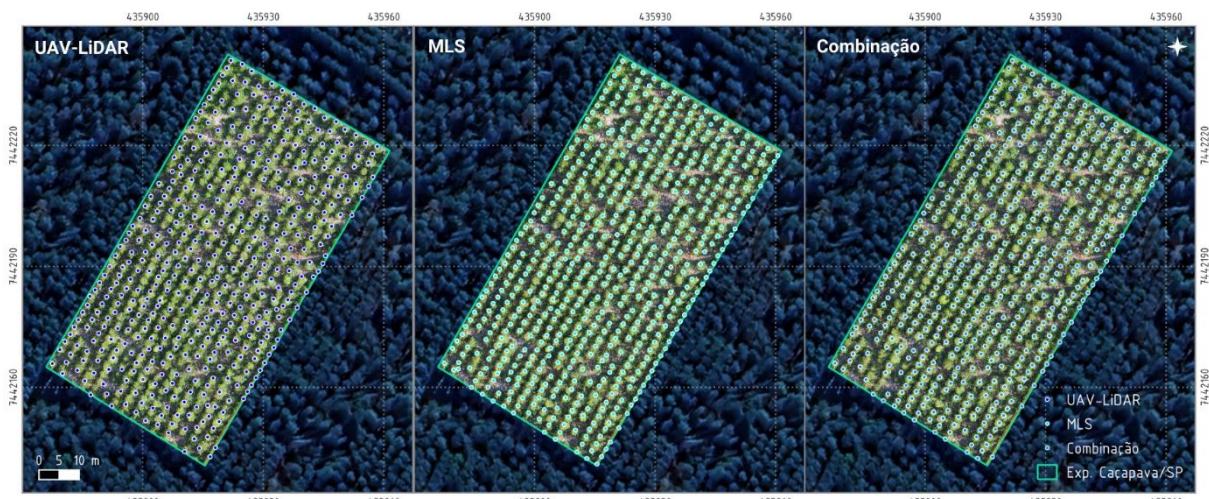
4.2.2 Dados LiDAR

Os resultados obtidos para a detecção de árvores individuais estão sintetizados na Tabela 6, bem como ilustrados nas Figuras 35 e 36. De modo geral, os dados MLS apresentaram desempenho superior, particularmente nos parâmetros de acurácia e recall. Esse desempenho mais elevado pode ser atribuído, quando em comparação com os dados UAV-LiDAR, a maior densidade de pontos nas porções inferiores e a menor interferência do dossel, além da diferença de abordagem utilizada para cada conjunto de dados. Já em relação aos dados combinados (MLS+UAV-LiDAR), a redução de desempenho pode ser explicada pela complexidade estrutural adicional da nuvem combinada, que intensifica a sobreposição entre copas e, consequentemente, reduz a definição dos limites entre indivíduos.

TABELA 6 - ESTATÍSTICAS DA DETECÇÃO DE ÁRVORES DOS DADOS LIDAR NOS EXPERIMENTOS DE ITAPEVA E CAÇAPAVA

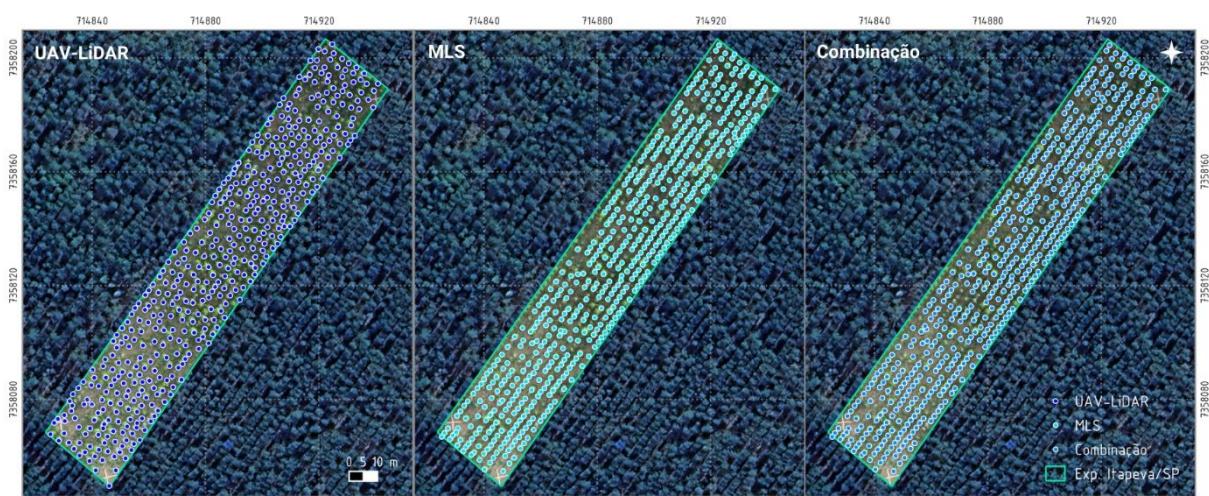
Dados	Caçapava			Itapeva		
	UAV-LiDAR	MLS	Combinação	UAV-LiDAR	MLS	Combinação
Acurácia	70,58%	93,44%	92,28%	68,57%	86,12%	82,73%
Precisão	94,28%	97,23%	96,54%	97,57%	99,28%	95,55%
Recall	70,81%	95,25%	94,57%	65,64%	84,66%	83,44%
F1-Score	80,88%	96,23%	95,54%	78,48%	91,39%	89,08%

FIGURA 35 - RESULTADO DA DETECÇÃO DE ÁRVORES NO EXPERIMENTO DE CAÇAPAVA



FONTE: A autora (2025).

FIGURA 36 - RESULTADO DA DETECÇÃO DE ÁRVORES NO EXPERIMENTO DE ITAPEVA



FONTE: A autora (2025).

A Tabela 7 apresenta a proporção de erro relativo de detecção por classe de qualidade do fuste. Observou-se uma maior incidência de erro de detecção nas

classes “Quebrada”, “Dominada”, “Tombada” e “Bifurcada”, respectivamente. Essas classes representam árvores com estruturas irregulares, o que compromete a definição dos contornos da copa e a continuidade do fuste nas nuvens de pontos, dificultando a identificação e segmentação correta pelos algoritmos. Árvores quebradas e tombadas, por exemplo, apresentam geometrias desviantes do padrão vertical esperado, enquanto árvores bifurcadas e dominadas frequentemente se sobrepõem ou estão parcialmente ocultas pelo dossel de indivíduos vizinhos.

TABELA 7 - PROPORÇÃO DE ERRO PARA A DETECÇÃO DE ÁRVORES EM CADA CLASSE DE QUALIDADE DO FUSTE

Dados	Caçapava			Itapeva		
	UAV-LiDAR	MLS	Combinação	UAV-LiDAR	MLS	Combinação
Normal	20,6%	1,7%	5,4%	30,6%	12,4%	17,3%
Bifurcada	37,5%	50,0%	62,5%	73,3%	50,0%	40,0%
Dominada	83,3%	33,3%	66,7%	100,0%	50,0%	50,0%
Falha	27,6%	0,0%	0,0%	11,3%	1,4%	0,0%
Quebrada	100,0%	100,0%	100,0%	-	-	-
Tombada	68,3%	14,3%	31,7%	83,3%	66,7%	66,7%
Torta	28,6%	0,0%	14,3%	61,9%	47,6%	38,1%

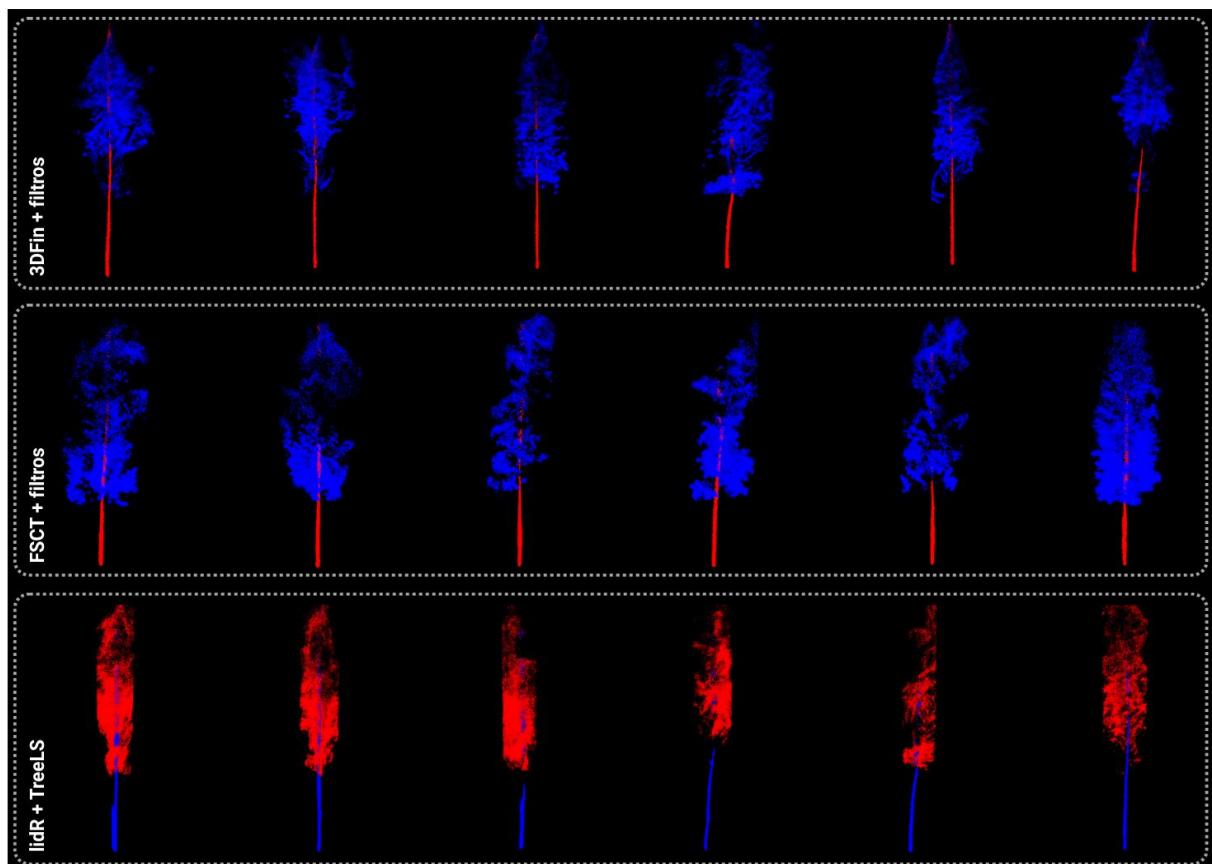
Por fim, na Tabela 8 estão sintetizados os resultados de detecção obtidos para as diferentes abordagens aplicadas aos dados MLS e MLS+UAV-LiDAR. A técnica FSCT apresentou desempenho ligeiramente superior na detecção de árvores quando aplicada aos dados MLS, enquanto o algoritmo 3DFin obteve melhores resultados nos dados MLS+UAV-LiDAR.

TABELA 8 - ESTATÍSTICAS DA DETECÇÃO DE ÁRVORES DAS DIFERENTES ABORDAGENS APLICADAS AOS DADOS LIDAR MLS E MLS+UAV-LIDAR

Dados	FSCT		3DFin		lidR + TreeLS	
	MLS	MLS+UAV-LiDAR	MLS	MLS+UAV-LiDAR	MLS	MLS+UAV-LiDAR
Acurácia	96,23%	89,62%	93,44%	92,28%	89,21%	87,10%
Precisão	99,07%	99,74%	97,23%	96,54%	96,72%	98,96%
Recall	96,61%	88,46%	95,25%	94,57%	90,08%	86,20%
F1-Score	97,82%	93,76%	96,23%	95,54%	93,28%	92,14%

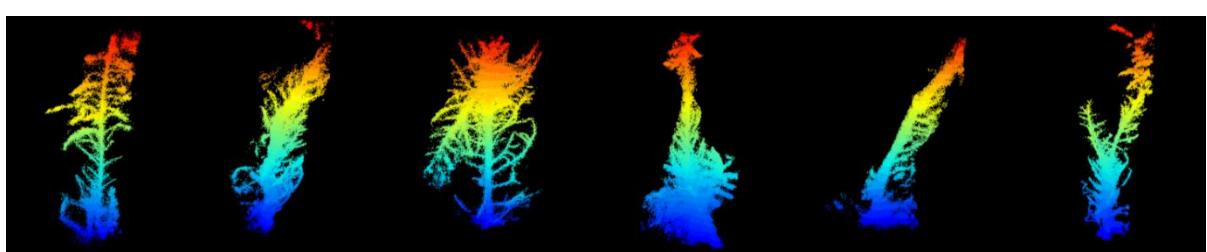
Em termos de qualidade da segmentação, ambos os métodos, FSCT e 3DFin, demonstraram desempenho comparável, conforme ilustrado na Figura 37. Contudo, observou-se que a abordagem baseada nos pacotes lidR + TreeLS resultou em uma degradação das copas, prejudicando a integridade das árvores segmentadas. Ainda, vale destacar que a aplicação dos filtros definidos no Quadro 3 (Tópico 3.6.3.1) contribuiu para a segmentação de árvores dominadas (Figura 38), um desafio recorrente em ambientes florestais (Xiang et al., 2024).

FIGURA 37 - EXEMPLOS DO RESULTADO QUALITATIVO DA SEGMENTAÇÃO SEMÂNTICA DE CADA ABORDAGEM



FONTE: A autora (2025).

FIGURA 38 - EXEMPLARES DE ÁRVORES DOMINADAS SEGMENTADAS PELAS ABORDAGENS FSCT + FILTROS E 3DFIN + FILTROS

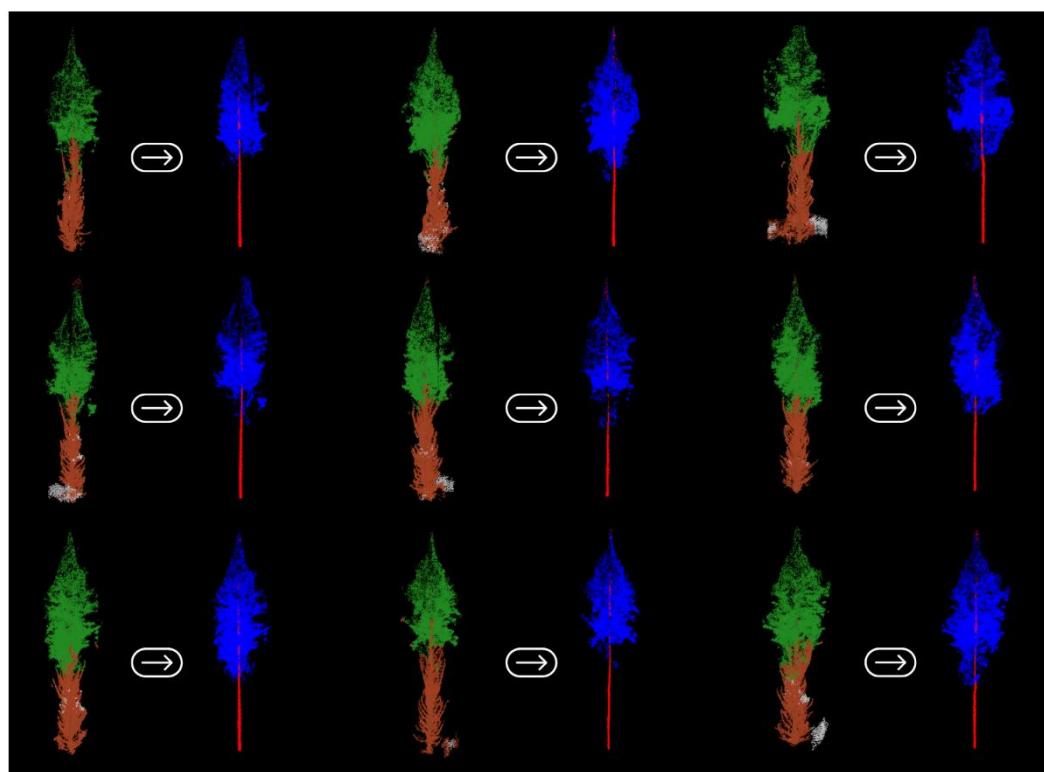


FONTE: A autora (2025).

4.3 SEGMENTAÇÃO SEMÂNTICA

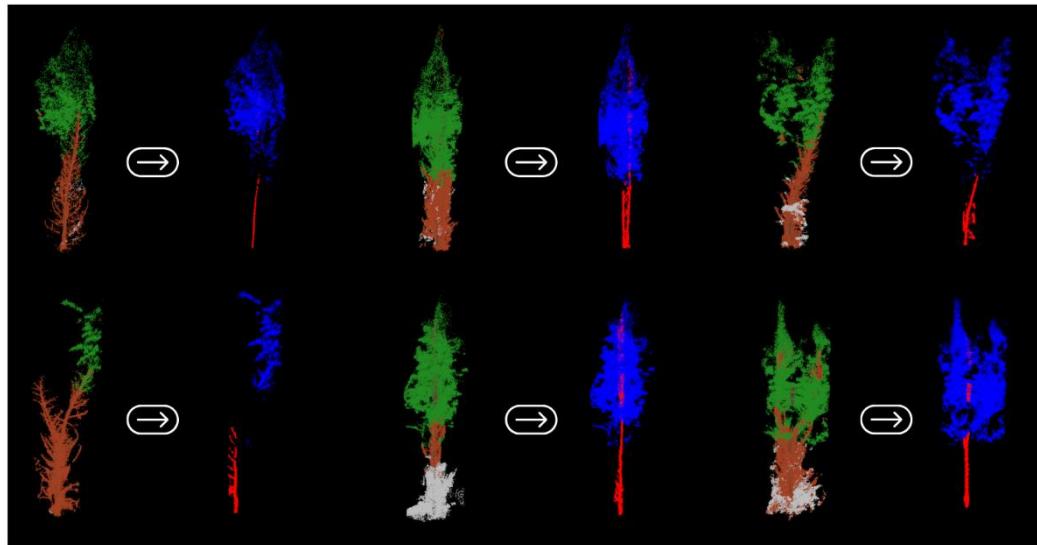
De modo geral, a segmentação semântica apresentou resultados satisfatórios, permitindo a discriminação coerente entre os principais componentes estruturais das árvores (Figura 39). No entanto, em casos específicos, notadamente em indivíduos com arquitetura mais complexa, observou-se uma limitação recorrente na segmentação adequada do fuste, conforme ilustrado na Figura 40.

FIGURA 39 - DESEMPENHO GERAL DA SEGMENTAÇÃO SEMANTICA



FONTE: A autora (2025).

FIGURA 40 - EXEMPLOS DAS PRINCIPAIS FALHAS NA SEGMENTAÇÃO SEMÂNTICA



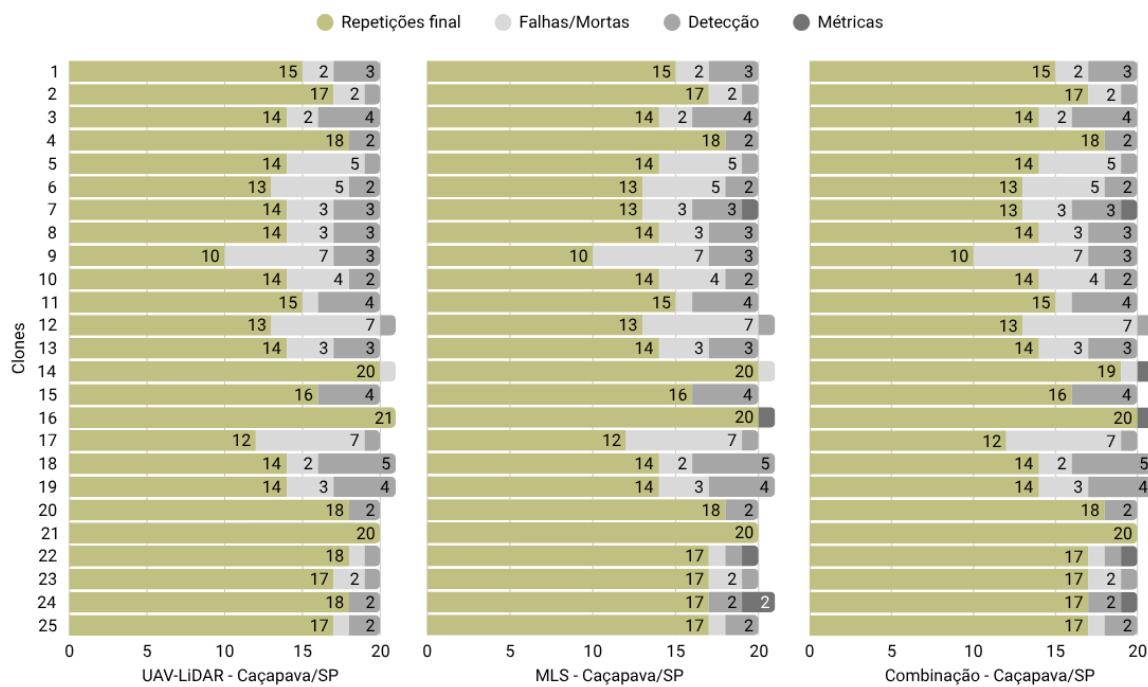
FONTE: A autora (2025).

A principal dificuldade encontrada reside na capacidade do algoritmo em identificar e isolar fustes com geometrias complexas, como aqueles que apresentam tortuosidade acentuada, inclinação ou bifurcação. Tais condições parecem comprometer a interpretação geométrica do modelo, levando a falhas na continuidade do fuste ou à sua fusão parcial com galhos adjacentes.

4.4 PERDA DE REPETIÇÕES NO PROCESSAMENTO

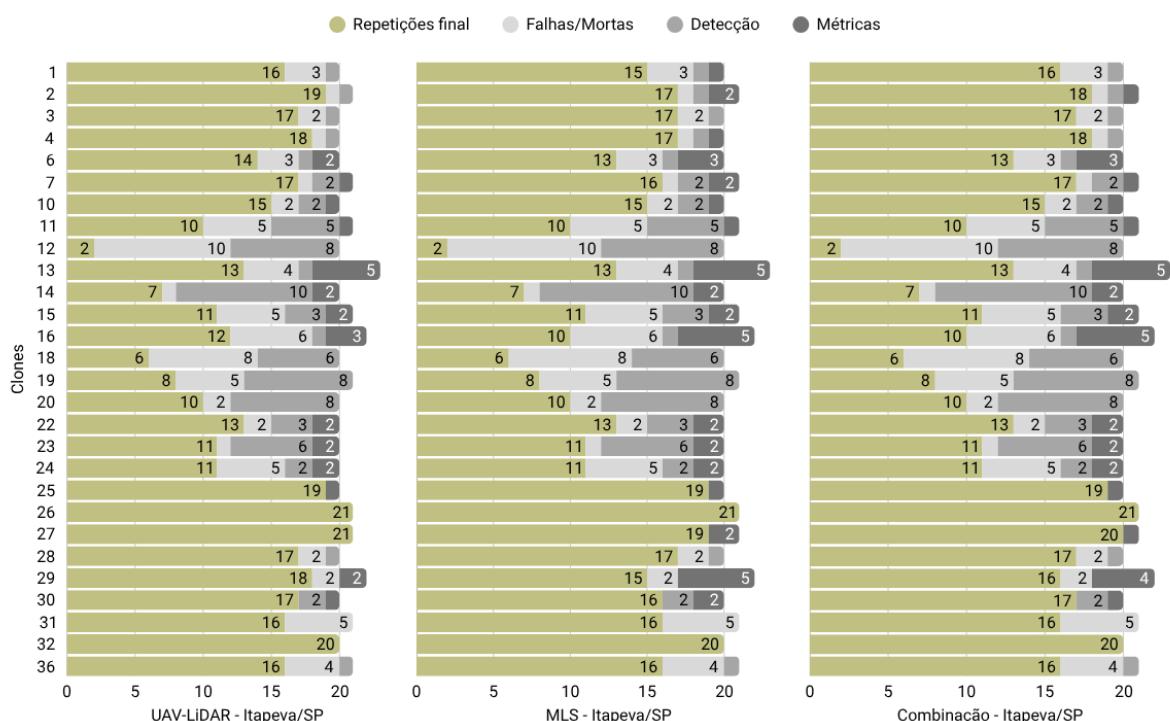
Durante as etapas de processamento dos dados LiDAR, observou-se uma perda de repetições para os diferentes clones avaliados. Conforme ilustrado nas Figuras 41 e 42, a principal causa dessa redução foi a falha na detecção automática das árvores, representando 94% das perdas no experimento de Caçapava e 68% em Itapeva. Nota-se que os clones com maior proporção de perdas também coincidem com aqueles que apresentaram maior incidência de indivíduos com baixa qualidade do fuste, conforme evidenciado nas Figuras 26 e 27 do Tópico 4.1.1.2.

FIGURA 41 - PERDA DE REPETIÇÕES DECORRENTE DO PROCESSAMENTO DOS DADOS LIDAR, DESCONSIDERADAS FALHAS DE PLANTIO E ÁRVORES MORTAS. EXPERIMENTO DE CAÇAPAVA



FONTE: A autora (2025).

FIGURA 42 - PERDA DE REPETIÇÕES DECORRENTE DO PROCESSAMENTO DOS DADOS LIDAR, DESCONSIDERADAS FALHAS DE PLANTIO E ÁRVORES MORTAS. EXPERIMENTO DE ITAPEVA



FONTE: A autora (2025).

Na etapa de extração de métricas, a maior proporção das perdas esteve associada à geração dos QSM, especialmente em Itapeva, onde 97,5% das perdas ocorreram por falhas na modelagem. Em alguns casos, não foi possível gerar QSM devido a inconsistências na nuvem de pontos ou à segmentação incompleta do fuste.

Apesar dessas limitações, o número de repetições válidas obtido foi suficiente para garantir a representatividade estatística da maioria dos clones avaliados, permitindo a continuidade das análises subsequentes.

4.5 MÉTRICAS PAREADAS (INVENTÁRIO X LIDAR)

As Tabelas 9 e 10 e Figuras 43 a 51 apresentam os resultados da comparação entre as métricas dendrométricas obtidas por inventário convencional e extraídas dos dados LiDAR, para o experimento de Caçapava e Itapeva. As estimativas de dap e ht foram derivadas das nuvens de pontos, enquanto os vt individuais foram obtidos a partir da modelagem QSM.

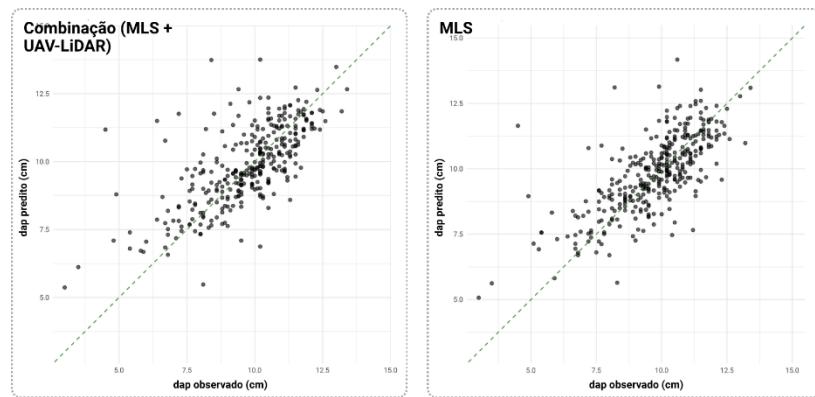
TABELA 9 - RESULTADOS DA AVALIAÇÃO DAS MÉTRICAS PAREADAS (INVENTÁRIO X LIDAR) - EXPERIMENTO DE CAÇAPAVA

Dados	Variável	r	RMSE	RMSE %	Bias	A	CC1
MLS	dap (cm)	0,72	1,16	11,97	-0,11	0,86	0,72
Combinação		0,69	1,25	12,81	-0,15	0,84	0,68
MLS	vt (m^3)	0,63	0,01318	32,89	0,01	0,72	0,47
Combinação		0,67	0,01420	35,25	0,01	0,70	0,45
MLS	ht (m)	0,11	2,87	25,32	2,26	0,32	0,04
Combinação		0,60	1,23	10,82	-0,33	0,74	0,49
UAV-LiDAR		0,50	2,36	20,46	-2,00	0,43	0,19

TABELA 10 - RESULTADOS DA AVALIAÇÃO DAS MÉTRICAS PAREADAS (INVENTÁRIO X LIDAR) - EXPERIMENTO DE ITAPEVA

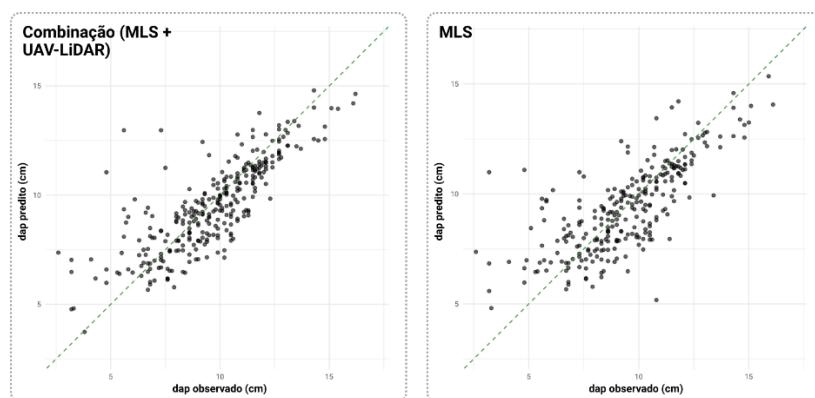
Dados	Variável	r	RMSE	RMSE %	Bias	A	CC1
MLS	dap (cm)	0,75	1,59	16,86	0,05	0,87	0,74
Combinação		0,81	1,41	14,69	0,13	0,90	0,80
MLS	vt (m^3)	0,65	0,04071	91,72	0,03	0,35	0,08
Combinação		0,66	0,04056	87,22	0,03	0,35	0,10
MLS	ht (m)	0,26	3,23	25,80	2,20	0,47	0,14
Combinação		0,51	2,33	18,37	-0,83	0,73	0,48
UAV-LiDAR		0,68	1,98	14,99	-1,39	0,69	0,46

FIGURA 43 - GRÁFICOS DE COMPARAÇÃO ENTRE OS DAP OBTIDO DOS DADOS LIDAR E DE INVENTÁRIO CONVENCIONAL - EXPERIMENTO DE CAÇAPAVA



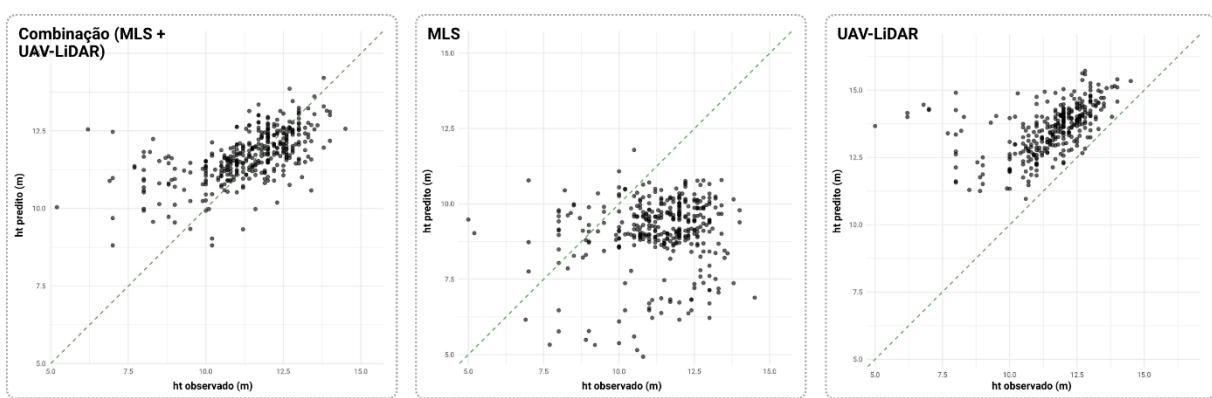
FONTE: A autora (2025).

FIGURA 44 - GRÁFICOS DE COMPARAÇÃO ENTRE OS DAP OBTIDO DOS DADOS LIDAR E DE INVENTÁRIO CONVENCIONAL - EXPERIMENTO DE ITAPEVA



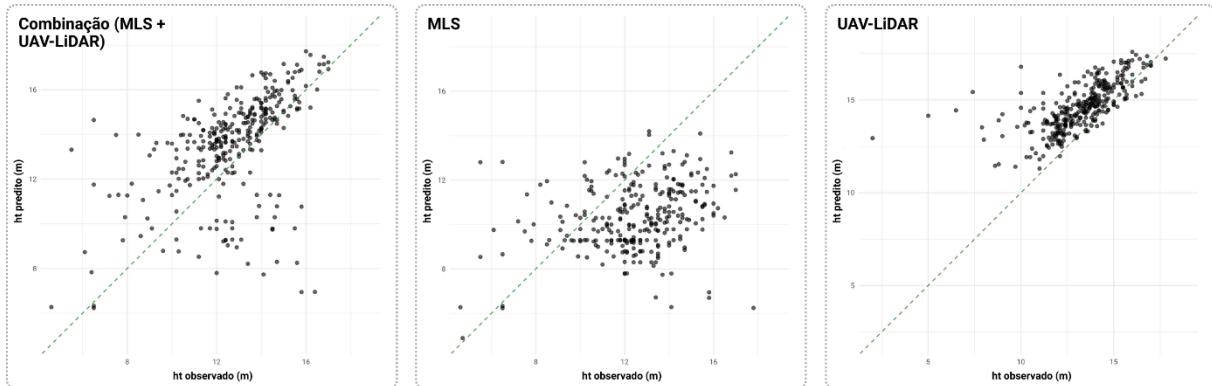
FONTE: A autora (2025).

FIGURA 45 - GRÁFICOS DE COMPARAÇÃO ENTRE AS ALTURAS OBTIDAS DOS DADOS LIDAR E DE INVENTÁRIO CONVENCIONAL - EXPERIMENTO DE CAÇAPAVA



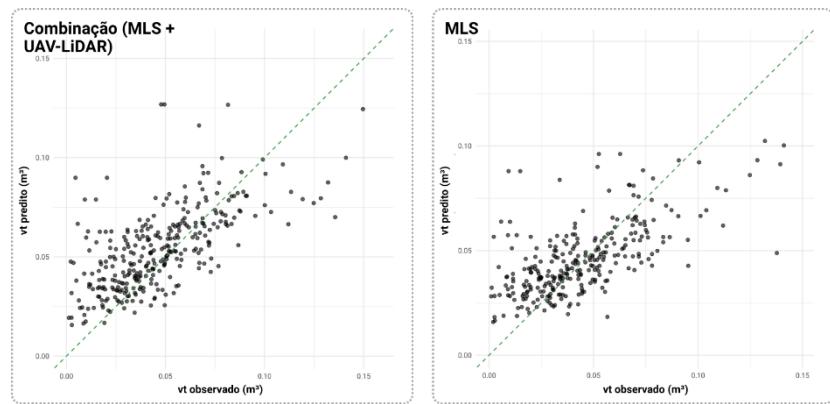
FONTE: A autora (2025).

FIGURA 46 - GRÁFICOS DE COMPARAÇÃO ENTRE AS ALTURAS OBTIDAS DOS DADOS LIDAR E DE INVENTÁRIO CONVENCIONAL - EXPERIMENTO DE ITAPEVA



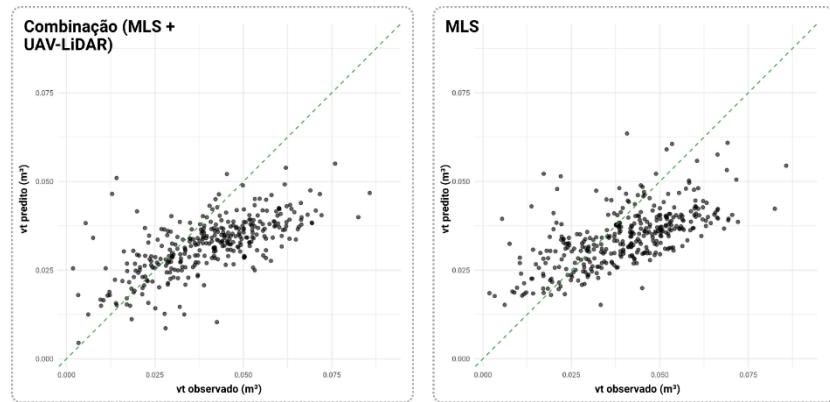
FONTE: A autora (2025).

FIGURA 47 - GRÁFICOS DE COMPARAÇÃO ENTRE OS VT OBTIDOS DOS DADOS LIDAR E DE INVENTÁRIO CONVENCIONAL - EXPERIMENTO DE CAÇAPAVA



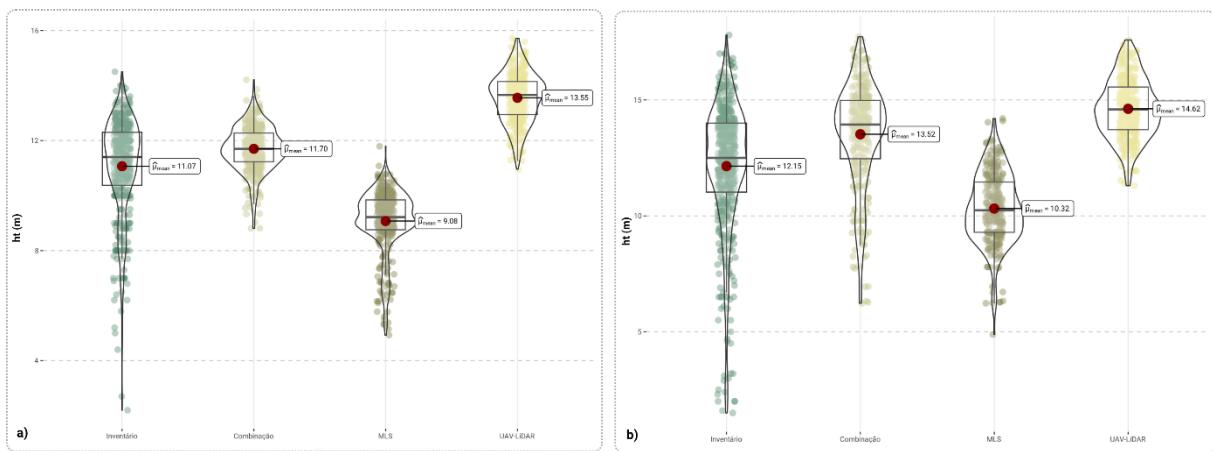
FONTE: A autora (2025).

FIGURA 48 - GRÁFICOS DE COMPARAÇÃO ENTRE OS VT OBTIDOS DOS DADOS LIDAR E DE INVENTÁRIO CONVENCIONAL - EXPERIMENTO DE ITAPEVA



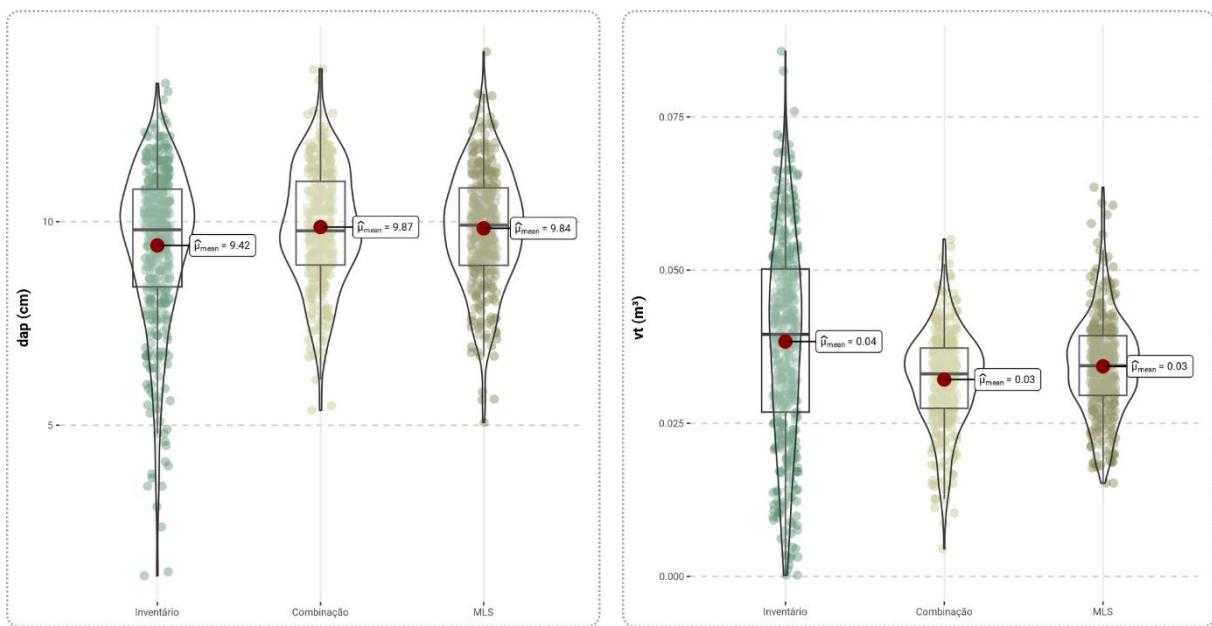
FONTE: A autora (2025).

FIGURA 49 - GRÁFICO VIOLINO DAS ALTURAS OBTIDAS POR INVENTÁRIO E EXTRAÍDAS DOS DADOS COMBINADOS (MLS + UAV-LIDAR), MLS, E UAV-LIDAR, RESPECTIVAMENTE. EXPERIMENTO DE CAÇAPAVA (A) E ITAPEVA (B)



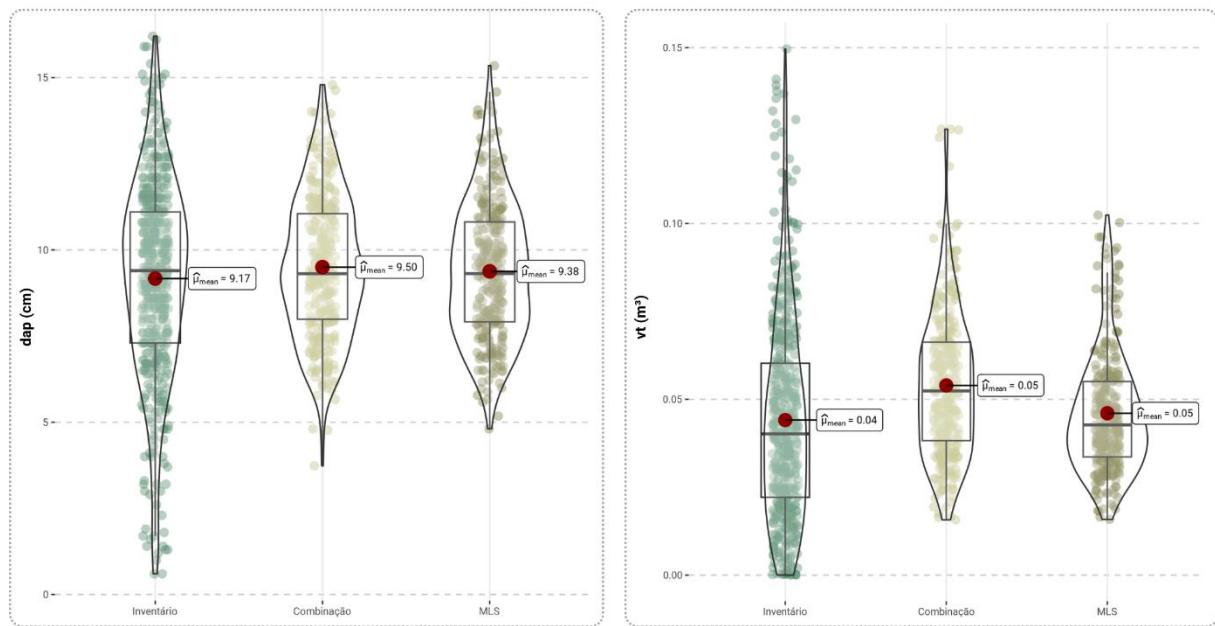
FONTE: A autora (2025).

FIGURA 50 - GRÁFICO VIOLINO DOS DAP (ESQUERDA) E VT (DIREITA) OBTIDOS POR INVENTÁRIO E EXTRAÍDOS DOS DADOS COMBINADOS (MLS + UAV-LIDAR) E MLS, RESPECTIVAMENTE. EXPERIMENTO DE CAÇAPAVA



FONTE: A autora (2025).

FIGURA 51 - GRÁFICO VIOLINO DOS DAP (ESQUERDA) E VT (DIREITA) OBTIDOS POR INVENTÁRIO E EXTRAÍDOS DOS DADOS COMBINADOS (MLS + UAV-LIDAR) E MLS, RESPECTIVAMENTE. EXPERIMENTO DE ITAPEVA



FONTE: A autora (2025).

De modo geral, observou-se desempenho semelhante para dap e vt extraídos dos dados MLS e MLS+UAV-LiDAR (Tabelas 9 e 10; Figuras 43 a 51). Entretanto, para ht, as estimativas derivadas dos dados MLS+UAV-LiDAR e UAV-LiDAR apresentaram desempenho superior em ambos os experimentos (Figuras 45 e 46), o que já era esperado dada a oclusão gerada pelas copas nos dados MLS, conforme evidenciado na Figura 32 do Tópico 4.1.2.

Observou-se também uma tendência sistemática de superestimativa nas alturas derivadas do UAV-LiDAR (Caçapava e Itapeva) e dos dados combinados (Itapeva), possivelmente associada ao gap temporal entre as coletas de inventário e dados LiDAR, de cerca de 2,6 meses em Caçapava e 5,3 meses em Itapeva.

No caso do vt, os erros foram notadamente elevados, em especial nas árvores de maior porte, indicando uma tendência de subestimativa (Figura 47 e 48). Essa distorção pode estar associada a deficiências na segmentação do fuste e à modelagem QSM, agravadas pela presença residual de galhos inferiores, mesmo após a aplicação da segmentação semântica. Adicionalmente, os dados MLS apresentaram elevado nível de ruído, contribuindo para a imprecisão na reconstrução do formato do fuste e, por consequência, na derivação das métricas associadas.

Cabe destacar que o vt foi estimado com base em uma equação volumétrica previamente ajustada pela empresa parceira, o que pode ter introduzido erros

sistemáticos adicionais na comparação. Da mesma forma, as alturas obtidas por hipsômetros são suscetíveis a erros instrumentais, operacionais e de inclinação (terreno e árvore) (Machado & Figueiredo Filho, 2014), o que também pode ter contribuído para a divergência entre os métodos.

Os resultados obtidos neste estudo apresentam consonância com os reportados na literatura, sobretudo em contextos caracterizados por elevada complexidade estrutural e densidade de vegetação (Tabela 11). Liang et al. (2018), por exemplo, compararam o desempenho de 18 algoritmos para extração de métricas individuais a partir de nuvens de pontos TLS com múltiplos escaneamentos. Os autores categorizaram os conjuntos de dados segundo três níveis de dificuldade, fácil, médio e difícil, com base, principalmente, na densidade de árvores e da vegetação rasteira. Os dados utilizados no presente trabalho apresentam características comparáveis às parcelas classificadas como de dificuldade média e difícil por Liang et al. (2018).

Estudos mais recentes, como os de Krisanski et al. (2021) e Laino et al. (2024), propuseram metodologias voltadas à mensuração automatizada de atributos dendrométricos a partir de nuvens de pontos de escaneamento terrestre. A Tabela 11 apresenta uma síntese comparativa entre os resultados obtidos neste estudo e aqueles relatados por esses autores.

TABELA 11 - COMPARAÇÃO DOS RESULTADOS OBTIDOS COM OS APRESENTADOS POR LIANG ET AL. (2018), MONTOYA ET AL. (2021), KRISANSKI ET AL. (2021) E LAINO ET AL. (2024)

Estudo e conjunto de dados	Completude (%)	Exatidão (%)	dap RMSE (cm)	dap RMSE (%)	ht RMSE (m)	ht RMSE (%)	vt RMSE (m³)	vt RMSE (%)
¹ [1]	90,4	93,6	< 2	5-10	2,80	13	0,12	28,30
² [1]	88	89,2	< 2	5-10	4,40	23	0,21	47,30
³ [1]	66,2	92,8	< 2	10-15	4,70	30	0,18	77,10
[2]	90,98	-	7,20	43,3	3,52	17,2	1,70	246
¹ [3]	98,86	99,76	1,75	5,12	-	-	-	-
² [3]	100	99,39	1,66	4,99	-	-	-	-
¹MLS	96,61	99,07	1,16	11,97	2,87	25,32	0,01318	32,89
¹ MLS+UAV-LiDAR	88,46	99,74	1,25	12,81	1,23	10,82	0,01420	35,25
²MLS	84,66	99,28	1,59	16,86	3,23	25,80	0,04056	91,72
²Combinação	83,44	95,55	1,41	14,69	2,33	18,37	0,04071	87,22

¹[1] Liang et al. (2018) - TLS multi-scan, parcelas fáceis; ²[1] Liang et al. (2018) - TLS multi-scan, parcelas médias; ³[1] Liang et al. (2018) - TLS multi-scan, parcelas difíceis; [2] Krisanski et al. (2021); ¹[3] Laino et al. (2024) - TLS; ²[3] Laino et al. (2024) - MLS; ¹Caçapava; ²Itapeva.

Os resultados de Laino et al. (2024) destacam-se por apresentarem desempenho superior para completude, exatidão e acurácia do dap, com erros até cerca de 12% inferiores aos observados no presente estudo. Contudo, vale ressaltar que a mesma ferramenta empregada por Laino et al. (2024) (3DFin) foi utilizada para detecção de árvores nesta pesquisa, inclusive testada para extração dos dap, sem alcançar os mesmos níveis de desempenho. Isso evidencia o maior grau de complexidade e heterogeneidade estrutural das áreas florestais abordadas neste trabalho, reforçando os desafios inerentes ao processamento e à análise das nuvens de pontos obtidas.

4.5.1 Resultados sem aplicação de segmentação semântica

A Tabela 12 apresenta os resultados obtidos na extração das métricas dendrométricas sem a aplicação da segmentação semântica para remoção de galhos. Adicionalmente, foi testada a ferramenta 3DFin, que incorpora um filtro automático para remoção de ruídos oriundos de galhos previamente à extração dos diâmetros.

TABELA 12 - RESULTADO DA AVALIAÇÃO DAS MÉTRICAS PAREADAS (INVENTÁRIO X LIDAR) SEM A REALIZAÇÃO DA SEGMENTAÇÃO SEMÂNTICA E FILTRAGEM DE GALHOS INFERIORES

Algoritmo	Variável	r	RMSE	RMSE %	Viés	A	CC1
3DFin	dap (cm)	0,65	2,12	21,84	-0,73	0,79	0,59
AdTree		0,12	65,22	675,00	-49,12	0,31	0,01
ITSMe		-0,05	85,62	891,45	-59,61	0,34	0,00
ITSMe	ht (m)	0,49	2,45	19,29	-0,81	0,72	0,46
3DFin		0,58	2,85	22,41	-2,15	0,57	0,30
AdTree	vt (m ³)	0,17	2,4960	5178,59	-1,64	0,36	0,00

Conforme esperado, a não aplicação da segmentação semântica comprometeu de forma substancial as estimativas de dap e vt, refletindo a influência da presença dos galhos na acurácia dessas métricas. Em contraste, a variável altura total apresentou menor sensibilidade à ausência deste procedimento. O algoritmo 3DFin apresentou desempenho superior em relação às demais abordagens avaliadas. Ainda assim, os erros obtidos permaneceram superiores àqueles observados quando se utilizou segmentação semântica.

4.6 MÉTRICAS NÃO PAREADAS

A Figura 52 apresenta um resumo das correlações consideradas mais significativas ($r > 0,4$) entre as métricas não pareadas derivadas de diferentes fontes de dados: UAV-LiDAR (prefixo uav), MLS (mls), combinação MLS+UAV-LiDAR (comb), sensores espectrais (índices de vegetação, prefixo iv), e os dados de inventário florestal convencional (dap, ht e vt). A matriz de correlação completa encontra-se disponível no Apêndice 5.

FIGURA 52 - MATRIZ DE CORRELAÇÕES PARCIAL ENTRE MÉTRICAS NÃO PAREADAS EXTRAÍDAS DOS DADOS LIDAR E ESPECTRAIS E DADOS DE INVENTÁRIO



FONTE: A autora (2025).

De modo geral, as variáveis de altura extraídas a partir do UAV-LiDAR apresentaram correlações moderadas a altas com o dap, ht e vt, indicando a robustez

dessas estimativas para inferência de atributos dendrométricos. Ademais, observaram-se correlações promissoras com métricas morfológicas associadas à copa, tais como índice de área foliar (LAI), perímetro de copa e volume de copa e outras como ângulos estruturais e *L-moments* (*t* e *l*).

No que tange aos dados espectrais, os índices de vegetação (Apêndices 6 e 7) TVI, RDVI, MCARI1 e DVI destacaram-se por apresentarem os maiores coeficientes de correlação com as variáveis de inventário, sugerindo um potencial para aplicação em modelos preditivos.

4.7 TEMPO DE PROCESSAMENTO E HARDWARE

A Tabela 13 apresenta a duração das etapas de processamento aplicadas aos diferentes tipos de dados utilizados neste estudo. Os dados UAV-LiDAR exigiram aproximadamente 1 hora e 25 minutos por experimento, enquanto os dados MLS e combinação MLS+UAV-LiDAR demandaram tempos substancialmente superiores, ultrapassando 13 horas em ambos os casos.

TABELA 13 - DURAÇÃO (EM HORAS:MINUTOS) DAS ETAPAS DO PROCESSAMENTO DOS DADOS LIDAR

Dados	Etapa	Sub-etapa	¹ Tempo	² Tempo
UAV-LiDAR	Pré-processamento	Geração dos tiles	0:05	0:04
		Geração do DSM	0:03	0:02
		Classificação de solo	0:05	0:01
		Geração do DTM	0:04	0:03
		Normalização	0:10	0:05
		Geração do CHM	0:03	0:02
		Segmentação em instância	0:15	0:17
MLS	Pré-processamento	Extração das métricas	0:41	0:49
		Total	1:26	1:23
		Geração dos tiles	0:09	0:07
		Geração do DSM	0:01	0:03
		Classificação de solo	0:22	0:27
		Geração do DTM	0:26	1:37
		Normalização	4:29	6:32
MLS	Segmentação em instância	Geração do CHM	0:02	0:03
		*Abordagem via lidR+TreeLS	1:08	-
		Corte das fileiras	13:37	10:05
		Abordagem via 3DFin+filtros	1:23	1:28
		*Abordagem via FSCT+filtros	22:23	-

MLS+UAV-LiDAR	Extração das métricas	Segmentação semântica	6:42	2:37
		TreeQSM	3:15	3:43
		AdTree	0:48	1:11
		ITSMe + QSM	2:43	2:30
		lidUrb + QSM	3:17	3:59
		lidR + rLiDAR	2:16	2:37
	Métricas próprias	Métricas próprias	0:02	0:02
		Total	15:32	13:01
	Pré-processamento	Combinação	0:39	0:38
		Geração do DSM	0:02	0:02
		Classificação de solo	0:21	0:31
		Geração do DTM	0:20	0:43
		Normalização	4:45	6:55
	Segmentação em instância	Geração do CHM	0:02	0:04
		*Abordagem via lidR+TreeLS	1:14	-
		Corte das fileiras	13:39	12:08
		*Abordagem via 3DFin+filtros	1:27	1:33
	Segmentação semântica	Abordagem via FSCT+filtros	22:44	-
		Segmentação semântica	6:36	3:19
		TreeQSM	3:33	2:58
		AdTree	1:25	1:04
		ITSMe + QSM	2:50	2:40
		lidUrb + QSM	3:36	3:04
	Extração das métricas	lidR + rLiDAR	2:21	1:53
		Métricas próprias	0:03	0:03
		Total	17:39	13:35

¹Caçapava. ²Itapeva. *Não contabilizado no total.

As etapas que mais contribuíram para o tempo total de processamento foram: corte das fileiras, normalização da nuvem de pontos, e a segmentação semântica e em instância (quando aplicáveis). Para os dados MLS e MLS+UAV-LiDAR, estas etapas representaram, em média, 30%, 14%, 12% e 3,8%, respectivamente, do tempo total de processamento. Já para os dados UAV-LiDAR, as etapas de extração das métricas e segmentação em instância foram as mais demandantes, representando, respectivamente, 52% e 19% do tempo total.

Entre os métodos de segmentação em instância testados, a abordagem baseada no algoritmo “FSCT” foi a mais computacionalmente intensiva, exigindo aproximadamente 16 vezes mais tempo que a abordagem via 3DFin, ainda que os resultados tenham sido semelhantes (vide Tópico 4.2.2).

Em relação à infraestrutura computacional, o principal fator gargalo de hardware identificado foi a memória RAM, especialmente no processamento das nuvens de alta densidade (MLS e MLS+UAV-LiDAR). Apesar dessa limitação, foi possível mitigar o problema por meio da divisão da nuvem em fragmentos menores, utilizando as funções `readLAScatalog()` e `clip_roi()` do pacote “`lidR`”. Tal abordagem permitiu que o processamento fosse realizado com sucesso tanto na estação de trabalho equipada com 64 GB de memória RAM quanto em um notebook com apenas 16 GB, embora com diferenças no tempo de execução.

4.8 AGRUPAMENTO DE CLONES

A MANOVA, considerando o conjunto completo das variáveis avaliadas, evidenciou, em todos os testes aplicados, diferenças estatisticamente significativas entre os clones ($\alpha < 0,05$), conforme apresentado na Tabela 14.

TABELA 14 - RESULTADOS DA ANÁLISE DE VARIÂNCIA MULTIVARIADA PARA O CONJUNTO COMPOSTO POR TODAS AS VARIÁVEIS AVALIADAS

Efeito	Estatística	Valor	F	Significância
Clone	Traço de Pillai	15,796	2,557	< 0,001
	Lambda de Wilks	0,0001	3,226	< 0,001
	Traço de Hotelling	60,632	6,205	< 0,001
	Maior raiz de Roy	30,483	>163,821	< 0,001

A análise discriminante resultou na extração de duas funções principais que, em conjunto, explicam 62,5% da variância total das variáveis originais. As funções discriminantes apresentaram coeficientes de correlação canônica elevados ($>0,9$), o que denota forte associação entre as variáveis originais e as funções discriminantes obtidas (Tabela 15).

TABELA 15 - PORCENTAGEM DA VARIÂNCIA EXPLICADA, AUTOVALORES (>1) E COEFICIENTES DE CORRELAÇÃO CANÔNICA DAS FUNÇÕES DISCRIMINANTES

Função	Autovalor	% de variância	% cumulativa	Correlação canônica
1	38,429	55,8	55,8	0,987
2	4,610	6,7	62,5	0,907
3	3,251	4,7	67,2	0,874
4	1,744	2,5	69,8	0,797
5	1,544	2,2	72	0,779
6	1,516	2,2	74,2	0,776
7	1,214	1,8	76	0,741
8	1,134	1,6	77,6	0,729
9	1,108	1,6	79,2	0,725

OBS: As demais funções não serão apresentadas pois explicam apenas 20,8% da variância total.

As variáveis que apresentaram maior correlação canônica com a primeira função discriminante foram majoritariamente métricas derivadas de altura dos dados LiDAR (percentis zq45, zq40, zq35, etc.) e *L-moments* (Apêndice 3). Já para a segunda função, destacaram-se algumas variáveis relacionadas à distribuição vertical (zpcum3, HCV, zpcum2), bem como métricas dendrométricas clássicas e derivadas do LiDAR, como vt, dap, área da seção transversal e IMA. As métricas com maior poder discriminante foram predominantemente derivadas dos dados MLS+UAV-LiDAR, seguidas pelas do inventário tradicional e do UAV-LiDAR (Tabela 16).

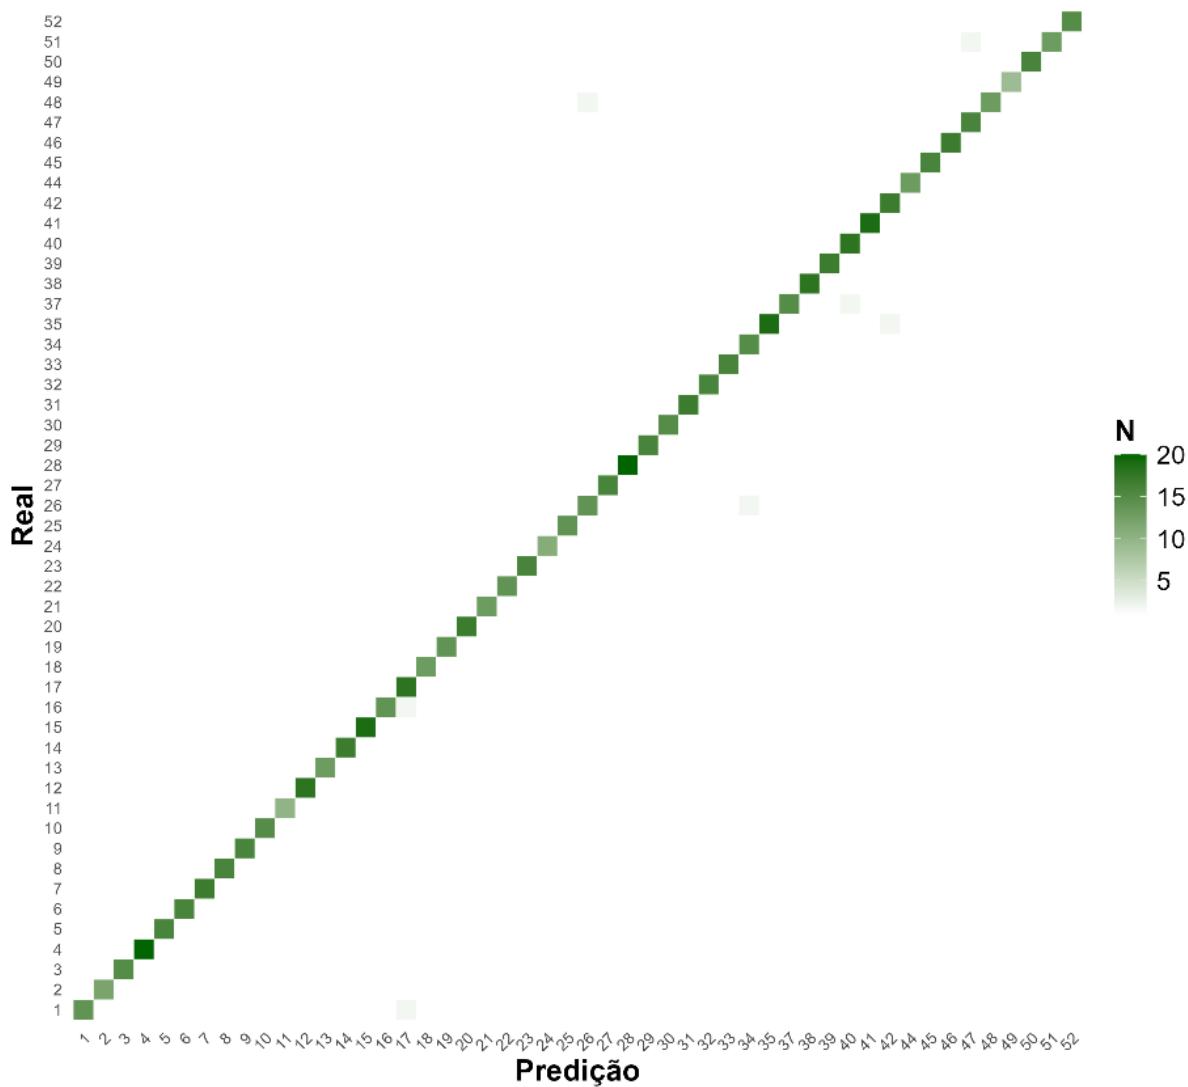
TABELA 16 - RESULTADO PARCIAL DAS CORRELAÇÕES CANÔNICAS ENTRE AS VARIÁVEIS ORIGINAIS AVALIADAS E AS FUNÇÕES DISCRIMINANTES OBTIDAS

Variáveis	FD1	Variáveis	FD2
¹ zq45 - 45º percentil da altura (m)	0,472*	¹ zpcum3 - % de alturas até 33% de ht	0,412*
¹ zq40 - 40º percentil da altura (m)	0,468*	¹ HCV - CV da altura (%)	0,395*
¹ zq35 - 35º percentil da altura (m)	0,460*	¹ zpcum2 - % de alturas até 22% de ht	0,381*
¹ zq50 - 50º percentil da altura (m)	0,455*	³ vt - (m ³)	0,376*
¹ zq30 - 30º percentil da altura (m)	0,445*	² IM_dap - dap derivado da NP (cm)	0,367*
¹ l_1 - L-moment L1	0,420*	³ secao - Seção transversal (m ²)	0,358*
¹ zmean - Mediana de Z	0,420*	¹ pzabove2 - % da altura abaixo de 2th	-0,333*
¹ zq25 - 25º percentil da altura (m)	0,417*	³ dap - (cm)	0,332*
¹ zq55 - 55º percentil da altura (m)	0,411*	¹ TrunkVolum - v do fuste TreeQSM (m ³)	0,327*
¹ zq60 - 60º percentil da altura (m)	0,374*	¹ HVAR - Variância da altura (m ²)	0,325*
¹ zq20 - 20º percentil da altura (m)	0,374*	¹ t_3 - L-moments L3	0,325*
² zq15 - 15º percentil da altura (m)	-0,372*	¹ zpcum1 - % de alturas até 11% de ht	0,323*
¹ zpcum5 - % de alturas até 55% de ht	-0,346*	¹ LAD_90 - Densidade de área foliar a 90% da copa	0,312*
¹ zpcum4 - % de alturas até 44% de ht	-0,343*		
¹ zskew -	-0,339*		
¹ zq65 - 65º percentil da altura (m)	0,335*		

OBS: Foram incluídas apenas variáveis das duas funções discriminantes principais selecionadas, com correlação mínima de 0,3. FD = Função discriminante; ¹MLS+UAV-LiDAR; ²UAV-LiDAR; ³Inventário; CV = Coeficiente de variação; IM = ITSMe (pacote R); NP = Nuvem de pontos; IMA = Incremento médio anual.

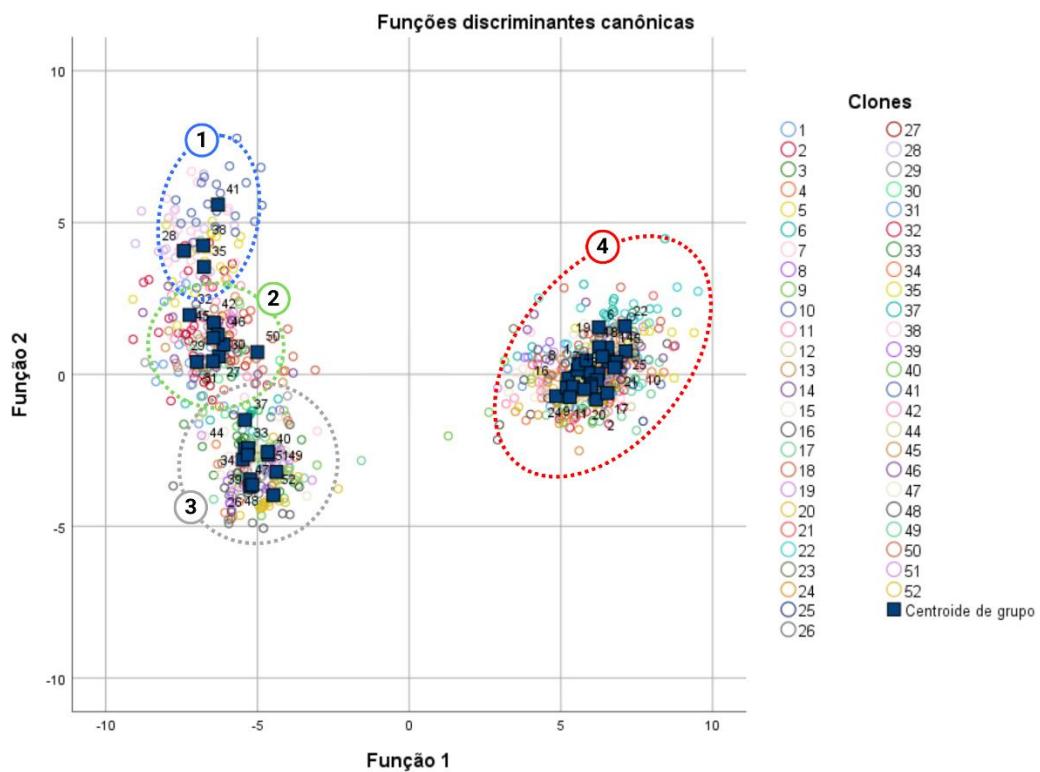
As funções discriminantes foram apropriadas para a separação dos clones, permitindo a classificação correta de 87,3% dos clones com base nas métricas extraídas (Figura 53). Na Figura 54 está ilustrado o agrupamento resultante, evidenciando quatro grupos principais.

FIGURA 53 - MATRIZ DE CONFUSÃO DA CLASSIFICAÇÃO DOS CLONES REALIZADA ATRAVÉS DE ANÁLISE DISCRIMINANTE



FONTE: A autora (2025).

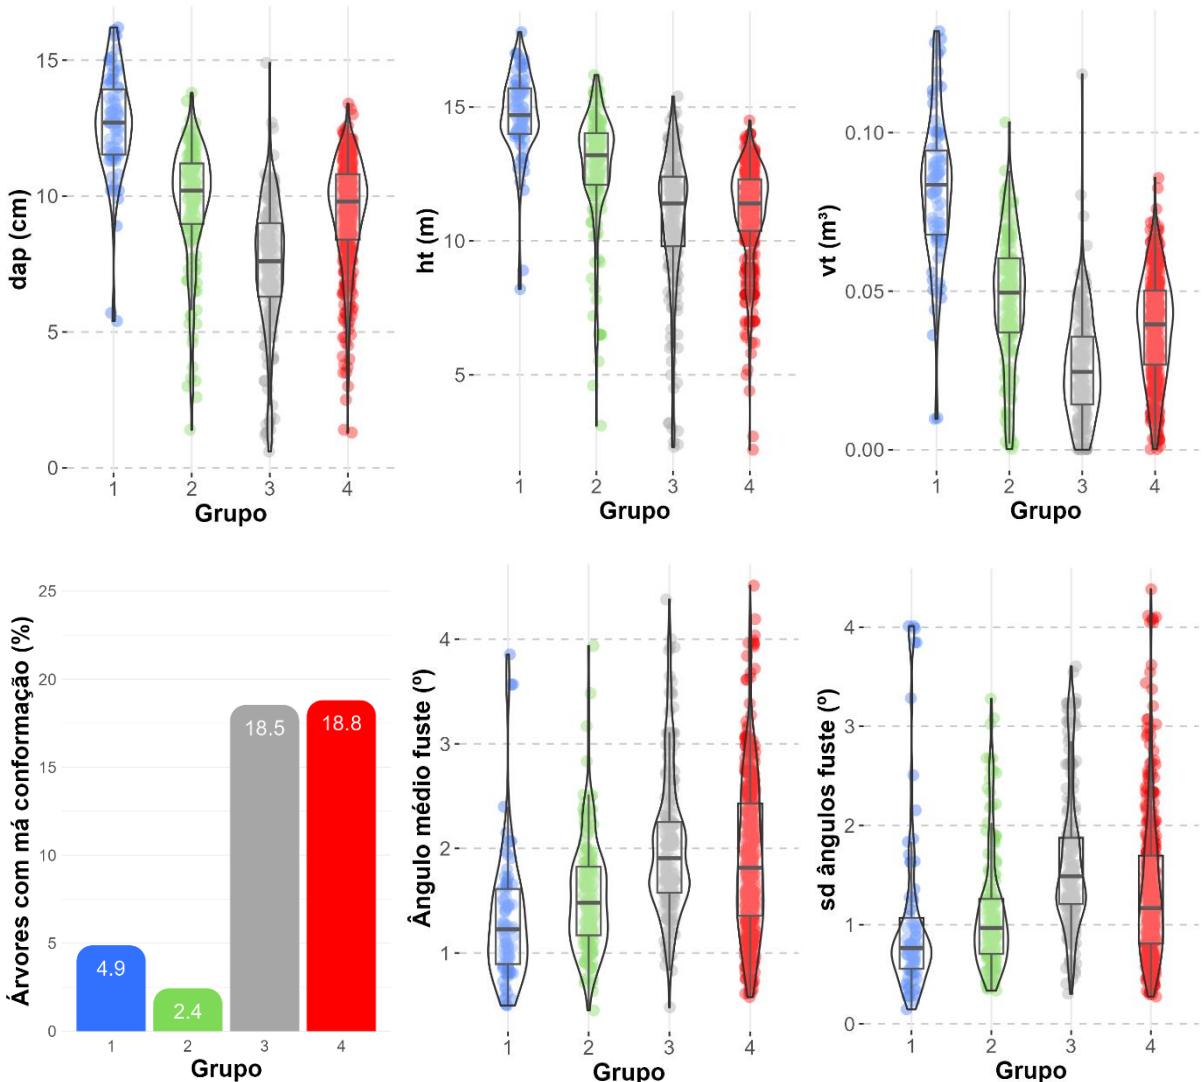
FIGURA 54 - RESULTADOS DAS FUNÇÕES DISCRIMINANTES 1 E 2, PARA O AGRUPAMENTO DOS CLONES, COM OS RESPECTIVOS GRUPOS CENTROIDES, PARA O CONJUNTO DE TODAS AS VARIÁVEIS AVALIADAS



A partir da análise dos gráficos apresentados na Figura 54, é possível caracterizar os agrupamentos de clones da seguinte forma:

- **Grupo 1 (Azul):** clones com maiores valores de dap, ht e vt, e baixa incidência de árvores com má conformação (ex: bifurcadas, tortas ou tombadas).
- **Grupo 2 (Verde):** clones com características intermediárias quanto a dap, ht e vt e baixa incidência de árvores com má conformação.
- **Grupo 3 (Cinza):** clones com menores valores de dap, ht e vt e alta incidência de árvores com má conformação.
- **Grupo 4 (Vermelho):** clones com valores de dap, ht e vt um pouco superiores que do grupo cinza e alta incidência de árvores com má conformação.

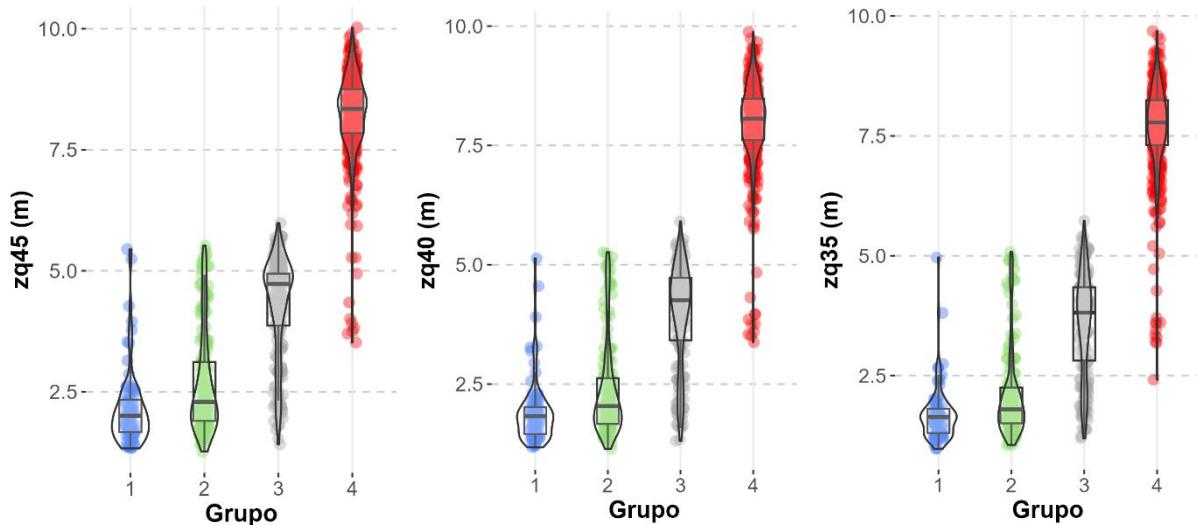
FIGURA 55 - GRÁFICOS VIOLETO, PARA CADA GRUPO, DAS MÉTRICAS DO INVENTÁRIO DAP, HT E VT E DAS MÉTRICAS LIDAR ÂNGULO MÉDIO DO FUSTE E DESVIO PADRÃO (SD) DOS ÂNGULOS DO FUSTE + GRÁFICO DE BARRAS DA PROPORÇÃO DE ÁRVORES COM MÁ CONFORMAÇÃO



FONTE: A autora (2025).

O grupo 4 (vermelho) apresentou maior separação ao longo do primeiro discriminante (Função 1 - Figura 54), ou seja, pelas variáveis relacionadas às alturas derivadas dos percentis dos dados MLS+UAV-LiDAR, assumindo valores superiores nessas variáveis em relação aos demais grupos, conforme exposto na Figura 56.

FIGURA 56 - GRÁFICOS VIOLINO DAS MÉTRICAS DAS MÉTRICAS DE ALTURA LIDAR NOS PERCENTIS 45,40 E 35 PARA CADA GRUPO



FONTE: A autora (2025).

Adicionalmente, observa-se uma correlação positiva entre a proporção de árvores com má conformação e as métricas extraídas dos dados LiDAR (MLS e MLS+UAV-LiDAR) relacionados ao ângulo médio do fuste e ao desvio padrão dos ângulos do fuste (Figura 55). Tal relação evidencia o potencial dessas métricas para fins de classificação da qualidade do fuste.

4.9 DISCUSSÃO: PARA ALÉM DAS MÉTRICAS

Este estudo explorou o potencial de aplicação de sensores LiDAR e espectrais no contexto do melhoramento florestal, com ênfase na utilização de dados LiDAR. Embora os resultados demonstrem avanços na extração automatizada de métricas dendrométricas, diversas limitações foram identificadas ao longo do processo, desde os altos custos associados à aquisição dos dados até os desafios inerentes ao seu processamento. O tratamento das nuvens de pontos exigiu intervenções específicas, ajustadas às particularidades de cada conjunto de dados, especialmente em função das características estruturais e ambientais das áreas estudadas. Destaca-se, por exemplo, a necessidade de filtragem de pontos correspondentes a galhos inferiores nos dados MLS e MLS+UAV-LiDAR, a fim de mitigar interferências na modelagem geométrica das árvores e extração de métricas estruturais.

Apesar dessas limitações, a metodologia proposta mostrou-se suficientemente robusta para permitir um grau razoável de generalização, viabilizando a extração automatizada de métricas que vão muito além do que seria possível obter com inventário tradicional. A aplicação de filtros semânticos e refinamentos na segmentação contribuíram diretamente para a melhoria das estimativas.

Um dos aspectos mais promissores observados ao longo deste trabalho refere-se à visualização tridimensional das árvores, sobretudo nos dados combinados (MLS+UAV-LiDAR). A possibilidade de reconstrução espacial precisa das árvores, oferece uma nova perspectiva para o melhoramento florestal, não apenas facilitando auditorias e validações visuais, mas também abrindo espaço para o desenvolvimento de novas estratégias de seleção e ranqueamento de clones, com base em atributos morfológicos tridimensionais.

Como exemplo prático desse potencial, o Apêndice 8 apresenta um produto visual com potencial de aplicabilidade ao processo de avaliação e seleção clonal, demonstrando o papel dos dados tridimensionais não apenas como fonte de métricas quantitativas, mas também como ferramenta qualitativa de suporte à tomada de decisão.

5 CONSIDERAÇÕES FINAIS

Este estudo demonstrou que a aplicação de sensores LiDAR (UAV-LiDAR e MLS) e espectrais (pancromáticos e multiespectrais) apresenta elevado potencial para a avaliação automatizada de experimentos de melhoramento genético florestal em *Eucalyptus* spp. Os resultados indicam que essas tecnologias não apenas complementam, mas podem, em determinados aspectos, superar os métodos tradicionais de inventário, oferecendo ganhos em eficiência, resolução temporal e abrangência na coleta de dados.

O desenvolvimento e implementação de um fluxo metodológico automatizado permitiu a extração de métricas dendrométricas, fisiológicas e estruturais em nível de árvore individual, viabilizando a aplicação em escala.

A comparação entre abordagens metodológicas evidenciou que a combinação dos algoritmos 3DFin e TreeLS foi a mais eficiente na segmentação em instância das nuvens MLS e combinadas (MLS+UAV-LiDAR). Além disso a segmentação semântica, com remoção dos galhos inferiores, resultou em melhorias significativas na precisão das estimativas de dap e vt.

Comparativamente ao inventário tradicional, as métricas extraídas por meio do LiDAR apresentaram correlações de moderadas a altas, com destaque para o dap, cujas estimativas não diferiram estatisticamente das obtidas em campo. A combinação dos dados MLS+UAV-LiDAR não resultou em ganhos substanciais na acurácia das estimativas de dap e vt, embora tenha proporcionado melhorias expressivas na estimativa de ht. Em termos de desempenho computacional, o tempo de processamento das nuvens combinadas (MLS+UAV-LiDAR) foi, em média, apenas 3,3% superior ao MLS isolado, porém 96,4% maior em relação ao processamento dos dados UAV-LiDAR.

Adicionalmente, as métricas não pareadas derivadas do LiDAR, como percentis de altura e *L-moments*, e os índices de vegetação (TVI, RDVI, MCARI1 e DVI) apresentaram correlações relevantes com as métricas do inventário tradicional, sugerindo potencial para aplicação em predições.

A análise discriminante permitiu a classificação de clones com acurácia de 87,3%, delineando quatro grupos distintos com base em métricas estruturais e dendrométricas, sendo que os dados MLS+UAV-LiDAR forneceram as principais métricas discriminatórias. Métricas como o ângulo médio do fuste e o desvio padrão

dos ângulos demonstraram aplicabilidade para avaliação indireta da arquitetura das árvores.

Em síntese, os achados desta pesquisa evidenciam que os sensores LiDAR e espectrais tem o potencial de transformar a avaliação em programas de melhoramento florestal, fornecendo dados tridimensionais precisos, dados fisiológicos e métricas inovadoras. Apesar dos desafios técnicos ainda existentes, a automação e a integração tecnológica emergem como caminhos promissores para um monitoramento mais eficiente, preciso e compatível com as crescentes exigências de sustentabilidade e produtividade do setor florestal.

5.1 RECOMENDAÇÕES PARA TRABALHOS FUTUROS

Com base nos resultados obtidos e nas limitações observadas, recomenda-se a realização de estudos futuros que aprofundem e expandam a aplicabilidade das metodologias aqui propostas. As seguintes direções de pesquisa são sugeridas:

- **Avaliação temporal da consistência das métricas:** Investigar a estabilidade e repetibilidade das métricas extraídas e suas correlações com variáveis dendrométricas em medições sucessivas ao longo do desenvolvimento dos experimentos, a fim de avaliar seu potencial para o monitoramento contínuo.
- **Otimização das coletas LiDAR:** Recomenda-se a realização de testes com diferentes estratégias de voo para UAV-LiDAR, incluindo variações de altitude, ângulos de inclinação do sensor (sugerindo-se a avaliação de ângulos próximos a 80°) e níveis de sobreposição entre faixas de varredura. No caso do MLS, sugere-se testar distintos padrões de caminhamento, visando maximizar a completude e a uniformidade da nuvem de pontos gerada.
- **Comparação entre equipamentos MLS:** Testar diferentes modelos de sistemas MLS, considerando a elevada presença de ruído observada nos dados do equipamento utilizado neste estudo, com vistas à identificação de soluções mais robustas e precisas.
- **Integração de dados espectrais e LiDAR:** Explorar abordagens de combinação de dados espectrais (RGB, multiespectrais ou hiperespectrais) com os dados LiDAR.

- **Aplicação de modelos de deep learning:** Re-treinar e aplicar modelos baseados em aprendizado profundo para segmentação em instância de árvores individuais, tanto para os dados LiDAR quanto para os espectrais, com o intuito de aumentar a eficiência, automação e reduzir o tempo necessário para essa etapa.
- **Aprofundamento da análise de classificação da qualidade do fuste:** Avaliar o desempenho das métricas elaboradas (ângulos e estatísticas) em modelos de machine e deep learning para classificação da conformação do fuste. Recomenda-se também explorar abordagens que utilizem diretamente a representação tridimensional gerada pelas nuvens de pontos, seja por meio de plots das árvores individuais como entrada para redes neurais convolucionais (CNNs), ou utilizando diretamente a nuvem de pontos bruta em arquiteturas específicas, como PointNet ou PointCNN.
- **Reaplicação da análise discriminante por grupos de variáveis:** Aplicar análise fatorial ou agrupar variáveis por tipo (ex: alturas, estruturais, dendrométricas, fisiológicas) e reaplicar a análise discriminante, com o objetivo de identificar as principais variáveis em cada grupo e seu respectivo poder discriminatório.
- **Avaliação de ganho genético:** Aplicar a metodologia em diferentes áreas experimentais com os mesmos clones, comparando as estimativas de ganho genético obtidas por meio do LiDAR com aquelas derivadas de inventários tradicionais.
- **Testes em novas áreas:** Validar a metodologia proposta em outros experimentos, sob diferentes condições de plantio e desenvolvimento e em dados MLS/TLS coletados com diferentes resoluções, a fim de avaliar sua robustez, escalabilidade e capacidade de generalização.

REFERÊNCIAS

- ADÃO, T. et al. Hyperspectral Imaging: A Review on UAV-Based Sensors, Data Processing and Applications for Agriculture and Forestry. *Remote Sensing*, v. 9, n. 11, p. 1110, 30 out. 2017.
- AHLINDER, J.; HALL, D.; SUONTAMA, M.; SILLANPÄÄ, M. J. Principal component analysis revisited: fast multitrait genetic evaluations with smooth convergence. *G3 Genes|Genomes|Genetics*, v. 14, n. 12, p. jkae228, 2024. DOI: <https://doi.org/10.1093/g3journal/jkae228>.
- AIAZZI, B.; BARONTI, S.; SELVA, M. Improving Component Substitution PanSharpening Through Multivariate Regression of MS +\$Pan Data. *IEEE Transactions on Geoscience and Remote Sensing*, v. 45, n. 10, p. 3230–3239, 2007. DOI: <https://doi.org/10.1109/TGRS.2007.901007>.
- ALVARES, C. A. et al. Köppen's climate classification map for Brazil. *Meteorologische Zeitschrift*, v. 22, n. 6, p. 711-728, 2013.
- AMIRI, A. et al. Forest fires under the lens: needleleaf index - a novel tool for satellite image analysis. *npj natural hazards.*, v. 2, n. 1, 2025. DOI: 10.1038/s44304-025-00063-w.
- ANDRADE JUNIOR, A. S. DE et al. Evaluation of the nutritional status of corn by vegetation indices via aerial images. *Ciência Rural*, v. 51, n. 8, 2021. DOI: 10.1590/0103-8478cr20200692.
- ARAGONESES, E. et al. A multi-sensor approach allows confident mapping of forest canopy fuel load and canopy bulk density to assess wildfire risk at the European scale. *Remote Sensing of Environment*, v. 318, p. 114578–114578, 2025. DOI: 10.1016/j.rse.2024.114578.
- ATKINS, J. W.; STOVALL, A. E. L.; YANG, X. Mapping Temperate Forest Phenology Using Tower, UAV, and Ground-Based Sensors. *Drones*, v. 4, n. 3, p. 56, 2020. DOI: 10.3390/drones4030056.
- ATKINS, J. W. et al. Scale dependency of lidar-derived forest structural diversity. *Methods in Ecology and Evolution*, v. 14, n. 1, p. 89–102, 2023. DOI: 10.1111/2041-210X.13845.
- AYREY, E. et al. Layer Stacking: A Novel Algorithm for Individual Forest Tree Segmentation from LiDAR Point Clouds. *Canadian Journal of Remote Sensing*, v. 43, n. 1, p. 16-27, 2017. DOI: 10.1080/07038992.2017.1294649.
- BALESTRA, M. et al. Advancing forest inventory: a comparative study of low-cost MLS lidar device with professional laser scanners. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, v. XLVIII-2-W8-2024, p. 9-16, 2024. DOI: 10.5194/isprs-archives-XLVIII-2-W8-2024-9-2024.
- BALESTRA, M. et al. LiDAR Data Fusion to Improve Forest Attribute Estimates: A Review. *Current Forestry Reports*, v. 10, n. 4, p. 281–297, 2024. DOI: 10.1007/s40725-024-00216-x.
- BALL, J. G. C. et al. Accurate delineation of individual tree crowns in tropical forests from aerial RGB imagery using Mask R-CNN. *Remote Sensing in Ecology and Conservation*, v. 9, n. 5, p. 641-655, 2023. DOI: 10.1002/rse2.332.

- BARNES, E. M. et al. Coincident detection of crop water stress, nitrogen status and canopy density using ground based multispectral data. In: Proceedings of the Fifth International Conference on Precision Agriculture, Bloomington, MN, USA, 2000. p. 1619.
- BARROS, Q. S. et al. Potencial da tecnologia LiDAR terrestre na área florestal. *Scientia Naturalis*, v. 5, n. 1, p. e4134, 2023. DOI: 10.5935/scinat(1).2023.4134.
- BDIA - Banco de Dados e Informações Ambientais. Brasília, DF: IBGE. Disponível em: <https://bdiaweb.ibge.gov.br/#/home>. Acesso em: 17 maio 2025.
- BENDIG, J. et al. Combining UAV-based plant height from crop surface models, visible, and near infrared vegetation indices for biomass monitoring in barley. *International Journal of Applied Earth Observation and Geoinformation*, v. 39, p. 79–87, 2015. DOI: 10.1016/j.jag.2015.03.012.
- BERNARDI, A. C. et al. Agricultura de precisão: resultados de um novo olhar. Brasília, DF: Embrapa, 2014. 596 p. ISBN 978-85-7035-352-8.
- BESIC, N. et al. Remote-sensing-based forest canopy height mapping: some models are useful, but might they provide us with even more insights when combined? *Geoscientific model development*, v. 18, n. 2, p. 337–359, 22 jan. 2025. DOI: 10.5194/gmd-18-337-2025.
- BIELAK, L. ForestClassR. [S.I.]: GitHub. Disponível em: <https://github.com/lucasbielak/ForestClassR>. Acesso em: 19 maio 2025.
- BRACH, M. et al. Feasibility of low-cost LiDAR scanner implementation in forest sampling techniques. *Forests*, v. 14, n. 4, p. 706, 2023. DOI: 10.3390/f14040706.
- BUCK, L. B. et al. Um algoritmo para filtragem do tronco em nuvem de pontos laser terrestre de árvores de pinus spp. *Boletim de Ciências Geodésicas*, v. 20, n. 4, p. 806–829, 1 dez. 2014. DOI: 10.1590/S1982-21702014000400046.
- BUTLER, B. J. et al. USDA Forest Service National Woodland Owner Survey: national, regional, and state statistics for family forest and woodland ownerships with 10+ acres, 2011-2013. Res. Bull. NRS-99. Newtown Square, PA: U.S. Department of Agriculture, Forest Service, Northern Research Station. p. 39, 2016. DOI: 10.2737/NRS-RB-99.
- CALDERS, K. et al. Terrestrial laser scanning in forest ecology: Expanding the horizon. *Remote Sensing of Environment*, v. 251, p. 112102, 2020. DOI: 10.1016/j.rse.2020.112102.
- CAMPOS, J. C. C.; LEITE, H. G. Mensuração Florestal. 5. ed. Viçosa, MG: Editora UFV, 2017.
- CHEN, S. et al. Measuring the Tree Height of *Picea crassifolia* in Alpine Mountain Forests in Northwest China Based on UAV-LiDAR. *Forests*, v. 13, n. 8, p. 1163, 2022. DOI: 10.3390/f13081163.
- CHEN, S. et al. Applicability of Deep Learning for Semantic Segmentation of Forest LiDAR Point Clouds. *ISPRS Journal of Photogrammetry and Remote Sensing*, v. 174, p. 262-275, 2021. DOI: 10.1016/j.isprsjprs.2021.02.012.
- CONTO, T. TreeLS: R functions for processing individual tree TLS point clouds. [S.I.]: GitHub. Disponível em: <https://github.com/tiagodc/TreeLS>. Acesso em: 19 maio 2025.

- CORTÉS, A. J.; RESTREPO-MONTOYA, M.; BEDOYA-CANAS, L. E. Modern Strategies to Assess and Breed Forest Tree Adaptation to Changing Climate. *Frontiers in Plant Science*, v. 11, p. 583323, 2020. DOI: <https://doi.org/10.3389/fpls.2020.583323>.
- COOPS, N. C. et al. Modelling lidar-derived estimates of forest attributes over space and time: A review of approaches and future trends. *Remote Sensing of Environment*, v. 260, p. 112477–112477, 1 maio 2021. DOI: 10.1016/j.rse.2021.112477.
- D'OLIVEIRA, S. P. et al. Aplicações da agricultura de precisão em pastagens. CIRCULAR TÉCNICA 127. Juiz de Fora, MG. 2023. Disponível em: <<https://www.infoteca.cnptia.embrapa.br/infoteca/bitstream/doc/1151612/1/Aplicacoes-da-agricultura-de-precisao-em-pastagens.pdf>>.
- DALLA CORTE, A. P. et al. Measuring Individual Tree Diameter and Height Using GatorEye High-Density UAV-Lidar in an Integrated Crop-Livestock-Forest System. *Remote Sensing*, v. 12, n. 5, p. 863, 2020. DOI: 10.3390/rs12050863.
- DALLA CORTE, A. P. et al. Aplicações do lidar para o inventário florestal: Enfoque unidade de área. Ponta Grossa: Editora Atena, 2022. DOI: 10.22533/at.ed.201221103.
- DASSOT, M. et al. Terrestrial laser scanning for measuring the solid wood volume, including branches, of adult standing trees in the forest environment. *Computers and Electronics in Agriculture*, v. 89, p. 86-93, 2012. DOI: 10.1016/j.compag.2012.08.003.
- DEBNATH, S. et al. Applications of LiDAR in Agriculture and Future Research Directions. *Journal of Imaging*, v. 9, n. 3, p. 57, 2023. DOI: 10.3390/jimaging9030057.
- DI STEFANO, F. et al. Mobile 3D scan LiDAR: a literature review. *Geomatics, Natural Hazards and Risk*, v. 12, n. 1, p. 2387-2429, 2021. DOI: 10.1080/19475705.2021.1961168.
- DONG, M. et al. Genetic Parameters and Selection Responses for Important Breeding Traits in *Liquidambar formosana* Based on a Provenance–Family Trial. *Forests*, v. 14, n. 12, p. 2293, 2023. DOI: <https://doi.org/10.3390/f14122293>.
- DU, S. et al. AdTree: Accurate, Detailed, and Automatic Modelling of Laser-Scanned Trees. *Remote Sensing*, v. 11, n. 18, p. 2074, 2019. DOI: 10.3390/rs11182074.
- DU TOIT, F. et al. Generating Douglas-fir Breeding Value Estimates Using Airborne Laser Scanning Derived Height and Crown Metrics. *Frontiers in Plant Science*, v. 13, 14 jul. 2022. DOI: 10.3389/fpls.2022.893017.
- DUARTE, D. et al. Genomic selection in forest trees comes to life: unraveling its potential in an advanced four-generation *Eucalyptus grandis* population. *Frontiers in Plant Science*, v. 15, p. 1462285, 2024. DOI: <https://doi.org/10.3389/fpls.2024.1462285>.
- DUNCANSON, L. et al. The importance of consistent global forest aboveground biomass product validation. *Surveys in Geophysics*, 40, p. 979-999, 2019. DOI: 10.1007/s10712-019-09538-8.
- ECKARD, J. T. et al. Selection efficiency for solid wood traits in *Pinus taeda* using time-of-flight acoustic and micro-drill resistance methods. *Forest Science*, v. 56, n. 3, p. 233-241, 2010. DOI: <https://doi.org/10.1093/forestscience/56.3.233>.

- ESTADO DE SÃO PAULO. Agritempo. Estatística. [S.I.]: Embrapa Informática Agropecuária. Disponível em: <https://www.agritempo.gov.br/br/estado/SP/estatistica/>. Acesso em: 17 maio 2025.
- EWALD, M. et al. LiDAR derived forest structure data improves predictions of canopy N and P concentrations from imaging spectroscopy. *Remote Sensing of Environment*, v. 211, p. 13–25, jun. 2018. DOI: 10.1016/j.rse.2018.03.038.
- FANGMING, W. et al. Performance evaluation of a lightweight and low-cost LiDAR sensor for mobile scanning in forest plots. In: ASIAN CONFERENCE ON REMOTE SENSING (ACRS), 45., 2024, Ho Chi Minh City. Proceedings [...]. [S. I.]: AARS, 2024. p. 1-12. Disponível em: <https://acrs-aars.org/proceeding/ACRS2024/AB0100.pdf>. Acesso em: 16 maio 2025.
- FASSNACHT, F. E. et al. Remote sensing in forestry: current challenges, considerations and opportunities. *Forestry: An International Journal of Forest Research*, v. 97, n. 1, p. 11–26, 2024. DOI: 10.1093/forestry/cpad024.
- FERRAZ, A. et al. 3-D mapping of a multi-layered Mediterranean forest using ALS data. *Remote Sensing of Environment*, v. 121, p. 210-223, 2012. DOI: 10.1016/j.rse.2012.01.020.
- FERRER VELASCO, R. F. et al. Towards accurate mapping of forest in tropical landscapes: A comparison of datasets on how forest transition matters. *Remote Sensing of Environment*, v. 274, p. 112997–112997, 24 mar. 2022. DOI: 10.1016/j.rse.2022.112997.
- FOSTER, A. et al. Cost-effectiveness of remote sensing technology for spruce budworm monitoring in Maine, USA. *Forests Monitor*, v. 12, n. 3, p. 245–261, 2024.
- GITELSON, A. A.; KAUFMAN, Y. J.; STARK, R.; RUNDQUIST, D. Novel algorithms for remote estimation of vegetation fraction. *Remote Sensing of Environment*, v. 80, n. 1, p. 76-87, 2002. DOI: [https://doi.org/10.1016/S0034-4257\(01\)00289-9](https://doi.org/10.1016/S0034-4257(01)00289-9).
- GRYBAS, H.; CONGALTON, R. G. A Comparison of Multi-Temporal RGB and Multispectral UAS Imagery for Tree Species Classification in Heterogeneous New Hampshire Forests. *Remote Sensing*, v. 13, n. 13, p. 2631, 4 jul. 2021. DOI: 10.3390/rs13132631.
- HAHSLER, M.; PIEKENBROCK, M.; DORAN, D. dbSCAN: Fast Density-Based Clustering with R. *Journal of Statistical Software*, v. 91, n. 1, p. 1-30, 2019. DOI: 10.18637/jss.v091.i01.
- HAGUE, T. et al. Automated crop and weed monitoring in widely spaced cereals. *Precision Agriculture*, v. 7, p. 21–32, 2006. DOI: <https://doi.org/10.1007/s11119-005-6787-1>.
- HAIR Jr. J.F.; ANDERSON, R.E. TATHAN, R.L.; BLACK, W.C. *Análise multivariada de dados*. Porto Alegre: Bookman, 2005.
- HENRICH, J. et al. TreeLearn: A deep learning method for segmenting individual trees from ground-based LiDAR forest point clouds. *Ecological Informatics*, v. 84, p. 102888, 2024. DOI: 10.1016/j.ecoinf.2024.102888.
- HOFFRÉN, R.; LAMELAS, M. T.; JUAN. Classification and Mapping of Fuels in Mediterranean Forest Landscapes Using a UAV-LiDAR System and Integration Possibilities with Handheld Mobile Laser Scanner Systems. *Remote Sensing*, v. 16, n. 18, p. 3536, 2024. DOI: 10.3390/rs16183536.

- HOWIE, N. A., & DE STEFANO, A. Measuring tree diameter using LiDAR equipped iPad: An evaluation of ForestScanner and Arboreal Forest applications. *Forest Science*, 70(4), 304-310, 2024. DOI: 10.1093/forsci/fxae017.
- HU, T. et al. Development and Performance Evaluation of a Very Low-Cost UAV-Lidar System for Forestry Applications. *Remote Sensing*, v. 13, n. 1, p. 77, 2020. DOI: 10.3390/rs13010077.
- HYYPPÄ, E. et al. Accurate derivation of stem curve and volume using backpack mobile laser scanning. *ISPRS Journal of Photogrammetry and Remote Sensing*, v. 161, p. 246-262, 2020. DOI: 10.1016/j.isprsjprs.2020.01.020.
- INMET. Estação: ITAPEVA (A714). Brasília, DF: INMET.
- JOCHER, G.; QIU, J.; CHAURASIA, A. Ultralytics YOLO (Version 8.0.0). [S.I.]: Ultralytics, 2023. Software. Disponível em: <https://github.com/ultralytics/ultralytics>. Acesso em: 15 maio 2025.
- JUSTICE, C. O. et al. The Moderate Resolution Imaging Spectroradiometer (MODIS): land remote sensing for global change research. *IEEE Transactions on Geoscience and Remote Sensing*, v. 36, n. 4, p. 1228-1249, 1998. DOI: 10.1109/36.701075.
- KAARTINEN, H. et al. Accuracy of Kinematic Positioning Using Global Satellite Navigation Systems under Forest Canopies. *Forests*, v. 6, n. 9, p. 3218–3236, 2015. DOI: 10.3390/f6093218.
- KAMOSKE, A. G. et al. Towards mapping biodiversity from above: Can fusing lidar and hyperspectral remote sensing predict taxonomic, functional, and phylogenetic tree diversity in temperate forests? *Global Ecology and Biogeography*, v. 31, n. 2, p. 211–226, 2022. DOI: 10.1111/geb.13516.
- KANG, K. S.; Klapste, J.; CAPPA, E. P. Forest Tree Breeding, Testing, and Selection. *Forests*, Special Issue, 2023-2025. DOI: https://www.mdpi.com/journal/forests/special_issues/T8WGLO3FA0.
- KIM, D. et al. Automated Segmentation of Individual Tree Structures Using Deep Learning over LiDAR Point Cloud Data. *Forests*, v. 14, n. 6, p. 1159, 2023. DOI: 10.3390/f14061159.
- KIRILLOV, A. et al. Segment Anything. arXiv:2304.02643, 2023. Disponível em: <https://arxiv.org/abs/2304.02643>. Acesso em: [data].
- KRISANSKI, S. et al. Forest Structural Complexity Tool—An Open Source, Fully-Automated Tool for Measuring Forest Point Clouds. *Remote Sensing*, v. 13, n. 22, p. 4677, 2021. DOI: 10.3390/rs13224677.
- LAETITIA LONCAN et al. Hyperspectral Pansharpening: A Review. *IEEE Geoscience and Remote Sensing Magazine*, v. 3, n. 3, p. 27–46, 1 set. 2015.
- LAINO, D. et al. 3DFin: a software for automated 3D forest inventories from terrestrial point clouds. *Forestry: An International Journal of Forest Research*, Oxford, 2024. Epub ahead of print. DOI: 10.1093/forestry/cpae020.
- LECIGNE, B. lidUrb: Urban trees analyses from terrestrial laser scanning. [S.I.]: GitHub. Disponível em: <https://github.com/Blecigne/lidUrb>. Acesso em: 19 maio 2025.

- LEE, Y.; LEE, J. Advancing Stem Volume Estimation Using Multi-Platform LiDAR and Taper Model Integration for Precision Forestry. *Remote Sensing*, v. 17, n. 5, p. 785, 2025. DOI: 10.3390/rs17050785.
- LI, W. et al. Forest-PointNet: A Deep Learning Model for Vertical Structure Segmentation of Forest Point Clouds. *Remote Sensing*, v. 15, n. 19, p. 4793, 2024. DOI: 10.3390/rs15194793.
- LI, W.; GUO, Q.; JAKUBOWSKI, M. K.; KELLY, M. A New Method for Segmenting Individual Trees from the Lidar Point Cloud. *Photogrammetric Engineering & Remote Sensing*, v. 78, n. 1, p. 75-84, 2012. DOI: 10.14358/PERS.78.1.75.
- LI, Y. et al. Genotype by environment interactions in forest tree breeding: review of methodology and perspectives on research and application. *Tree Genetics & Genomes*, v. 13, n. 60, 2017. DOI: <https://doi.org/10.1007/s11295-017-1144-x>.
- LIANG, X. et al. International benchmarking of terrestrial laser scanning approaches for forest inventories. *ISPRS Journal of Photogrammetry and Remote Sensing*, v. 144, p. 137-179, 2018. DOI: 10.1016/j.isprsjprs.2018.06.020.
- LIAO, K. et al. Examining the Role of UAV Lidar Data in Improving Tree Volume Calculation Accuracy. *Remote Sensing*, v. 14, n. 17, p. 4410, 2022. DOI: 10.3390/rs14174410.
- LIZINIEWICZ, M. et al. LiDAR-estimated height in a young Scots pine (*Pinus sylvestris* L.) genetic trial supports high-accuracy early selection for height. *Annals of Forest Science*, v. 82, n. 12, p. 1-15, 2025. DOI: <https://doi.org/10.1186/s13595-025-01283-w>.
- LOUHAICHI, M.; BORMAN, M. M.; JOHNSON, D. E. Spatially Located Platform and Aerial Photography for Documentation of Grazing Impacts on Wheat. *Geocarto International*, v. 16, n. 1, p. 65–70, 2001. DOI: 10.1080/10106040108542184.
- LOUISE, T. Imterryn/ITSMe: submission release (Version v1.0.0). [S.I.]: Zenodo, 2022. Software. DOI: 10.5281/zenodo.6769105.
- MAK, N. P. L. et al. Mapping Individual Tree- and Plot-Level Biomass Using Handheld Mobile Laser Scanning in Complex Subtropical Secondary and Old-Growth Forests. *Remote Sensing*, v. 17, n. 8, p. 1354, 2025. DOI: 10.3390/rs17081354.
- MALLADI, V. V. N. S. et al. Tree Instance Segmentation and Traits Estimation for Forestry Applications Using LiDAR Point Clouds. In: IEEE INTERNATIONAL CONFERENCE ON ROBOTICS AND AUTOMATION (ICRA), 2024, Yokohama. Proceedings [...]. Piscataway: IEEE, 2024. p. 1-7. DOI: 10.1109/ICRA55202.2024.10597988.
- MARCELLO, J. et al. Performance of individual tree segmentation algorithms in different forest ecosystems using high-density LiDAR data. *Drones*, v. 8, n. 12, p. 772, 2024. DOI: 10.3390/drones8120772.
- MACHADO S. A.; FIGUEIREDO FILHO, A. *Dendrometria*. 2.ed. 2.reimp. Guarapuava: Unicentro, 2014.
- MÄYRÄ, J. et al. Tree species classification from airborne hyperspectral and LiDAR data using 3D convolutional neural networks. *Remote Sensing of Environment*, v. 256, p. 112322, abr. 2021. DOI: 10.1016/j.rse.2021.112322.

- MCCLELLAND, M.; VAN AARDT, J.; HALE, D. S. A comparison of manned and unmanned aerial Lidar systems in the context of sustainable forest management. In: SPIE DEFENSE + COMMERCIAL SENSING, 2018, Orlando. Autonomous Air and Ground Sensing Systems for Agricultural Optimization and Phenotyping III. Bellingham: SPIE, 2018. v. 10664, p. 26. DOI: 10.1117/12.2304850.
- MELVILLE, G. et al. Application of LiDAR data to maximise the efficiency of inventory plots in softwood plantations. *New Zealand Journal of Forestry Science*, v. 45, n. 1, p. 1–16, 2015. DOI: 10.1186/s40490-015-0038-7.
- MEYER, G. E. et al. Verification of color vegetation indices for automated crop imaging applications. *Computers and Electronics in Agriculture*, v. 63, p. 282-293, 2008. DOI: 10.1016/j.compag.2008.03.009.
- MITCHELL, A. L. et al. Current remote sensing approaches to monitoring forest degradation in support of countries measurement, reporting and verification (MRV) systems for REDD+. *Carbon Balance and Management*, v. 12, n. 1, p. 1–22, 2017. DOI: 10.1186/s13021-017-0078-9.
- MORSDORF, F. et al. Assessing forest structural and physiological information content of multi-spectral LiDAR waveforms by radiative transfer modelling. *Remote Sensing of Environment*, v. 113, n. 10, p. 2152–2163, 2009. DOI: 10.1016/j.rse.2009.05.019.
- MOTOHKA, T. et al. Applicability of green-red vegetation index for remote sensing of vegetation phenology. *Remote Sensing*, v. 2, n. 10, p. 2369-2387, 2010. DOI: <https://doi.org/10.3390/rs2102369>.
- NÆSSET, E. Area-Based Inventory in Norway – From Innovation to an Operational Reality. *Managing Forest Ecosystems*, p. 215–240, 2014. DOI: 10.1007/978-94-017-8663-8_11.
- OLIVEIRA, G. G. et al. Full-Tree Biomass, Root Carbon Stock, and Nutrient Use Efficiency Across Ages in Eucalyptus Stands Under Seedling and Coppice Systems. *Plants*, v. 14, n. 9, p. 1382, 2025. DOI: <https://doi.org/10.3390/plants14091382>.
- PÁDUA, L. et al. (2017). UAS, sensors, and data processing in agroforestry: a review towards practical applications. *International Journal of Remote Sensing*, 38(8–10), 2349–2391. <https://doi.org/10.1080/01431161.2017.1297548>
- PANAGIOTIDIS, D.; ABDOLLAHNEJAD, A.; SLAVÍK, M. 3D point cloud fusion from UAV and TLS to assess temperate managed forest structures. *International Journal of Applied Earth Observation and Geoinformation*, v. 112, p. 102917, 2022. DOI: 10.1016/j.jag.2022.102917.
- PARK, J. K.; WANG, L. K. Analysis of Data Characteristics by UAV LiDAR Sensor. *Journal of the Korea Academia-Industrial cooperation Society*, v. 21, n. 5, p. 1–6, 2020. DOI: 10.5762/KAIS.2020.21.5.1.
- PICOS, J. et al. Individual Tree Detection in a Eucalyptus Plantation Using Unmanned Aerial Vehicle (UAV)-LiDAR. *Remote Sensing*, v. 12, n. 5, p. 885, 2020. DOI: 10.3390/rs12050885.
- PILARSKA, M. et al. THE POTENTIAL OF LIGHT LASER SCANNERS DEVELOPED FOR UNMANNED AERIAL VEHICLES – THE REVIEW AND ACCURACY. *The International Archives of the Photogrammetry, Remote Sensing and Spatial*

- Information Sciences, v. XLII-2/W2, p. 87–95, 2016. DOI: 10.5194/isprs-archives-XLII-2-W2-87-2016.
- PIRES, R. P. et al. Mobile laser scanning as reference for estimation of stem attributes from airborne laser scanning. *Remote Sensing of Environment*, v. 315, p. 114414, 2024. DOI: 10.1016/j.rse.2024.114414.
- PUGH, N. A. et al. High-throughput phenotyping of stay-green in a sorghum breeding program using unmanned aerial vehicles and machine learning. *The Plant Phenome Journal*, v. 8, n. 1, 2025. DOI: 10.1002/ppj2.20112.
- PULETTI, N. et al. A Semi-Automatic Approach for Tree Crown Competition Indices Assessment from UAV LiDAR. *Remote Sensing*, v. 16, n. 14, p. 2576, 2024. DOI: 10.3390/rs16142576.
- QGIS DEVELOPMENT TEAM. QGIS Geographic Information System. [S.I.]: Open Source Geospatial Foundation Project, 2025. Software. Disponível em: <http://qgis.osgeo.org>. Acesso em: [data].
- RAUMONEN, P.; ÅKERBLOM, M. InverseTampere/TreeQSM: Version 2.4.1. [S.I.]: Zenodo, 11 maio 2022. Software. DOI: 10.5281/zenodo.6539638.
- RAVI, N. et al. SAM 2: Segment Anything in Images and Videos. arXiv:2408.00714, 2024. Disponível em: <https://arxiv.org/abs/2408.00714>. Acesso em: [data].
- ROUSSEL, J. R. et al. lidR: An R package for analysis of Airborne Laser Scanning (ALS) data. *Remote Sensing of Environment*, v. 251, p. 112061, 2021. DOI: 10.1016/j.rse.2020.112061.
- ROUSE, J. W. et al. Monitoring vegetation systems in the Great Plains with ERTS. In: Third ERTS-1 Symposium, v. 1, p. 309–317, 1974. NASA SP-351.
- RSPATIAL. terra: R package for spatial data handling. [S.I.]: GitHub. Disponível em: <https://github.com/rspatial/terra>. Acesso em: 20 maio 2025.
- SANO, H. et al. Quantitative Genetic Aspects of Accuracy of Tree Biomass Measurement Using LiDAR. *Remote Sensing*, v. 16, n. 24, p. 4790, 2024. DOI: <https://doi.org/10.3390/rs16244790>.
- SCHLAGER, S. Morpho and Rvcg - Shape Analysis in R. In: ZHENG, G.; LI, S.; SZEKELY, G. (ed.). Statistical Shape and Deformation Analysis. [S.I.]: Academic Press, 2017. p. 217-256.
- SHENKIN, A. et al. The World's Tallest Tropical Tree in Three Dimensions. *Frontiers in Forests and Global Change*, v. 2, p. 32, 2019. DOI: 10.3389/ffgc.2019.00032.
- SILVA, C. A. rLiDAR: LiDAR Data Processing and Visualization. [S.I.]: GitHub. Disponível em: <https://github.com/carlos-alberto-silva/rLiDAR>. Acesso em: 19 maio 2025.
- SIMIQUELI, G. F. et al. Genomic evaluation for breeding and genetic management in polyploid forest trees. *BMC Genomics*, v. 25, n. 1, p. 1, 2024. DOI: <https://doi.org/10.1186/s12864-023-09907-z>.
- TATSUMI, S. et al. ForestScanner: A mobile application for measuring and mapping individual trees using LiDAR. *Methods in Ecology and Evolution*, v. 14, n. 1, p. 220–229, 2023. DOI: 10.1111/2041-210x.13900.

- TERRYN, L. et al. Quantifying tropical forest structure through terrestrial and UAV laser scanning fusion in Australian rainforests. *Remote Sensing of Environment*, v. 271, p. 112912, 2022. DOI: 10.1016/j.rse.2022.112912.
- TERRYN, L. et al. Tree species classification using structural features derived from terrestrial laser scanning. *ISPRS Journal of Photogrammetry and Remote Sensing*, v. 168, p. 170-181, 2020. DOI: 10.1016/j.isprsjprs.2020.08.010.
- TITTMANN, P. et al. Tree Detection, Delineation, and Measurement from LiDAR Point Clouds Using RANSAC. In: SILVILASER, 11., 2011, Hobart. Proceedings [...]. Hobart: [s.n.], 2011. p. 1-8.
- TORRES-SÁNCHEZ, E. et al. Volume-based selection in *Pinus pinaster* Aiton breeding: evaluating resistance to *Bursaphelenchus xylophilus* (Steiner & Buhrer) Nickle and wood properties. *Annals of Forest Science*, v. 81, n. 46, 2024. DOI: <https://doi.org/10.1186/s13595-024-01266-3>.
- VANDENDAELE, B. et al. Mobile Laser Scanning for Estimating Tree Structural Attributes in a Temperate Hardwood Forest. *Remote Sensing*, v. 14, n. 18, p. 4522, 2022. DOI: 10.3390/rs14184522.
- VINCINI, M.; FRAZZI, E.; D'ALESSIO, P. Comparison of narrow-band and broad-band vegetation indices for canopy chlorophyll density estimation in sugar beet. In: *Precision Agriculture 2007 - Papers Presented at the 6th European Conference on Precision Agriculture*, ECPA 2007, p. 189–196, 2007.
- WANG, D. et al. Separating Tree Photosynthetic and Non-Photosynthetic Components from Point Cloud Data Using Dynamic Graph Convolutional Neural Networks. *Remote Sensing*, v. 12, n. 7, p. 1231, 2020. DOI: 10.3390/rs12071231.
- WANG, M. et al. The use of mobile lidar data and Gaofen-2 image to classify roadside trees. *Measurement Science and Technology*, v. 31, n. 12, p. 125005, 2020. DOI: 10.1088/1361-6501/aba322.
- WANG, Y. et al. Is field-measured tree height as reliable as believed – A comparison study of tree height estimates from field measurement, airborne laser scanning and terrestrial laser scanning in a boreal forest. *ISPRS Journal of Photogrammetry and Remote Sensing*, v. 147, p. 132-145, 2019. DOI: 10.1016/j.isprsjprs.2018.11.015.
- WHITE, J. C. et al. Remote sensing technologies for enhancing forest inventories: A review. *Canadian Journal of Remote Sensing*, 42(5), p. 619-641, 2016. DOI: 10.1080/07038992.2016.1207484.
- WIELGOSZ, M. et al. SegmentAnyTree: A sensor and platform agnostic deep learning model for tree segmentation using laser scanning data. *Remote Sensing of Environment*, v. 313, p. 114367, 2024. DOI: 10.1016/j.rse.2024.114367.
- WOEBBECKE, D. M. et al. Color indices for weed identification under various soil, residue, and lighting conditions. *Transactions of the ASAE*, v. 38, n. 1, p. 259–269, 1995. DOI: 10.13031/2013.27838.
- WOŁK, K.; TATARA, M. S. A Review of Semantic Segmentation and Instance Segmentation Techniques in Forestry Using LiDAR and Imagery Data. *Electronics*, v. 13, n. 20, p. 4139, 2024. DOI: 10.3390/electronics13204139.
- XIANG, B. et al. Automated forest inventory: Analysis of high-density airborne LiDAR point clouds with 3D deep learning. *Remote Sensing of Environment*, v. 305, p. 114078, 2024. DOI: 10.1016/j.rse.2024.114078.

- XIANG, B.; SCHINDLER, K.; LEITERER, R.; MORSDORF, F. Unsupervised deep learning for semantic segmentation of forest point clouds. arXiv:2502.06227, 2025. Disponível em: <https://arxiv.org/abs/2502.06227>. Acesso em: [data].
- XIE, B. et al. Regional forest volume estimation by expanding LiDAR samples using multi-sensor satellite data. *Remote Sensing*, v. 12, n. 3, p. 360, 2020. DOI: 10.3390/rs12030360.
- YADAV, V. et al. Assessing the Robustness of Multispectral Satellite Imagery with LiDAR Topographic Attributes and Ancillary Data to Predict Vertical Structure in a Wet Eucalypt Forest. *Remote Sensing*, v. 17, n. 10, p. 1733–1733, 2025. DOI: 10.3390/rs17101733.
- YAN, K. et al. A global systematic review of the remote sensing vegetation indices. *International Journal of Applied Earth Observation and Geoinformation*, v. 139, p. 104560–104560, 2025. DOI: 10.1016/j.jag.2025.104560.
- YANG, S. et al. A Novel Point Cloud Adaptive Filtering Algorithm for LiDAR SLAM in Forest Environments Based on Guidance Information. *Remote Sensing*, v. 16, n. 15, p. 2714, 2024. DOI: 10.3390/rs16152714.
- YANG, W. et al. Greenness identification based on HSV decision tree. *Information Processing in Agriculture*, v. 2, n. 3-4, p. 149–160, 2015. DOI: 10.1016/j.inpa.2015.07.003.
- YOSHII, T.; MATSUMURA, N.; LIN, C. Integrating UAV-SfM and Airborne Lidar Point Cloud Data to Plantation Forest Feature Extraction. *Remote Sensing*, v. 14, n. 7, p. 1713, 2022. DOI: 10.3390/rs14071713.
- ZEYBEK, M.; VATANDAŞLAR, C. An Automated Approach for Extracting Forest Inventory Data from Individual Trees Using a Handheld Mobile Laser Scanner. *Croatian Journal of Forest Engineering*, v. 42, n. 3, p. 517-530, 2021. DOI: 10.5552/crojfe.2021.1096.
- ZHANG, C.; ZHOU, Y.; QIU, F. Individual Tree Segmentation from LiDAR Point Clouds for Urban Forest Inventory. *Remote Sensing*, v. 7, n. 6, p. 7892-7913, 2015. DOI: 10.3390/rs7067892.
- ZHANG, W. et al. An Easy-to-Use Airborne LiDAR Data Filtering Method Based on Cloth Simulation. *Remote Sensing*, v. 8, n. 6, p. 501, 2016. DOI: 10.3390/rs8060501.
- ZHAO, X. et al. Fast Segment Anything. arXiv:2306.12156, 2023. Disponível em: <https://arxiv.org/abs/2306.12156>. Acesso em: [data].
- ZHAO, X. et al. Leaf-wood classification of airborne LiDAR point clouds using a multi-scale convolutional neural network. *International Journal of Applied Earth Observation and Geoinformation*, v. 101, p. 102356, 2021. DOI: 10.1016/j.jag.2021.102356.

APÊNDICE 1 - DESCRIÇÃO DOS PROGRAMAS, PACOTES, FERRAMENTAS, ALGORITMOS E FUNÇÕES APLICADOS.

Programa	Linguagem	Dados	Pacote/ algoritmo/ ferramenta	Autor	Etapa	Tópico relativo	Funções e parâmetros
Rstudio 2023.12.1 Build 402	R 4.4.2	UAV-LiDAR	lidR 4.1.2	Roussel & Auty (2023)	Pré-processamento		catalog_retile() opt_chunk_buffer(ctg) <- 0 opt_chunk_size(ctg) <- 100
		MLS e Combinação					catalog_retile() opt_chunk_buffer(ctg) <- 0 opt_chunk_size(ctg) <- 40
		UAV-LiDAR, MLS e Combinação					ctg()
		UAV-LiDAR					rasterize_canopy(x, res = 0.1, algorithm = p2r(na.fill = tin()))
		UAV-LiDAR					classify_ground(x, csf())
		UAV-LiDAR, MLS e Combinação					rasterize_terrain(x, res = 0.1, algorithm = tin())
		UAV-LiDAR					normalize_height(x, tin())
		UAV-LiDAR					locate_trees(x, lmf(y))
		UAV-LiDAR, MLS e Combinação					segment_trees(ctg, silva2016(x, y, max_cr_factor = 0.3, exclusion = 0.3))
		UAV-LiDAR	lidUrb 0.3.0	Lecigne (2022)	Extração de métricas individuais		crown_metrics(x, func = .stdtreemetrics, geom = "concave")
		UAV-LiDAR, MLS e Combinação					crown_metrics(x, func = .stdmetrics)
		UAV-LiDAR, MLS e Combinação	ITSMe 2.0.0	Louise, T. (2022)			crown_metrics(x, func = ~as.list(lmom::samilmu(Z)))
		UAV-LiDAR, MLS e Combinação					green_crown_volume(x, npts_in_clust = 200)
		UAV-LiDAR, MLS e Combinação					leaves_traits(x, layer_thickness = 0.2)
		UAV-LiDAR, MLS e Combinação					projected_area_pc()

				alpha_volume_pc()
	rLiDAR 0.1.6	Silva (2019)		CrownMetrics()
	lidR 4.1.2	Roussel & Auty (2023)	Todas	<code>readLAS()</code> <code>writeLAS()</code> <code>clip_roi()</code>
			Segmentação de árvores individuais; Segmentação semântica	<code>tlsSample(x, smp.voxelize(0.02))</code>
MLS e Combinação	TreeLS 2.0.2	Conto (2020)	Segmentação de árvores individuais	<code>treeMap(x, map.hough(min_density = 0.3), 0)</code>
			Segmentação de árvores individuais; Segmentação semântica	<code>treePoints(x, map, trp.crop())</code> <code>stemPoints(x, stm.hough())</code> <code>tlsInventory(x, d_method = shapeFit())</code>
	Microsoft Visual Studio Code 1.97	Python 3.9		Padrão, exceto por: <code>num_cpu_cores=4</code> <code>ground_veg_cutoff_height=0.001</code>
	Rstudio 2023.12.1 Build 402	R 4.4.2	FSCT	Krisanski et al. (2021)
		dbSCAN 1.2.2	Hahsler, Piekenbrock & Doran (2019)	Segmentação de árvores individuais
3DFin 0.5.0a1	standalone	-	Laino et al. (2024)	Padrão, exceto por: Pruning Intensity = 5, Stripe Upper Limit = 2,5
Rstudio 2023.12.1 Build 402	R 4.4.2	ForestClassR/FSCT	Bielak (2025)	<code>run_fsct(x)</code>
		TreeLS 2.0.2	Conto (2020)	<code>treeMap(x, map.hough(min_density = 0.4), 0)</code> <code>nnFilter(x, d = 0.05, n = 30)</code>

		lidR 4.1.2	Roussel & Auty (2023)		catalog_retile()
MATLAB R2024B	matlab	TreeQSM 2.4.1	Raumonen & Åkerblom (2022)		Modificado (ver código)
					read_tree_pc()
					tree_position_pc()
					tree_height_pc()
					dbh_pc(x, thresholdR2 = 0.01, slice_thickness = 0.1)
					read_tree_qsm()
					stem_branch_angle_qsm()
				Extração de métricas individuais	stem_branch_cluster_size_qsm()
Rstudio 2023.12.1 Build 402	R 4.4.2	ITSMe 2.0.0	Louise, T. (2022)		volume_below_55_qsm()
					cylinder_length_volume_ratio_qsm()
					shedding_ratio_qsm()
					branch_angle_ratio_qsm()
					relative_volume_ratio_qsm()
					crown_evenness_qsm()
					stem_branch_radius_qsm()
					stem_branch_length_qsm()
					stem_branch_distance_qsm()
					dbh_height_ratio_qsm()
					dbh_volume_ratio_qsm()

				crown_start_height_qsm()
				crown_height_qsm()
				crown_diameterheight_ratio_qsm()
				dbh_minradius_ratio_qsm()
AdTree 1.1.2 standalone		-	DU et al. (2019)	Padrão
Rstudio 2023.12.1 Build 402	R 4.4.2	Morpho 2.0.3-1	Stefan & Schlager (2017)	obj2mesh()
		lidUrb 0.3.0	Lecigne (2022)	adtree2qsm() qsm_topology()
		terra	Rspatial	Pré-processamento e cálculo de índices de vegetação
				rast() vect() project() writeRaster()
Microsoft Visual Studio Code 1.97	Python 3.8	detectree2 2.0.1	Ball et al. (2023)	Modelo: 250312_flexi.pth
	Espectrais	FastSAM	Zhao et al. (2023)	Modelo: FastSAM-x.pt; FastSAM-s.pt
		SAM	Kirillov et al. (2023)	Modelo: sam_b.pt
		SAM2	Ravi et al. (2024)	Modelo: sam2.1_hiera_large.pt/sam2.1_hiera_l.yaml
	Python 3.8	ultralytics	Jocher, Qiu & Chaurasia (2023)	Modelo: yolo11x-seg.pt
QGIS 3.34.6 standalone		-	QGIS (2025)	Criar grade (3x2 metros); Centroides; Buffer (1 metro)

APÊNDICE 2 - DESCRIÇÃO DAS MÉTRICAS EXTRAÍDAS DOS DADOS UAV-LIDAR

Métricas UAV-LiDAR	Origem	Base	Descrição
hc	Próprio	Nuvem	Altura de copa (m)
perimetro	Próprio	Nuvem	Perímetro de copa (m)
dap_maior_c	Próprio	Nuvem	Diâmetro maior da copa (m)
dap_perp_c	Próprio	Nuvem	Diâmetro perpendicular ao maior (m)
LAI_1	lidUrb	Nuvem	Índice de área foliar
TLA_1	lidUrb	Nuvem	Área foliar total (m^2)
LAD_10_1	lidUrb	Nuvem	Densidade de área foliar a 10% da copa
LAD_20_1	lidUrb	Nuvem	Densidade de área foliar a 20% da copa
LAD_30_1	lidUrb	Nuvem	Densidade de área foliar a 30% da copa
LAD_40_1	lidUrb	Nuvem	Densidade de área foliar a 40% da copa
LAD_50_1	lidUrb	Nuvem	Densidade de área foliar a 50% da copa
LAD_60_1	lidUrb	Nuvem	Densidade de área foliar a 60% da copa
LAD_70_1	lidUrb	Nuvem	Densidade de área foliar a 70% da copa
LAD_80_1	lidUrb	Nuvem	Densidade de área foliar a 80% da copa
LAD_90_1	lidUrb	Nuvem	Densidade de área foliar a 90% da copa
LAD_100_1	lidUrb	Nuvem	Densidade de área foliar a 100% da copa
ETOP_3	rLiDAR	Nuvem	Coordenada UTM Leste do topo da árvore
NTOP_3	rLiDAR	Nuvem	Coordenada UTM Norte do topo da árvore
EMIN_3	rLiDAR	Nuvem	Coordenada UTM Leste mínima
NMIN_3	rLiDAR	Nuvem	Coordenada UTM Norte mínima
EMAX_3	rLiDAR	Nuvem	Coordenada UTM Leste máxima
NMAX_3	rLiDAR	Nuvem	Coordenada UTM Norte máxima
EWIDTH_3	rLiDAR	Nuvem	Largura leste da copa da árvore
NWIDTH_3	rLiDAR	Nuvem	Largura norte da copa da árvore
HMIN_3	rLiDAR	Nuvem	Altura mínima (m)
HMEDIAN_3	rLiDAR	Nuvem	Mediana da altura (m)
HMODE_3	rLiDAR	Nuvem	Moda da altura (m)
HVAR_3	rLiDAR	Nuvem	Variância da altura (m)
HCV_3	rLiDAR	Nuvem	Coeficiente de variação da altura
ISKE_3	rLiDAR	Nuvem	Assimetria das intensidades
I05TH_3	rLiDAR	Nuvem	5º percentil da intensidade
I10TH_3	rLiDAR	Nuvem	10º percentil da intensidade
I15TH_3	rLiDAR	Nuvem	15º percentil da intensidade
I20TH_3	rLiDAR	Nuvem	20º percentil da intensidade
I25TH_3	rLiDAR	Nuvem	25º percentil da intensidade
I30TH_3	rLiDAR	Nuvem	30º percentil da intensidade

I35TH_3	rLiDAR	Nuvem	35º percentil da intensidade
I40TH_3	rLiDAR	Nuvem	40º percentil da intensidade
I45TH_3	rLiDAR	Nuvem	45º percentil da intensidade
I50TH_3	rLiDAR	Nuvem	50º percentil da intensidade
I55TH_3	rLiDAR	Nuvem	55º percentil da intensidade
I60TH_3	rLiDAR	Nuvem	60º percentil da intensidade
I65TH_3	rLiDAR	Nuvem	65º percentil da intensidade
I70TH_3	rLiDAR	Nuvem	70º percentil da intensidade
I75TH_3	rLiDAR	Nuvem	75º percentil da intensidade
I80TH_3	rLiDAR	Nuvem	80º percentil da intensidade
I90TH_3	rLiDAR	Nuvem	90º percentil da intensidade
I95TH_3	rLiDAR	Nuvem	95º percentil da intensidade
I99TH_3	rLiDAR	Nuvem	99º percentil da intensidade
npoints_4	lidR	Nuvem	Número total de pontos
convhull_area_4	lidR	Nuvem	Área de copa (m^2)
zmax_4	lidR	Nuvem	Altura máxima (m)
zmean_4	lidR	Nuvem	Altura média (m)
zsd_4	lidR	Nuvem	Desvio padrão da altura (m)
zskew_4	lidR	Nuvem	Assimetria das alturas
zkurt_4	lidR	Nuvem	Curtose das alturas
zentropy_4	lidR	Nuvem	Entropia da altura
pzabovemean_4	lidR	Nuvem	Porcentagem da altura abaixo da média
pzabove2_4	lidR	Nuvem	Porcentagem da altura abaixo de 2th
zq5_4	lidR	Nuvem	5º percentil da altura (m)
zq10_4	lidR	Nuvem	10º percentil da altura (m)
zq15_4	lidR	Nuvem	15º percentil da altura (m)
zq20_4	lidR	Nuvem	20º percentil da altura (m)
zq25_4	lidR	Nuvem	25º percentil da altura (m)
zq30_4	lidR	Nuvem	30º percentil da altura (m)
zq35_4	lidR	Nuvem	35º percentil da altura (m)
zq40_4	lidR	Nuvem	40º percentil da altura (m)
zq45_4	lidR	Nuvem	45º percentil da altura (m)
zq50_4	lidR	Nuvem	50º percentil da altura (m)
zq55_4	lidR	Nuvem	55º percentil da altura (m)
zq60_4	lidR	Nuvem	60º percentil da altura (m)
zq65_4	lidR	Nuvem	65º percentil da altura (m)
zq70_4	lidR	Nuvem	70º percentil da altura (m)
zq75_4	lidR	Nuvem	75º percentil da altura (m)
zq80_4	lidR	Nuvem	80º percentil da altura (m)

zq85_4	lidR	Nuvem	90º percentil da altura (m)
zq90_4	lidR	Nuvem	95º percentil da altura (m)
zq95_4	lidR	Nuvem	99º percentil da altura (m)
zpcum1_4	lidR	Nuvem	Percentual de alturas até 11%
zpcum2_4	lidR	Nuvem	Percentual de alturas até 22%
zpcum3_4	lidR	Nuvem	Percentual de alturas até 33%
zpcum4_4	lidR	Nuvem	Percentual de alturas até 44%
zpcum5_4	lidR	Nuvem	Percentual de alturas até 56%
zpcum6_4	lidR	Nuvem	Percentual de alturas até 67%
zpcum7_4	lidR	Nuvem	Percentual de alturas até 78%
zpcum8_4	lidR	Nuvem	Percentual de alturas até 89%
zpcum9_4	lidR	Nuvem	Percentual de alturas até 100%
area_4	lidR	Nuvem	Área de copa (m^2)
l_1_4	lidR	Nuvem	L-moments L1
l_2_4	lidR	Nuvem	L-moments L2
t_3_4	lidR	Nuvem	L-moments L3
t_4_4	lidR	Nuvem	L-moments L4
itot_4	lidR	Nuvem	Intensidade total
imax_4	lidR	Nuvem	Intensidade máxima
imean_4	lidR	Nuvem	Intensidade média
isd_4	lidR	Nuvem	Desvio padrão da intensidade
iskew_4	lidR	Nuvem	Assimetria das intensidades
ikurt_4	lidR	Nuvem	Curtose das intensidades
ipcumzq10_4	lidR	Nuvem	Percentual de intensidades até o 10º percentil da altura
ipcumzq30_4	lidR	Nuvem	Percentual de intensidades até o 30º percentil da altura
ipcumzq50_4	lidR	Nuvem	Percentual de intensidades até o 50º percentil da altura
ipcumzq70_4	lidR	Nuvem	Percentual de intensidades até o 70º percentil da altura
ipcumzq90_4	lidR	Nuvem	Percentual de intensidades até o 90º percentil da altura
p1th_4	lidR	Nuvem	Percentual de retornos no terço superior da altura
p2th_4	lidR	Nuvem	Percentual de retornos no terço intermediário da altura
p3th_4	lidR	Nuvem	Percentual de retornos no terço inferior da altura

APÊNDICE 3 - DESCRIÇÃO DAS MÉTRICAS EXTRAÍDAS DOS DADOS LIDAR MLS E COMBINAÇÃO

Métricas MLS e Combinação	Origem	Base	Descrição
dap	AdTree + lidUrb	QSM	Diâmetro à altura do peito (m)
volume_total	AdTree + lidUrb	QSM	Volume total (fuste + ramos) (m ³)
length	AdTree + lidUrb	QSM	Comprimento (m)
h_1_d	AdTree + lidUrb	QSM	Diâmetro a 1% da altura total
h_2_d	AdTree + lidUrb	QSM	Diâmetro a 2% da altura total
h_3_d	AdTree + lidUrb	QSM	Diâmetro a 3% da altura total
h_4_d	AdTree + lidUrb	QSM	Diâmetro a 4% da altura total
h_5_d	AdTree + lidUrb	QSM	Diâmetro a 5% da altura total
h_10_d	AdTree + lidUrb	QSM	Diâmetro a 10% da altura total
h_15_d	AdTree + lidUrb	QSM	Diâmetro a 15% da altura total
h_25_d	AdTree + lidUrb	QSM	Diâmetro a 25% da altura total
h_35_d	AdTree + lidUrb	QSM	Diâmetro a 35% da altura total
h_45_d	AdTree + lidUrb	QSM	Diâmetro a 45% da altura total
h_50_d	AdTree + lidUrb	QSM	Diâmetro a 50% da altura total
h_55_d	AdTree + lidUrb	QSM	Diâmetro a 55% da altura total
h_65_d	AdTree + lidUrb	QSM	Diâmetro a 65% da altura total
h_75_d	AdTree + lidUrb	QSM	Diâmetro a 75% da altura total
h_85_d	AdTree + lidUrb	QSM	Diâmetro a 85% da altura total
h_95_d	AdTree + lidUrb	QSM	Diâmetro a 95% da altura total
Diameter_class_X-X_length	AdTree + lidUrb	QSM	Classe de diâmetro X a X - Comprimento (m)
Diameter_class_X-X_volume	AdTree + lidUrb	QSM	Classe de diâmetro X a X - Volume (m ³)
Branching_order_X_length	AdTree + lidUrb	QSM	Ordem de ramificações X - Comprimento (m)
Branching_order_X_volume	AdTree + lidUrb	QSM	Ordem de ramificações X - Volume (m ³)
Axes_X_length	AdTree + lidUrb	QSM	Comprimento do eixo X (m)

Axes_X_volume	AdTree + lidUrb	QSM	Volume do eixo X (m ³)
cloud.dbh	ITSMe	Nuvem	Diâmetro à altura do peito (circular) (m)
cloud.fdbh	ITSMe	Nuvem	Diâmetro à altura do peito (polígono fit) (m)
cloud.ht	ITSMe	Nuvem	Altura total (m)
cloud.crown_area	ITSMe	Nuvem	Área de copa (m ²)
cloud.crown_volume	ITSMe	Nuvem	Volume de copa (m ³)
qsm.stem_branch_angle	ITSMe + TreeQSM	QSM	Ângulo do ramo do fuste (graus)
qsm.stem_branch_cluster_si ze	ITSMe + TreeQSM	QSM	Tamanho do grupo de ramos do fuste
qsm.volume_below_55	ITSMe + TreeQSM	QSM	Volume abaixo de 55%
qsm.cylinder_length_volume _ratio	ITSMe + TreeQSM	QSM	Relação entre volume e comprimento do cilindro (m ²)
qsm.shedding_ratio	ITSMe + TreeQSM	QSM	Proporção de queda
qsm.branch_angle_ratio	ITSMe + TreeQSM	QSM	Razão do ângulo do galho
qsm.relative_volume_ratio	ITSMe + TreeQSM	QSM	Índice de volume relativo
qsm.crown_evenness	ITSMe + TreeQSM	QSM	Regularidade da copa
qsm.stem_branch_radius	ITSMe + TreeQSM	QSM + Nuvem	Raio do ramo do fuste (m)
qsm.stem_branch_length	ITSMe + TreeQSM	QSM + Nuvem	Comprimento do ramo do fuste (m)
qsm.stem_branch_distance	ITSMe + TreeQSM	QSM + Nuvem	Distância do ramo do fuste (m)
qsm.dbh_height_ratio	ITSMe + TreeQSM	QSM + Nuvem	Relação dap/ht
qsm.dbh_volume_ratio	ITSMe + TreeQSM	QSM + Nuvem	Relação de volume da árvore (m ²)
qsm.crown_start_height	ITSMe + TreeQSM	QSM + Nuvem	Altura inicial da copa (m)
qsm.crown_height	ITSMe + TreeQSM	QSM + Nuvem	Altura da copa (m)
qsm.crown_diameterheight_r atio	ITSMe + TreeQSM	QSM + Nuvem	Razão entre o diâmetro da copa e a altura da copa
qsm.dbh_minradius_ratio	ITSMe + TreeQSM	QSM + Nuvem	Índice de raio mínimo da árvore (dap)
hc	Próprio	Nuvem	Altura de copa (m)
perimetro	Próprio	Nuvem	Perímetro de copa (m)
dap_maior_c	Próprio	Nuvem	Diâmetro maior da copa (m)
dap_perp_c	Próprio	Nuvem	Diâmetro perpendicular ao maior (m)
LAI_1	lidUrb	Nuvem	Índice de área foliar
TLA_1	lidUrb	Nuvem	Área foliar total (m ²)
LAD_10_1	lidUrb	Nuvem	Densidade de área foliar a 10% da copa
LAD_20_1	lidUrb	Nuvem	Densidade de área foliar a 20% da copa

LAD_30_1	lidUrb	Nuvem	Densidade de área foliar a 30% da copa
LAD_40_1	lidUrb	Nuvem	Densidade de área foliar a 40% da copa
LAD_50_1	lidUrb	Nuvem	Densidade de área foliar a 50% da copa
LAD_60_1	lidUrb	Nuvem	Densidade de área foliar a 60% da copa
LAD_70_1	lidUrb	Nuvem	Densidade de área foliar a 70% da copa
LAD_80_1	lidUrb	Nuvem	Densidade de área foliar a 80% da copa
LAD_90_1	lidUrb	Nuvem	Densidade de área foliar a 90% da copa
LAD_100_1	lidUrb	Nuvem	Densidade de área foliar a 100% da copa
ETOP_3	rLiDAR	Nuvem	Coordenada UTM Leste do topo da árvore (m)
NTOP_3	rLiDAR	Nuvem	Coordenada UTM Norte do topo da árvore (m)
EMIN_3	rLiDAR	Nuvem	Coordenada UTM Leste mínima (m)
NMIN_3	rLiDAR	Nuvem	Coordenada UTM Norte mínima (m)
EMAX_3	rLiDAR	Nuvem	Coordenada UTM Leste máxima (m)
NMAX_3	rLiDAR	Nuvem	Coordenada UTM Norte máxima (m)
EWIDTH_3	rLiDAR	Nuvem	Largura leste da copa da árvore (m)
NWIDTH_3	rLiDAR	Nuvem	Largura norte da copa da árvore (m)
HMIN_3	rLiDAR	Nuvem	Altura mínima (m)
HMEDIAN_3	rLiDAR	Nuvem	Mediana da altura (m)
HMODE_3	rLiDAR	Nuvem	Moda da altura (m)
HVAR_3	rLiDAR	Nuvem	Variância da altura (m)
HCV_3	rLiDAR	Nuvem	Coeficiente de variação da altura %
npoints_4	lidR	Nuvem	Número total de pontos
convhull_area_4	lidR	Nuvem	Área de copa (m ²)
zmax_4	lidR	Nuvem	Altura máxima (m)
zmean_4	lidR	Nuvem	Altura média (m)
zsd_4	lidR	Nuvem	Desvio padrão da altura (m)
zskew_4	lidR	Nuvem	Assimetria das alturas
zkurt_4	lidR	Nuvem	Curtose das alturas
zentropy_4	lidR	Nuvem	Entropia da altura
pzabovemean_4	lidR	Nuvem	Porcentagem da altura abaixo da média
pzabove2_4	lidR	Nuvem	Porcentagem da altura abaixo de 2th
zq5_4	lidR	Nuvem	5º percentil da altura (m)
zq10_4	lidR	Nuvem	10º percentil da altura (m)
zq15_4	lidR	Nuvem	15º percentil da altura (m)
zq20_4	lidR	Nuvem	20º percentil da altura (m)
zq25_4	lidR	Nuvem	25º percentil da altura (m)
zq30_4	lidR	Nuvem	30º percentil da altura (m)
zq35_4	lidR	Nuvem	35º percentil da altura (m)
zq40_4	lidR	Nuvem	40º percentil da altura (m)

zq45_4	lidR	Nuvem	45º percentil da altura (m)
zq50_4	lidR	Nuvem	50º percentil da altura (m)
zq55_4	lidR	Nuvem	55º percentil da altura (m)
zq60_4	lidR	Nuvem	60º percentil da altura (m)
zq65_4	lidR	Nuvem	65º percentil da altura (m)
zq70_4	lidR	Nuvem	70º percentil da altura (m)
zq75_4	lidR	Nuvem	75º percentil da altura (m)
zq80_4	lidR	Nuvem	80º percentil da altura (m)
zq85_4	lidR	Nuvem	90º percentil da altura (m)
zq90_4	lidR	Nuvem	95º percentil da altura (m)
zq95_4	lidR	Nuvem	99º percentil da altura (m)
zpcum1_4	lidR	Nuvem	Percentual de alturas até 11%
zpcum2_4	lidR	Nuvem	Percentual de alturas até 22%
zpcum3_4	lidR	Nuvem	Percentual de alturas até 33%
zpcum4_4	lidR	Nuvem	Percentual de alturas até 44%
zpcum5_4	lidR	Nuvem	Percentual de alturas até 56%
zpcum6_4	lidR	Nuvem	Percentual de alturas até 67%
zpcum7_4	lidR	Nuvem	Percentual de alturas até 78%
zpcum8_4	lidR	Nuvem	Percentual de alturas até 89%
zpcum9_4	lidR	Nuvem	Percentual de alturas até 100%
area_4	lidR	Nuvem	Área de copa (m ²)
l_1_4	lidR	Nuvem	L-moments L1
l_2_4	lidR	Nuvem	L-moments L2
t_3_4	lidR	Nuvem	L-moments L3
t_4_4	lidR	Nuvem	L-moments L4
d_10	Próprio	Nuvem	Proporção de ramos acumulados até 10% da altura total
d_20	Próprio	Nuvem	Proporção de ramos acumulados até 20% da altura total
d_30	Próprio	Nuvem	Proporção de ramos acumulados até 30% da altura total
d_40	Próprio	Nuvem	Proporção de ramos acumulados até 40% da altura total
d_50	Próprio	Nuvem	Proporção de ramos acumulados até 50% da altura total
d_60	Próprio	Nuvem	Proporção de ramos acumulados até 60% da altura total
d_70	Próprio	Nuvem	Proporção de ramos acumulados até 70% da altura total
d_80	Próprio	Nuvem	Proporção de ramos acumulados até 80% da altura total
d_90	Próprio	Nuvem	Proporção de ramos acumulados até 90% da altura total
d_100	Próprio	Nuvem	Proporção de ramos acumulados até a altura total

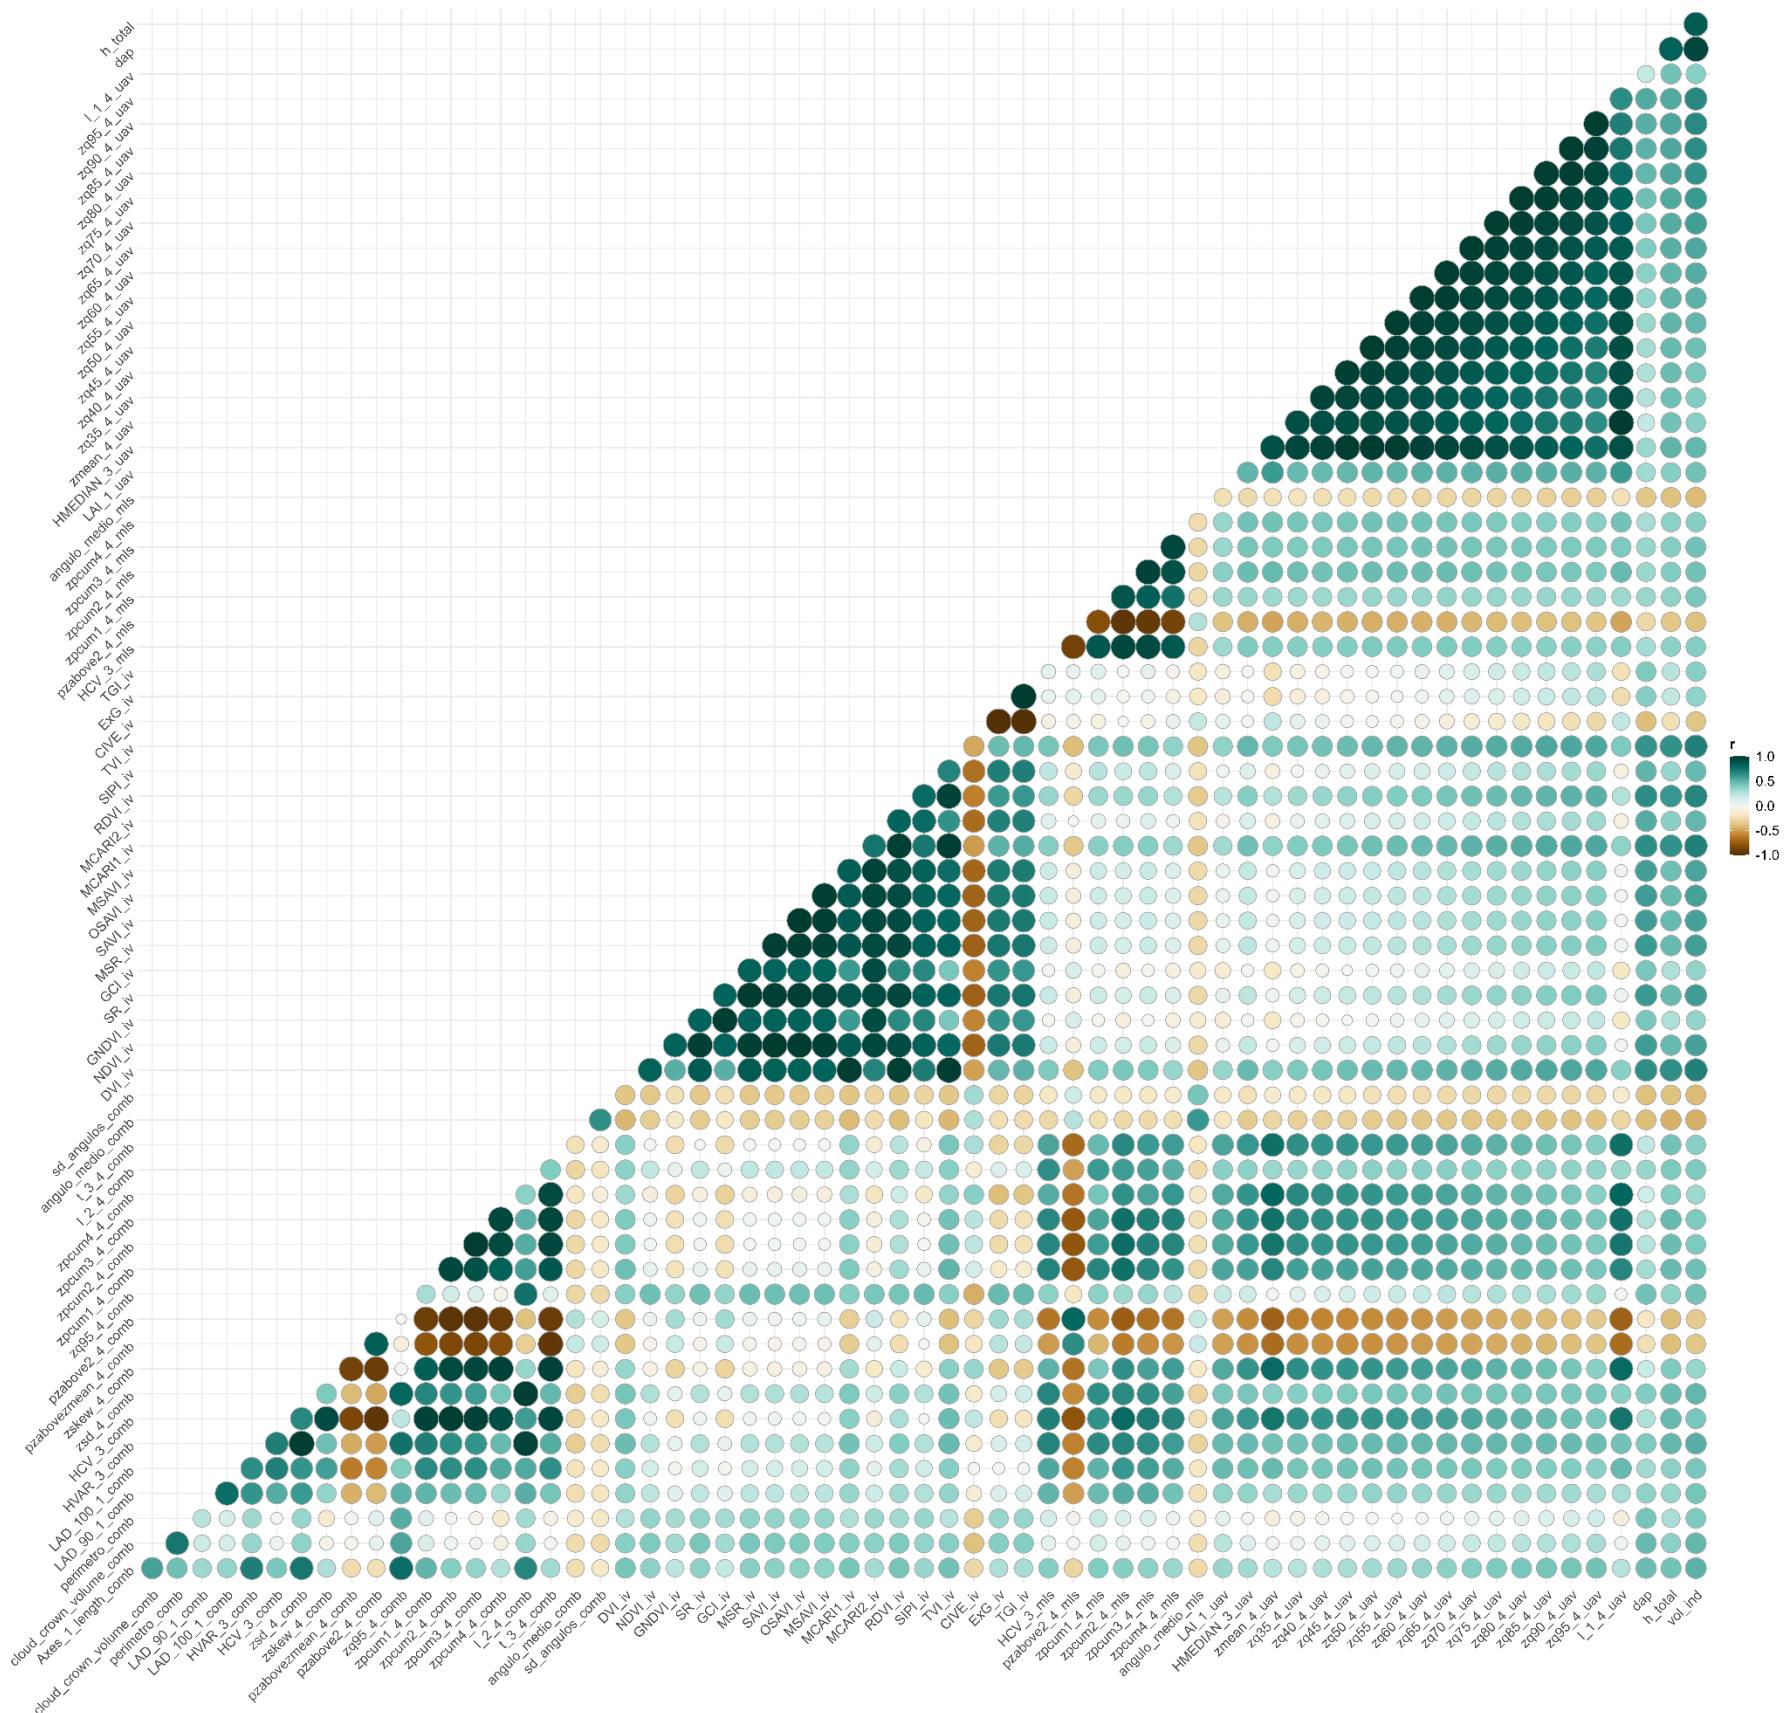
angulo_medio	Próprio	Nuvem	Ângulo médio do fuste em graus
sd_angulos	Próprio	Nuvem	Desvio padrão do ângulo médio do fuste
classificacao	Próprio	Nuvem	Classificação de qualidade do fuste
angulo_1	Próprio	Nuvem	Ângulo entre os centroides da seção 1 e 2 do fuste
angulo_2	Próprio	Nuvem	Ângulo entre os centroides da seção 2 e 3 do fuste
angulo_3	Próprio	Nuvem	Ângulo entre os centroides da seção 3 e 4 do fuste
angulo_4	Próprio	Nuvem	Ângulo entre os centroides da seção 4 e 5 do fuste
angulo_5	Próprio	Nuvem	Ângulo entre os centroides da seção 5 e 6 do fuste
angulo_6	Próprio	Nuvem	Ângulo entre os centroides da seção 6 e 7 do fuste
angulo_7	Próprio	Nuvem	Ângulo entre os centroides da seção 7 e 8 do fuste
angulo_8	Próprio	Nuvem	Ângulo entre os centroides da seção 8 e 9 do fuste
angulo_9	Próprio	Nuvem	Ângulo entre os centroides da seção 9 e 10 do fuste
TotalVolume	TreeQSM	Nuvem	Volume total (fuste + ramos) (L)
TrunkVolume	TreeQSM	Nuvem	Volume do fuste (L)
BranchVolume	TreeQSM	Nuvem	Volume dos ramos (L)
TreeHeight	TreeQSM	Nuvem	Altura total (m)
TrunkLength	TreeQSM	Nuvem	Comprimento do fuste (m)
BranchLength	TreeQSM	Nuvem	Comprimento de galhos (m)
TotalLength	TreeQSM	Nuvem	Comprimento total (m)
NumberBranches	TreeQSM	Nuvem	Número de ramos
MaxBranchOrder	TreeQSM	Nuvem	Ordem máxima de ramificação
TrunkArea	TreeQSM	Nuvem	Área do fuste (m^2)
BranchArea	TreeQSM	Nuvem	Área de ramos (m^2)
TotalArea	TreeQSM	Nuvem	Área total (m^2)
DBHqsm	TreeQSM	Nuvem	Diâmetro à altura do peito QSM (m)
DBHcyl	TreeQSM	Nuvem	Diâmetro à altura do peito cilindro (m)
CrownDiamAve	TreeQSM	Nuvem	Diâmetro médio de copa (m)
CrownDiamMax	TreeQSM	Nuvem	Diâmetro máximo de copa (m)
CrownAreaConv	TreeQSM	Nuvem	Área de copa (m^2)
CrownAreaAlpha	TreeQSM	Nuvem	Área de copa (m^2)
CrownBaseHeight	TreeQSM	Nuvem	Altura de copa (m)
CrownLength	TreeQSM	Nuvem	Comprimento de copa (m)
CrownRatio	TreeQSM	Nuvem	Proporção de copa
CrownVolumeConv	TreeQSM	Nuvem	Volume de copa (m^3)
CrownVolumeAlpha	TreeQSM	Nuvem	Volume de copa (m^3)

APÊNDICE 4 - LINK E QR CODE PARA REPOSITÓRIO GITHUB CONTENDO OS CÓDIGOS DESENVOLVIDOS

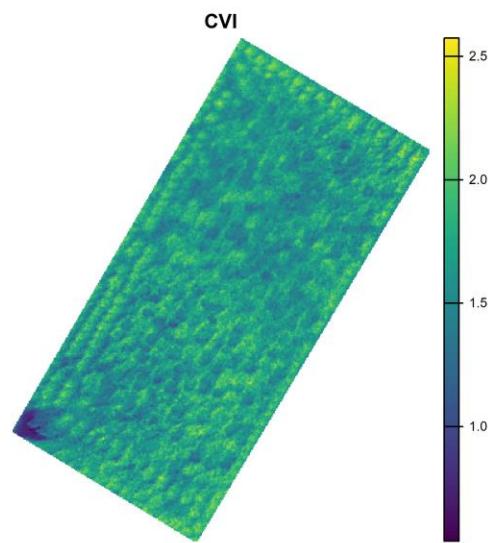
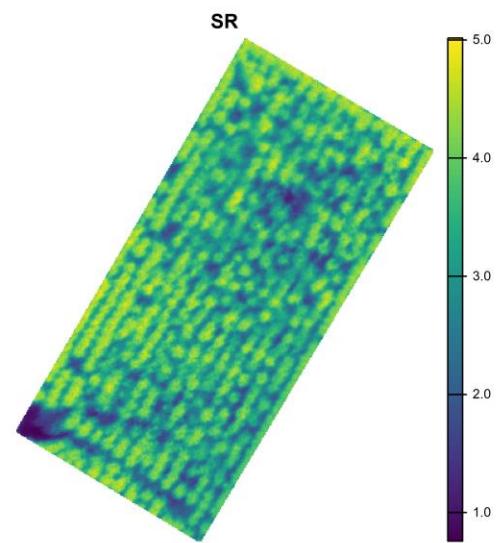
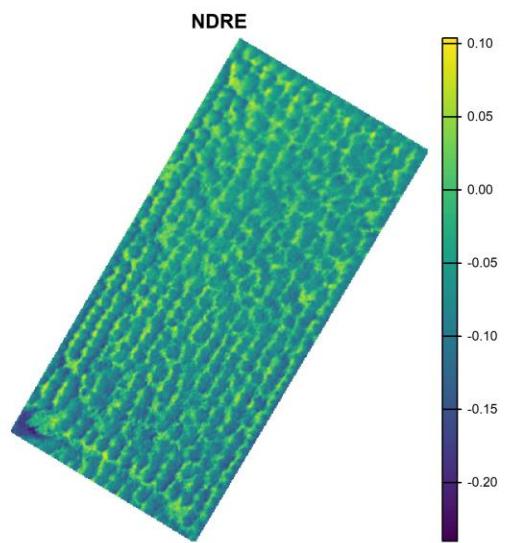
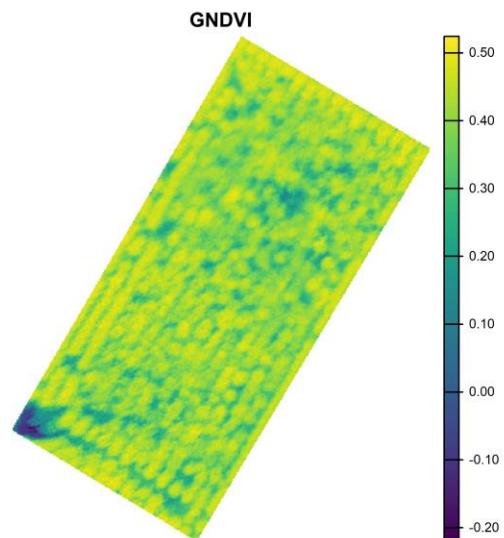
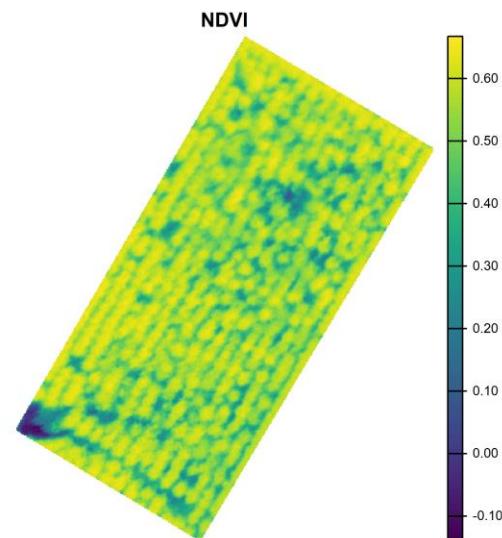
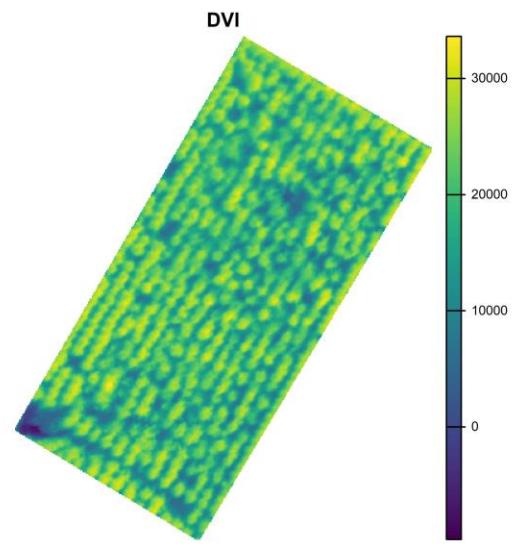
Link: <https://github.com/Nat-MZ99/Pipeline-for-extracting-metrics-from-MLS-UAV-LiDAR-and-Combination-forest-data>

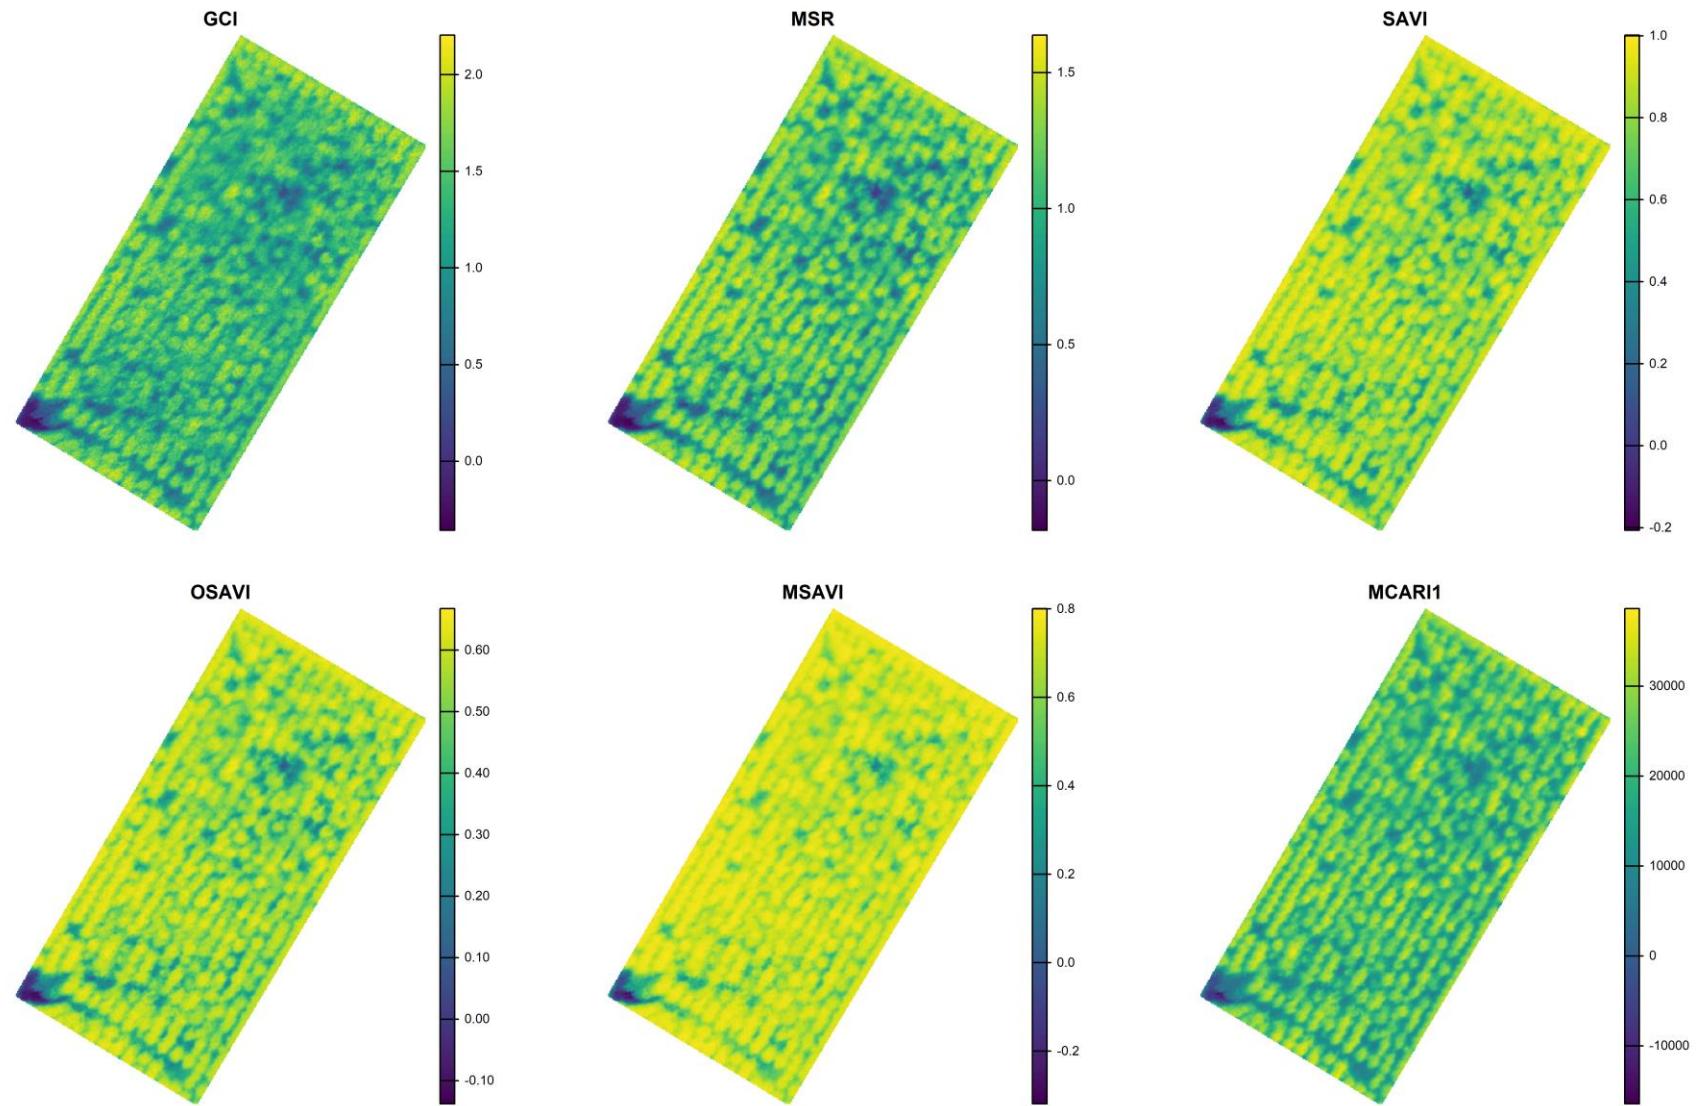


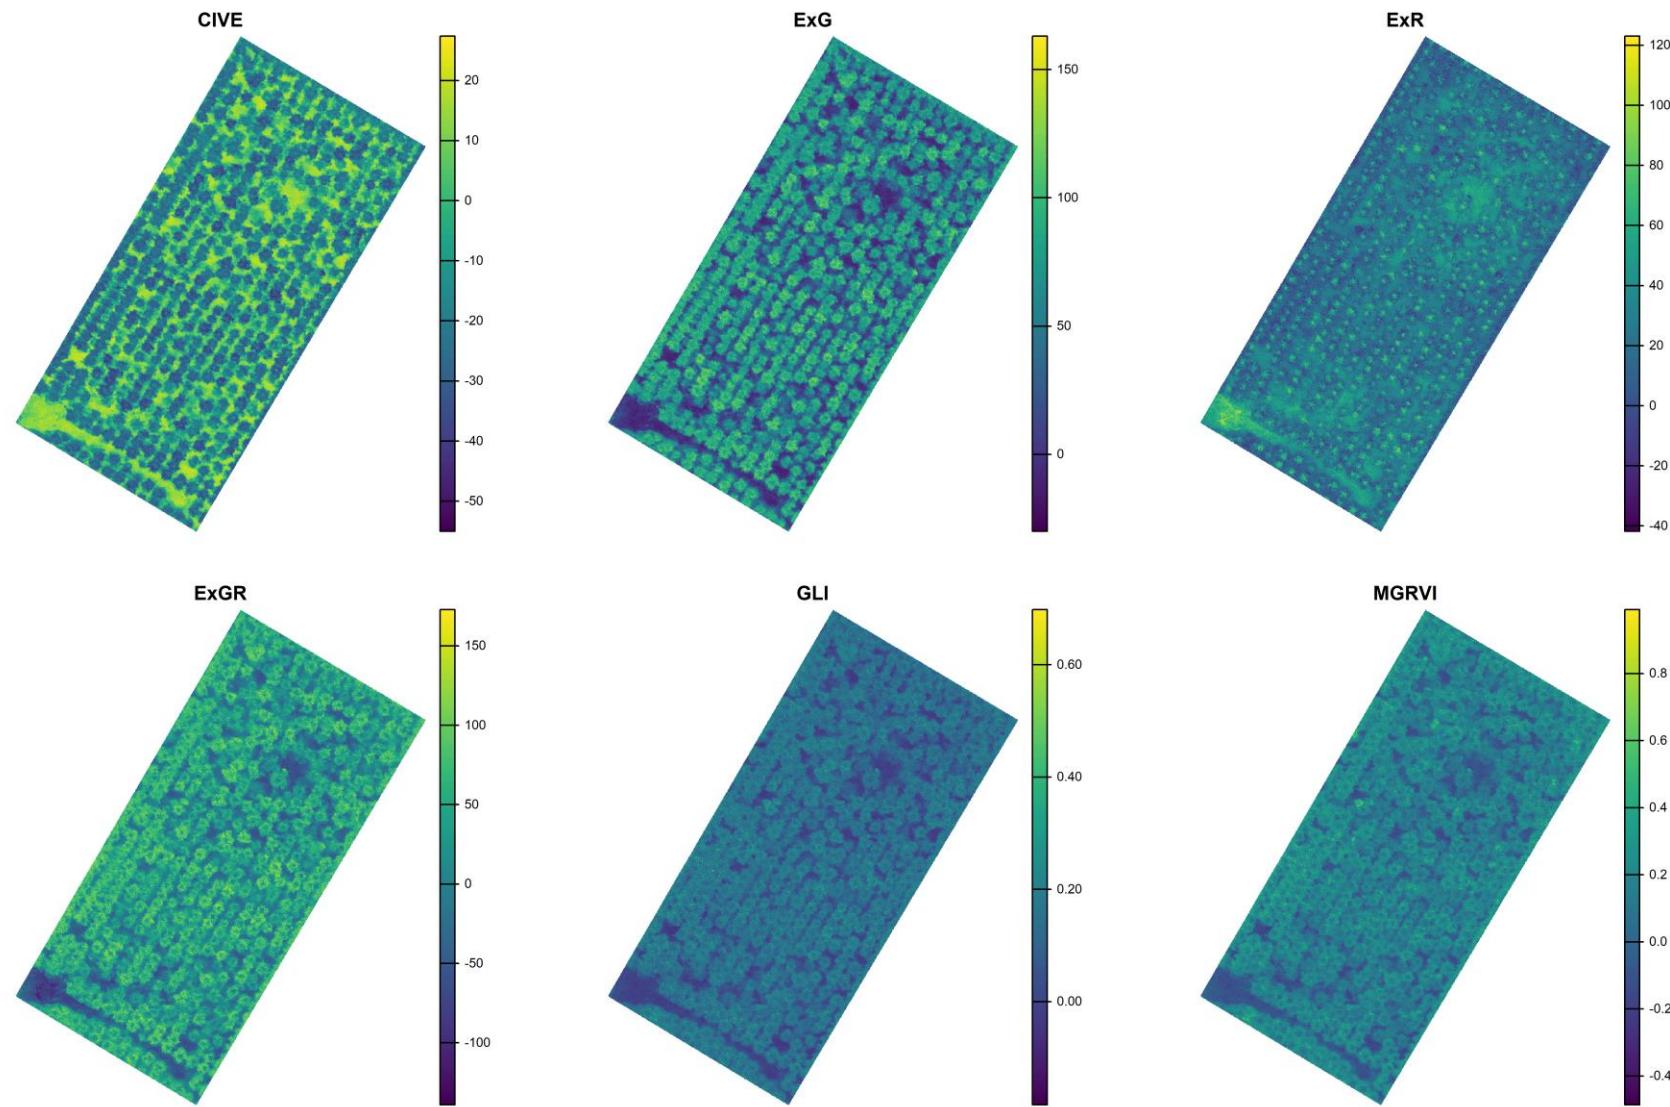
APÊNDICE 5 - MATRIZ DE CORRELAÇÃO COMPLETA - MÉTRICAS NÃO PAREADAS COM $r > 0,4$

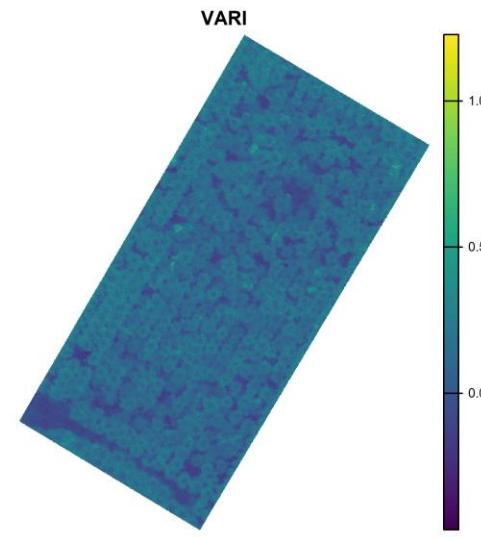
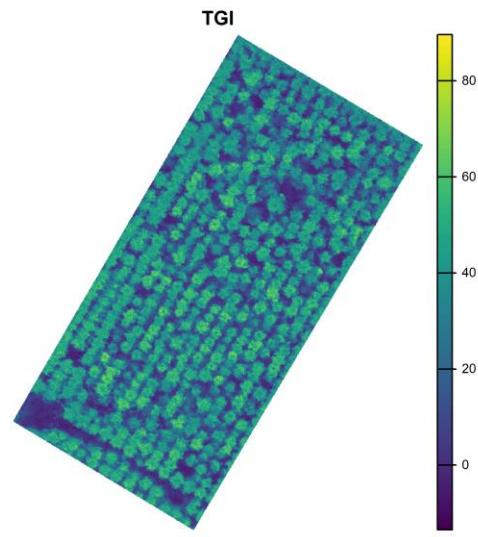
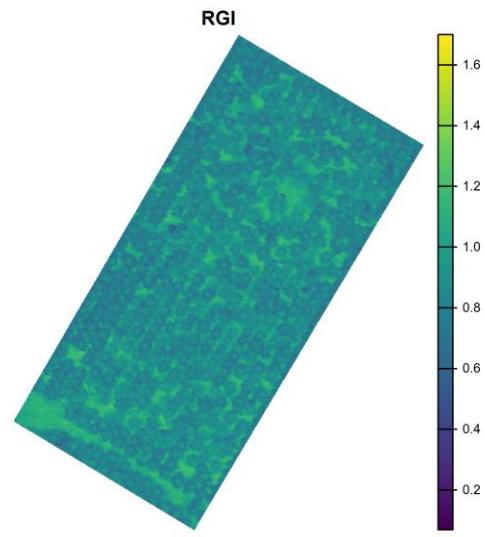
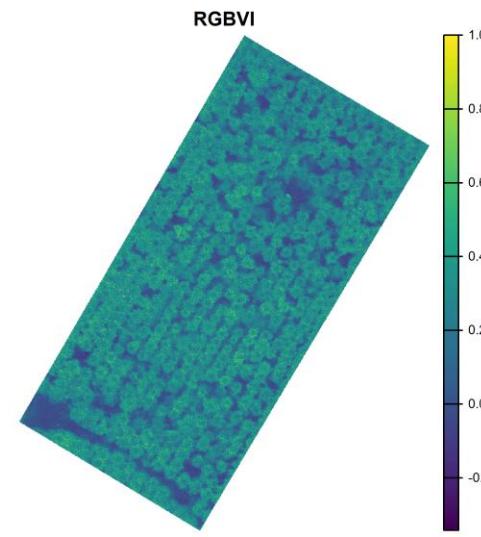
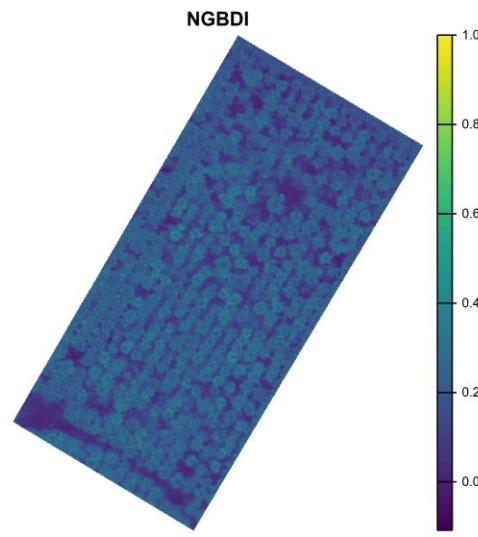
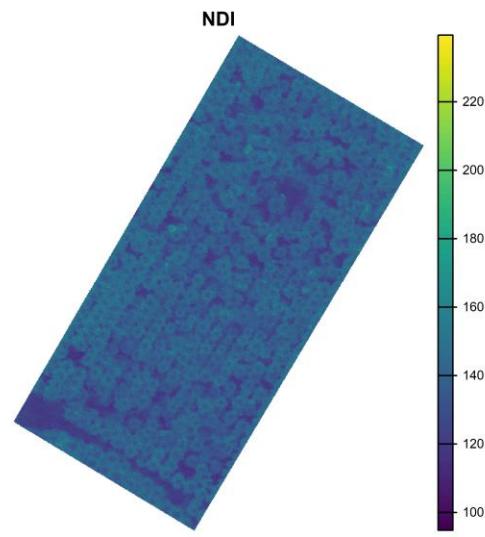


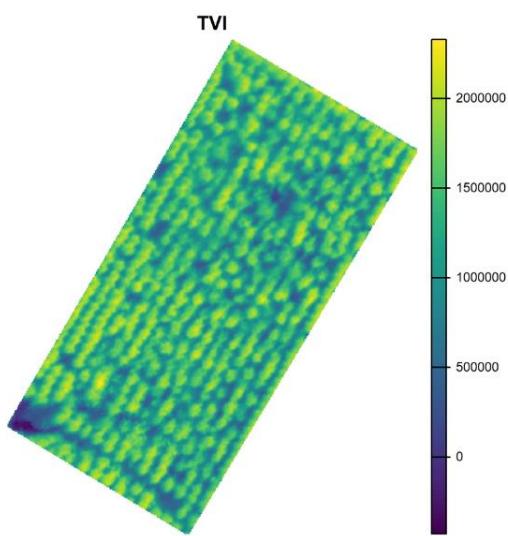
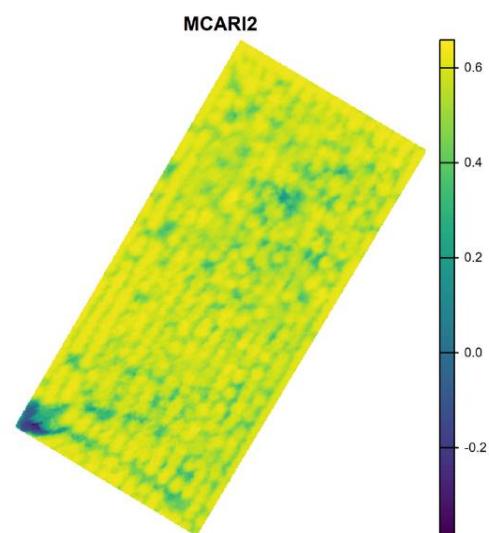
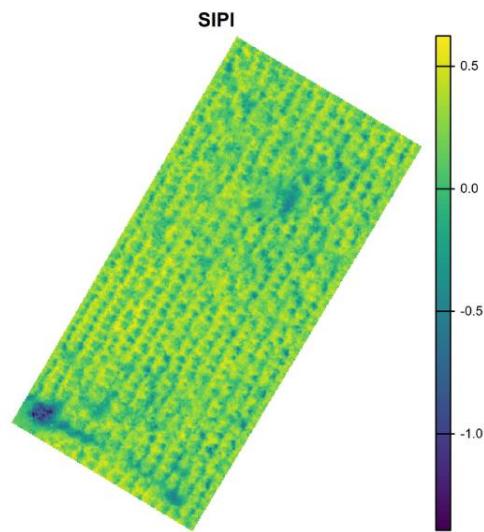
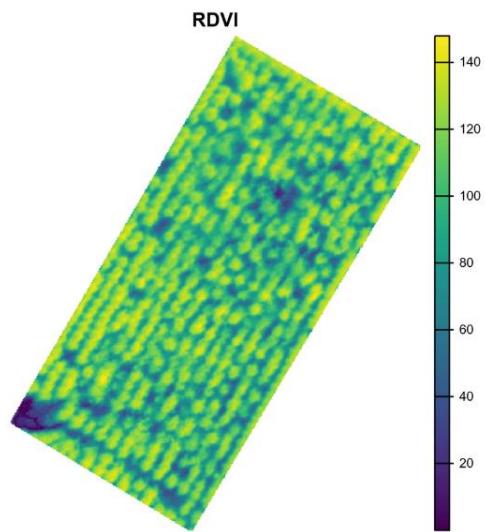
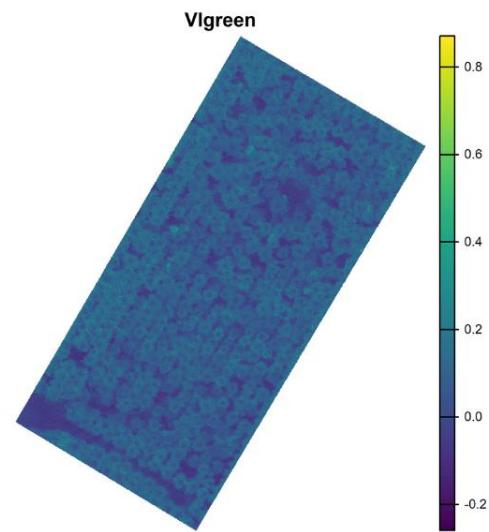
APÊNDICE 6 - PLOT DOS IV CALCULADOS - EXPERIMENTO DE CAÇAPAVA



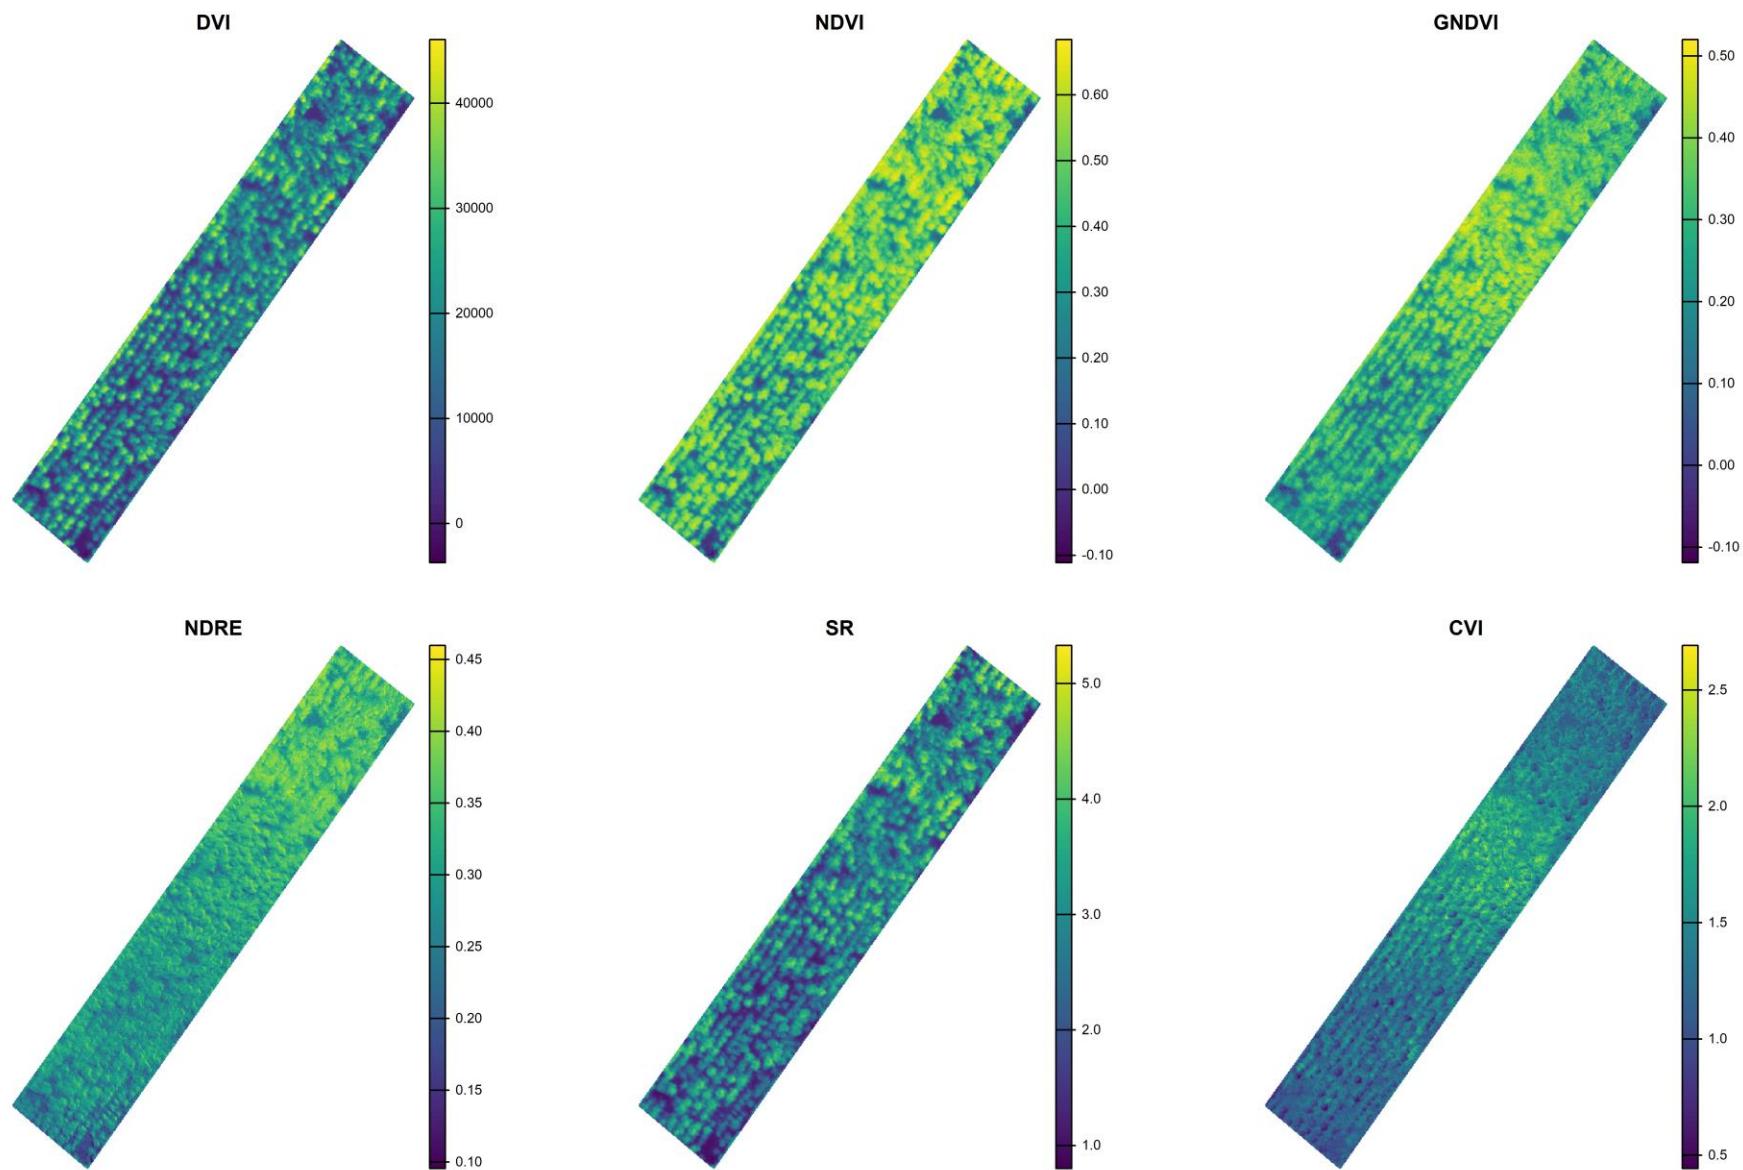


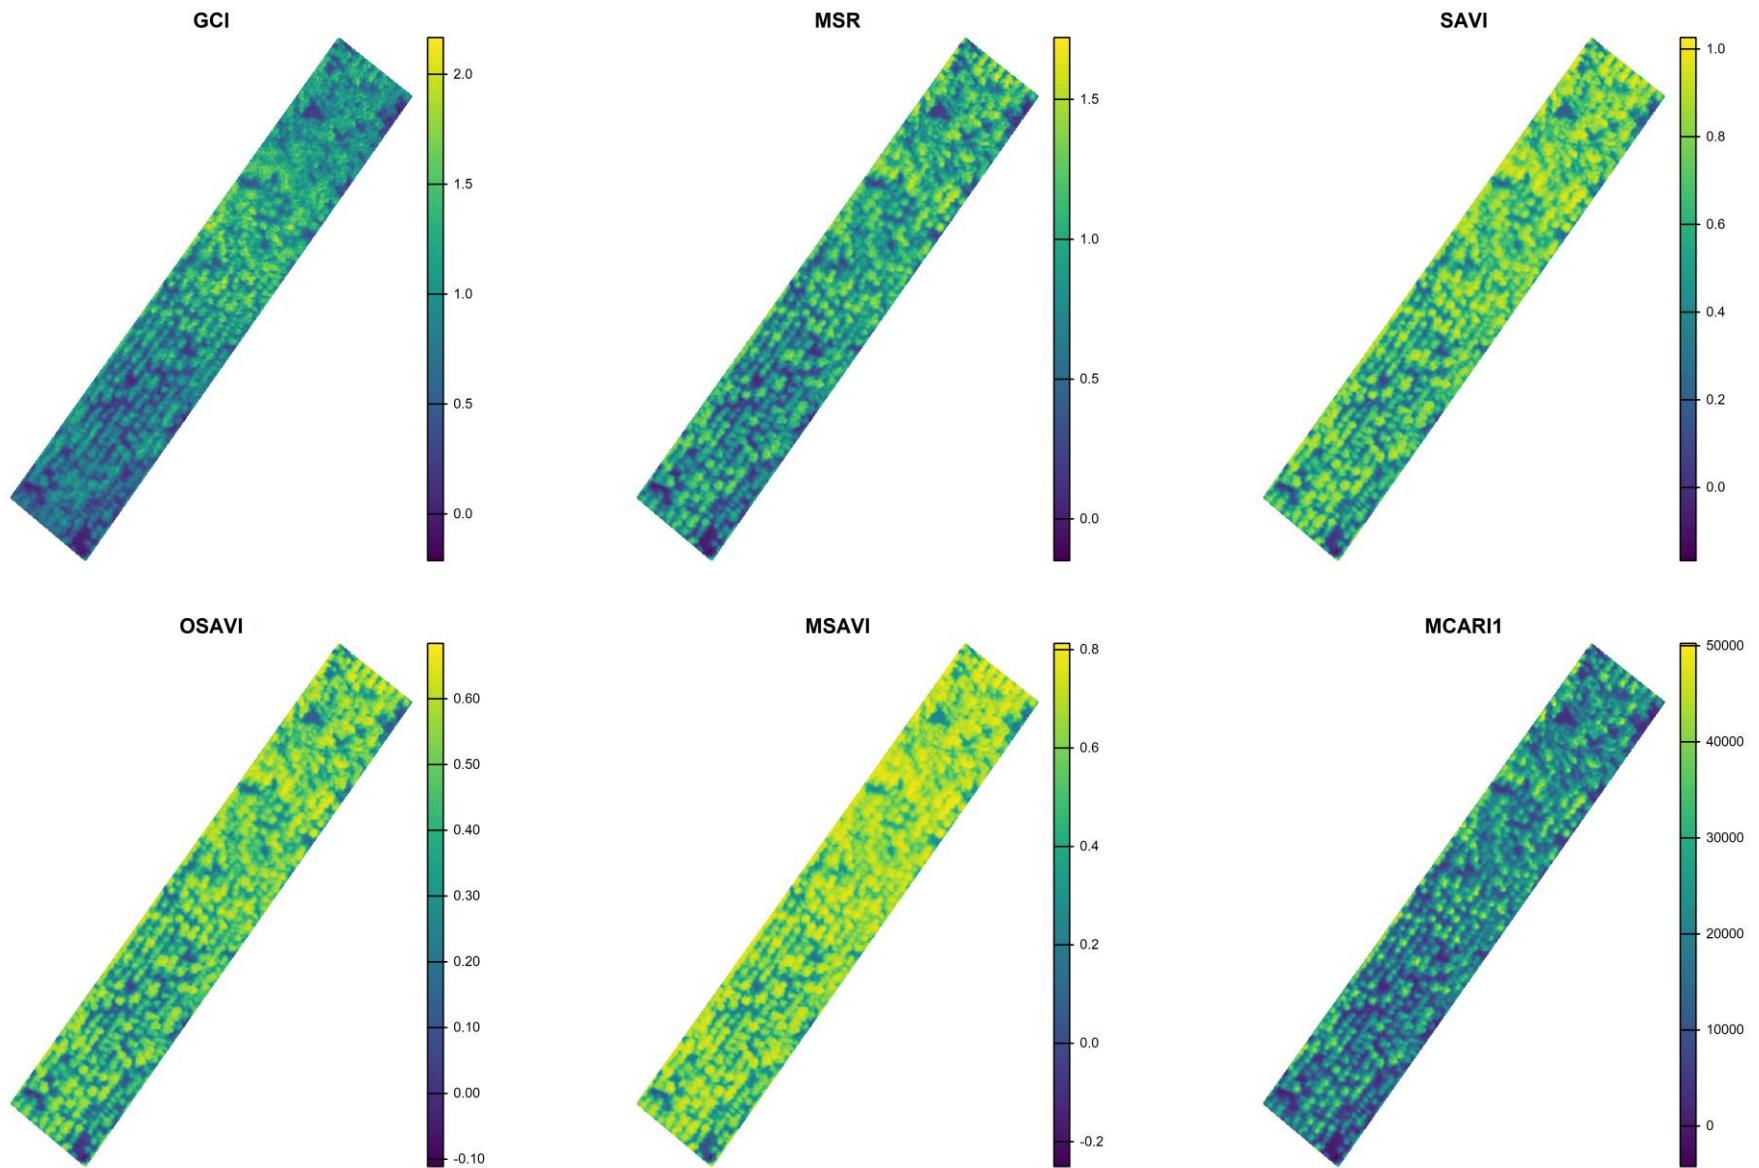


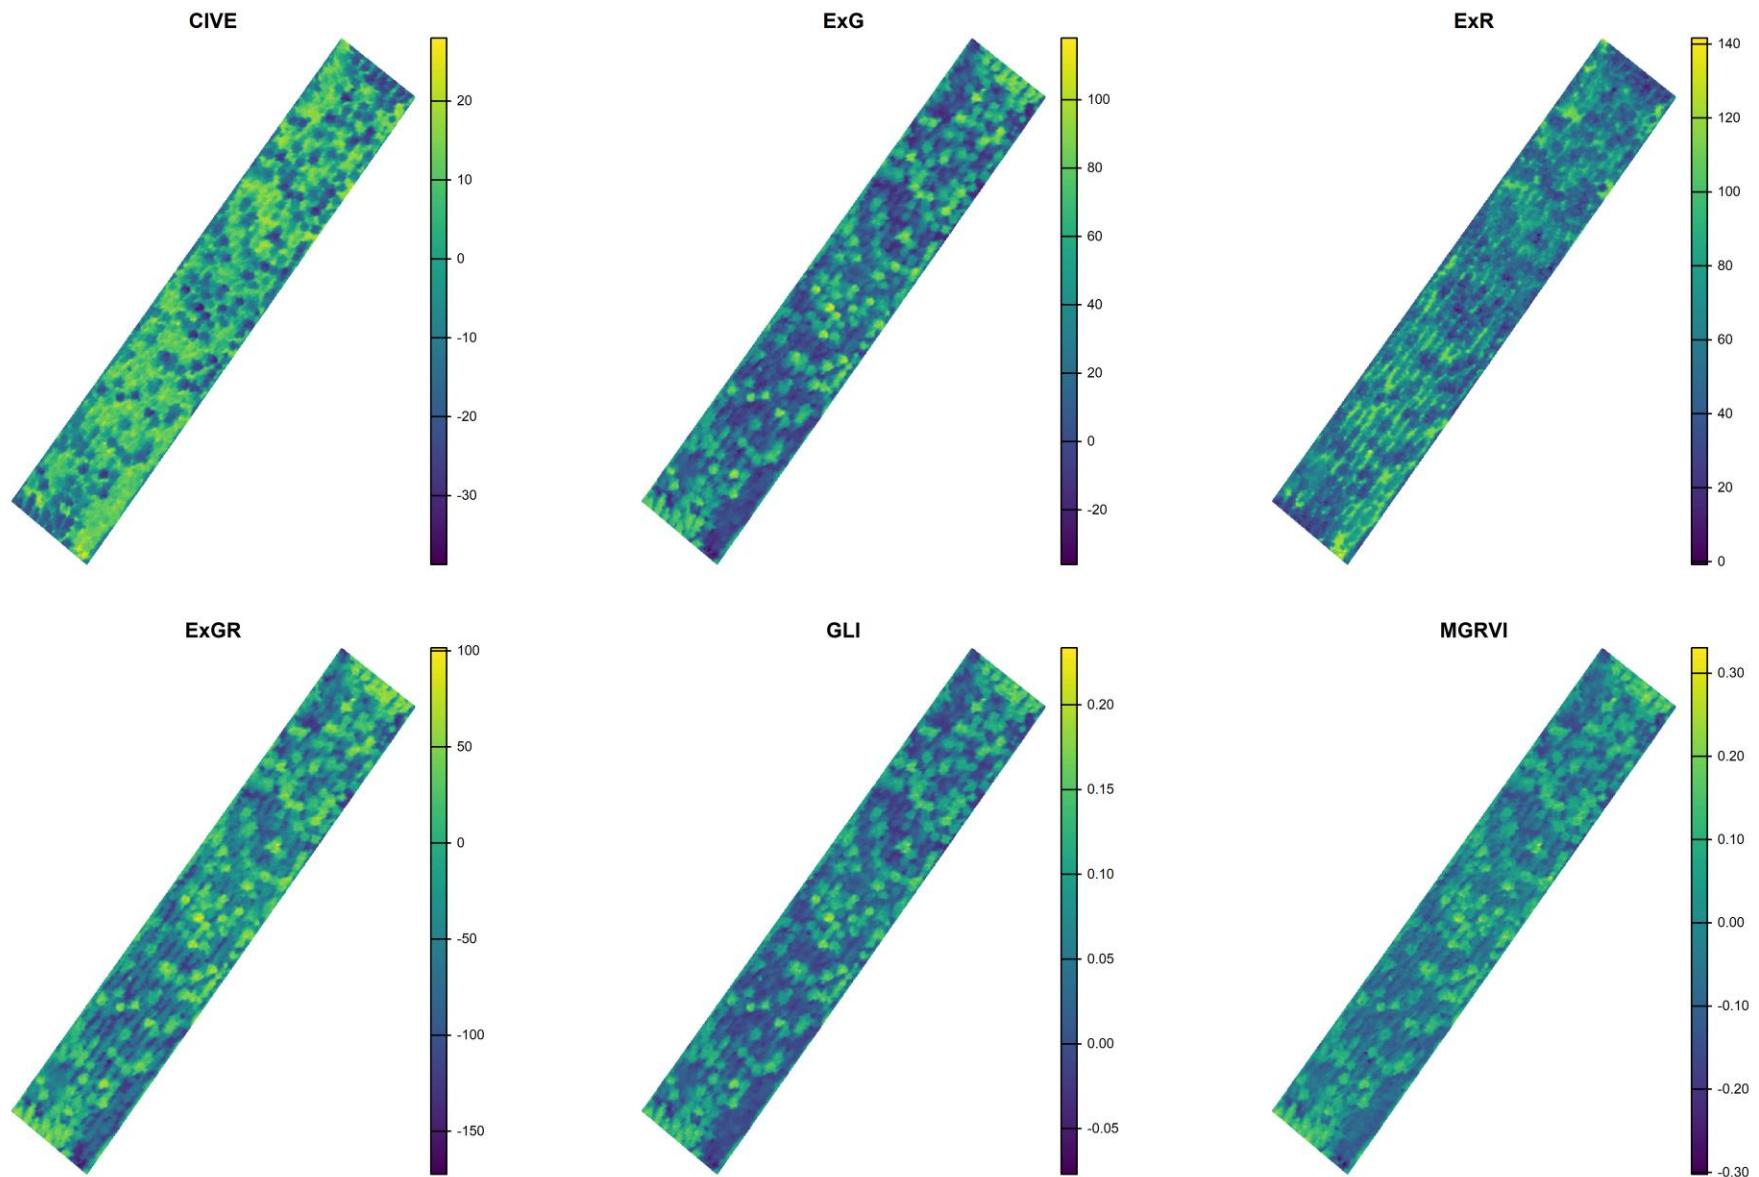


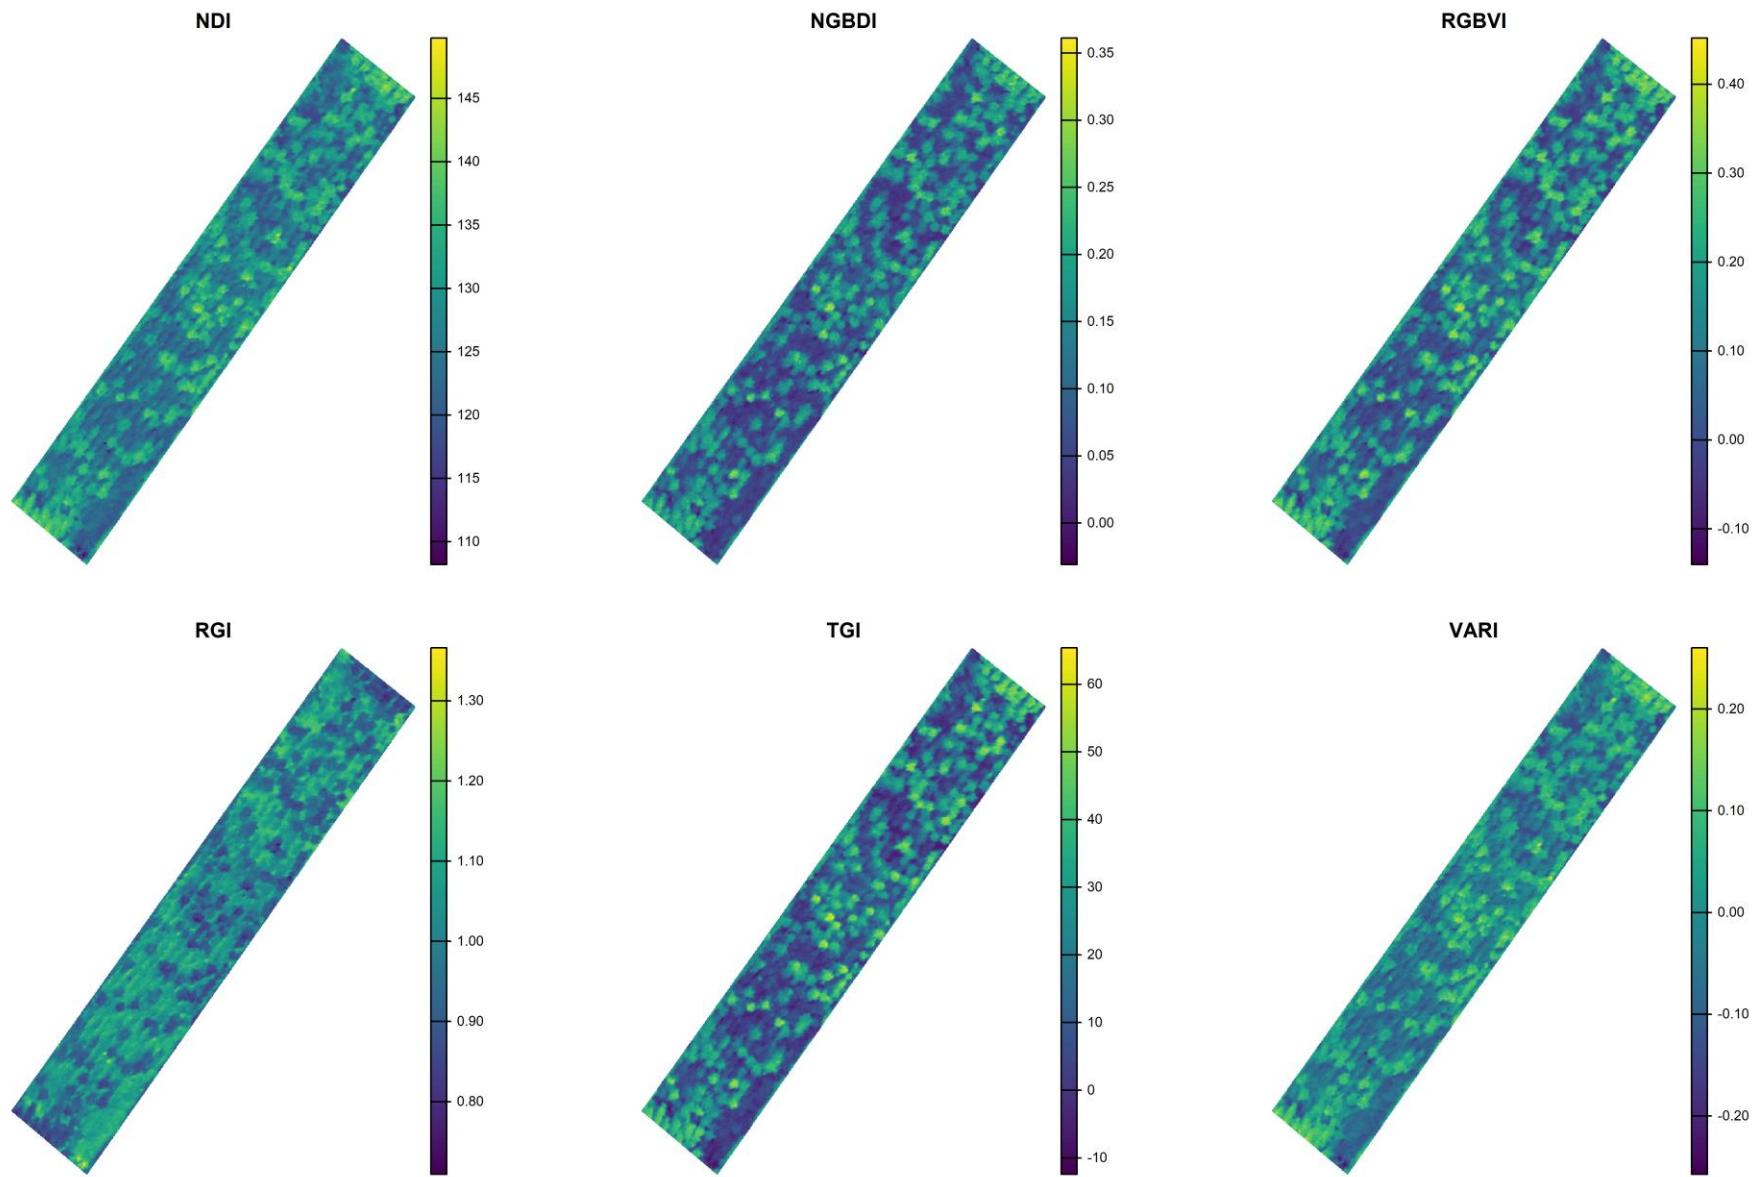


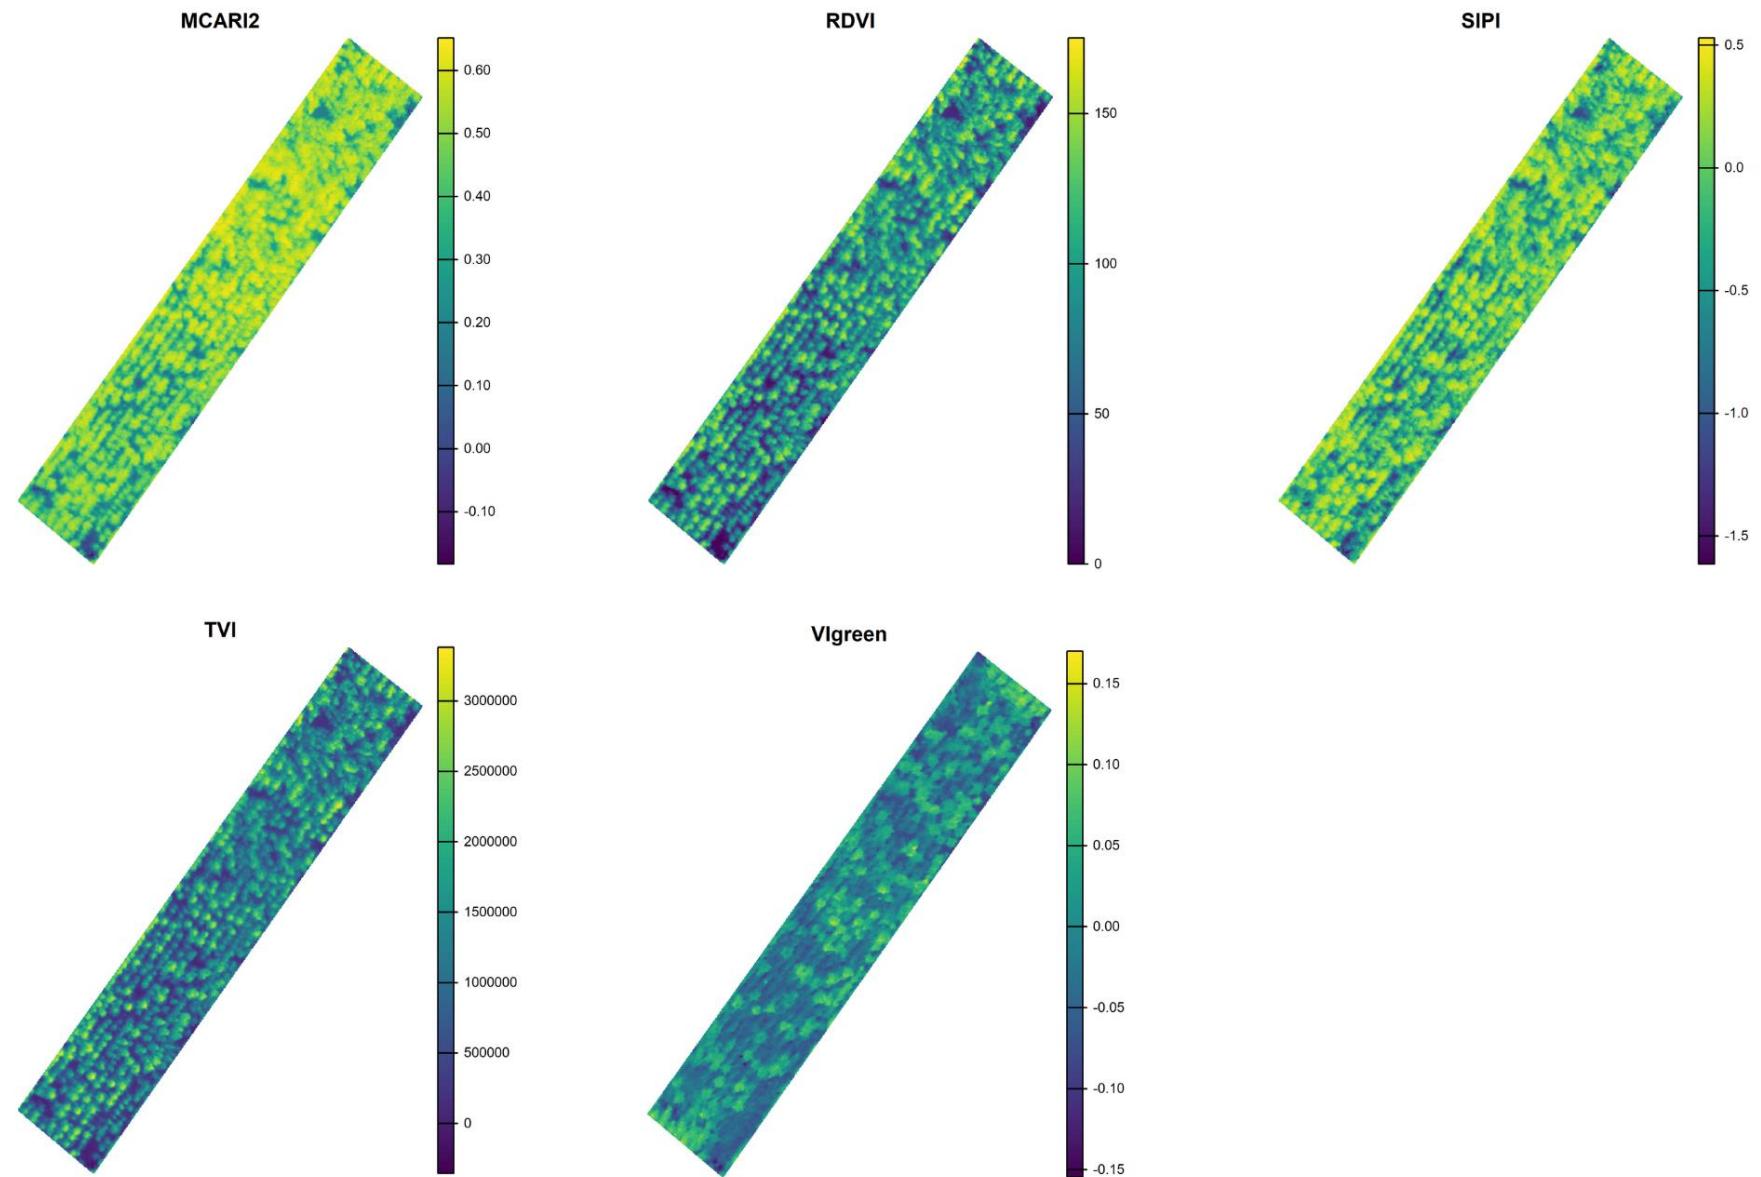
APÊNDICE 7 - PLOT DOS IV CALCULADOS - EXPERIMENTO DE ITAPEVA





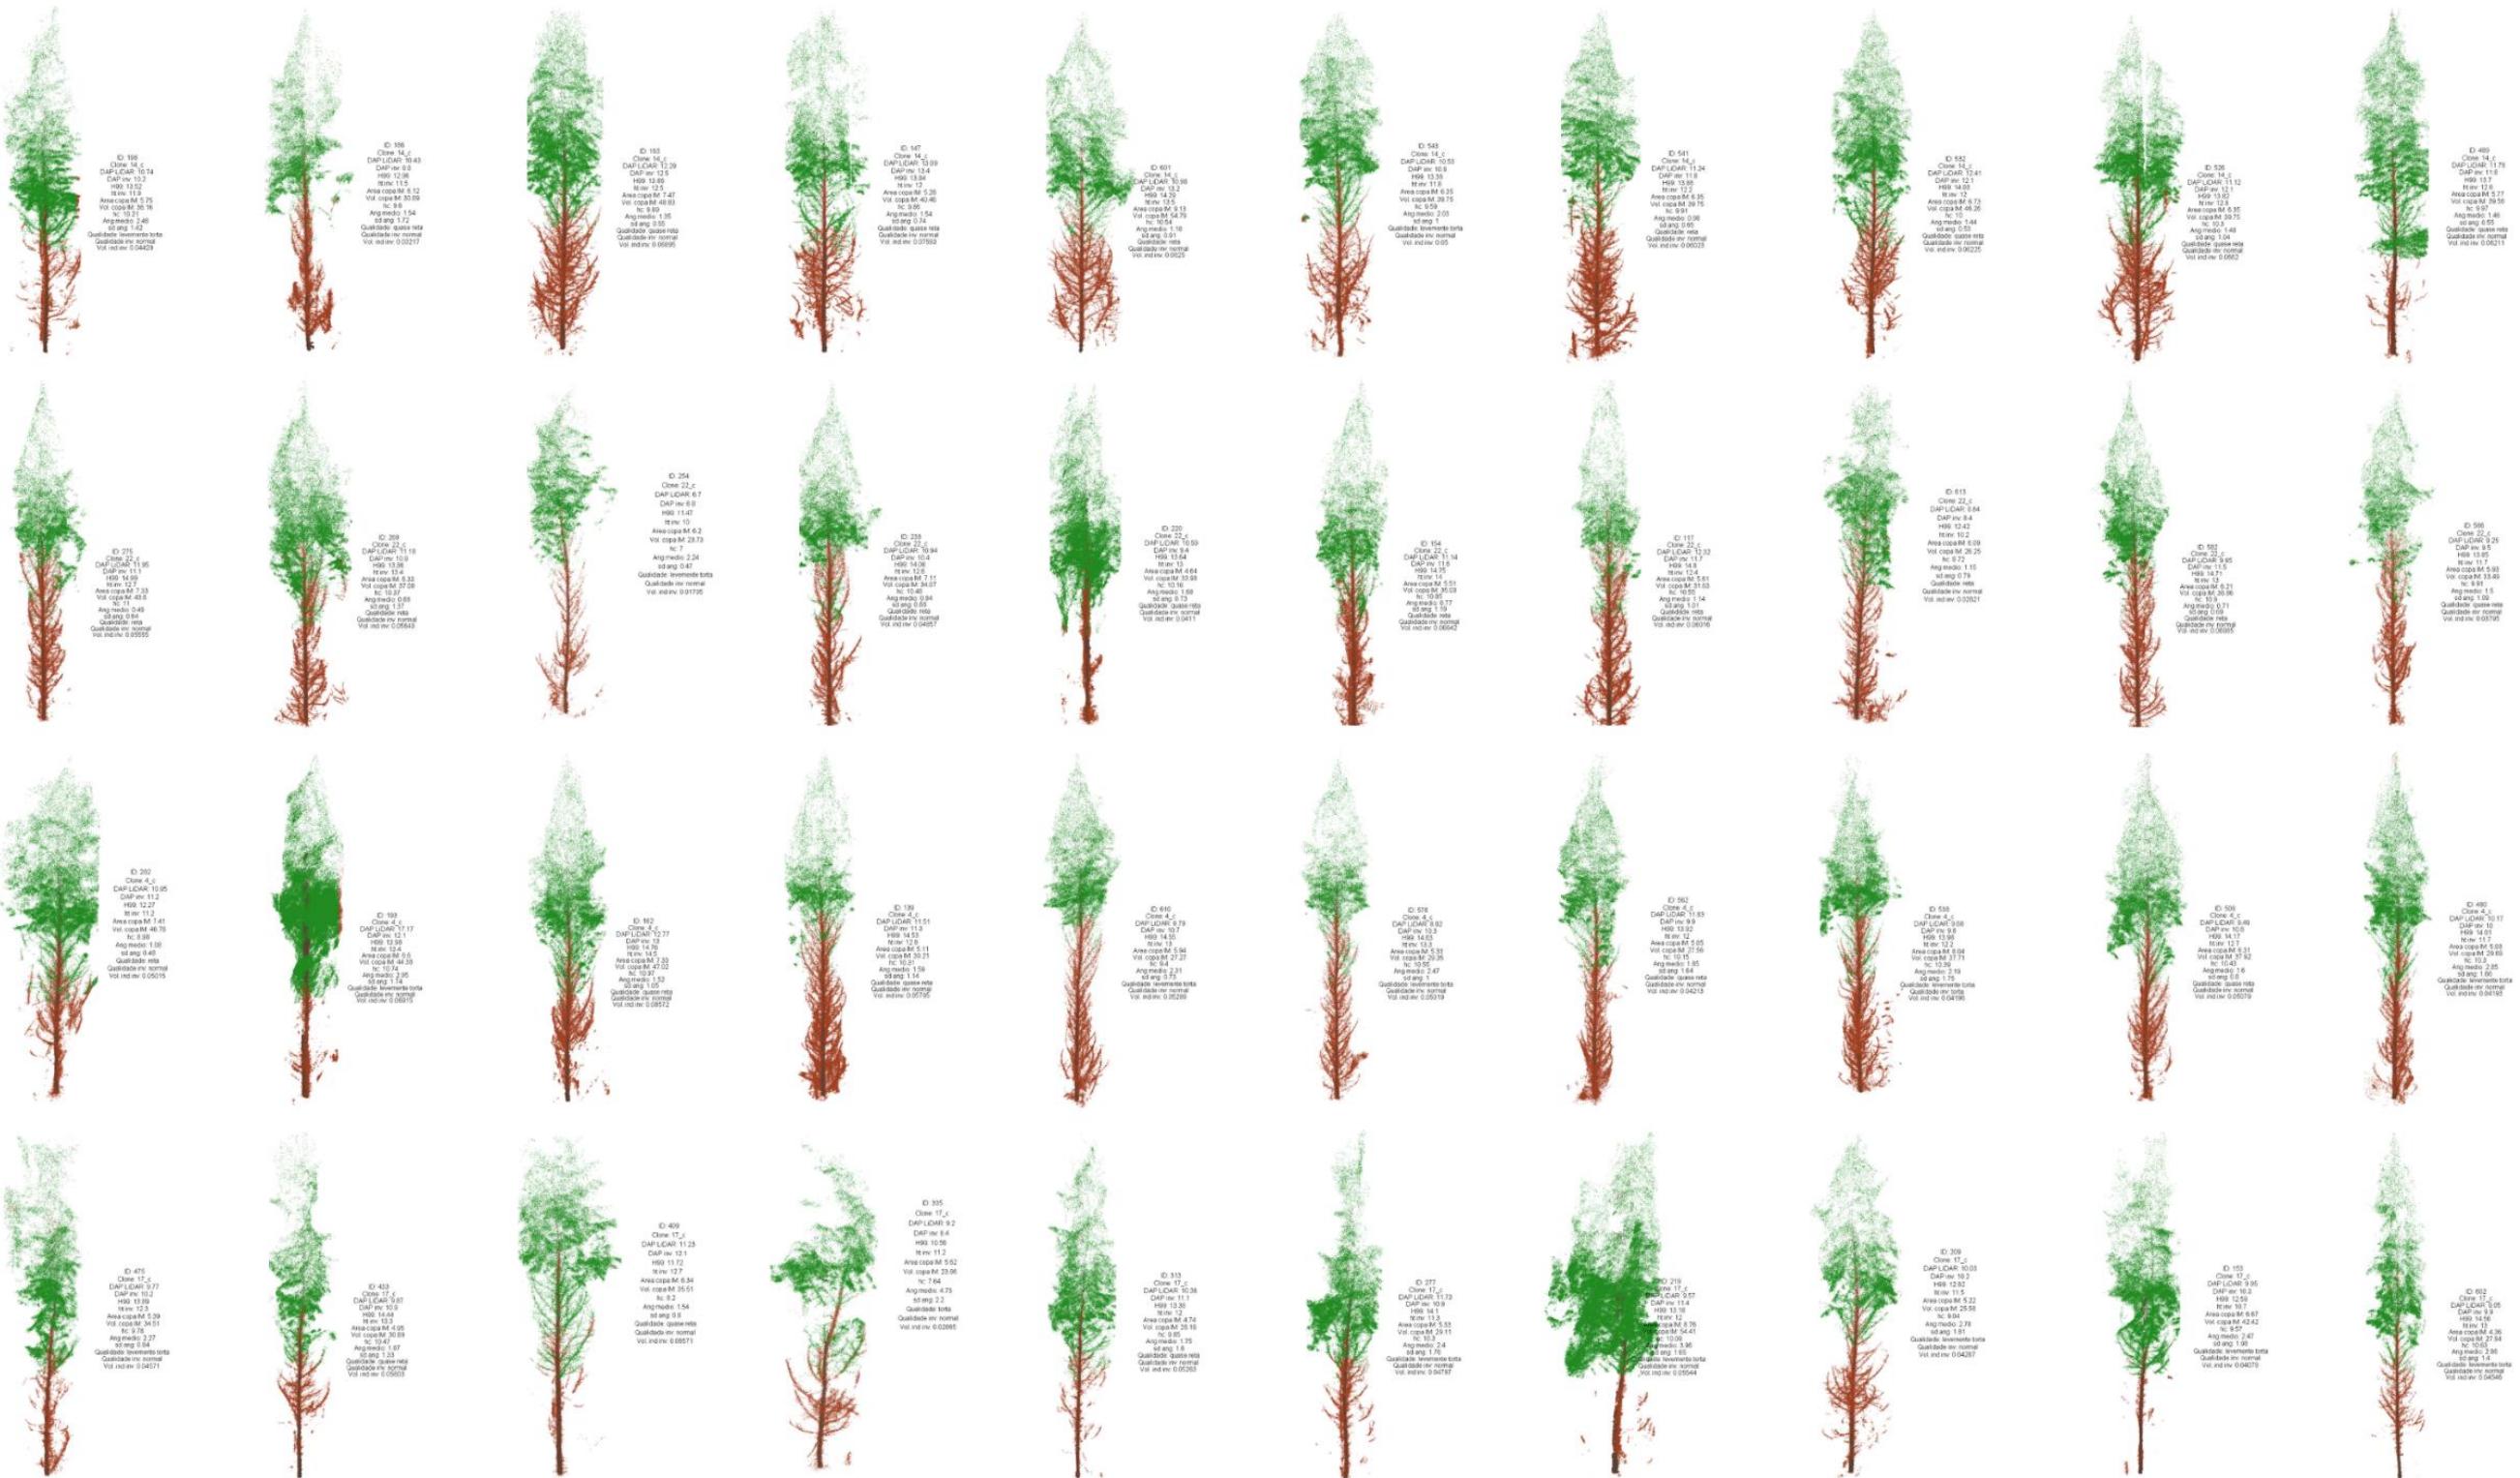




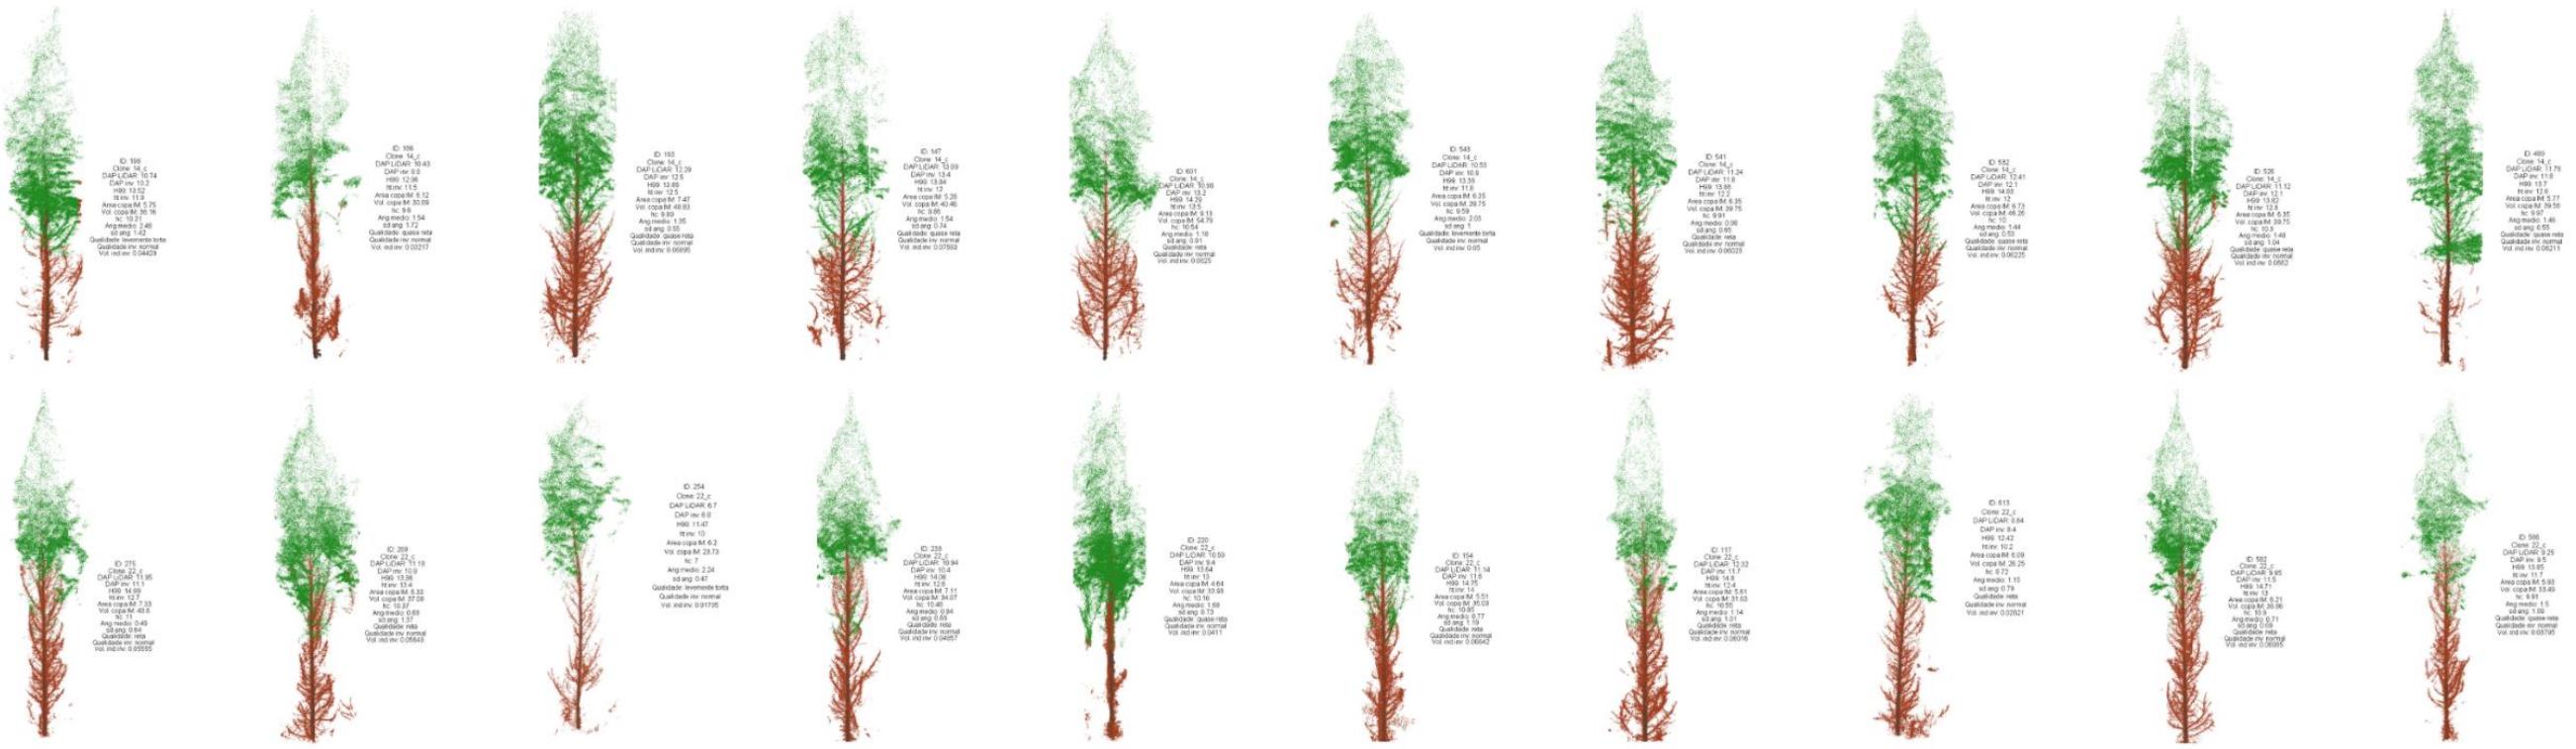


APÊNDICE 8 - EXEMPLO DE APLICAÇÃO DE DADOS MLS+UAV-LIDAR PARA AVALIAÇÃO VISUAL DE CLONES

Top 1 - Caçapava



Top 2 - Cacapava



Top 3 - Caçapava



Top 4 - Caçapava

